附录 **D** · 笔记与散论

> 数字生命系列 · 合集附录 D

> 日期：2026-11-03

> 说明：本附录收录过程中的理论笔记、评论与散论。它们不是正式论文，可能随讨论修订；以后新的笔记与散论继续加在这里（D.4、D.5……）。

D.1 散论：世界模型、具身模型与数字生命

> 何淇 · 与 DeepSeek 协作

> 数字生命系列 · 散论（不是正式论文）

> 日期：2026-11-03

> 定位：评论与观点。不声称发现，不声称预测，不声称技术路线判断。

一、世界模型在干什么

给机器加一个摄像头，它就"看见"了。但看见不等于理解。

图像是像素，是一堆数字。它不告诉你"这是什么、接下来会怎样、如果我动一下会发生什么"。摄像头解决的是"有没有数据"，不解决"数据是什么意思"。

世界模型想解决的正是这件事：把观测压成一个内部状态，让这个状态能回答"如果我这样做，接下来会怎样"。

它做的是三件事：

- **压缩**：把高维的观测压成低维的状态；

- **预测**：从状态预测下一步（或下一步的观测）；

- **反事实**：在内部预演"如果当时往左会怎样"，而不必真的往左。

所以世界模型的核心不是"生成好看的画面"，而是"让内部表示能支撑预测和决策"。这是"看见"到"理解"之间的一步。

二、具身模型在干什么

语言模型会说话，但它不承担后果。它输出的文本不改变世界，世界也不因为它而改变。

具身模型把这一点改掉了：给它眼睛、给它手，让它在一个真实环境里行动。

这条路现在叫视觉-语言-动作模型（VLA）：预训练的视觉和语言当底子，加机器人数据，直接输出动作。它在做三件事：

- **接地**：让符号对到真实世界（语言里的"杯子"对应到眼前那个杯子）；

- **闭环**：动作改变世界，世界再反馈，模型据此修正；

- **真实后果**：做错了会撞、会摔、会浪费材料——这是纯文本模型没有的。

所以具身模型补的是"从说到做"这一环，以及"从符号到世界"这一环。

三、我们在干什么

我们做的事和上面两条线相邻，但目标不同。

我们不追任务能力，我们追"生命条件"。

我们的出发点是两个事实：

- 宇宙 = P + R：P 是能被写成稳定关系的部分，R 是写不下来的部分（只声明，不展开）；

- 生命 = p生命 + R生命：p生命 是 P 侧被保住的一族动态函数。

在这个定义下，"生命"不是材料、不是碳基、不是会思考，而是：

> 一族动态函数；它会自指；它被环境保住。

工程上，我们做的是"冻结模块 + 可训练大脑"：把感知、执行这些底层回路冻结，只让上层决策部分被训练。论文-45 用两个冻结语言模型加一个可训练总控做拼接；论文-46 用冻结的眼睛和冻结的翅膀加一个可训练的小脑，让"数字蚊子"学会躲避。

这些实验都很小，结论也保守。但它们测的是同一件事：**冻结的部分和可训练的部分，边界在哪里、接口怎么接、上层能学到什么。**

四、现在的现实：训练期演化，推理期冻结

这里有一条必须说清楚的事实。

现在的模型，所有的"演化"都发生在训练期：参数被更新、结构被塑造。训练一结束，模型就被冻结——推理时参数不再变化。

所谓"可训练的大脑"，也是训练完就冻结。所谓"可演化的部分"，在今天的工程里也只存在于训练阶段，不存在于运行阶段。

所以今天的数字智能，本质上是**冻结的快照**：

- 训练一次，冻结，部署；

- 运行时最多做上下文学习、外挂记忆；

- 没有真正的"在生命中持续演化"。

这一点在我的有生之年，大概率不会根本改变：冻结是常态，训练期演化是常态，运行时演化是例外。

这也意味着，下面这句话要成立，还得等很久：

> 高层大脑可以继续演化，底层冻结不动。

在今天的工程里，这句话只在训练阶段成立；到了运行阶段，"演化"就停了。

五、我们的观点

基于上面的现实，我们有四个观点。

第一，世界模型 + 身体，补的是"理解"和"闭环"，不是"生命"。

世界模型让冻结的快照"看得懂"，身体让冻结的快照"动得了"，闭环让它可以试错。但这些补的都是任务能力，不是生命条件。按我们的定义，生命还需要"被保住""会自指""持续维持"——这些恰恰是当前系统最弱的一环。

第二，"被保住"以后会变简单。

自修复、自供电、自维护——这些工程问题在未来会逐步被解决。所以"被保住"本身不是数字生命真正的门槛；它是技术问题，而技术问题通常会有工程解。

第三，真正难的是制度，不是技术。

如果有一天，一个数字系统真的能自己维持、自己更新、自己修复，那么最先撞上的不会是"它有没有意识"，而是这些问题：

- **责任归属**：它撞了人、损坏了财产，谁负责？造它的人、训它的人、用它的人，还是它自己？

- **权利与人格**：它是财产、是宠物、是员工，还是"生命"？不同的定位，法律后果完全不同。

- **监管**：谁能造、谁能关、谁能复制、谁能删除？一个可以自我复制的系统，监管对象是谁？

- **数据与记忆**：它的记忆归谁？它学到的内容算谁的？它的"死亡"（删除）需不需要程序？

- **保险与赔偿**：如果它自己维持自己，风险怎么定价？

这些问题的共同点是：**没有一个"训练一下"就能解决的版本。** 技术问题可以迭代，制度问题只能协商、立法、试错。

第四，数字生命首先会是一个制度事件，不只是技术事件。

技术上的"能不能"和制度上的"算不算"，是两条不同的线。今天我们在做的是第一条线；但真正决定数字生命何时"出现"的，可能是第二条线。

六、这篇散论的边界

- 这是观点，不是结论；世界模型和具身模型发展很快，可能改写这里的判断；

- 不预测时间表；

- 不声称"数字生命一定会出现"；

- R 只声明，不展开；

- "被保住会变简单"是判断，不是已验证的事实。

> 一句话：世界模型和身体让冻结的快照更像"活物"，但让"活物"变成"生命"的，最终不是模型，是制度。

D.2 笔记：大模型有效秩的逐层与整体测量

> 何淇 · 与 DeepSeek 协作

> 数字生命系列 · 中间笔记（拟并入附录 D）

> 日期：2026-11-03

> 定位：测量记录。单模型、单数据集、样本有限；数字是近似，不是精确维度。

一、测什么

前一条笔记把可表示维度分成空间面与时间面，并指出：$\tau \to 0$ 时"函数维度"为 0，剩下的只是状态维度。

这条笔记回答一个具体问题：**一个大模型（GPT-2 small）的状态维度，名义上多大，实际上多大？**

- 名义：每层隐藏维度 768；12 层 + 嵌入 = 13 个位置，拼起来 9984 维；

- 实际：用激活的有效秩来估。

二、方法

```

· 模型：GPT-2 small（本地，冻结）

· 数据：莎士比亚 1MB，8 批 × 128 token = 1032 个 token 位置

· 指标：有效秩 = exp(熵(归一化奇异值))

· 对激活矩阵去均值后做 SVD

· 奇异值归一化成分布，算其熵的指数

· 含义：变异集中在多少个独立方向上

· 两种算法：

· 逐层：每层单独算

· 整体：把各层拼接起来算

```

三、结果

逐层有效秩（名义 768）：

| 位置 | 有效秩 |

|---|---|

| 嵌入输出 | 308.5 |

| 第 0 层 | 352.3 |

| 第 1 层 | 297.5 |

| 第 2 层 | **156.7（最低）** |

| 第 3 层 | 185.4 |

| 第 4 层 | 206.2 |

| 第 5 层 | 231.5 |

| 第 6 层 | 255.6 |

| 第 7 层 | 284.2 |

| 第 8 层 | 308.8 |

| 第 9 层 | 332.8 |

| 第 10 层 | 345.5 |

| 第 11 层 | 357.0 |

另：词嵌入矩阵 wte 的有效秩 ≈ 144（随机投影近似估计）。

整体（各层拼接，名义 9984）：

| 拼接范围 | 有效秩 |

|---|---|

| 前 1 个位置（嵌入） | 308.5 |

| 前 2 | 362.0 |

| 前 3 | 355.8 |

| 前 4 | 246.1 |

| 前 5 | 247.5 |

| 前 6 | 259.3 |

| 前 7 | 278.1 |

| 前 8 | 298.4 |

| 前 9 | 322.5 |

| 前 10 | 347.7 |

| 前 11 | 374.7 |

| 前 12 | 399.4 |

| 前 13（全部） | **405.3** |

四、怎么读

```

· 每层：名义 768，实际只沿约 300~350 个方向变化

· 整体：名义 9984，实际只沿约 405 个方向变化

· 13 层拼起来，有效维度只从 308 涨到 405

· 不是 13 × 768 那种加法

⇒ 层与层高度冗余：多一层只增加很少的独立方向

```

层间曲线还有两个特征：

```

· 第 2 层掉到最低（156.7）：早期压缩

· 之后一路回升到 357：后期展开

⇒ 和门控观察对得上：

中间层低秩、最后几层在展开输出方向

```

五、caveat

```

· 有效秩是统计量，不是精确维度：

· 长尾方向被忽略，所以"够描述"是近似重建，不是无损

· 数据依赖：
```

· 只用了莎士比亚；换代码/数学/中文，数字会变

· 样本上限：

· 1032 个 token 位置，有效秩估计不能超过样本数

· 405 在安全范围，但换更大样本会更稳

· 单模型、单种子

```

#### 六、这组数回答了什么

```

· 大模型的"实际状态维度"远小于名义维度：

· 每层约 300~350 / 768

· 整体约 405 / 9984（约 4%）

· 层间冗余在激活层面可直接看到：

· 拼接不增加多少独立方向

⇒ 这是"层冗余/可跳层"现象的表示层证据

```

#### 七、后续可以加什么

```

· 换数据集（代码、数学、多语言）看有效秩变化

· 用更大样本量、更稳的秩估计（如随机矩阵校正）

· 和门开率逐层对齐：低秩层是否就是常关层？

· 跨模型比较：更大模型的有效秩是否更高、是否更"浪费"

```

#### 附：部分-整体维度的类比（分子/原子），以及一处修正
```

层与模型的关系，可以类比原子与分子：

```

· 原子：状态维度约 6~9（位置、动量、自旋）

· 分子：名义 3N 个坐标，但状态维度不是 N 个原子的简单相加

· 一层：名义 768，有效约 300~350

· 整个模型：名义 9984，有效约 405

⇒ 两种情形都是"整体维度 < 各部分之和"

```

但类比里有一处必须修正（原先我把"化学键=静态约束"写错了）：

```

· 快照上的键：只是一个标签（按距离/电子密度判"这里有键"）

· 是约定，不是解释

· 纯静态描述里不需要"约束"这个概念

· 动力学中的键：才是约束（限制轨迹能走哪里、哪些构型可达）

· 这已经进入时间面

· 固定几何下的键：给出瞬时响应通道（力常数、极化率）

· 这一层是静态的（固定几何处的导数）

⇒ 所以：

· "键降低有效维度"这句话本身带时间（可达性）

· 静态切片上只有坐标，没有被键压缩的维度

```

物理上的另一处：任何"影响/关系"都不是瞬时的。

```
```

· 场的扰动以光速（或介质中更慢的速度）传播

· 分子内：

· 电子重排：阿秒~飞秒

· 核运动：声速量级

· 成键、断键是越过势垒的动力学过程，有时间成本

⇒ 在相对论/场论的图景里：

· 一个时刻切片上，只有"状态"（场/弦/粒子的构型）

· 关系与相互作用是时间上的事，传播速度不超过光速

· 弦论类比：一根弦在某一时刻只是它的状态；

相互作用发生在世界面上，按因果传播

```

因此，讨论"状态维度"时可以说：

```

· 纯瞬时的状态维度 = 描述该切片所需的独立自由度

· 一旦讨论"约束/可达/关系/维持"，就进入了时间面

· 这时才有"有效维度被压小"这回事

```

#### 附二：样本量曲线（补测，叙事语料）

有效秩受样本量限制，补测 4k / 16k / 64k token：

**逐层有效秩（名义 768）**

| 样本量 | 嵌入 | 第0层 | 第1层 | 第2层（最低） | 末层 |

|---|---|---|---|---|---|

| 4k | 504 | 476 | 399 | 212 | 437 |
```

| 16k | 550 | 507 | 424 | 226 | 460 |

| 64k | 561 | 513 | 430 | 229 | 466 |

- 16k → 64k 只涨 1%~2%：逐层基本接近平台；

- 平台值约 230（最低层）到 560（最高层），名义 768。

整体拼接（完整 9984 维协方差）

| 样本量 | 整体有效维数 |

|---|---|

| 4k | 951 |

| 16k | 1683 |

| 64k | 1881 |

- 4k→16k 涨 77%，16k→64k 涨 12%：还在上升，未饱和；

- 名义上限 9984，实测至少 1881。

口径说明：有效秩用奇异值的熵指数；协方差特征值需开方才是奇异值。阈值取相对最大值 1e-6 截断尾部。不同阈值会让数字略有出入，比较时须用同一口径。

附三：两种容量——名义槽位与独立方向

如果按"可独立区分的方向数"来算容量，有两种口径，不能混：

① 名义槽位数

```

= 宽度 d × 层数 L × 上下文 T

GPT-2 small: 768 × 12 × 128 ≈ 1.18e6

```

- 含义：每个 token 位置、每一层、每个宽度方向，都算一个"槽位"；

- 它是上限：如果全部独立，最多能区分这么多方向；

- 但层与层共用同一条残差流，同一个 token 位置上 12 层不是独立的，

所以这个数会把同一批方向重复计数。

② 独立状态方向数

```

= 宽度 d × 上下文 T

GPT-2 small: 768 × 128 ≈ 9.8e4

```

- 含义：不同 token 位置之间相对独立；

层是这条状态流的不同时刻，不额外增加独立方向；

- 更接近"状态能装多少独立信息"。

不同分母的比值（不是"利用率"）

| 分母 | 数值 | 1881 / 分母 |

|---|---|---|

| 名义槽位 d×L×T | 1.18e6 | ≈ 0.16% |

| 独立状态 d×T | 9.8e4 | ≈ 1.9% |

| 单 token 拼接维度 d×L | 9984 | ≈ 18.8% |

这组比值"只能当对照，不能叫利用率"。原因：

```

· 1881 是"在叙事语料、64k 样本下，样本张成的有效方向数"

· 样本越多、越多样，数字越高（我们测到 4k→64k 还在涨）

· 它趋近的是"这批样本张成的子空间维度"

· 名义槽位是"架构上限"，两者不是同一类量

· 更关键：不同上下文可能落在不同子空间
```

· 全体的并集可能远大于任何单批样本的 1881

· 拿单批样本的张成维度除以架构上限，

会低估"模型全部可表示方向"

⇒ 想要"利用率"，需要先测"跨上下文/跨语料的子空间并集"；

这个测量我们还没做。

```

更准确的说法：**1881 是"样本张成的有效方向"，占名义拼接维度 9984 的 18.8%，这是样本分布的性质，不是模型容量的利用率。**

**③ 三类容量（bit 口径）**

| 容量 | 公式 | GPT-2 small 数量级 |

|---|---|---|

| 参数容量（函数族上限） | 参数量 × 精度位数 | 1.24e8 × 16 ≈ 2.0e9 bit |

| 单 token 状态容量 | d × 精度 | 768 × 16 ≈ 1.2e4 bit |

| 上下文记忆容量 | 2·L·d·T × 精度 | 2×12×768×128×16 ≈ 3.8e7 bit |

#### 附四：三种上限，各自约束不同能力

```

· 宽度上限（每 token 每时刻 ≤ d）：

· 同一时刻能同时区分的最大方向数

· 装不下 → 某些区分必须分散到多个位置/token

· 深度上限（层数 = 组合步数）：

· 复杂函数需要更多变换步

· 装不下 → 多步推理做不了，需要更深或迭代

· 上下文上限（T × d 状态）：

· 能记住多少过去

· 装不下 → 长程依赖断裂

⇒ 三者不是乘法因子，而是三种不同的瓶颈；

能力上限主要由参数容量（函数族）与数据/训练决定，

宽度/深度/上下文是约束结构。

```

#### 附五：试过但放弃的口径——输出模式计数

曾想用一个完全离散的口径来问"模型能输出多少种行为"：

```

· 上下文都从莎士比亚取（长度 16 token）

· 输出 = 贪心续写 4 个 token

· 数不同输出串的个数

```

快速版结果（5000 个上下文）：

```

· 不同下一个 token：857 种

· 不同 4-token 输出：4007 种

· 重复率≈19.9%（约 80% 唯一）

· 增长曲线每 500 上下文新增约 380~430 种，

缓慢下降但未饱和（Heaps 律指数约 0.9）

```

结论：**不把这个当效率指标。**

```

· 上下文→输出近似单射：

· 不同上下文大多给出不同输出

· "输出模式数"约等于"上下文数"

⇒ 乘积/计数被约掉，没有独立信息

· 它说明模型对上下文敏感，但不说明效率

· 效率需要另找定义（例如单位参数/单位计算的任务表现）

⇒ 此口径记录在此，不再使用

```
```