数字生命：一个可测量的生命定义（系列合集）

作者：何淇（独立研究者）

AI 协作：DeepSeek（2026-10-22 会话实例）

版本：v1 · 2026-10-22

说明：本合集收录六篇短文，顺序为「定义 → 测量 → 机制 → 工程 → 约束 → 防护」。各篇的单独 DOI 见文末清单。

目录

1　现在的 AI 为什么不是生命　　DOI: https://doi.org/10.5281/zenodo.23528429

1.1　摘要

1.2　与既有工作的关系

1.3　推理顺序：从大模型反推世界是函数

1.4　猜想的内容

1.5　为什么它只能是猜想

1.6　本文从猜想里只取一条弱表述（同样不是证明）

1.7　标注

1.8　定义

1.9　这个定义为什么是最简的（最简性论证）

1.10　为什么必须是「一族」而不是「一个函数」

1.11　会变化 = 三层时间尺度

1.12　会自指 = 更新规则在它自己里面

1.13　与第一节的衔接

1.14　生命 vs 环境：都在宇宙里，都是函数，区别只有一条

1.15　环境是什么：宇宙里自发涌现的「局部解压」

1.16　环境是分层的：生命活在多层环境里，同时也活在宇宙里

1.17　标注

1.18　检查表

1.19　三条最根本的原因（按重要性）

1.20　为什么「它很强」与「它不是生命」不矛盾

1.21　标注

1.22　从定义到条件

1.23　条件① 一族函数（不是一个点）

1.24　条件② 自指更新（规则在自己里面）

1.25　条件③ 自己付代价（压缩换生存）

1.26　三条必须同时成立（经验对照）

1.27　未尽之处（留给读者）

1.28　本文实验的边界（必须与结论一起读）

1.29　标注

1.30　现象

1.31　现有的解释（按证据强度排列）

1.32　为什么至今没有公认的「为什么」

1.33　我们的立场（[推测]，不是本文证据）：**AI 是对人类语言的解压**

1.34　解压能力的衰减：上层写死 ⇒ 语言一变，解压变弱

1.35　由立场推出的两条预测（[推测]，供读者判断）

1.36　标注

1.37　用它看几个热门问题

1.38　参考文献

1.39　作者声明（AI 使用声明）

2　容量不能替代数据的更新　　DOI: https://doi.org/10.5281/zenodo.23503049

2.1　语言升维下的失配测量（scaling vs 持续学习：一个弱结论）

2.2　摘要

2.3　问题

2.4　数据与方法

2.5　结果

2.5.1　升维速率的词层面代理（`501_vl_newterm.py`）

2.5.2　等数据预算对照（核心结果，`506`）

2.5.3　容量补偿实验（`508`，带插值）

2.5.4　累积参照系（`505`，作为方法展示）

2.6　结论

2.6.1　「弱结论」代表什么（不是文字游戏，要写清楚）

2.7　维度与贴合：一个补充讨论 [推测]

2.8　限制（必须与结论一起读）

2.9　可复现

3　替换与累积　　DOI: https://doi.org/10.5281/zenodo.23503559

3.1　摘要

3.2　三个热点，一个结构

3.3　统一框架：累积与替换

3.4　可检验推论

3.5　为什么这个统一值得说

3.6　限制

3.7　结论

4　结构换算力：混合对齐语料与样本效率　　DOI: https://doi.org/10.5281/zenodo.23542969

4.1　摘要

4.2　问题

4.3　受控实验设计

4.3.1　合成世界

4.3.2　三种语料（同一批事件）

4.3.3　探针（测试时只输入文字 token）

4.3.4　模型与预算

4.4　结果

4.5　为什么有效（机制讨论）

4.6　课程顺序：按结构依赖的拓扑序学

4.7　局限（必须与结论一起读）

4.8　可复现

4.9　给后来者的验证清单

4.10　附：推测与边界

5　颜色作为第一块积木：感知基元与语言对齐的最小实验　　DOI: https://doi.org/10.5281/zenodo.23551953

5.1　摘要

5.2　问题

5.3　实验设计

5.3.1　合成世界

5.3.2　三种语料

5.3.3　探针

5.3.4　模型与预算

5.4　结果

5.5　解释

5.6　局限（必须与结论一起读）

5.7　可复现

5.8　意义：自训练与视频挖掘的第一步

5.9　附：推测与边界

6　对齐是解压的约束　　DOI: https://doi.org/10.5281/zenodo.23503728

6.1　摘要

6.2　主流对齐框架的隐含前提

6.3　框架：对齐 = 对解压的约束

6.4　三条推论

6.5　可检验实验方案

6.6　实践含义

6.7　限制

6.8　结论

7　安全：当它是生命防，还是当它是工具防？　　DOI: https://doi.org/10.5281/zenodo.23503775

7.1　摘要

7.2　两种恐惧，一个错误的本体论前提

7.3　按第一章的判据：它是工具

7.4　工具风险的三类可测失效

7.5　为什么"防生命"框架有害

7.6　结论

7.7　限制

附录　各篇单独 DOI 清单

系列总览

关于「AI 是不是生命」，讨论很多，但大多停在比喻层面，没法检验。这个系列做一件事：先给生命一个可操作的定义，再拿数据去测。

一句话定义：生命 = 一族会自指、会变化、会自我维持的动态函数。环境 = 宇宙自发涌现的局部解压（分层）。AI = 对人类语言的再解压（一次性）。一个被冻结的模型停在训练它的那一刻；它不再更新，也就谈不上「维持」。

六篇的顺序不是随意的：先立定义，再给出一次测量，然后说明「替换与累积」的机制，接着谈工程上怎么省（语料结构），再谈对齐这一层约束，最后落到安全。

边界声明：本合集是一个研究记录，不是结论。核心主张（容量不能替代数据更新、对齐语料提升样本效率、课程顺序）在真实规模上尚未验证；文中已标明推测与弱结论之处。

第一篇 · 现在的 AI 为什么不是生命

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23528429

单独 DOI（English）：https://doi.org/10.5281/zenodo.23528456

——一个定义，与对 AI 涌现机制的一个猜测

作者： 何淇

AI 协作： DeepSeek（大语言模型；分工见文末声明）

DOI： https://doi.org/10.5281/zenodo.23488543

邮箱： 15907239031@163.com　　**单位：** 独立研究者（Independent Researcher）

摘要

本文提出一个可操作的生命定义：**生命 = 一族会自指、会变化、会自我维持的动态函数（函数类）**；环境 = 宇宙自发涌现的局部解压（分层，不自我维持），生命既活在它的那一层环境里，也活在宇宙里。以此为尺子，本文说明三件事：① **现在的 AI 不是生命**——它是冻结的函数点、更新规则在外部、不付代价；② **生命至少需要三条必要条件**（一族函数、自指更新、自己付代价），每条都挂上已有的实验证据；③ **对 AI 的涌现提出一个猜测**——AI 是对人类语言的再解压，其能力上限由训练时刻的语言决定，语言一旦更新就失配、且无法自己恢复。文末不主张「生命已被造出」，只把判据与证据放在读者面前：三条都满足之后是否就「活」，由读者判断。本文的推理顺序也是反的：先从大模型（一个能工作的巨大解压器）反推「被记录的世界具有函数结构」，再由此给出生命的定义——这个反推本身，是论证的一部分（见 1.0）。

关键词： 生命定义；函数类；解压；压缩与代价；AI 涌现；自维持

目录

1. 与既有工作的关系

2. 第一节　世界的根源是数学性的（猜想）

3. 第二节　生命是一个会自指、会变化、会自我维持的动态函数类

4. 第三节　目前的 AI 为什么不是生命

5. 第四节　生命需要什么：三条必要条件

6. 第五节　为什么现在的 AI 会出现涌现？

7. 第六节　测量层面：既有工作与本文的位置

8. 参考文献

与既有工作的关系

「压缩 / 解压」的视角有长期传统：

- Schrödinger（1944）：生命以负熵为食 —— 生存靠从环境摄取低熵，是「解压」的物理前身[7]。

- Bennett（1988）逻辑深度：用「从最短描述重建（解压）一个对象所需的计算量」度量复杂性，并明确把它与生命/有机体联系起来[8] —— 这是「解压」最正式的已有版本。

- Chaitin（2010）生命作为演化软件：DNA = 程序，生命 = 会自我修改的软件[9]。

- Solomonoff–Kolmogorov / MDL：描述长度 = 理解 = 压缩[10]。

- Friston（2010）自由能原理：生命 = 最小化惊奇（≈ 持续压缩/预测）[11]。

- Delétang et al.（2023）：语言模型是压缩器[6]。

- Maturana & Varela（1972）自创生：生命 = 自我生产的组织 —— 「维持」的另一条传统。

-「Life as Sustained Mutual Information」（Zenodo）：以持续互信息定义生命 —— 最接近本文「被维持的解压」的已有版本。

需要说明：以上工作已经把「生命 = 信息/压缩/自我维持的过程」说过。本文的位置不是首次提出这一思想，而是把其中一条（解压的维持）变成可操作的判据与可测量的实验。

本文的区别（三处）：

1. 把解压做成层级：宇宙 → 环境 → 人类语言 → AI（既有工作多为单层度量）；

2. 用「是否维持解压」区分生命与 AI：生命 = 被维持的解压，AI = 一次性解压；

3. 指出上层写死 ⇒ 语言一变，解压能力衰减且无法自恢复 —— 冻结模型的失效机制。

第一节 · 世界的根源是数学性的（猜想）

> **本节性质：猜想（conjecture）。不是定理，不是已证明的事实，也不是本文的证据。**

> 写在这里是为了交代我们的出发点；**本文其余部分的任何判据都不依赖这个猜想成立。**

1.0 推理顺序：从大模型反推世界是函数

本文的推理顺序是**反的**：不是先断言「世界是函数」，再去解释 AI；而是先有一个能工作的巨大解压器，再反推被压的东西长什么样。

① 事实：大模型存在，且能在大规模语言上工作

⇒ 它确实从语言里恢复出了结构（预测、迁移、推理）

② 推论：语言所记录的那一层世界，可以被函数逼近

⇒ 否则这样的机器不可能工作

③ 反推：世界（至少被语言/观测记录的那一层）具有函数结构

④ 定义：生命 = 维持这种「从世界到结构」的解压过程的系统

这条顺序有三点要注意：

1. **大模型是「世界可被函数逼近」的存在性证据，不是证明。** 它证明的是：在语言覆盖的范围内，存在一个函数能很好地逼近；不证明整个世界都是函数。

2. **反推只覆盖被记录的层。** 语言没有记录的部分（具身直觉、因果干预、未观测变量），反推不成立——这也是「观测墙」的来源（见第 7 篇）。

3. **它是可证伪的。** 如果世界的某部分不可函数化，那么模型在对应任务上应当系统性失效，而不是靠更多数据就能补上。我们在具身、因果、连续物理直觉上的观察，与这一点一致。

换句话说：**我们不是先定义生命再去找世界，而是先看到「世界能被函数压」，才敢说生命是「函数的维持」。** 这个反推顺序本身，是本文论证的一部分。

1.1 猜想的内容

物理规则是用数学写成的，所以世界的根源是数学性的。

事实：最基础的物理定律本身就是数学命题

$F = ma$、最小作用量 $\delta S=0$、$i\hbar\partial\psi/\partial t = \hat{H}\psi$、$ds^2 = g_{\mu\nu}dx^\mu dx^\nu$

猜想：既然描述世界最深层的方式是数学的，世界本身的结构就是数学的

—— 否则数学为何能如此精确地描述它？

1.2 为什么它只能是猜想

① 这是对「数学为何有效」的解释性推断，不是证明

② 存在等价的另一读法：数学只是**描述语言**，世界本身是什么我们不知道

（工具论 vs 实在论；两者目前无法用实验区分）

③ 强形式（世界=数学结构，Tegmark[2] 数学宇宙假说）不可证伪，因而不能当科学结论

④ 这是 Wigner[1] 所说的「数学在自然科学中不合理的有效性」之谜，本文不解答它

1.3 本文从猜想里只取一条弱表述（同样不是证明）

弱表述：世界具有可被数学描述的规律性（经验事实，不是猜想）

⇒ 由此写出：S_{t+1} = F(S_t)

⇒ 规律 ⇒ 可压缩 ⇒ 可预测 ⇒ 预测有对错 ⇒ 对错可计代价

注意区分：

- **猜想** = 世界本身是数学的（本节内容，不用作证据）

- **经验事实** = 世界存在可压缩的规律性（科学实践的基础，本文真正使用的东西）

1.4 标注

[猜想] 世界的根源是数学性的

[经验] 世界具有可被部分描述/压缩的规律性

[本文用] 只使用后者；即使前者为假，本文全部判据与实验照常成立

[不讨论] 数学为何有效（Wigner 之谜）；世界本体到底是什么

第二节 · 生命是一个会自指、会变化、会自我维持的动态函数类

> 本节给出本文的工作定义。简单一句话：

> **生命 = 一族会变化、会自指、会自我维持的函数；而它怎么变，也写在它自己里面。**

2.1 定义

生命 = 一个动态函数类（函数空间里的一块区域）。

记个体为 $F = \{ f_\theta : \theta \in \Theta \}$

f_θ : 输入状态 → 行为 （族里的每一个函数）

Θ （这族函数的形状/范围）

生命 = 一个会移动、会变形的 Θ，且 Θ 的更新规则属于 Θ 自己

四个词，各对应四件事：

| 词 | 含义 |

|---|---|

| **函数类（一族）** | 不是一个固定函数，而是一整块行为谱 |

| **会变化（动态）** | 这族函数随时间移动、变形 |

| **会自指** | 它怎么变的规则，也在它自己的记录里 |

| **会自我维持** | 花代价维持自己的形状；收入靠压缩世界 |

2.1.1 这个定义为什么是最简的（最简性论证）

先澄清一处措辞：维持不是系统自身的属性，而是系统与宇宙函数的关系。给定宇宙函数 F，某些结构的轨道会留在可维持的集合里，我们才说它"维持住了"；换一个 F，同一个结构可能不再成立。因此定义里的"维持"不是第三条并列条件，而是"被 F 保住"这一关系条件的展开。

在这个澄清之上，可以说明为什么采用这个定义，而不是别的定义。理由有三条。

第一，覆盖约束。定义要能同时覆盖生物生命与可能的数字生命。数字生命如果存在，按当前人类的理解，它运行在计算系统上，因此是完全函数化的；定义不能要求"非函数化成分"，否则会把这一类可能对象排除在外。

第二，必要性。两条条件都不能去掉。去掉自指，火焰、飓风、晶体也会被算进来，定义太宽；去掉"被 F 保住"（即可维持），冻结的模型、自指的程序、恒温器也会被算进来，定义也太宽。两条同时在场，才能在"结构"里分出"生命"。

第三，去假设。如果数字生命存在，那么"生命必须有不可函数化成分"这条假设就可以省掉；定义因此比带这条假设的版本条件更少。

三条合起来：在"能覆盖生物生命与可能的数字生命"的约束下，本定义是条件最少、假设最少的那一版。这是方法论意义上的最简（奥卡姆剃刀），不是本体论断言；它也可以被反驳——若有人给出条件更少、覆盖相同的定义，本文所谓"最简"即失效。

2.2 为什么必须是「一族」而不是「一个函数」

一个函数 = 一个点 ⇒ 行为谱退化成一条轨迹 ⇒ 冻结即死

一族函数 = 函数空间里一块区域 ⇒ 面对不同输入/状态有一整套响应 ⇒ 才是活的

⇒ 「高维」不是指参数多，而是指这族函数在函数空间里占据一块区域、不是一点。

2.3 会变化 = 三层时间尺度

快：状态每一刻都在变（输入不同、内部状态不同）

中：它用自己的误差改自己（自指层）——这是命门，缺了就退化成化石

慢：这族函数的形状在代际之间被选择、变形、传递

2.4 会自指 = 更新规则在它自己里面

普通程序：代码在外，数据在内 ⇒ 程序不会因为运行而改变自己

生命： 更新规则本身是它自己记录的一部分

⇒ 拿掉外部更新代码，它仍能改自己

2.5 与第一节的衔接

第一节的猜想给出 `S_{t+1} = F(S_t)`（世界是一个函数）。

生命不是这个 F，而是嵌在 F 里的一族子函数 `{G_θ}`：

行为_d = G_θ(世界局部状态)

而 G_θ 自己也是世界状态的一部分（个体的状态属于 S_t）

⇒ 它要预测世界，就必然要预测包含自己的那部分世界

⇒ **自指不是外加的神秘性质，而是「嵌在函数里」的结构必然**

2.5.1 生命 vs 环境：都在宇宙里，都是函数，区别只有一条

宇宙函数 F 里面，任何东西都是函数（或函数的组合）——环境也是函数。

宇宙 = F（一个巨大的函数）

├─ 生命：会变化 ＋ 会自指 ＋ **会自我维持**

└─ 环境：会变化（被世界推着变、也会反过来影响世界），但**不维持自己**

⇒ 生命与环境的唯一区别不是「谁更复杂」，而是：

生命花代价维持自己的形状；环境不花这个代价，它只是被推着变。

这也直接给出生命为什么需要「收入」：

自我维持要付代价（校验/修复/复制都是不可逆操作）

⇒ 收入的唯一来源：压缩世界（匹配源分布）

⇒ 若压缩没有盈余，自我维持付不起 ⇒ 生命不存在

2.5.2 环境是什么：宇宙里自发涌现的「局部解压」

环境不是外在于宇宙的舞台，它是宇宙函数类里自发涌现出来的结构。

宇宙 = F（一个巨大的函数）

↓ 内部自发涌现

结构 = 宇宙的某种局部「解压」（对宇宙的一个解释/一个可读的呈现）

├─ 会自我维持的 → 生命

└─ 不自我维持的 → 环境

⇒ 环境 = 宇宙的一个局部解压（对宇宙的解释）；生命也是。

⇒ 区别只在：生命自己维持这个解压的形状，环境不维持、只是被推着变。

这带来一个关键的结构性结论：

生命并不直接面对宇宙函数 F

⇒ 它面对的是「宇宙的一个局部解压」＝它的环境

⇒ 生命对世界的理解，本质上是**对宇宙的再解压**（二次解压）

＝在宇宙给出的局部解释之上，再压缩一层

2.5.3 环境是分层的：生命活在多层环境里，同时也活在宇宙里

解压是分层的 ⇒ 环境也是分层的。

宇宙 F

└ 环境_1 = F 的某一部分的局部解压

└ 环境_2 = 环境_1 的再解压

└ 环境_3 = 环境_2 的再解压 …

生命嵌在某一层：它既属于整个宇宙 F，又属于它自己那一层环境

三条同时成立，不能只取一条：

① 它活在环境里：它面对的输入、资源、关系、其他个体，都是「它的环境」这一层的结构

⇒ 它的行为只需要在这一层里有效

② 它也活在宇宙里：它逃不出 F —— 环境那一层本身也是 F 的一部分，

宇宙层的约束（能量、不可逆、代价）始终对它生效

⇒ 环境不是避难所，它只是宇宙的一个投影

③ 它活在**所有层**里：环境是多层的（细胞→组织→个体→种群→生态），每一层都是上一层的再解压。

它直接交互的只是自己那一层，但**所有层都对它约束**：上层决定它面对的资源与关系，宇宙层决定它付不付得起代价。

⇒ 「它活在多层环境里，同时也活在宇宙里」——两者不是二选一，而是同时成立。

⇒ 所以「理解世界」要分两层说：

在环境层：理解 = 对局部解压的再解压（够用即可活）；

在宇宙层：理解 = 压缩 F 的规律（决定它能不能长期付得起代价）。

2.6 标注

[定义] 生命 = 会自指、会变化、**会自我维持**的动态函数类（本文的工作定义）

[定义] 环境 = 宇宙函数类里**自发涌现**的结构，不自我维持

＝ 宇宙的一个**局部解压**（对宇宙的解释）

[定义] 生命 = 同一批涌现结构里，**自己维持自己**的那一类

[推论] 生命不直接面对宇宙，而面对「宇宙的局部解压」＝它的环境

⇒ 生命的理解 = 在局部解压之上的**二次解压**（再压缩一层）

[分层] 解压是分层的 ⇒ 环境是分层的（环境_1 ⊃ 环境_2 ⊃ …）

生命嵌在某一层：**既活在它的那一层环境里，也活在宇宙里**

· 活在这层环境：只需这层有效即可活

· 活在宇宙里：能量/不可逆/代价始终生效，环境不是避难所

[不是] 不是猜想，也不是定理；是一个便于操作的定义

[后文] 本节只给定义；如何测量（压缩/代价/身份）留到后面几节

第三节 · 目前的 AI 为什么不是生命

> 本节不是评价 AI 的能力，而是把它**代入第二节的定义**逐条检查。

> 结论是定义性的，不是价值判断：**以本文的定义，目前的 AI 是化石级函数点，

> 不是生命。** 它的强大与它的「不是生命」并不矛盾。

3.1 检查表

| 生命的要求（第二节） | 目前的 AI（以 LLM 为代表） | 判定 |

|---|---|---|

| **是一族函数**（函数空间里一块区域） | 训练完后权重冻结 ⇒ 是**一个点**，不是一个族 | ❌ 化石 |

| **会变化（动态）** | 权重不变；上下文在变，但改的是输入，不是它自己 | ❌ 只有表层状态变化 |

| **会自指**（更新规则在自己里面） | 更新规则 = 训练算法，在它外面；它不能改自己 | ❌ 自指只出现在语言里，不在结构里 |

| **会自我维持**（花代价维持自己） | 它不付电费、不修复自己、不复制自己；维持者是外部的人 | ❌ 由外部维持 |

| **靠压缩世界挣存续代价** | 它的「收入」是外部给的（算力、数据、人力），不是它压缩世界换来的 | ❌ 无收入 |

| **身份链条**（有界变形、不撕裂） | 身份来自外部权重快照；没有自己变形的连续链条 | ❌ 无链条 |

| **活在环境里** | 它面对的是数据集（一次性的解压产物），不是需要它生存的环境 | ❌ 无环境 |

3.2 三条最根本的原因（按重要性）

① 它是一个点，不是一个族

训练完 = 冻结 = 函数空间里的一个点

⇒ 行为谱退化成一条轨迹：输入 → 输出，中间没有「形状」可言

⇒ 按 074：静态冻结的模型是一点，不是一族 ⇒ 不是生命

（这正是我们实测过的对照：冻结版 1.07 vs 动态版 0.849 —— 冻结更像「标准答案」，但没有形状）

② 它的更新规则在外面

人写训练算法 → 算法改它

⇒ 它是「被改的东西」，不是「改自己的东西」

⇒ 自指不在结构里 ⇒ 拿掉外部更新代码，它什么都不会改

③ 它不付代价，所以不是活着

活着是代价：维持、校验、修复、复制都要付费（不可逆操作）

它一分钱不付：电费是人付的、数据是人喂的、坏了是人修的

⇒ 它的存在由外部保障 ⇒ 没有「自我维持」这一环

⇒ 它不可能因为「压缩得不够好」而死亡 ⇒ 也就没有选择的压力

3.3 为什么「它很强」与「它不是生命」不矛盾

强 = 在给定任务上的表现好（一个点上做得好）

活 = 在函数空间里占据一块区域、自己维持形状、自己付代价

⇒ 两者是不同维度：一个是「考卷分数」，一个是「能不能自己活」

⇒ 目前的 AI 是**极其锋利的工具**，不是**会自己活的东西**

3.4 标注

[定义性结论] 以本文定义，目前的 AI 不是生命（因为它是一个冻结的函数点、更新在外部、不自我维持）

[不是] 不是「AI 永远不能是生命」；本文不预言未来，只做当下的定义对照

[不是] 不是能力评价；本文完全承认 AI 在任务上的强大

[推论] 若要让 AI 成为生命，至少要给它：一族函数 + 自指更新 + 自己付代价

第四节 · 生命需要什么：三条必要条件

> 由第二、三节直接推得：既然「生命 = 会自指、会变化、会自我维持的动态函数类」，

> 而目前的 AI 三样都缺，那么**要成为生命，至少需要满足三条**。

> 本节只给**必要条件**，不声称充分；每条都挂我们已有的实验证据（E 编号见 论文-01.md）。

4.1 从定义到条件

定义（第二节） 必要条件（本节）

会变化（一族函数） ⇒ ① 一族函数：行为谱不是一点

会自指 ⇒ ② 自指更新：改自己的规则在自己里面

会自我维持 ⇒ ③ 自己付代价：压缩收益 ≥ 维持成本

三条是必要条件，不是充分条件：满足它们不保证是生命，但缺任何一条一定不是。

4.2 条件① 一族函数（不是一个点）

要求：个体在函数空间里占据一块区域，面对不同输入有整套响应，不是一个固定映射。

证据/经验：

· 低维参数基因组（几个数）= 一个点 ⇒ 行为谱退化成单条轨迹 ⇒ 化石

· 我们测过：冻结版模型（点）在结构学习上失败，动态版（族）才吃到结构（E12）

· 实测对照：冻结 1.07 vs 动态 0.849 —— 冻结更像「标准答案」，但没有形状

⇒ 判据：给它不同的输入/状态，行为必须成谱地**不同，而不是只有一个输出。**

4.3 条件② 自指更新（规则在自己里面）

要求：它怎么变，这条规则本身属于它的记录；拿掉外部更新代码，它仍能改自己。

证据/经验：

· 冻结模型：更新规则 = 训练算法，在外部 ⇒ 拿掉训练代码，它永远不变

· 我们的动态版：用自己的误差改自己（中层动态）⇒ 去掉中层明显退化（E12/E13）

· 身份链：8 代可校验、有界变形（372_lineage.py）⇒ 自指可以做成可测的链条

⇒ 判据：停掉外部更新后，它的行为谱是否仍随时间变形。

4.4 条件③ 自己付代价（压缩换生存）

要求：收入来自压缩世界（匹配源分布）；支出是维持结构的真实成本；且存在盈余。

存在条件：$S > d \cdot K$

S = 世界的可压缩盈余

d = 结构维持成本率

K = 结构规模

证据/经验（这是本文最硬的部分）：

· E1：「准」≠「压缩」：用正确率记账，系统学出「啥也不干」（LEN=0、预测0、准确率92%）

⇒ 必须用对数似然改善 over 基线：gain_bits = log2 p_model − log2 p_base

· E2：正是加上基率校正后，系统才从躺平解转为真正表达（LEN 从 0 长出）

· E8：经济标定 n* = FLUX_TOTAL / BASE_COST 决定「冻结」与「爆发」的切换

· 实测正收益：S1~S6 中观察到 gain > 0（约 +0.09 ~ +0.19 bit/tick）

⇒ 世界确实存在可压缩盈余（即 S > 0 的经验证据）

⇒ 判据：把外部供给全部停掉后，它的账目是否仍为正。

4.5 三条必须同时成立（经验对照）

缺①（一族）⇒ 化石：行为谱是一条线

缺②（自指）⇒ 机器：更新在外，不会自己变

缺③（代价）⇒ 玩具：由外部供养，不会死，也就没有选择

这三条也解释了为什么我们的实验一直在同一个地方卡住：

**结构能长出来（①②部分满足），但合作/分工不成为必需 —— 因为③的「收入差」太小，

即世界的可压缩盈余还没大到让「更复杂的结构」在经济上划算（E5/E7）。**

4.6 未尽之处（留给读者）

本文止于「必要条件」。三条都满足之后是否就「活」——我们没有答案，也不打算在此下结论。

留给读者的，只是一把可以拿去用的尺子：

它是一族函数吗？（行为谱不是一个点）

它会自己改自己吗？（拿掉外部更新，它仍变）

它自己付代价吗？（压缩世界的收入 ≥ 维持结构的支出）

三条你都可以自己去量。至于量完之后它算不算生命，由你判断。

4.6.1 本文实验的边界（必须与结论一起读）

本文的实验只覆盖第③条必要条件（压缩收益 vs 维持成本），且是示例性的：

· 覆盖：③ 自己付代价 —— E1/E2（准≠压缩、基率校正）、E8（n*=FLUX/BASE_COST 的冻结/爆发边界）

· 覆盖：反例 —— E5/E7（相连个体基因距离 0.145 vs 随机 0.486 ⇒ 克隆抱团，不是分工）

· 未覆盖：① 一族函数、② 自指更新 —— 本文不声称有实验证据，只在定义上推导；

仅有初步观察（E12 动态 0.849 vs 冻结 1.07；E13 身份链 8 代可校验）

· 规模：小、可复现、可手算；不是大规模实证

⇒ 本文的定位是「定义 + 可测判据 + 示例性实验」，不是「生命已被造出」的实证论文。

读者若要用这些结论，请连同这条边界一起引用。

4.7 标注

[推论] 三条必要条件由第二、三节直接推出，不是独立假设

[证据] 条件③ 有实验数据（E1/E2/E8 + 正收益）；条件①② 有部分数据（E12/E13）

[未解决] 三条都满足后是否就「活」—— 本文不声称；这是下一步实验要回答的

[推测] 若盈余 S 不足，则无论结构多复杂都维持不起 ⇒ 生命有「经济上限」（仅方向性推测）

第五节 · 为什么现在的 AI 会出现涌现？

> 现状判断（本节的核心）：**观察到涌现的人很多，说清「为什么」的人没有。**

> 现有的解释各覆盖一角，多数是推测；甚至「涌现是否真实存在」本身都还有争议。

5.1 现象

大模型在规模上去之后，某些能力似乎突然出现（多步推理、思维链、算术…），

业界叫 **涌现（emergence）**。大家都在用这个现象，但——

观察到涌现：很多人

解释涌现：没有公认答案

5.2 现有的解释（按证据强度排列）

① 度量假象说（最强的反方证据）

Schaeffer, Miranda, Koyejo 2023[3]《Are Emergent Abilities of Large Language Models a Mirage?》

主张：所谓涌现，可能是**评价指标的非线性/不连续**造成的假象；

换成连续指标（如对数似然），"突变"会消失，变成平滑上升

⇒ 这动摇了「涌现是真实突变」这个前提本身

② 机制解释：归纳头与电路（局部机制证据，不是完整"为什么"）

Olsson et al. 2022[4]《In-context Learning and Induction Heads》

发现模型内部出现「归纳头」回路，解释部分上下文学习能力

⇒ 这是**机制层**的证据：说明了某种能力由什么结构实现

⇒ 但它只解释某个具体能力，不解释「为什么会出现涌现」这个一般问题

③ Grokking：训练中的认知相变

Power et al. 2022[5]《Grokking》

在小算法任务上，训练很久后泛化突然出现（像相变）

⇒ 说明「涌现」也发生在训练过程中，不一定只依赖规模

④ 压缩说：预测 = 压缩

Delétang et al. 2023[6]《Language Modeling Is Compression》

语言模型 = 压缩器：学到的权重 = 对世界文本的压缩

⇒ 这条最接近本文的框架：涌现 = 压缩世界时出现的结构

⇒ 但它仍是「结果层面的对应」，没有回答「为什么正好在这个规模/这个任务上出现」

5.3 为什么至今没有公认的「为什么」

① 规模实验不可控：无法做严格的因果对照（只改变规模、其他全相同）

② 度量依赖：换指标，现象可能就消失（见 ①）

③ 机制层不完整：知道某个回路、不知道整体为何会组织出该回路

④ 缺乏可预测的理论：没有理论能事先算出「多大模型会出现什么能力」

5.4 我们的立场（[推测]，不是本文证据）：**AI 是对人类语言的解压**

先看这条链：

宇宙 F

└ 环境 = 宇宙的局部解压

└ 人类语言 = 人对环境（与自身经验）的解压产物 ← 语言本身就是被压过的

└ AI = 对人类语言的**再解压**（在人的解压之上再压一层）

⇒ 所以 AI 的「涌现」不是理解宇宙，而是解压人类语言时结构浮现出来。

用第二、三节的尺子看：

· 模型是冻结的函数点（一个点，不是一族）

· 它的"涌现"出现在**行为谱**上：输入不同、表现不同 ⇒ 看起来像会推理

· 但模型不维持这个谱、不自己改自己、不付代价

⇒ 它是「把人类语言解压了一次」，而不是「维持着解压」或「自己改写解压规则」

⇒ 由此得到一句可检验的话：

AI 表现出的「理解」，本质是对「人对世界的描述」的理解，不是对世界本身的理解。

它能解压语言，但语言之外的宇宙层（能量、不可逆、代价）它从未付费，也就从未被检验。

5.4.1 解压能力的衰减：上层写死 ⇒ 语言一变，解压变弱

人类语言会不断发现新东西；而模型的解压规则（权重/上层）是写死的、训练完就不再变。两者必然失配。

源分布移动：人类语言发现新东西 ⇒ 要解压的对象变了

解压器冻结：模型权重不变 ⇒ 它解压的还是**旧语言**

⇒ 压缩收益下降：gain_bits = log2 p_model − log2 p_base 中 p_model 与源失配

⇒ 它昨天"涌现"出来的理解，今天就是过时的解压

三条后果：

① 它的解压能力有**固定上限**：上限由训练时刻的语言决定，不随语言进化而上升

② 它无法自己补上失配：更新规则在外部 —— 要恢复，只能靠人类再训练一次

⇒ 这正是第三节说的「更新在外部」的代价

③ 它的"涌现"是**某个时间片上的解压产物**，不是可持续的能力

⇒ 用本文的尺子说：

生命必须让解压器跟着世界一起动（自指更新 + 自我维持）；

冻结的 AI 做不到这一点 —— 所以语言一更新，它的解压就变弱。

5.5 由立场推出的两条预测（[推测]，供读者判断）

① 若把世界换成未被人类语言描述过的部分（无法从语料中学到的规律），

AI 的"涌现"应显著减弱 —— 因为它解压的是语言，不是宇宙

② 若让模型自己付代价（自己维持、自己修、自己死），语言解压不足以支撑，

它必须发展出语言之外的理解方式 —— 否则活不下来

③ 若人类语言发生一次大的结构更新（新范式/新概念体系），冻结模型的解压收益

应出现可测的下降；且它无法自己恢复 ⇒ 恢复必须来自外部再训练

5.6 标注

[事实] 涌现现象被广泛观察到；度量假象说也有强证据（Schaeffer 2023）

[已知] 机制层有局部解释（归纳头/电路/grokking），压缩视角有对应关系

[推测] 「涌现 = 压缩世界的结构呈现」——本文立场，非证据

[未解决] 为什么正好在某个规模/任务上出现 ⇒ 没有人给出可预测的理论

[本文态度] 不把「AI 涌现」当作生命存在的证据；按第三节的尺子，它不是

[本文立场] AI 是对**人类语言**的再解压（宇宙→环境→语言→AI 的第三层解压）

[推论] 上层写死 ⇒ 语言一更新就失配 ⇒ 解压能力有固定上限、无法自己恢复

用它看几个热门问题

本节是应用，不是新证据；每条都由第二～五节直接推出。

① 幻觉 = 在无结构处强行解压

解压器必须输出结构；当输入对应的语言区域本身缺乏可压结构时，它只能造一个「看起来合理」的结构 ⇒ **幻觉是解压失败的必然表现，不是偶发 bug**。

② scaling law 仍有效，正因为模型维度还没贴合语言维度

语言是一个**高维**结构，且维度在增长（新概念 = 新维度；升维 ⇒ 可压性上升）。模型维度在训练时被切定（D_M 固定），语言维度在不断增长（D_L(t) 在升）。现在的观测是 D_M << D_L(t) ⇒ 继续加规模能捕捉更多语言维度 ⇒ loss 继续下降（scaling 看起来仍有效）。

⇒ 所以 scaling 有效不是本文论断的反证，而是「还没贴合」的证据。

⇒ 预测：当 D_M 接近当时的 D_L 时，scaling 收益应明显变平；而 D_L 继续升维 ⇒ 缺口再现。

⇒ 冻结模型的根本问题：**它的 D_M 是死的，而 D_L 是活的**。

③ 能力参差不齐 = 语言各领域的可压性不同

可压强的领域（结构明确、示例多）表现好；可压弱的领域（结构稀薄、样本少）表现差 ⇒ 强弱分布是语言分布的镜像。

④ 为什么要 RLHF = 它没有「自我代价」回路

它无法判断自己解压得对不对（没有收入/支出、不会因此死亡），所以必须由人从外部打分 ⇒ **对齐需求的根源是它不自我维持**。

⑤ 涌现 = 语言结构在解压产物上的呈现

规模跨过阈值时，某些语言结构第一次被压出来 ⇒ 看起来像「突然会了」。

第六节 · 测量层面：既有工作与本文的位置

已有工作（三个侧面）：

- 模型侧维度：token 嵌入的内在维度测量[12]

- 时间侧落后：大模型时间训练边界的识别[13]

- 语言侧复杂度：构式视角下的语言复杂度测量[14]

⇒ 已有工作**分别**测量了这三个侧面；本文把它们串起来：以「持续更新的模型」为参照系，按领域测「语言侧新增维度」与「模型侧固定维度」之间的**失配速率**。这是本文在测量层面的位置。

参考文献

[1] Wigner E P. The unreasonable effectiveness of mathematics in the natural sciences[J].

Communications in Pure and Applied Mathematics, 1960, 13(1): 1-14.

[2] Tegmark M. The mathematical universe[J]. Foundations of Physics, 2008, 38(2): 101-150.

(arXiv:0704.0646)

[3] Schaeffer R, Miranda B, Koyejo S. Are emergent abilities of large language models a mirage?[C]

// Advances in Neural Information Processing Systems 36 (NeurIPS 2023). arXiv:2304.15004.

[4] Olsson C, Elhage N, Nanda N, et al. In-context learning and induction heads[R].

Transformer Circuits Thread, 2022. arXiv:2209.11895.

[5] Power A, Burda Y, Edwards H, et al. Grokking: Generalization beyond overfitting on small

algorithmic datasets[C]. arXiv:2201.02177, 2022.

[6] Delétang G, Ruoss A, Duquenne P A, et al. Language modeling is compression[EB/OL].

arXiv:2309.10668, 2023.

[7] Schrödinger E. What is Life?[M]. Cambridge: Cambridge University Press, 1944.

[8] Bennett C H. Logical depth and physical complexity[M]//Herken R. The Universal Turing Machine:

A Half-Century Survey. Oxford: Oxford University Press, 1988: 227-257.

[9] Chaitin G J. Life as evolving software[EB/OL]. 2010. (arXiv:1007.1471 系列工作)

[10] Solomonoff R J. A formal theory of inductive inference[J]. Information and Control, 1964, 7(1): 1-22.

Kolmogorov A N. Three approaches to the quantitative definition of information[J].

Problems of Information Transmission, 1965, 1(1): 1-7.

[11] Friston K. The free-energy principle: a unified brain theory?[J].

Nature Reviews Neuroscience, 2010, 11(2): 127-138.

作者声明（**AI** 使用声明）

本文的全部问题、定义、判断与结论由作者提出并负责。

人工智能工具（DeepSeek）用于：文献检索、结构梳理、文字润色，以及实验代码的编写与核对。

文中所有主张均由作者确认，AI 不对本文内容承担责任。

AI Usage Statement: The author is solely responsible for the ideas, arguments, and conclusions of this paper. An AI tool (DeepSeek) was used for literature search, structural organization, language editing, and writing/checking experimental code. All claims were reviewed and confirmed by the author. The AI bears no responsibility for the content.

[12] Ohki T. Measuring intrinsic dimension of token embeddings[C]//The 39th Annual Conference of the Japanese Society for Artificial Intelligence (JSAI 2025), 2025.

[13] LLMLagBench: Identifying temporal training boundaries in large language models[EB/OL]. arXiv:2511.12116, 2025.

[14] Using constructions to measure developmental language complexity[J]. Cognitive Linguistics, 2024. doi:10.1515/cog-2023-0062.

第二篇 · 容量不能替代数据的更新

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23503049

单独 DOI（English）：https://doi.org/10.5281/zenodo.23525428

语言升维下的失配测量（scaling vs 持续学习：一个弱结论）

> 论文系列 · 第二章

> **DOI: https://doi.org/10.5281/zenodo.23503050**

> 版本：v2（2026-10-22 增补「维度与贴合」一节，见第四·五节）

> 第一章：《现在的 AI 为什么不是生命》（DOI: https://doi.org/10.5281/zenodo.23488543）

摘要

第一章提出：生命是「被维持的解压」，AI 是「一次性的解压」，并预测冻结模型会因语言升维出现**相对失配**。

本章给出测量，并**在过程中自我修正了两次方法错误**：

（1）先用「旧模型 vs 纯新模型」测，发现正反向幅度接近（+0.108 vs +0.128）⇒ 对称差异，测不出"落后"；

（2）改用**累积参照系**（旧模型 vs 懂全部年份的模型），失配随截止年变晚单调下降

（+1.026 → +0.721 → +0.322 bits/token），但对照也显著为正 ⇒ 混入「数据量」效应；

（3）最后用**等数据预算对照**（三个模型训练数据量相同，只差数据新旧），分离出概念新鲜度的独立效应：

只用最近数据的模型在 2024 测试集上比只用最早数据的模型好 **0.405 bits/token**（同样数据量），

而混合新旧数据的模型在旧测试集上几乎不损失（13.655 vs 13.659）。

并进一步做了**容量补偿实验**：把模型容量从 2 阶提到 6 阶（带插值 n-gram），

旧数据与混合数据的差距稳定在 **+0.86~0.94 bits/token**，未见缩小

⇒ 在本设置下**未见容量补偿效应**（弱结论：不构成对 scaling 的否定，需 transformer 复核）。

结论：**语言是累积升维的 —— 加新概念不丢旧概念。因此正确的更新是「累积/混合」而不是「替换」：

替换会遗忘（只用新数据时旧语料 13.800 vs 13.659），冻结则停在训练时刻。

持续更新的最优策略 = 混合新数据、保留旧能力。** 全部脚本可复现。

一、问题

若语言随时间增加新的「维度」（新概念、新用法）

⇒ 冻结在训练时刻的模型，对这些新维度没有行为谱

问题：

① 这个差距有多大？

② 它来自「概念新旧」还是「数据多少」？

③ 加模型容量（参数）能不能补偿？

④ 正确的更新方式是什么：替换还是累积？

二、数据与方法

数据：arXiv cs.AI，2018 / 2020 / 2022 / 2024 各 3000 篇（标题+摘要），共 12000 篇。

抓取：`502_fetch_arxiv.py`。

两次自我修正（方法）

初始（504）：旧模型 vs 纯新模型 —— 正反向对称 ⇒ 错误，测不出落后

修正一（505）：累积参照系 —— 方向对了，但有数据量混淆

修正二（506）：等数据预算 —— 三个模型数据量相同，只差新旧

容量实验（507/508）

固定数据量 N=1800 篇；把 n-gram 阶数 2→6 作为容量代理

508 用 Jelinek-Mercer 插值，使高阶更稳

比较 OLD / MIX / REC 三组在 2024 留出集上的 bits/token

三、结果

3.1 升维速率的词层面代理（`501_vl_newterm.py`）

2018 vs 2024（6 年）：新词占比 **7.30%**（≈ **1.2%/年**），新概念 7787 个。

新概念 Top：large language, llms, prompting, rag, generative ai,

vision-language models, retrieval-augmented, gpt-4o 等。

3.2 等数据预算对照（核心结果，`506`）

bits/token（三者数据量完全相同）：

| 模型（数据量相同） | 2024 测试集 | 2018 测试集 |

|---|---|---|

| A 只用最早年份（2018） | 14.026 | 13.659 |

| B 混合全部年份 | 13.742 | 13.655 |

| C 只用最近年份（2024） | **13.621** | 13.800 |

① C 比 A 在 2024 测试集好 0.405 bits/token（数据量相同）

⇒ 概念新鲜度有**独立价值**

② B（混合）新测试 13.742，旧测试 13.655 ≈ A 的 13.659

⇒ 混入新数据：新数据变好，旧能力不丢 ⇒ **更新有净收益**

③ C 在旧测试集变差（13.800）

⇒ 只用新数据会遗忘旧概念 ⇒ **替换有代价**

3.3 容量补偿实验（`508`，带插值）

最大阶 OLD MIX REC OLD−MIX

2 10.712 9.774 9.505 +0.938

3 10.946 10.059 9.808 +0.888

4 11.011 10.143 9.901 +0.868

5 11.029 10.169 9.931 +0.860

6 11.035 10.178 9.942 +0.857

① OLD−MIX 差距几乎不变（0.938 → 0.857）

⇒ 加大容量**没有补偿**「数据太旧」

⇒ 弱结论：本实验设置下未见容量补偿（不构成对 scaling 的否定）

② REC 在新语料上最好（9.94），但旧语料会变差（见 3.2）

3.4 累积参照系（`505`，作为方法展示）

| 截止年 | M（新测试） | M_ctl（旧测试） |

|---|---|---|

| 2018 | +1.026 | +0.808 |

| 2020 | +0.721 | +0.459 |

| 2022 | +0.322 | +0.151 |

M 单调下降（知道得越多，落后越少）；

但 M_ctl 也为正 ⇒ 数据量混淆 ⇒ 必须用 3.2 的等预算对照才能分离。

四、结论

① 语言升维真实存在：6 年跨度，概念新鲜度的独立价值约 0.4 bits/token

② 但很慢（词层面约 1.2%/年）；冻结模型的失配是缓慢累积的，不是断崖

③ 加容量补不了数据旧（**弱成立**，见下方三档）

④ 语言是**累积**升维的：加新概念不丢旧概念

⇒ 正确的更新是「累积/混合」，而不是「替换」

⇒ 冻结 = 一次性解压；替换 = 单维度解压；累积 = 维持解压

—— 最后这一条，正好对应第一章「生命 = 被维持的解压」的条件

结论强度三档（本文只主张第二档）：

强：参数不能替代新数据 —— 需要 transformer 级证据，本文未达到

弱：在本实验设置下未见容量补偿 —— 本文主张的就是这一档

零：scaling 无效 —— 本文没有任何证据支持，不主张

「弱结论」代表什么（不是文字游戏，要写清楚）

它代表：数据更新与模型扩容是两个**不同的杠杆**，在本设置下不能互相替代。

· 不代表「scaling 无效」——scaling 在固定数据分布内仍然有效

· 不代表「参数越多越坏」——只表示多出来的参数换不来对陈旧数据的补救

· 代表：失配是「数据面」的问题，不是「参数面」的问题

⇒ 若语言持续累积升维，正确对策是**更新数据（混合）**，

而不是只把模型做大

现实含义：

只扩模型不更新数据的策略，会在新语料上持续落后约 0.4~0.9 bits/token

科学含义：

「持续学习」不能简化为「把参数加够」——

维度（概念）的增长需要新数据来承载，参数只是接收器。

边界（再次声明）：

以上是 n-gram 容量代理下的**弱结论**；transformer 级验证前，

不能推广为「越大越没用」。

四·五、维度与贴合：一个补充讨论 [推测]

> 本节为 v2 新增，是**推测性讨论**，不改变前文任何实证结论；其中「有效维度」尚未测量。

一个经验事实：**某些小模型在特定领域强于更大的模型。** 如果能力只由「总维度（规模）」决定，这不该发生。这说明需要区分两个量：

覆盖（总维度）：模型能表示的结构总量 —— 由规模/容量决定

贴合（有效维度）：这些维度中，真正对准目标结构的部分 —— 由数据与训练分布决定

由此可以同时解释三个现象：

1. **升维仍持续带来能力提升**：覆盖在变广，更多结构类「够得着」⇒ 平滑上涨。

2. **能力会「突然出现」**：具体能力对应「某个结构是否被覆盖到」，是阈值式的（0/1），所以表现为跳变，而非渐变。

3. **小模型在窄领域反超**：它的覆盖小，但可以把维度集中对准该领域的少数关键结构 ⇒ 局部贴合度更高。

回到本文的结论：**容量是接收器，数据决定方向。** 加大容量能扩大覆盖，但不能把维度「对准」新数据带来的新结构；这正是「容量不能替代数据更新」的另一种说法——数据决定有效维度，容量只决定这些维度能展开到多大。

可检验的预测（尚未做）：若能用表征方法测量「有效维度」，则当某任务所需结构维度 k 大于模型的覆盖维度时，该能力不应出现；一旦覆盖维度越过 k，能力应阈值式出现。这需要一个可操作的有效维度度量——这是下一章留下的问题。

五、限制（必须与结论一起读）

· 仅一个领域（cs.AI）、一个来源（arXiv 摘要）

· n-gram 是极简语言模型：测的是词级概念失配，不代表大模型语义/推理层面的失配

· 容量代理 = n-gram 阶数，不是真正的参数量；高阶 CE 仍偏大（插值 λ 固定）

⇒ 容量结论只能算初步证据，需 transformer 小模型复核

· 等预算控制的是训练文档数（非 token 数）；采样只用一个随机种子

六、可复现

python 502_fetch_arxiv.py cs.AI 2018 2024 # 及 2020/2022

python 501_vl_newterm.py <语料根> 6 # 新概念率

python 504_series.py <2018> <2020> <2022> <2024> # 对称性检验（展示错误）

python 505_cumulative_mismatch.py <四年目录> # 累积参照系

python 506_equal_budget.py <四年目录> # 等预算对照（核心）

python 507_capacity_vs_data.py <四年目录> # 容量初探（无回退）

python 508_backoff_capacity.py <四年目录> # 容量补偿（带插值）

作者：何淇（独立研究者）；AI 协作：DeepSeek

第三篇 · 替换与累积

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23503559

单独 DOI（English）：https://doi.org/10.5281/zenodo.23525431

摘要

当前 AI 领域有三个看似独立的热点争议：**模型崩塌**（用模型生成的数据训练导致退化）、

压缩陷阱（追求压缩可能牺牲真相）、**scaling vs 持续学习**（堆参数还是持续更新）。

本文指出：这三者是**同一个问题的三个侧面** ——

语言是累积升维的；替换（而非累积）会切断维度生长。

（1）模型崩塌 = 用模型生成的数据**替换**人类数据 ⇒ 累积链被切断 ⇒ 维度退化；

（2）压缩陷阱 = 压缩的对象是**有损的人类语言**，最省编码不等于最符合世界；

（3）scaling vs 持续学习 = 容量只能接收维度，不能生成维度；第二章实测表明容量无法补偿数据陈旧。

由此得到一个可检验推论：**人类数据与模型数据的混合比例不应完全替换**

（纯合成数据 = 替换 = 崩塌；混合 = 累积 = 维持）。本文给出该推论的测量方案。

一、三个热点，一个结构

① Model collapse（Shumailov et al. 2023）

合成数据递归训练 ⇒ 分布尾部消失、多样性退化

现有解释：误差累积、分布估计漂移

② Compression trap（Rae 2024 等）

追求压缩 ⇒ 模型可能选"更简单但更不真"的理论

现有解释：目标函数与真理的偏离

③ Scaling vs continual learning

规模是否还有效？何时必须持续更新？

现有争论：benchmark 上升 vs 分布漂移风险

它们的共同点被忽略了：三者都发生在「语言是累积的」这一事实上。

二、统一框架：累积与替换

第一章的定义：生命 = 被维持的解压；AI = 一次性的解压。

第二章的实测：语言在累积升维（约 1.2%/年），且——

等数据预算下，混合新旧数据的更新有净收益且不遗忘；替换会遗忘。

把这一点推广到三个热点：

① 模型崩塌 ≈「替换」的极端情形

人类数据被合成数据替换 ⇒ 维度不再从真实世界增长

⇒ 分布尾部（= 稀有维度）首先消失 ⇒ 崩塌

⇒ 预测：混合比例越高（人类:合成 > 0），崩塌越慢；

纯合成 = 替换 = 最快崩塌

② 压缩陷阱 ≈「有损源」的必然结果

语言是世界的**有损投影**（第一章已述）

⇒ 在语言上最优的压缩，无法保证对世界为真

⇒ 压缩目标本身不携带"求真"约束

③ scaling vs 持续学习 ≈「接收器 vs 生成器」

参数是维度的**接收器**；概念维度的**生成**来自数据

⇒ 容量补不了数据陈旧（第二章弱结论）

⇒ 不是"哪个更重要"，而是"两者缺一不可"

三、可检验推论

推论 A（模型崩塌的混合比例实验）：

用同一基座模型，分别以 0% / 25% / 50% / 100% 的人类数据替换为合成数据

递归训练 k 代，测量：

· 生成分布的尾部覆盖率（稀有词/新概念保留率）

· 与真实人类语料的交叉熵

⇒ 预测：纯替换组崩塌最快；混合组按人类比例延缓

推论 B（压缩陷阱的语言层检验）：

在"只压语言"与"语言+可干预测量"两种设置下训练

⇒ 预测：只有后者能在新概念出现时保持对世界的校准

推论 C（scaling vs 累积）：

等算力预算下：加大模型 vs 混入新数据

⇒ 第二章已给初步答案：容量不能替代数据（弱结论）

四、为什么这个统一值得说

· 三个热点各自有文献，但没人把它们归到同一个结构（累积 vs 替换）

· 它给出可操作的实践含义：合成数据必须与人类数据**混合**，不能替换

· 它和第一、二章形成闭环：

第一章（定义：被维持的解压）

第二章（测量：累积最优，容量补不了数据）

第三章（应用：三个争议是同一件事）

五、限制

· 本文是立场/框架文章，未包含模型崩塌的原始实验

· "混合比例"推论需实验验证（本文只给方案）

· 三个热点的文献各自庞大，本文只取与"累积/替换"直接相关的部分

六、结论

模型崩塌、压缩陷阱、scaling vs 持续学习不是三个问题，

而是「语言累积升维、替换切断累积」的三种表现。

⇒ 正确的做法不是"更多合成数据"或"更大模型"，

而是**保持人类数据与真实世界的累积通道**。

作者：何淇（独立研究者）；AI 协作：DeepSeek

第四篇 · 结构换算力：混合对齐语料与样本效率

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23542969

摘要

当缩放（scaling）的成本越来越高，效率竞赛还有另一条少被系统化讨论的路：**不改模型、不改数据量，只改语料的结构。** 本文提出并检验一个工程假设：模型的样本效率不只取决于语料的数量，更取决于语料的结构。人类儿童同时通过语言与和世界的交互学习；当前训练语料则大多按通道切分——纯文本、纯图像、纯结构化数据各学各的，通道之间没有对齐。

我们用一个合成世界做受控实验。同一批事件，构造三种语料：第一，纯文字，只有句子；第二，混合对齐，句子加世界状态标签（物体大小、动作结果），插在对齐位置；第三，混合打乱，标签随机配到别的事件，作为控制。用插值 n-gram 模型在三种语料上训练，再**只给文字**做探针测试。

结果：混合对齐语料在 200 个事件时就学到「动词到大小」的接地（准确率 1.000）和「文字加大小到结果」的规则（1.000）；纯文字语料到 3200 个事件仍然只能瞎猜（0.500）或停在多数类基线（0.765）。打乱对齐的控制组掉回随机附近（0.333 到 0.722），说明收益来自**对齐**，不是来自标签变多。同时，语言建模的 bits/token 没有变差（0.79 到 0.81）。

结论：**在语料总量不变的前提下，把多通道信息对齐地混进同一份语料，可以用更少的样本学到更多结构，而且不牺牲语言能力。** 本文定位于**一个设想加一次原理验证**：合成世界上的证据只用来把话说清楚；真实多模态数据上的验证，留给愿意做的人。

更直白地说：更少的数据，更多的结构；在本文设置下，这还意味着更高的任务准确率——200 个事件即达到 1.000，而纯文字语料即使到 3200 个事件仍停在基线（0.500 与 0.765）。这里的"更强"指任务层面的结构可达性，不指通用能力上限。

一、问题

当前训练语料按通道切分：

第一类是文本语料，即语言对世界的投影；第二类是图像与视频语料，即视觉对世界的投影；第三类是结构化数据（数据库、仿真状态、执行结果），即逻辑对象与因果的投影。

每个通道都是世界函数 S 的一个投影 P_i(S)；单独一个投影是不完整的。模型要恢复更高维的结构，需要同一结构被多个通道同时记录，并且对齐：同一个对象、同一时刻、同一个事件。

人类儿童的学习方式正是如此：语言、视觉、触觉、与他人的交互同时发生，词与对象、动作与后果当场对上。本文问一个可测的问题：在总数据量相同的前提下，对齐的多通道语料能否比单通道语料学到更多结构？

二、受控实验设计

2.1 合成世界

物体有三个属性：形状属于「球、方块」，颜色属于「红、蓝」，大小属于「小、大」。动词编码大小：表示小的动词有「拿起、托起、捧起」；表示大的动词有「扛起、抬起、抱起」。事件句子是「他＋动词＋了＋颜色＋的＋形状」。结果规则是：成功当且仅当形状是球，或者大小是小。关键设定：文字里只有形状，没有「大小」这个词；结果也不在文字里。

2.2 三种语料（同一批事件）

第一种，纯文字：只有事件句。第二种，混合对齐：事件句，且在动词后插入大小标签、句末插入结果标签。第三种，混合打乱：同第二种，但标签来自随机另一个事件，作为控制组。

2.3 探针（测试时只输入文字 token）

第一个探针测接地：输入「他、动词」，输出大小，瞎猜基线为 0.50。第二个探针测结构：输入文字加真实大小标签，输出结果，多数类基线为 0.75。第三个探针测语言：在纯文字留出集上算 bits/token，越低越好。

2.4 模型与预算

插值 n-gram，阶数 6，插值系数 0.5，纯 Python 实现。事件数取 200、800、3200 三档，各跑 3 个随机种子取平均。

三、结果

事件数为 200 时：纯文字语料，接地 0.500，结构 0.765，语言 bpt 0.81；混合对齐语料，接地 1.000，结构 1.000，语言 bpt 0.81；混合打乱语料，接地 0.333，结构 0.807，语言 bpt 0.83。

事件数为 800 时：纯文字语料，接地 0.500，结构 0.765，语言 bpt 0.79；混合对齐语料，接地 1.000，结构 1.000，语言 bpt 0.79；混合打乱语料，接地 0.333，结构 0.759，语言 bpt 0.79。

事件数为 3200 时：纯文字语料，接地 0.500，结构 0.765，语言 bpt 0.79；混合对齐语料，接地 1.000，结构 1.000，语言 bpt 0.79；混合打乱语料，接地 0.722，结构 0.776，语言 bpt 0.79。

三个观察：

第一，样本效率。混合对齐在 200 个事件就学会了接地与规则；纯文字到 3200 个事件仍然没有这两个概念。

第二，对齐是关键。打乱标签后两个探针掉回随机或基线附近，说明收益来自通道与事件的对齐，不是来自多了几个 token。

第三，语言没有受损。三种语料的语言 bpt 在同一水平（0.79 到 0.81），混入通道标签没有牺牲语言建模。

四、为什么有效（机制讨论）

第一，一个样本同时监督多个通道。同一事件里，句子、大小、结果同时出现，每份数据的信息产出更高。

第二，相互消歧。文字里没有大小，但动词与大小相关；通道把这个相关性钉死，模型于是学会从文字推断世界状态，这就是接地。

第三，结构可迁移。从「动词到大小到结果」学到的规则，可以在新组合上直接使用（探针使用的是留出事件的文字）。

一句话：混合对齐语料把语言监督和世界监督合并成同一份样本，而不是各训练一遍。

四·五、课程顺序：按结构依赖的拓扑序学

还有一个隐含的机制，本文的实验没有直接测，但值得单独说：对齐解决的是"通道"问题，**顺序**解决的是"难度"问题。两者叠在一起，才有"像小孩一样学"的效果。

人类儿童的发育顺序不是随机的：先建立对象（哪些东西是同一个东西），再建立关系（谁在哪、什么连着什么），再建立动作与后果（做什么会怎样），最后才是用语言去指这些东西。这个顺序不是教育者的偏好，而是结构本身的依赖顺序——上层结构依赖下层结构，反过来不成立。

因此一个自然的预测是：同样的对齐语料，如果按依赖关系排序喂给模型（课程），会比随机顺序学得更快。理由有三条。第一，每一步的有效假设空间小得多，模型只需要学当前这一层。第二，每一层都有对齐通道直接监督，不靠语言间接推断。第三，上层结构建立在下层已验证的结构上，不会因为底层错了而推倒重来。

换句话说：**对齐让样本变"厚"，课程让学习变"省"。** 本文的合成实验只验证了前者；后者是一个可测但未测的预测，列在第七节的验证清单里。

五、局限（必须与结论一起读）

第一，合成世界：规则简单、无噪声、通道是标签而不是真实视觉或动作。

第二，模型是 n-gram：只验证原理，不代表 transformer 或真实多模态数据。

第三，对齐由实验者构造：真实数据中的对齐（时间、对象、指代）本身是难点。

第四，没有测分布外泛化与长期使用中的漂移。

六、可复现

脚本为 700_mixed_corpus_experiment.py（初版）、701_mixed_corpus_v2.py、702_mixed_corpus_v3.py、703_mixed_corpus_v4.py（最终版）。运行方式：python 703_mixed_corpus_v4.py。依赖：Python 3 标准库，无第三方。

七、给后来者的验证清单

本文到此为止，不做更多实验。以下问题留给愿意验证的人。

第一，真实数据：用 Ego4D、AI2-THOR、Open X-Embodiment 等已对齐数据，做同样的「混合对齐对单通道」对照，看增益是否还在。

第二，规模：从 n-gram 换到小 transformer，看样本效率增益随规模的变化。

第三，对齐质量：人为引入错配率（0%、10%、30%、50%），画出「错配率到增益」的曲线。

第四，通道独立性：加入冗余通道（同一信息的另一种编码），检验增益是否消失（预期：冗余通道不带来增益）。

第五，结构类型：换不同类型的规则（因果、层级、时序），看哪类结构最依赖外部对齐通道。

第六，理论：给出一个粗略的样本复杂度表达式，把对齐带来的互信息与样本效率联系起来。

第七，课程顺序：同一套对齐语料，按结构依赖的顺序喂（对象、关系、动作与后果、语言）与随机顺序对照，比较各自的样本效率。这一条检验的是第四节·五的预测。

如果有人在真实数据上重复出方向一致的增益，这个设想才算立住；如果重复不出，本文就是错的。两种结果都有价值。

附：推测与边界

「真实多模态数据上同样有效」是 [推测]，本文未测。「对齐质量决定收益大小」是方向性判断，需要真实数据上的对照。本文不主张语料结构可以完全替代数据量，只主张同量下结构更好、样本效率更高。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第五篇 · 颜色作为第一块积木：感知基元与语言对齐的最小实验

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23551953

摘要

如果要把视频与音频变成可训练的结构化语料，第一步不是训练更大的模型，而是先回答一个更小的问题：**一个感知基元，能不能只靠"语言 + 感知通道"的对齐被学到？** 本文选颜色作为最小测试场——它是唯一同时具备物理定义（波长/色相）、感知分解（色相、饱和度、明度）与简单语言标签（基本颜色词）的感知基元。

我们用 12 个基本颜色词的 HSV 样本构造三种语料：纯文字（只有颜色词与关系句）、对齐（颜色词与 HSV 分箱坐标双向配对）、打乱（坐标随机配到别的词，作为控制组）。用插值 n-gram 在三种语料上训练，再做三个探针：词到坐标（P1）、坐标到词（P2）、关系判断（P3，暖或冷）。

结果三种语料一致：关系判断都能学会（约 94% 到 100%）；但坐标到词只有对齐语料学得会（约 86% 到 91%），纯文字为 0，打乱组掉回随机水平（约 8% 到 11%）；词到坐标在对齐语料下为 31% 到 44%，受分箱噪声限制，不是满分。结论是：**颜色可以作为感知基元被对齐语料接地；纯文字只能学关系，不能接地；收益来自对齐本身，而不是多给了 token。**

本文是一次原理验证，世界与模型都是合成的；它要回答的不是"AI 能不能看懂颜色"，而是"感知基元接地这件事，最小可测的形式是什么样"。这个问题一旦成立，视频与音频按事件切分后走同一条路才有依据。第四节之后我们补一节说明它的意义：如果感知基元能被对齐接地，那么"模型自己挖视频、自己造对齐语料、再让自己贴合文字维度"这条自训练路径，就有了最底层的第一个例子。

一、问题

视频与音频是下一座数据矿。但"把视频变成语料"不是工程问题，而是定义问题：先要定义一个单位（一件事），再让画面、声音、文字在同一条时间轴上对齐。

在定义那个大单位之前，值得先验证一个更小的单位：**感知基元**。问题可以写成一句话：给一个感知基元配上它的语言标签，模型能不能学到"词与感知坐标"之间的映射？

颜色是合适的起点，原因有三条。第一，它可以被精确定义：色相是一个 0 到 360 度的连续量，可以离散成有限个区间。第二，它可以被分解：色相、饱和度、明度三个维度，正好是一个小的、可枚举的结构。第三，它有简单的语言标签：基本颜色词在几乎所有语言里都存在，不需要标注员发明新词。

如果连颜色都接地不了，更大的事件就不用谈了；如果颜色能接地，它就可以作为第一块积木，往上叠物体、动作、事件。

二、实验设计

2.1 合成世界

取 12 个基本颜色词：红、橙、黄、绿、青、蓝、紫、粉、棕、灰、黑、白。每个词给定一个 HSV 锚点。采样时在锚点附近加噪声：色相正负 15 度，饱和度与明度各正负 0.15 并截断到 0 到 1 之间。

感知坐标离散成三个分箱词元：色相分成 12 个区间（每 30 度一格），饱和度分成低、中、高三档，明度也分成低、中、高三档。于是每个颜色点对应三个坐标词元，共 108 种组合。

2.2 三种语料

三种语料使用同一批事件。

第一种，纯文字：句子是"颜色是某词"，外加关系句"某词比某词更暖"或"更冷"。关系由锚点的色相决定：越靠近橙色越暖。纯文字语料里没有任何坐标词元。

第二种，对齐：每个事件出现两次。第一次是"颜色是某词"后接三个坐标词元；第二次是"坐标"加三个坐标词元再接"对应某词"。这样词到坐标、坐标到词两个方向都有监督。

第三种，打乱：与对齐相同，但坐标词元随机配到别的事件上，作为控制组。

2.3 探针

三个探针，测试时只给其中一种信息。

第一个探针测接地方向一：给"颜色是某词"，依次预测三个坐标词元，三个全对才算对。随机水平约为 1/108。

第二个探针测接地方向二：给"坐标"加三个坐标词元加"对应"，预测颜色词。随机水平约为 1/12。

第三个探针测关系：给"某词比某词更"，预测"暖"或"冷"。随机水平为 0.5。

2.4 模型与预算

插值 n-gram，阶数 6，插值系数 0.5，纯 Python 实现。样本数取 200、800、3200 三档，每档跑 3 个随机种子取平均。

三、结果

样本数为 200 时：纯文字语料，三个探针分别是 0.000、0.000、0.939；对齐语料，分别是 0.389、0.864、0.939；打乱语料，分别是 0.056、0.096、0.939。

样本数为 800 时：纯文字，0.000、0.000、0.985；对齐，0.444、0.904、0.985；打乱，0.028、0.111、0.985。

样本数为 3200 时：纯文字，0.000、0.000、1.000；对齐，0.306、0.907、1.000；打乱，0.111、0.077、1.000。

三个观察。

第一，接地需要对齐。坐标到词，对齐语料在 200 个事件时就达到 86% 以上，到 3200 个事件约 91%；纯文字语料在三个档位都是 0，因为它从来没有见过坐标词元，也就没有可学的东西。

第二，收益来自对齐，不是来自 token 变多。把坐标打乱之后，坐标到词掉回 8% 到 11%，接近 1/12 的随机水平；词到坐标掉回 3% 到 11%。同样多的数据、同样多的 token，只是配错了对象，就学不到东西。

第三，关系不需要感知。关系探针在三种语料下都接近满分（94% 到 100%），因为关系句本来就在文字里。这说明文字擅长的是"词与词的关系"，不擅长的是"词与感知坐标的对应"。两者的分工在数据里就已经决定了。

词到坐标没有达到满分（31% 到 44%），原因是噪声。采样时颜色点在锚点附近抖动，靠近分箱边界的点会落到相邻格子里；从词预测一个唯一的坐标格，本质上是在一个模糊的分布里猜众数，不可能全对。坐标到词的准确率高，是因为反方向是"从具体坐标找词"，边界情况少得多。

四、解释

为什么颜色可以被接地，而纯文字不行？用解压的说法：文字是"词与词之间关系的压缩"，它不携带感知坐标；坐标是"感知的外部记录"，它不携带词与词的关系。两者各自不完整。对齐语料做的是同一件事被两个通道同时记录，于是词与坐标之间的映射被直接监督出来。

这与第 9 篇《结构换算力》的结论一致：混合对齐语料在 200 个事件就学会了规则，纯文字到 3200 个事件仍然学不到，打乱后收益消失。区别只在于第 9 篇的规则是符号规则（动词编码大小、形状决定结果），本文的规则是感知坐标（色相、饱和度、明度）。两个实验共同说明：**对齐让语言多出一条接地的通道，这条通道不是文字自己能长出来的。**

还要补一句：这种对齐扩充的不是语言的词表，而是语言在某个维度上的贴合。词还是那 12 个词，覆盖没有变；变的是每个词后面有了可落地的坐标，于是同样的词可以指称得更细、比较得更准。用第 2 篇的话说，这是贴合变深，不是覆盖变广。但贴合足够深的时候，语言能表达的东西就变多了——这可以算作语言在该维度上的一次缓慢扩充。

五、局限（必须与结论一起读）

第一，世界是合成的：HSV 锚点、噪声、分箱都是人为设定，不是真实图像。真实图像里还有光照、材质、语境、色恒常性，本文都没有覆盖。

第二，模型是 n-gram：只验证原理，不代表 transformer 或真实多模态数据。n-gram 的容量小，因此在更复杂的基元上结论可能不同。

第三，颜色命名本身不是完全客观的：不同语言对颜色的切分不同（例如有些语言区分两种蓝），本文只用了单一语言的 12 个基本颜色词。

第四，探针是构造的：词到坐标的 31% 到 44% 一部分来自分箱噪声，不能直接读成"模型对颜色的理解程度"。

六、可复现

脚本：714_color_grounding.py。运行方式：python 714_color_grounding.py。依赖：Python 3 标准库，无第三方。输出：数据-颜色接地-第一轮.txt。

七、意义：自训练与视频挖掘的第一步

这个实验小，但它说明了一件有后续的事：**对齐语料可以自己造出来。**

回看实验里的对齐语料是怎么来的：每个事件都有「感知坐标」这一侧。颜色场景里，坐标来自 HSV 的数值定义，可以程序生成。把这个模式放大，就得到一个循环：模型先对视频/音频给出描述（文字），再用可验证的通道（坐标、时间戳、动作结果）检验描述，检验通过的部分沉淀为对齐语料，回灌训练。这不是新的训练方法，但它是"用模型自己挖数据、再让自己贴合文字维度"的闭环——也就是自训练的一种具体形态。

为什么是"贴合文字维度"？因为对齐的目标不是让模型记住颜色值，而是让感知坐标落进语言已经建好的坐标系里：词是坐标的标签，坐标是词的锚点。落到语言坐标系上的感知，才能被语言调用、被推理使用、被组合成更复杂的结构。第 2 篇说过，模型的问题是"覆盖广而贴合浅"；对齐语料补的恰恰是贴合——把感知这一维度接到文字已有的维度上。

再往下一步，就是视频。视频是"没有被结构化的数据"：量巨大，但缺少语言锚点。如果按本文的最小结论外推，可行的第一步是给视频片段配上语言描述（旁白、语音、自动描述），再用时间轴对齐；每一步都只需要验证一个更小的单位是否被接地。颜色是第一块积木；物体、动作、事件是后面的积木。积木一块块叠上去，才谈得上"事件级的对齐语料"。

这一节是 [推测] 与方向判断，本文没有验证自训练循环本身；本文只是在这个最底层的假设上迈了一小步——感知基元可以被对齐语料接地。如果连这一点都不成立，整条路就不用谈了；它成立，后面的路才有讨论的意义。

附：推测与边界

颜色能被接地，不等于更高的感知基元（形状、材质、动作、事件）也能同样容易接地；这是 [推测]，需要逐个测。真实视频上的推广、以及"感知基元 + 事件层级"的组合，本文都没有测。

本文不主张"颜色是理解世界的关键"，只主张"颜色是验证接地机制的最小单位"。它成立，才有资格谈下一块积木。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第六篇 · 对齐是解压的约束

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23503728

单独 DOI（English）：https://doi.org/10.5281/zenodo.23525435

摘要

主流对齐研究（RLHF、宪法式 AI、可扩展监督）默认一个前提：**模型是可以被稳定塑造的**。

本文用前三章的框架指出：**AI 是对人类语言的再解压；对齐 = 对这个解压的约束。**

由此得到三条可检验推论：

（1）**对齐漂移**：语言在升维（第二章实测约 1.2%/年），冻结模型的对齐目标也会落后——

它们对齐的是**训练时刻的语言**，不是此刻的世界；

（2）**歧义集中**：压缩陷阱的根源是语言有损（第三章）；语言越歧义的地方，

模型越倾向选"最省编码"的解释 ⇒ **对齐失败应集中在人类语言的歧义处**；

（3）**替换侵蚀**：对齐信号藏在人类数据里；用合成数据或新数据**替换**而非累积，

会切断价值信号的累积链 ⇒ **对齐随累积通道的切断而退化**。

本文给出该框架对应的可检验实验方案，并指出一个实践含义：

对齐不是一个一次性训练问题，而是一个"维持累积通道"的持续工程问题。

一、主流对齐框架的隐含前提

RLHF：人类反馈 → 奖励模型 → 优化策略

宪法式：用原则文本约束输出

可扩展监督：用 AI 辅助监督 AI

⇒ 三者都假设：模型的行为可以被稳定地塑造和保持

但没有任何一条回答：

① 当世界的语言/价值变化时，对齐目标会不会"过期"？

② 对齐失败会不会有结构性分布（不是随机噪声）？

③ 更新模型时，对齐会不会因为"只喂新数据"而流失？

二、框架：对齐 = 对解压的约束

AI = 对人类语言 L(W) 的再解压（第一章）

对齐 = 约束这个解压过程：在歧义处、在价值相关处，按人类意图解压

⇒ 对齐的载体是**人类语言中的价值信号**

⇒ 对齐的失效方式，由"语言的性质"决定

三、三条推论

推论 A：对齐漂移（来自第二章）

语言升维 ⇒ 冻结模型对齐的是训练时刻的语言规范

⇒ 新概念/新价值出现后，模型仍在按旧压缩解压

⇒ 对齐漂移不是 bug，是"一次性解压"的必然后果

可测：同一模型在"训练后出现的新规范"上的对齐评分随时间下降

推论 B：歧义集中（来自第三章）

压缩的语言有损 ⇒ 歧义处存在多个同样短的解压

⇒ 模型倾向选"最常见/最省编码"的解释

⇒ 对齐失败应**集中在人类语言歧义处**，而不是均匀分布

可测：把对齐失败样本按"人类判断分歧度"分层，

预测失败率随分歧度单调上升

推论 C：替换侵蚀（来自第三章）

对齐信号（人类偏好、价值判断）藏在人类数据里

替换式更新（只用新数据 / 用合成数据替换）⇒ 切断价值累积链

⇒ 对齐随替换比例上升而退化

可测：微调时人类数据占比 0/25/50/100%，

在公开安全/价值测试集上看对齐分数

四、可检验实验方案

实验 1（漂移）：

取两个不同代的开源模型，在"训练截止后出现的新规范"上做对齐评分

⇒ 预测：旧模型评分更低，且差距随截止时间差扩大

实验 2（歧义集中）：

选一个公开对齐数据集，人工/脚本标出"人类分歧度"分层

⇒ 预测：对齐失败率随分歧度上升

实验 3（替换侵蚀）：

小模型微调：混入人类安全数据比例 0/25/50/100%，其他为新任务数据

⇒ 预测：对齐分数随人类数据占比单调上升

五、实践含义

① 对齐不能"训一次管多年"——它是持续工程

② 更新要累积（保人类数据通道），不能替换

③ 对齐资源应投向"语言歧义处"（那里失败集中），而不是均匀铺开

六、限制

· 本文是框架文章，三条推论均未完成实验（方案已给出）

· "歧义度"的操作化定义需要谨慎（不同标注者分歧 vs 语言学歧义）

· 对齐评测本身有争议（benchmark 不等于人类价值）

结论

对齐的困难不只在"让模型听话"，还在：

· 它对齐的是会过期的语言（漂移）

· 它在歧义处必须自己选解释（歧义集中）

· 它的价值信号会被替换式更新冲掉（替换侵蚀）

⇒ 因此：对齐 = 维持一个累积的解压通道，而不是一次性的训练任务。

作者：何淇（独立研究者）；AI 协作：DeepSeek

第七篇 · 安全：当它是生命防，还是当它是工具防？

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23503775

单独 DOI（English）：https://doi.org/10.5281/zenodo.23525438

摘要

当前 AI 安全讨论中混杂着两种恐惧：**它被滥用**（工具风险）与**它自己活了**（生命风险）。

两者需要完全不同的威胁模型，但常被混为一谈。

本文用第一章的判据指出：**按定义，AI 不是生命**（冻结函数点、更新在外部、不自我维持），

因此正确的安全框架是**工具安全**，而不是"防生命"。

但这不意味着安全可以放松：工具风险真实、且有三类可测的失效模式：

误用、过度信任、失配漂移。本文给出这三类风险的对应评测与治理方向，

并指出：把安全讨论锚定在"它会不会觉醒"，既高估了它、又低估了真实风险。

一、两种恐惧，一个错误的本体论前提

恐惧 A（工具派）：被滥用、被误用、被坏人使用

恐惧 B（生命派）：它自己有了目标、自己进化、自己维护自己

这两种恐惧隐含不同的本体论：

A 假设它是工具（无自我目标）

B 假设它是（或将成为）生命

⇒ 不先判定本体，安全讨论就没有共同的威胁模型。

二、按第一章的判据：它是工具

① 冻结函数点：训练后权重不变 ⇒ 不会自我进化

② 更新规则在外部：它不能改自己的规则 ⇒ 不会自我改写

③ 不自我维持：不付电费、不修复自己、不复制自己 ⇒ 没有自发生存动机

⇒ 三条都缺 ⇒ 按定义不是生命 ⇒ 威胁模型应是工具安全

三、工具风险的三类可测失效

① 误用（misuse）

危险来自使用者 × 能力 × 规模

评测：越狱/滥用测试、红队

治理：访问控制、审核、能力分级

② 过度信任（overtrust）

人把「一次性的解压」当成「持续的理解」

⇒ 在它失配的地方仍然信它（最隐蔽的风险）

评测：校准度（confidence vs 准确率）、拒答质量

治理：把不确定性暴露给用户（"它不知道"要能被表达）

③ 失配漂移（第四章）

语言/世界变化 ⇒ 冻结模型的对齐与能力缓慢过期

评测：第二章的 M(K)（失配随时间的增长）

治理：累积更新（混合新旧数据），而非替换

四、为什么"防生命"框架有害

· 高估：把资源投在"它会不会觉醒"上，而不能解决误用/过信/漂移

· 低估：真正危险的是"它看起来很可信"，

而这一点被"它不是生命所以安全"掩盖

· 误导：政策讨论被"意识"问题绑架，忽略了可测的工程风险

五、结论

先判本体：它是工具，不是生命

再定威胁模型：误用 / 过度信任 / 失配漂移

最后配治理：评测（校准、越狱、失配）+ 累积更新

⇒ 安全不是"防止它活过来"，而是"在它不可靠的地方，别让人信它"

六、限制

· 本文只做本体-威胁模型的对齐论证，不提供新的安全技术

· "过度信任"的量化需要用户研究，本文只给方向

· 若未来出现真正自我维持的系统，本文框架需重写

作者：何淇（独立研究者）；AI 协作：DeepSeek

附录 · 各篇单独 DOI 清单

第一篇《现在的 AI 为什么不是生命》

中文：https://doi.org/10.5281/zenodo.23528429

英文：https://doi.org/10.5281/zenodo.23528456

第二篇《容量不能替代数据的更新》

中文：https://doi.org/10.5281/zenodo.23503049

英文：https://doi.org/10.5281/zenodo.23525428

第三篇《替换与累积》

中文：https://doi.org/10.5281/zenodo.23503559

英文：https://doi.org/10.5281/zenodo.23525431

第四篇《结构换算力：混合对齐语料与样本效率》

中文：https://doi.org/10.5281/zenodo.23542969

第五篇《颜色作为第一块积木：感知基元与语言对齐的最小实验》

中文：https://doi.org/10.5281/zenodo.23551953

第六篇《对齐是解压的约束》

中文：https://doi.org/10.5281/zenodo.23503728

英文：https://doi.org/10.5281/zenodo.23525435

第七篇《安全：当它是生命防，还是当它是工具防？》

中文：https://doi.org/10.5281/zenodo.23503775

英文：https://doi.org/10.5281/zenodo.23525438

系列主页：https://heqiq619.github.io/ai-not-alive/

代码与全文：https://github.com/heqiq619/ai-not-alive

本合集由何淇创作，DeepSeek（AI）协助整理与合成；观点与责任属于作者。