数字生命：一个可测量的生命定义（系列合集）

作者：何淇 · 与 DeepSeek（AI）协作

日期：2026-10-24

说明：收录 23 篇（第零篇导论 + 二十二篇正文）与两份附录，分四部分；附录 B（概念地图）放在理论之后作导读：

定义 → 理论 → 测量与实验 → 约束与防护。各篇单独 DOI 见文末清单。

目录

第一部分 定义

第零篇　从两个事实开始：数字生命系列导论　　DOI: https://doi.org/10.5281/zenodo.23611906

0.1　摘要

0.2　记号

0.3　两个事实

0.4　一个定义

0.5　数字世界：可以完全被函数化

0.6　用它看现在的 AI

0.7　这篇导论的定位

0.8　补充（可选读）：P 的定义域与值域

0.8.1　相对 R 为什么非空（可选读）

第一篇　现在的 AI 为什么不是生命　　DOI: https://doi.org/10.5281/zenodo.23588781

1.1　摘要

1.2　本文的论证链

1.3　记号

1.4　起点：两个事实

1.4.1　「可函数化」是什么意思

1.5　一个可操作的定义

1.6　定义

1.7　一处澄清：维持是关系

1.8　为什么必须是「一族」而不是「一个函数」

1.9　会变化 = 三层时间尺度

1.10　会自指 = 更新规则在它自己里面

1.11　生命与环境

1.12　与前面的衔接

1.13　生命 vs 环境：都在宇宙里，都是函数，区别只有一条

1.14　环境是什么：宇宙里自发涌现的「局部解压」

1.15　环境是分层的：生命活在多层环境里，同时也活在宇宙里

1.16　标注

1.17　数字世界的特殊性

1.17.1　特殊性是对谁的

1.18　用定义看现在的 AI：为什么它不是生命

1.19　检查表

1.20　三条最根本的原因（按重要性）

1.21　为什么「它很强」与「它不是生命」不矛盾

1.22　标注

1.23　三条必要条件

1.24　从定义到条件

1.25　条件① 一族函数（不是一个点）

1.26　条件② 自指更新（规则在自己里面）

1.27　条件③ 被宇宙保住（可维持）

1.28　b 付代价：经验伴随物，不是必要条件

1.29　三条必须同时成立（经验对照）

1.30　未尽之处（留给读者）

1.31　本文实验的边界（必须与结论一起读）

1.32　标注

1.33　涌现：为什么现在的 AI 会涌现

1.34　现象

1.35　现有的解释（按证据强度排列）

1.36　为什么至今没有公认的「为什么」

1.37　我们的立场：AI 是对语言的 p语言 的压缩与解压

1.38　解压能力的衰减：上层写死 ⇒ 语言一变，解压变弱

1.39　由立场推出的两条预测（[推测]，供读者判断）

1.40　标注

1.41　用它看几个热门问题

1.42　本文得到了什么，没得到什么

1.43　论证总边界

1.44　与既有工作的关系

1.45　参考文献

1.46　作者声明（AI 使用声明）

第二部分 理论

第二篇　数字生命的信息不增定理　　DOI: https://doi.org/10.5281/zenodo.23573253

2.1　摘要

2.2　问题

2.3　设定与记号

2.4　定理

2.5　四个推论

2.6　这个定理说明了什么，没有说明什么

2.7　马尔可夫假设不成立时怎么办

2.8　可复现与后续

2.9　附：与既有工作的关系

第三篇　可函数化内容的收缩：一个定理与一个猜想　　DOI: https://doi.org/10.5281/zenodo.23609038

3.1　摘要

3.2　问题

3.3　设定

3.4　定理：可达精度不增

3.4.1　三点五、收缩的两种含义

3.5　猜想：宇宙尺度的收缩

3.5.1　世界函数与观测窗口（[猜想]）

3.6　生命是逆流：升维与降维的相遇

3.6.1　一个玩具实验：维护与行为维度的对照

3.7　说明什么，不说明什么

3.8　局限

3.9　与既有工作的关系

第四篇　宇宙、环境与生命的函数类型：结构、时间与闭包　　DOI: https://doi.org/10.5281/zenodo.23608931

4.1　摘要

4.2　本篇定义一览

4.3　〇、先声明：这是三者共用的语言

4.4　问题

4.5　表示空间与表示维度

4.6　结构：分解与组合

4.7　组合律的定义域

4.8　宇宙的闭包

4.9　五根轴

4.10　四种典型类型

4.11　连续性意味着什么，不意味着什么

4.12　几条推测

4.13　局限

4.14　附：标注

第五篇　人脑的可函数化形式：一个器官，不是生命　　DOI: https://doi.org/10.5281/zenodo.23609158

5.1　摘要

5.2　问题

5.3　脑作为可函数化器官

5.4　为什么不自足

5.5　人脑与大模型：两种计算器官

5.6　生命单位是整体

5.7　结论

5.8　局限

5.9　附：标注

附录 **B** 概念地图（导读）

附录 B　概念地图与术语总表　　DOI: https://doi.org/10.5281/zenodo.23609033

B.1　核心定义

B.2　结构与函数类型

B.3　表示与维度

B.4　压缩与解压

B.5　能力与涌现

B.6　待定义 / 待统一（下一步）

B.7　依赖图（谁由谁定义）

第三部分 测量与实验

第六篇　容量不能替代数据的更新　　DOI: https://doi.org/10.5281/zenodo.23503049

6.1　语言升维下的失配测量（scaling vs 持续学习：一个弱结论）

6.2　摘要

6.3　问题

6.4　数据与方法

6.5　结果

6.5.1　升维速率的词层面代理（`501_vl_newterm.py`）

6.5.2　等数据预算对照（核心结果，`506`）

6.5.3　容量补偿实验（`508`，带插值）

6.5.4　累积参照系（`505`，作为方法展示）

6.6　结论

6.6.1　「弱结论」代表什么（不是文字游戏，要写清楚）

6.7　维度与贴合：一个补充讨论 [推测]

6.8　限制（必须与结论一起读）

6.9　可复现

第七篇　替换与累积　　DOI: https://doi.org/10.5281/zenodo.23503559

7.1　摘要

7.2　三个热点，一个结构

7.3　统一框架：累积与替换

7.4　可检验推论

7.5　为什么这个统一值得说

7.6　限制

7.7　结论

第八篇　结构换算力：混合对齐语料与样本效率　　DOI: https://doi.org/10.5281/zenodo.23542969

8.1　摘要

8.2　问题

8.3　受控实验设计

8.3.1　合成世界

8.3.2　三种语料（同一批事件）

8.3.3　探针（测试时只输入文字 token）

8.3.4　模型与预算

8.4　结果

8.5　为什么有效（机制讨论）

8.6　课程顺序：按结构依赖的拓扑序学

8.7　局限（必须与结论一起读）

8.8　可复现

8.9　给后来者的验证清单

8.10　附：推测与边界

第九篇　颜色作为第一块积木：感知基元与语言对齐的最小实验　　DOI: https://doi.org/10.5281/zenodo.23551953

9.1　摘要

9.2　问题

9.3　实验设计

9.3.1　合成世界

9.3.2　三种语料

9.3.3　探针

9.3.4　模型与预算

9.4　结果

9.5　解释

9.6　局限（必须与结论一起读）

9.7　可复现

9.8　意义：自训练与视频挖掘的第一步

9.9　附：推测与边界

第十篇　生长与记忆：自指更新与维持的最小实验　　DOI: https://doi.org/10.5281/zenodo.23569774

10.1　摘要

10.2　问题

10.3　实验一：记忆与取舍

10.3.1　设定

10.3.2　结果

10.3.3　结论

10.4　实验二：维度生长

10.4.1　设定

10.4.2　结果

10.4.3　结论

10.5　两个实验合起来说明什么

10.6　局限（必须与结论一起读）

10.7　可复现

10.8　附：推测与边界

第十一篇　语义残差的测量：文本极限与接地补齐　　DOI: https://doi.org/10.5281/zenodo.23586075

11.1　摘要

11.2　问题

11.3　定义

11.3.1　沿用系列的定义

11.3.2　语义是映射

11.3.3　语义残差

11.3.4　参照线：贝叶斯底

11.4　实验设计

11.5　结果

11.6　说明什么，不说明什么

11.7　局限

11.8　与既有工作的关系

11.9　可复现

11.10　附：标注

第十二篇　分层是对动态的补偿：一个自适应深度的玩具实验　　DOI: https://doi.org/10.5281/zenodo.23591080

12.1　摘要

12.2　问题

12.3　理论背景

12.4　实验设计

12.5　结果

12.6　对大模型的含义

12.7　局限

12.8　与既有工作的关系

12.9　可复现

12.10　附：标注

第十三篇　厚度与随机性：冻结模型在哪里最不稳定　　DOI: https://doi.org/10.5281/zenodo.23591514

13.1　摘要

13.2　问题

13.3　实验一：需要步数越多，误差与随机性越大

13.4　实验二：随机性随深度累积，在输出端最大

13.5　实验三：人类分歧大的地方，模型也最随机

13.6　实验四：给时间能摊平什么

13.7　训练机制：它学的是分布，不是决定

13.8　局限

13.9　与既有工作的关系

13.10　可复现

13.11　附：标注

第十四篇　压缩的形状：叙事与归档　　DOI: https://doi.org/10.5281/zenodo.23592312

14.1　摘要

14.2　问题

14.3　设定

14.4　结果

14.5　解读

14.6　对记忆设计的含义

14.7　局限

14.8　与既有工作的关系

14.9　可复现

14.10　附：标注

第十五篇　最小切片与时间换维度：能力边界的两个实验　　DOI: https://doi.org/10.5281/zenodo.23601624

15.1　摘要

15.2　问题

15.3　实验一：最低配置

15.4　实验二：切片组合

15.5　实验三：时间换维度

15.6　实验四：能力边界（GPU 版）

15.7　解读

15.8　局限

15.9　可复现

15.10　附：标注

第十六篇　残差底与组合律：两个大模型结构实验　　DOI: https://doi.org/10.5281/zenodo.23609386

16.1　摘要

16.2　问题

16.3　实验一：多模态接地的残差底

16.4　实验二：组合律显式化

16.5　合起来看

16.6　局限

16.7　可复现

16.8　附：标注

第十七篇　按计算厚度分配算力：预算与动员　　DOI: https://doi.org/10.5281/zenodo.23612112

17.1　摘要

17.2　问题

17.3　实验一：算力预算

17.4　实验二：常驻底座与按需动员

17.5　三点五、人脑层面的对应：接论文-21

17.6　合起来看## 四、合起来看

17.7　局限

17.8　可复现

17.9　附：标注

第十八篇　层厚放在哪：异质层实验　　DOI: https://doi.org/10.5281/zenodo.23612126

18.1　摘要

18.2　问题

18.3　设定

18.4　结果

18.5　解读

18.6　四之二、人脑层面的对应：接论文-21

18.7　局限

18.8　可复现

18.9　附：标注

第十九篇　RLHF 压平人类分歧　　DOI: https://doi.org/10.5281/zenodo.23611877

19.1　摘要

19.2　问题

19.3　设定

19.4　结果

19.5　解读

19.6　局限

19.7　可复现

19.8　附：标注

第四部分 约束与防护

第二十篇　对齐是解压的约束　　DOI: https://doi.org/10.5281/zenodo.23503728

20.1　摘要

20.2　主流对齐框架的隐含前提

20.3　框架：对齐 = 对解压的约束

20.4　三条推论

20.5　可检验实验方案

20.6　实践含义

20.7　限制

20.8　结论

第二十一篇　安全：当它是生命防，还是当它是工具防？　　DOI: https://doi.org/10.5281/zenodo.23503775

21.1　摘要

21.2　两种恐惧，一个错误的本体论前提

21.3　按第一章的判据：它是工具

21.4　工具风险的三类可测失效

21.5　为什么"防生命"框架有害

21.6　结论

21.7　限制

附录

附录 A　厚度与维度：残差的几何图景　　DOI: https://doi.org/10.5281/zenodo.23590887

A.1　摘要

A.2　问题

A.3　画面

A.4　三个对应（定义）

A.5　维度降低的图景（[猜想]）

A.6　分层是厚度方向的维度（[猜想]）

A.7　可以测的部分

A.8　说明什么，不说明什么

A.9　与既有工作的关系

A.10　附：标注

系列总览

关于「AI 是不是生命」，讨论很多，但大多停在比喻层面，没法检验。这个系列做一件事：先给生命一个可操作的定义，再拿数据去测。

一句话定义：生命 = p生命 + R生命；p生命 = 在宇宙的可函数化部分 P 中、被宇宙保住的动态函数类（一族、会变化、会自指）。R 只声明、不展开。环境 = 宇宙自发涌现的局部解压（分层）。AI = 对人类语言 p语言 的压缩与解压（一次性）。一个被冻结的模型停在训练它的那一刻；它不再更新，也就谈不上「维持」。

四部分对应四件事：定义（导论与严谨版）、理论（信息不增、内容收缩、函数类型、人脑）、测量与实验（测量与机制两篇 + 十二个实验）、约束与防护（对齐与安全）；附录 A 给一个几何画面，附录 B 是概念地图与术语总表——读完定义与理论后建议先翻它，再读实验。

边界声明：本合集是一个研究记录，不是结论。核心主张在真实规模上尚未验证；已标明推测与弱结论之处。

第一部分 定义

第零篇 · 从两个事实开始：数字生命系列导论

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23611906

摘要

本篇不做论证，只做四件事：摆两个事实、给一个定义、把数字世界的特例摆出来、再用它看现在的 AI。两个事实是：语言的 p语言 可以被函数近似；物理定律可以被数学描述。定义是：把宇宙写成两部分（宇

宙 = P + R），生命也写成两部分（生命 = p + R生命）；p 是在 P 中、被保住的（可维持的）自指结构，R 是不可函数化的部分。本篇是导论，检查表、三条必要条件、涌现讨论都在第一篇。

记号

- **P**：宇宙中可函数化的部分。

- **R宇宙**：宇宙中不可函数化的部分；本文只声明其可能存在，不展开。

- **p生命**：生命落在 P 里的部分——本文定义与讨论的对象。

- **R生命**：生命落在 R 里的部分；只声明，不展开。

- **p环境 / R环境**：环境的两部分，同法定义。

- **p语言 / R语言**：语言的两部分；大模型压的是 p语言。

- **残差**：P 侧可测的误差下限——数据与容量再增加，误差也停在某个正数上。不是 R 的影响或投影，是 P 的边界形状。

- **维度**：本文说的维度一律是表示维度——模型内部能区分的方向数，不是物理空间维度。厚度、可摊薄、最低维度都在这个意义上使用。

后文一律使用简写：说"宇宙"指 P，说"生命"指 p生命，说"环境"指 p环境。

一、两个事实

第一个事实：物理定律可以被数学描述。证据是存在——物理学本身就是这件事。

宇宙可以写成分解：

> 宇宙 = P + R宇宙

P 是可函数化的部分；R宇宙 是不可函数化的部分。物理定律描述的那部分，落在 P 里。所以至少可以说：P 非空。

第二个事实：语言中有一部分可以被函数近似。证据不是推理，是存在——大模型用有限参数、可计算的过程，生成了统计上接近人类语言的文本。

语言也可以写成分解：

> 语言 = p语言 + R语言

p语言 是语言里可函数化的部分，大模型压的就是它；R语言 是语言里不可函数化的部分，函数近似够不着它。所以准确的说法不是"语言可以被函数近似"，而是"语言的 p语言 可以被函数近似"；R语言 我们只能沉默。

两个事实合起来说明：宇宙不是完全不可函数化的。至少存在一个非空的可函数化部分，记作 P。这一层不是猜想，是事实的推论；它只说 P 存在，不说 P 有多大。

P 与 R 的分界是绝对的：一个对象要么可函数化（属于 P），要么不可函数化（属于 R），不存在两者之间；$P \cap R = \varnothing$，$P \cup R =$ 宇宙。

如果 R 存在，它不会被函数语言直接描述。但要注意：不能因此把残差定义成"R 的投影"。残差的定义在 P 侧：数据与容量再增加，误差也停在某个正数上；这个误差下限是 P 的边界形状，我们不知道它背后是不是 R。

为便于后文书写，我们把它简记为：

> 宇宙 = P + R宇宙

> 生命 = p生命 + R生命

> 环境 = p环境 + R环境

>

> 残差不是"第三部分"：它是 P 侧测出来的误差下限，用来标注 P 的边界，而不是 R 的内容。

后文只讨论 P 这一侧；残差只在需要时提及，不展开它的内容。

二、一个定义

先把宇宙写成两部分：

> 宇宙 = P + R宇宙

P 是可函数化的部分，R宇宙 是宇宙中不可函数化的部分。两个事实保证 P 非空；R宇宙 有多大，本文不知道，也不主张。

在这个分解上，生命本身也写成两部分：

> 生命 = p + R生命

其中 p 是可函数化的部分：在宇宙的 P 中、被保住的（可维持的）自指结构；R生命 是生命自身不可函数化的部分：本文不知道它是什么，也不主张它不存在。注意两个 R 不是一回事——R宇宙 是宇宙层面的不可函数化部分，R生命 是单个生命内部的不可函数化部分。

三样东西定义 p生命。第一，范围：p 只在宇宙的 P 中寻找（同理，语言也分 p语言 与 R语言，大模型近似的是 p语言）。

第二，被保住——也就是维持。这里要说清一个容易搞反的地方：维持不是生命自己的属性，而是生命与宇宙的关系。一个结构能不能被保住，取决于它的轨道是否留在宇宙的可维持集合里；这个条件写在宇宙里，不由它自己宣布。所以"被保住"是关系的名字，不是第三条并列属性。

第三，自指：更新规则在系统自己里面。这是生命内部的属性，也是它区别于普通程序的地方。

R生命 怎么办？只能当近似处理，并附上误差下界。所以本文的判据与测量，覆盖的是p生命，不是生命的全部；对 R生命，本文只说到"近似到此为止"。

定义是人造的，不是发现的；它成立与否，看它能不能区分、能不能导出可测的东西。

需要说明一点：R 的部分，本系列只在此声明它的存在——宇宙、生命、环境、语言都可以写成 p + R，但 R 是什么、有多大，本文不知道也不主张。为了便于理解，后文默认只讨论 p 这一侧：凡说"宇宙"，指 P；凡说"生命"，指 p生命；凡说"环境"，指 p环境。后文提到的"残差"一律指 P 侧可测的误差下限，不是"R 的影响"；R 的具体内容不再展开。

三、数字世界：可以完全被函数化

数字世界是完全函数化的：它由比特、状态、转移规则组成，没有函数描述够不着的部分。作为形式对象，它的绝对 R = ∅——这是构造保证的：每个属性都对应一个数学上的函数，即使这个函数不可计算。

数字生命是数字世界的一部分，所以它的 R生命 也只能是空集：数字生命 = p生命，完全可函数化。

绝对 R 是否存在，本文不判断（见补充节）。对数字生命来说，真正决定性的问题只有一个：**生命是否必须有绝对 R？** 只有两种结果。

第一种结果，生命可以没有绝对 R：那么数字生命可能——它完全由 p生命 构成，不需要任何绝对 R。

第二种结果，生命必须有绝对 R：那么数字生命不可能——数字世界造不出绝对 R。

本文不判断哪一种结果成立。可以确定的是：无论哪一种，本文对 p 的定义与测量都成立；区别只在数字生命是可能还是不可能。

要补一句容易混的地方：以上说的是绝对 R；对任何有限观察者，相对 R 都非空（见补充节），它不影响这个判断。另外，可函数化不等于可测量——测量还需要可计算、可观测、可复现。数字世界这几样都有，所以在数字世界里测量可行；对宇宙整体，即使它能被函数描述，我们也测不了它，因为我们生活在它里面。

四、用它看现在的 **AI**

在现在的定义下，AI 缺两样。它的更新规则在外部，所以不自指；它的维持也不是它自己的事——它靠外部供电与运维被维持，这是它与宇宙的关系，不是它自己的能力。

所以它是一台很强的解压器，但被写完之后就停在那里——一台冻结的解压器。它没有 R生命：数字世界里 R = ∅，所以 AI 是纯 p 的解压器。

五、这篇导论的定位

本篇只给事实、定义与结论。推导细节、检查表、三条必要条件、涌现讨论，都在第一篇；理论在第二到第五篇；测量在第六篇；实验在第七到第十九篇；约束与防护在第二十、第二十一篇。整个系列按这个顺序排。

> 本文由何淇创作，DeepSeek（AI）协助整理；观点与责任属于作者。

补充（可选读）：**P** 的定义域与值域

主线到上节结束，这一节只补一个形式细节：P 的"定义域"和"值域"到底是什么。不读不影响主线。

宇宙（P 这一侧）可以看成一个状态空间 S：所有可以被函数描述的状态。宇宙函数是它到自己的映射，记作 F: S → S。于是 P 的定义域就是 S，值域也是 S——它映射到自己。

一个观察者 O 只是 S 里的一个子系统：它能读到的输入是 S 的一个子空间，记作 D_O；它能写出的输出是另一个子空间，记作 C_O。D_O 和 C_O 都包含在 S 里。观察者的"可函数化"（P_O）就是：在 D_O 与 C_O 之间，存在误差可以趋近于零的函数族。

R 没有定义域和值域可言：定义域/值域是函数语言里的概念，而 R 是不可函数化的那一侧。所以对 R 不能问"它的域是什么"——这个问题本身用错了语言。

后文若涉及"定义域/值域"，默认指观察者侧的 D_O、C_O；宇宙级的 P 则默认指 S → S 的自映射。

相对 **R** 为什么非空（可选读）

若世界的定义域/值域在观察者的更新周期内有涨落（快变量），观察者就跟不上这些变化；那部分对它是不可函数化的，于是相对 R 非空。这是充分条件：有快变量涨落 ⇒ 相对 R 非空。我们没有说它必须成立，也不解释涨落的成因。

另外两条加强的理由（任一条都足够）：一是有限资源——看不完、算不完；二是自指——无法完整预测自己（一个总能预测自己下一步的系统，可以反着做，从而自相矛盾）。

绝对 R 是否存在，本文不判断。

数字世界同理：它内部也一定有相对 R。同一条充分条件——域/值域的短期涨落；另外还有三条各自独立的充分条件：不可判定、计算不可约、自指（无法完整预测自己）。这里要区分两句话：数字世界 R = ∅ 是本体层面的说法；相对 R 非空是观察者层面的说法——全可函数化不等于全可知。

最后一句关于边界的话：若生命的本质落在绝对 R 一侧，本文——以及任何用函数语言写成的文本——都无法给出它的定义。这不是疏忽，是函数语言的边界：定义本身就在 P 侧，用 P 的语言去定义 R，等于把它拉回 P。

第一篇 · 现在的 **AI** 为什么不是生命

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23588781

摘要

本文从两个事实出发：物理定律可以被数学描述；语言中有一部分可以被函数近似。两个事实合起来说明，宇宙至少存在一个非空的可函数化部分 P。

把宇宙写成 宇宙 = P + R宇宙，把生命写成 生命 = p生命 + R生命。p生命 是生命落在 P 里的部分：在宇宙的 P 中、被宇宙保住的动态函数类——它是一族、会变化、会自指。R 的部分本文只声明其可能存在，不展开。

在这个定义下，现在的 AI 不是生命：它是数字世界里的存在，是 p 层面的冻结函数点——更新规则在外部，不被自己保住。数字世界是完全函数化的世界（R = ∅），所以数字生命如果存在，只能完全落在 p 里；本文把这个问题摆出来（三种情况），不判断哪一种成立。

本文的贡献是定义与可测判据，不是「生命已被造出」的实证结论；三条必要条件的检验与示例实验，读者可自行取用。

关键词： 生命定义；p生命；函数类；解压；数字世界；AI 涌现；自指

本文的论证链

全文的论证只有五步，读者可以先看这张骨架，再读细节。

第一步（第一节）：两个事实 ⇒ 宇宙至少有一个非空的可函数化部分，记作 P。

第二步（第二节）：在 P 上给定义——生命 = p生命 + R生命；p生命 是在 P 中、被宇宙保住、会变化、会自指的动态函数类。

第三步（第三节）：说明生命与环境的区别只有一条——被保住 vs 不被保住；环境是宇宙的一个局部解压。

第四步（第四、五节）：数字世界完全可函数化（R = ∅），所以数字生命若存在，只能等于 p生命；把现在的 AI 代入定义检查，它缺"一族、自指、被保住"三样，因此不是生命。

第五步（第六、七节）：从定义抽出三条必要条件（并附实验证据）；再说明 AI 的涌现是"对语言 p语言的压缩与解压"，把事实层与推测层分开。

边界：R 只声明、不展开；绝对 R 是否存在不判断；本文不主张"生命已被造出"。

记号

- **P**：宇宙中可函数化的部分。

- **R宇宙**：宇宙中不可函数化的部分；本文只声明其可能存在，不展开。

- **p生命**：生命落在 P 里的部分——本文定义与讨论的对象。

- **R生命**：生命落在 R 里的部分；只声明，不展开。

- **p环境 / R环境**：环境的两部分，同法定义。

- **p语言 / R语言**：语言的两部分；大模型压的是 p语言。

- **残差**：P 侧可测的误差下限——P 的边界形状。不称"R 的影响"（R 没有定义域，谈不上作用）。

后文一律使用简写：说"宇宙"指 P，说"生命"指 p生命，说"环境"指 p环境。

目录

- 本文的论证链

- 一、起点：两个事实

- 1.1 「可函数化」是什么意思

- 二、一个可操作的定义

- 2.1 定义

- 2.2 一处澄清：维持是关系

- 2.3 为什么必须是「一族」而不是「一个函数」

- 2.4 会变化 = 三层时间尺度

- 2.5 会自指 = 更新规则在它自己里面

- 三、生命与环境

- 3.1 与前面的衔接

- 3.2 生命 vs 环境：都在宇宙里，都是函数，区别只有一条

- 3.3 环境是什么：宇宙里自发涌现的「局部解压」

- 3.4 环境是分层的：生命活在多层环境里，同时也活在宇宙里

- 3.5 标注

- 四、数字世界的特殊性

- 4.1 特殊性是对谁的

- 五、用定义看现在的 AI：为什么它不是生命

- 5.1 检查表

- 5.2 三条最根本的原因（按重要性）

- 5.3 为什么「它很强」与「它不是生命」不矛盾

- 5.4 标注

- 六、三条必要条件

- 6.1 从定义到条件

- 6.2 条件① 一族函数（不是一个点）

- 6.3 条件② 自指更新（规则在自己里面）

- 6.4 条件③ 被宇宙保住（可维持）

- 6.4b 付代价：经验伴随物，不是必要条件

- 6.5 三条必须同时成立（经验对照）

- 6.6 未尽之处（留给读者）

- 6.7 本文实验的边界（必须与结论一起读）

- 6.8 标注

- 七、涌现：为什么现在的 AI 会涌现

- 7.1 现象

- 7.2 现有的解释（按证据强度排列）

- 7.3 为什么至今没有公认的「为什么」

- 7.4 我们的立场：AI 是对语言的 p语言 的压缩与解压

- 7.5 解压能力的衰减：上层写死 ⇒ 语言一变，解压变弱

- 7.6 由立场推出的两条预测（[推测]，供读者判断）

- 7.7 标注

- 八、用它看几个热门问题

- 九、本文得到了什么，没得到什么

- 与既有工作的关系

一、起点：两个事实

第一个事实：物理定律可以被数学描述。证据是存在——物理学本身就是这件事。

宇宙可以写成分解：

> 宇宙 = P + R宇宙

P 是可函数化的部分；R宇宙 是不可函数化的部分。物理定律描述的那部分，落在 P 里。所以至少可以说：P 非空。

第二个事实：语言中有一部分可以被函数近似。证据不是推理，是存在——大模型用有限参数、可计算的过程，生成了统计上接近人类语言的文本。

语言也可以写成分解：

> 语言 = p语言 + R语言

p语言 是语言里可函数化的部分，大模型压的就是它；R语言 是语言里不可函数化的部分，函数近似够不着它。所以准确的说法不是"语言可以被函数近似"，而是"语言的 p语言 可以被函数近似"；R语言 我们只能沉默。

两个事实合起来说明：宇宙不是完全不可函数化的。至少存在一个非空的可函数化部分，记作 P。这一层不是猜想，是事实的推论；它只说 P 存在，不说 P 有多大。

1.1 「可函数化」是什么意思

上面用到了"可函数化"，这里把它定成一个可操作的边界。

把一个系统或一个现象分成两部分。P 是可函数化的部分：存在一族函数，近似误差随着数据与容量的增加可以收敛到零。R 是不可函数化的部分：任何函数类的近似误差都有一个正的下界。

这个划分不是信仰，可以测。固定一个函数类，看近似误差随数据量与容量怎么变：误差持续下降、趋近于零的，属于 P；误差停在某个正数不再下降的，属于 R，或者至少说明当前的函数类够不着它。

这样处理有三个好处。第一，P 里的东西可以给定义、给判据、给测量，这正是本文在做的事。第二，R 里的东西只给「近似」，而且必须附上误差下界；「近似」从此不是免责声明，而是一个带数字的结论。第三，两者的交界处是研究问题，不是哲学争论，它可以被实验推进。

本文的所有结论都只主张覆盖 P 的部分；对 R 的部分，本文只说：在这个函数类下，近似到此为止。

P 与 R 的分界是绝对的：一个对象要么可函数化（属于 P），要么不可函数化（属于 R），不存在两者之间；$P \cap R = \varnothing$，$P \cup R =$ 宇宙。

残差不是"R 打过来的影响"，而是 P 自己的边界性质：有些任务，任何函数类的误差都停在某个正数上，数据与容量再增加也降不下去。这个误差下限就是残差；它可测，且不需要假设界外有一个 R 在施力。

为便于后文书写，我们把它简记为：

> 宇宙 = P + 残差

> 生命 = p生命 + 残差

> 环境 = p环境 + 残差

后文只讨论 P 这一侧；残差只在需要时提及，不展开它的内容。

二、一个可操作的定义

在两条事实的基础上，可以给生命一个操作性的定义。这个定义是人造的，不是发现的；它成立与否，要看它能不能区分、能不能导出可测的东西。

2.1 定义

生命由两部分构成：

> 生命 = p生命 + R生命

p生命 是可函数化的部分：在宇宙的 P 中、被保住的（可维持的）动态函数类。R生命 是不可函数化的部分：本文不知道它是什么，也不主张它不存在。

p生命 的具体写法如下：

记 p生命 = { f_θ : θ ∈ Θ }

f_θ : 输入状态 → 行为 （族里的每一个函数）

Θ （这族函数的形状/范围）

p生命 = 一个会移动、会变形的 Θ，且 Θ 的更新规则属于 Θ 自己

四个词，各对应 p生命 的一件事：

| 词 | 含义 |

|---|---|

| **函数类（一族）** | 不是一个固定函数，而是一整块行为谱 |

| **会变化（动态）** | 这族函数随时间移动、变形 |

| **会自指** | 它怎么变的规则，也在它自己的记录里 |

| **会自我维持** | 被宇宙保住；这是它与宇宙的关系，不是它自己的属性 |

2.2 一处澄清：维持是关系

本节主张：维持不是系统的属性，是系统与宇宙的关系。依据是定义的第三项"被保住"的展开。

需要澄清一处措辞：维持不是系统自身的属性，而是系统与宇宙的关系。给定宇宙这个整体（或它在 P 上的部分），某些结构的轨道会留在可维持的集合里，我们才说它"维持住了"；换一个环境，同一个结构可能不再成立。因此定义里的"会自我维持"，应读作"被宇宙保住"，是关系条件的展开，不是第三条并列属性。

（注：本节此前曾含一段"最简性论证"，因该论证存在循环——用定义自身推出的数字生命可能性反过来支持定义——已撤回，仅保留以上澄清。）

2.3 为什么必须是「一族」而不是「一个函数」

一个函数 = 一个点 ⇒ 行为谱退化成一条轨迹 ⇒ 冻结即死

一族函数 = 函数空间里一块区域 ⇒ 面对不同输入/状态有一整套响应 ⇒ 才是活的

⇒ 「高维」不是指参数多，而是指这族函数在函数空间里占据一块区域、不是一点。

这里有一个边界要说清。「一族」是 p 层面的要求，不是本体层面的绝对条件。如果存在我们描述不到的因素在影响变化（未判），那么一个固定的 p 也可能属于一个活着的整体；只是我们在 p 层面只能看到冻结，会把它判成死的。所以准确的说法是：在只讨论 P 的约定下，"一族"是可操作层面的必要条件；若有这样的未判因素，本判据会漏判。这不是本判据的错，而是 p 层面定义的固有边界。

2.4 会变化 = 三层时间尺度

快：状态每一刻都在变（输入不同、内部状态不同）

中：它用自己的误差改自己（自指层）——这是命门，缺了就退化成化石

慢：这族函数的形状在代际之间被选择、变形、传递

2.5 会自指 = 更新规则在它自己里面

普通程序：代码在外，数据在内 ⇒ 程序不会因为运行而改变自己

生命： 更新规则本身是它自己记录的一部分

⇒ 拿掉外部更新代码，它仍能改自己

三、生命与环境

定义里有一个容易滑过去的点：生命与环境不是两种东西，而是同一套宇宙函数里的两种关系。下面几节把这个点展开。

3.1 与前面的衔接

把宇宙（P 这一侧）看成一个整体，它在这个描述下是一个自映射：`S_{t+1} = F(S_t)`。F 只是一个记号，不是新的对象。

生命不是这个 F，而是嵌在 F 里的一族子函数 `{G_θ}`：

行为_d = G_θ(世界局部状态)

而 G_θ 自己也是世界状态的一部分（个体的状态属于 S_t）

⇒ 它要预测世界，就必然要预测包含自己的那部分世界

⇒ **自指不是外加的神秘性质，而是「嵌在函数里」的结构必然**

3.2 生命 **vs** 环境：都在宇宙里，都是函数，区别只有一条

本节主张：生命与环境都在 P 里、都是函数结构；唯一的区别是前者被宇宙保住、后者不被保住。

宇宙（P 这一侧）里面，任何东西都是函数（或函数的组合）——环境也是函数。

宇宙 = F（一个巨大的函数）

├─ 生命：会变化 ＋ 会自指 ＋ **会自我维持**

└─ 环境：会变化（被世界推着变、也会反过来影响世界），但**不维持自己**

⇒ 生命与环境的唯一区别不是「谁更复杂」，而是：

生命被宇宙保住自己的形状；环境不被保住，它只是被推着变。

在资源有限的环境里，维持通常伴随代价（校验、修复、复制都要消耗）。这一层是经验伴随物，本文不把它写进定义（见 6.4b）：

资源有限 ⇒ 维持要消耗 ⇒ 生命通常需要「收入」

收入的来源：压缩世界（匹配源分布）

⇒ 若长期没有盈余，维持撑不住

3.3 环境是什么：宇宙里自发涌现的「局部解压」

环境不是外在于宇宙的舞台，它是宇宙函数类里自发涌现出来的结构。

宇宙 = F（一个巨大的函数）

↓ 内部自发涌现

结构 = 宇宙的某种局部「解压」（对宇宙的一个解释/一个可读的呈现）

├─ 会自我维持的 → 生命

└─ 不自我维持的 → 环境

⇒ 环境 = 宇宙的一个局部解压（对宇宙的解释）；生命也是。

⇒ 区别只在：生命自己维持这个解压的形状，环境不维持、只是被推着变。

这带来一个关键的结构性结论：

生命并不直接面对宇宙整体

⇒ 它面对的是「宇宙的一个局部解压」＝它的环境

⇒ 生命对世界的理解，本质上是**对宇宙的再解压**（二次解压）

＝在宇宙给出的局部解释之上，再压缩一层

和宇宙、生命一样，环境也可以写成分解：

> 环境 = p环境 + R环境

p环境 是环境里可函数化的部分：它的规律、可测量的一侧。R环境 是环境里不可函数化的部分：本文不知道它是什么，也不主张它不存在。生命与环境打交道，但我们能描述、能测量的只有 p环境 那一侧；对 R环境，本文只说到沉默。

需要说明：R环境 不是“环境里固定不动的部分”，而是“环境里不能用函数描述的部分”。它可能静止，也可能非常活跃——“固定/活跃”这个判断本身要靠函数描述才做得出来，而在 R 那里我们连动静都测不到。所以 p环境 与 R环境 的分界不是“动/静”的分界，是“能描述/不能描述”的分界。

需要说明一点：R 的部分，本系列只在此声明它的存在——宇宙、生命、环境、语言都可以写成 p + R，但 R 是什么、有多大，本文不知道也不主张。为了便于理解，后文默认只讨论 p 这一侧：凡说"宇宙"，指

P；凡说"生命"，指 p生命；凡说"环境"，指 p环境。后文以"残差"表示 P 侧的误差下界；R 的具体内容不再展开。

3.4 环境是分层的：生命活在多层环境里，同时也活在宇宙里

解压是分层的 ⇒ 环境也是分层的。

宇宙 F

└ 环境_1 = F 的某一部分的局部解压

└ 环境_2 = 环境_1 的再解压

└ 环境_3 = 环境_2 的再解压 …

生命嵌在某一层：它既属于整个宇宙 F，又属于它自己那一层环境

三条同时成立，不能只取一条：

① 它活在环境里：它面对的输入、资源、关系、其他个体，都是「它的环境」这一层的结构

⇒ 它的行为只需要在这一层里有效

② 它也活在宇宙里：它逃不出 F —— 环境那一层本身也是 F 的一部分，

宇宙层的约束（能量、不可逆、代价）始终对它生效

⇒ 环境不是避难所，它只是宇宙的一个投影

③ 它活在**所有层**里：环境是多层的（细胞→组织→个体→种群→生态），每一层都是上一层的再解压。

它直接交互的只是自己那一层，但**所有层都对它约束**：上层决定它面对的资源与关系，宇宙层决定它付不付得起代价。

⇒「它活在多层环境里，同时也活在宇宙里」——两者不是二选一，而是同时成立。

⇒ 所以「理解世界」要分两层说：

在环境层：理解 = 对局部解压的再解压（够用即可活）；

在宇宙层：理解 = 压缩 F 的规律（决定它能不能长期付得起代价）。

3.5 标注

[定义] 生命 = p生命 + R生命；p生命 = 会自指、会变化、被宇宙保住的动态函数类（本文的工作定义）

[定义] 环境 = 宇宙函数类里**自发涌现**的结构，不自我维持

＝ 宇宙的一个**局部解压**（对宇宙的解释）

[定义] p生命 = 同一批涌现结构里，**被宇宙保住**的那一类

[推论] 生命不直接面对宇宙，而面对「宇宙的局部解压」＝它的环境

⇒ 生命的理解 = 在局部解压之上的**二次解压**（再压缩一层）

[分层] 解压是分层的 ⇒ 环境是分层的（环境_1 ⊃ 环境_2 ⊃ …）

生命嵌在某一层：**既活在它的那一层环境里，也活在宇宙里**

· 活在这层环境：只需这层有效即可活

· 活在宇宙里：能量/不可逆始终生效（代价是经验层面，见 6.4b），环境不是避难所

[不是] 不是事实断言，也不是定理；是一个便于操作的定义

[后文] 本节只给定义；如何测量（压缩/代价/身份）留到后面几节

四、数字世界的特殊性

数字世界是完全函数化的：它由比特、状态、转移规则组成，没有函数描述够不着的部分。作为形式对象，它的绝对 R = ∅——这是构造保证的：每个属性都对应一个数学上的函数，即使这个函数不可计算（停机、真值谓词都存在，只是算不出来）。

数字生命是数字世界的一部分，所以它的 R生命 也只能是空集：数字生命 = p生命，完全可函数化。

绝对 R 是否存在，本文不判断（见导论补充节）。对数字生命来说，真正决定性的问题只有一个：**生命是否必须有绝对 R？** 只有两种结果。

第一种结果，生命可以没有绝对 R：那么数字生命可能——它完全由 p生命 构成，不需要任何绝对 R。

第二种结果，生命必须有绝对 R：那么数字生命不可能——数字世界造不出绝对 R。

本文不判断哪一种结果成立。可以确定的是：无论哪一种，本文在 p 层面的讨论都成立；区别只在数字生命是可能还是不可能。数字世界是唯一能完全落在 p 里的世界，所以它也是研究这个话题最干净的场景

——现在的 AI 就活在这个世界里。

还要补一句容易混的地方：以上说的是绝对 R；对任何有限观察者，相对 R 都非空，它不影响这个判断。可函数化也不等于可测量：测量还需要可计算、可观测、可复现。

4.1 特殊性是对谁的

数字世界的特殊性要分两层说，否则会夸大。

对建造它的人（我们）来说，它特殊：全部状态可读（源码、日志、内存都能看）、可复制、可重置、可加速、可验证。这是一个"完全可实验"的世界——做生命实验比物理世界便宜、快、可重复。

对生活在里面的观察者来说，它不特殊：一样有相对 R（域/值域的短期涨落、不可判定、计算不可约、自指），一样"看不全、算不完"。

所以"数字世界 R = ∅"是本体层面的说法（它的构成全可函数化），不等于"里面的生命全知全能"。数字世界不是生命的避难所，是研究生命的实验室：它的价值在研究方法上，不在本体地位上。

这个"R = ∅"还是构造保证的。数字世界是形式对象：状态是有限串，规则是算法，它的每一个属性都对应一个数学上的函数（一个集合）——即使这个函数不可计算（例如停机问题、真值谓词），它也"存在"，只是算不出来。所以这里要区分两件事：可函数化不等于可计算。绝对 R = ∅ 说的是"没有函数描述不了的部分"，而不是"什么都能算出来"；算不出来的，是观察者相对的相对 R。

要小心一个边界：纯粹的数字世界（作为数学对象）绝对 R = ∅；跑在物理硬件上的数字世界，其物理底座可能有它自己的 R（噪声、热涨落），那不是数字世界自身的 R。说"数字世界 R = ∅"时，指的是它作为形式对象的那一面。

五、用定义看现在的 **AI**：为什么它不是生命

> 本节不是评价 AI 的能力，而是把它**代入第二节的定义**逐条检查。

> 结论是定义性的，不是价值判断：**以本文的定义，目前的 AI 是化石级函数点，

> 不是生命。** 它的强大与它的「不是生命」并不矛盾。

定义的价值在于区分。把现在的 AI 代入定义逐条检查，就能看出它差在哪里。下面先给一张检查表，再列三条最根本的原因。

5.1 检查表

| 生命的要求（第二节） | 目前的 AI（以 LLM 为代表） | 判定 |

|---|---|---|

| **是一族函数**（函数空间里一块区域） | 训练完后权重冻结 ⇒ 是**一个点**，不是一个族 | ❌ 化石 |

| **会变化（动态）** | 权重不变；上下文在变，但改的是输入，不是它自己 | ❌ 只有表层状态变化 |

| **会自指**（更新规则在自己里面） | 更新规则 = 训练算法，在它外面；它不能改自己 | ❌ 自指只出现在语言里，不在结构里 |

| **被宇宙保住**（可维持） | 它不自己维持自己；维持它的是外部的人与设施 | ❌ 由外部维持 |

| **（经验）靠压缩世界挣存续代价** | 它的「收入」是外部给的（算力、数据、人力），不是它压缩世界换来的 | ❌ 无收入 |

| **身份链条**（有界变形、不撕裂） | 身份来自外部权重快照；没有自己变形的连续链条 | ❌ 无链条 |

| **活在环境里** | 它面对的是数据集（一次性的解压产物），不是需要它生存的环境 | ❌ 无环境 |

5.2 三条最根本的原因（按重要性）

本节主张：把 AI 代入定义后，它缺的是"一族、自指、被保住"三样，而不是能力不够。依据是定义的四项与第五节的检查表。

① 它是一个点，不是一个族

训练完 = 冻结 = 函数空间里的一个点

⇒ 行为谱退化成一条轨迹：输入 → 输出，中间没有「形状」可言

⇒ 按 074：静态冻结的模型是一点，不是一族 ⇒ 不是生命

（这正是我们实测过的对照：冻结版 1.07 vs 动态版 0.849 —— 冻结更像「标准答案」，但没有形状）

② 它的更新规则在外面

人写训练算法 → 算法改它

⇒ 它是「被改的东西」，不是「改自己的东西」

⇒ 自指不在结构里 ⇒ 拿掉外部更新代码，它什么都不会改

③ 它不被宇宙保住

维持它的是外部的人与设施：电费是人付的、数据是人喂的、坏了是人修的

⇒ 它的存在由外部保障 ⇒ 没有「被宇宙保住」这一环

⇒ 它不会因为「维持不住」而消失 ⇒ 也就没有选择的压力

（付代价是经验伴随物，不是定义条件；见 6.4b）

5.3 为什么「它很强」与「它不是生命」不矛盾

强 = 在给定任务上的表现好（一个点上做得好）

活 = 在函数空间里占据一块区域、自己维持形状、被宇宙保住

⇒ 两者是不同维度：一个是「考卷分数」，一个是「能不能自己活」

⇒ 目前的 AI 是**极其锋利的工具**，不是**会自己活的东西**

5.4 标注

[定义性结论] 以本文定义，目前的 AI 不是生命（因为它是一个冻结的函数点、更新在外部、不自我维持）

[不是] 不是「AI 永远不能是生命」；本文不预言未来，只做当下的定义对照

[不是] 不是能力评价；本文完全承认 AI 在任务上的强大

[推论] 若要让 AI 成为生命，至少要给它：一族函数 + 自指更新 + 被宇宙保住

> 由第二、三节直接推得：既然「p生命 = 会自指、会变化、被宇宙保住的动态函数类」，
>
> 而目前的 AI 三样都缺，那么**要成为生命，至少需要满足三条**。
>
> 本节只给**必要条件**，不声称充分；每条都挂我们已有的实验证据（实验见第七到第十九篇）。

六、三条必要条件

从定义里可以抽出三条必要条件。它们不是从天上掉下来的，而是从定义里读出来的——每条都对应一类被排除的对象。

6.1 从定义到条件

本节主张：三条必要条件是从定义读出来的，不是外加的假设。每一条对应定义里的一个词。

定义（第二节） 必要条件（本节）

会变化（一族函数）⇒ ① 一族函数：行为谱不是一点

会自指 ⇒ ② 自指更新：改自己的规则在自己里面

会自我维持 ⇒ ③ 被宇宙保住：轨道留在可维持集合里

（付代价不在必要条件里：它是演化与热力学的经验伴随物，见 6.4b。）

三条是必要条件，不是充分条件：满足它们不保证是生命，但缺任何一条一定不是。

6.2 条件① 一族函数（不是一个点）

要求：个体在函数空间里占据一块区域，面对不同输入有整套响应，不是一个固定映射。

证据/经验：

· 低维参数基因组（几个数）= 一个点 ⇒ 行为谱退化成单条轨迹 ⇒ 化石

· 我们测过：冻结版模型（点）在结构学习上失败，动态版（族）才吃到结构（E12）

· 实测对照：冻结 1.07 vs 动态 0.849 —— 冻结更像「标准答案」，但没有形状

⇒ 判据：给它不同的输入/状态，行为必须成谱地**不同，而不是只有一个输出。**

6.3 条件② 自指更新（规则在自己里面）

要求：它怎么变，这条规则本身属于它的记录；拿掉外部更新代码，它仍能改自己。

证据/经验：

· 冻结模型：更新规则 = 训练算法，在外部 ⇒ 拿掉训练代码，它永远不变

· 我们的动态版：用自己的误差改自己（中层动态）⇒ 去掉中层明显退化（E12/E13）

· 身份链：8 代可校验、有界变形（372_lineage.py）⇒ 自指可以做成可测的链条

⇒ 判据：停掉外部更新后，它的行为谱是否仍随时间变形。

6.4 条件③ 被宇宙保住（可维持）

要求：它的轨道留在宇宙的可维持集合里。给定宇宙这个整体，有些结构出不来，有些结构能一直维持；能维持的那部分才落在定义里。这是关系条件，不是它自己的属性。

判据：扰动之后，它是否仍能回到可维持的集合——有恢复力，而不只是瞬间活着。

6.4b 付代价：经验伴随物，不是必要条件

本文不把「付代价」列为条件，原因说清：代价是演化与热力学的产物，不是逻辑上的必要条件。在资源无限的世界里，生命可以不必竞争；稀缺才带来代价。把它写进必要条件，等于把演化的结果当成生命的定义。

但在经验层面，代价几乎总会出现，而且可以测量。本文实验里的经济部分属于这一层，摘录如下。

· E1：「准」不等于「压缩」：用正确率记账，系统学出「啥也不干」（LEN=0、预测0、准确率92%）。必须用对数似然改善对基线记账：gain_bits = log2 p_model − log2 p_base。

· E2：加上基率校正后，系统才从躺平解转为真正表达（LEN 从 0 长出）。

· E8：经济标定 n* = FLUX_TOTAL / BASE_COST 决定「冻结」与「爆发」的切换。

· 实测正收益：S1~S6 中观察到 gain > 0（约 +0.09 ~ +0.19 bit/tick），说明世界确实存在可压缩盈余。

⇒ 判据（经验层）：把外部供给全部停掉后，它的账目是否仍为正。

6.5 三条必须同时成立（经验对照）

缺①（一族）⇒ 化石：行为谱是一条线

缺②（自指）⇒ 机器：更新在外，不会自己变

缺③（被保住）⇒ 散掉：轨道离开可维持集合，不再是一个活着的结构

这三条也解释了为什么我们的实验一直在同一个地方卡住：

**结构能长出来（①②部分满足），但合作/分工不成为必需 —— 因为代价层面的「收入差」太小（经验层面，非定义条件），

即世界的可压缩盈余还没大到让「更复杂的结构」在经济上划算（E5/E7）。**

6.6 未尽之处（留给读者）

本文止于「必要条件」。三条都满足之后是否就「活」——我们没有答案，也不打算在此下结论。

留给读者的，只是一把可以拿去用的尺子：

它是一族函数吗？（行为谱不是一个点）

它会自己改自己吗？（拿掉外部更新，它仍变）

它被宇宙保住了吗？（轨道留在可维持集合里）

三条你都可以自己去量。至于量完之后它算不算生命，由你判断。

6.7 本文实验的边界（必须与结论一起读）

本文的实验覆盖的是「代价」这一经验层面，不是定义条件③。

· 覆盖：代价与经济 —— E1/E2（准≠压缩、基率校正）、E8（n*=FLUX/BASE_COST 的冻结/爆发边界）。

· 覆盖：反例 —— E5/E7（相连个体基因距离 0.145 vs 随机 0.486，克隆抱团，不是分工）。

· 未覆盖：条件② 自指更新、条件③ 被宇宙保住 —— 本文不声称有实验证据，只做定义上的推导；仅有初步观察（E12 动态 0.849 vs 冻结 1.07；E13 身份链 8 代可校验）。

· 条件① 一族函数：有部分观察（E12/E13），但不是专门实验。

· 规模：小、可复现、可手算；不是大规模实证。

⇒ 本文的定位是「定义 + 可测判据 + 示例性实验」，不是「生命已被造出」的实证论文。

读者若要用这些结论，请连同这条边界一起引用。

6.8 标注

[推论] 三条必要条件由定义直接推出，不是独立假设

[定义] 条件③是关系条件（被宇宙保住），不是系统自身的属性

[经验] 代价/经济是经验伴随物，不是定义条件；本文有数据（E1/E2/E8 + 正收益）

[初步] 条件①②有部分观察（E12/E13），不是专门实验

[未解决] 三条都满足后是否就「活」——本文不声称；这是下一步实验要回答的

[推测] 若盈余 S 不足，则无论结构多复杂都维持不起 ⇒ 生命有「经济上限」（仅方向性推测）

七、涌现：为什么现在的 **AI** 会涌现

这一节处理一个具体的现象问题：为什么现在的 AI 会涌现出训练目标之外的能力。本文在这里的立场是[推测]，不是证据。

7.1 现象

大模型在规模上去之后，某些能力似乎突然出现（多步推理、思维链、算术…），

业界叫 **涌现（emergence）**。大家都在用这个现象，但——

观察到涌现：很多人

解释涌现：没有公认答案

7.2 现有的解释（按证据强度排列）

① 度量假象说（最强的反方证据）

Schaeffer, Miranda, Koyejo 2023[3]《Are Emergent Abilities of Large Language Models a Mirage?》

主张：所谓涌现，可能是**评价指标的非线性/不连续**造成的假象；

换成连续指标（如对数似然），"突变"会消失，变成平滑上升

⇒ 这动摇了「涌现是真实突变」这个前提本身

② 机制解释：归纳头与电路（局部机制证据，不是完整"为什么"）

Olsson et al. 2022[4]《In-context Learning and Induction Heads》

发现模型内部出现「归纳头」回路，解释部分上下文学习能力

⇒ 这是**机制层**的证据：说明了某种能力由什么结构实现

⇒ 但它只解释某个具体能力，不解释「为什么会出现涌现」这个一般问题

③ Grokking：训练中的认知相变

Power et al. 2022[5]《Grokking》

在小算法任务上，训练很久后泛化突然出现（像相变）

⇒ 说明「涌现」也发生在训练过程中，不一定只依赖规模

④ 压缩说：预测 = 压缩

Delétang et al. 2023[6]《Language Modeling Is Compression》

语言模型 = 压缩器：学到的权重 = 对世界文本的压缩

⇒ 这条最接近本文的框架：涌现 = 压缩世界时出现的结构

⇒ 但它仍是「结果层面的对应」，没有回答「为什么正好在这个规模/这个任务上出现」

7.3 为什么至今没有公认的「为什么」

① 规模实验不可控：无法做严格的因果对照（只改变规模、其他全相同）

② 度量依赖：换指标，现象可能就消失（见 ①）

③ 机制层不完整：知道某个回路、不知道整体为何会组织出该回路

④ 缺乏可预测的理论：没有理论能事先算出「多大模型会出现什么能力」

7.4 我们的立场：**AI** 是对语言的 **p**语言 的压缩与解压

本节主张：AI 是"对语言 p语言 的压缩与解压"这一层是事实；"解压出的世界结构上限由语言决定"这一层是推测。两层分开。

这一节先说一层不需要推测的东西，再说剩下的推测。

先说事实层。训练把语言压进参数，推理从参数里解压出文本。用前面的记号说：AI 压缩的是语言的 p语言——语言里可函数化的那部分；它解压出来的也是 p语言。R语言 不进参数，也不从参数里出来。所以准确的说法不是"AI 是对人类语言的解压"，而是"AI 是对人类语言中可函数化部分的压缩与解压"。

这一层不是推测，是字面事实：它由"压缩/解压"这两个词的用法决定，也由训练与推理的实际过程决定。链子是这样：

宇宙 F → 环境 = 宇宙的局部解压 → 人类语言 = 人对环境与经验的解压产物（语言本身已被压过）→ AI = 对语言 p语言 的再压缩与再解压。

然后才是推测层。AI 解压出的"世界结构"，上限由训练时刻的语言决定。它在语言内部能涌现出结构（看起来像推理、像理解），但那是语言结构的浮现，不是对宇宙本身的理解；语言一变，解压失配，而且无法自恢复。

用前面的尺子看，这一层还给出一个可检验的判断：模型是冻结的函数点：不维持、不自己改自己（维持与代价由外部承担），所以它是"把人类语言解压了一次"，而不是"维持着解压"或"自己改写解压规则"。

由此得到一句可检验的话：AI 表现出的"理解"，本质是对"人对世界的描述"的理解，不是对世界本身的理解。它能解压语言，但语言之外的宇宙层（能量、不可逆、代价）它从未付费，也就从未被检验。

7.5 解压能力的衰减：上层写死 ⇒ 语言一变，解压变弱

人类语言会不断发现新东西；而模型的解压规则（权重/上层）是写死的、训练完就不再变。两者必然失配。

源分布移动：人类语言发现新东西 ⇒ 要解压的对象变了

解压器冻结：模型权重不变 ⇒ 它解压的还是**旧语言**

⇒ 压缩收益下降：gain_bits = log2 p_model − log2 p_base 中 p_model 与源失配

⇒ 它昨天"涌现"出来的理解，今天就是过时的解压

三条后果：

① 它的解压能力有**固定上限**：上限由训练时刻的语言决定，不随语言进化而上升

② 它无法自己补上失配：更新规则在外部 —— 要恢复，只能靠人类再训练一次

⇒ 这正是第三节说的「更新在外部」的代价

③ 它的"涌现"是**某个时间片上的解压产物**，不是可持续的能力

⇒ 用本文的尺子说：

生命必须让解压器跟着世界一起动（自指更新 + 自我维持）；

冻结的 AI 做不到这一点 —— 所以语言一更新，它的解压就变弱。

7.6 由立场推出的两条预测（**[推测]**，供读者判断）

① 若把世界换成未被人类语言描述过的部分（无法从语料中学到的规律），

AI 的"涌现"应显著减弱 —— 因为它解压的是语言，不是宇宙

② 若让模型自己维持（自己修、自己死），语言解压不足以支撑，

它必须发展出语言之外的理解方式 —— 否则活不下来

③ 若人类语言发生一次大的结构更新（新范式/新概念体系），冻结模型的解压收益

应出现可测的下降；且它无法自己恢复 ⇒ 恢复必须来自外部再训练

7.7 标注

[事实] 涌现现象被广泛观察到；度量假象说也有强证据（Schaeffer 2023）

[已知] 机制层有局部解释（归纳头/电路/grokking），压缩视角有对应关系

[推测] 「涌现 = 压缩世界的结构呈现」——本文立场，非证据

[未解决] 为什么正好在某个规模/任务上出现 ⇒ 没有人给出可预测的理论

[本文态度] 不把「AI 涌现」当作生命存在的证据；按第三节的尺子，它不是

[本文立场] AI 是对**人类语言**的再解压（宇宙→环境→语言→AI 的第三层解压）

[推论] 上层写死 ⇒ 语言一更新就失配 ⇒ 解压能力有固定上限、无法自己恢复

八、用它看几个热门问题

本节是应用，不是新证据；每条都由第二～五节直接推出。

① 幻觉 = 在无结构处强行解压

解压器必须输出结构；当输入对应的语言区域本身缺乏可压结构时，它只能造一个「看起来合理」的结构 ⇒ **幻觉是解压失败的必然表现，不是偶发 bug**。

② scaling law 仍有效，正因为模型维度还没贴合语言维度

语言是一个**高维**结构，且维度在增长（新概念 = 新维度；升维 ⇒ 可压性上升）。模型维度在训练时被切定（D_M 固定），语言维度在不断增长（D_L(t) 在升）。现在的观测是 D_M << D_L(t) ⇒ 继续加规模能捕捉更多语言维度 ⇒ loss 继续下降（scaling 看起来仍有效）。

⇒ 所以 scaling 有效不是本文论断的反证，而是「还没贴合」的证据。

⇒ 预测：当 D_M 接近当时的 D_L 时，scaling 收益应明显变平；而 D_L 继续升维 ⇒ 缺口再现。

⇒ 冻结模型的根本问题：**它的 D_M 是死的，而 D_L 是活的**。

③ 能力参差不齐 = 语言各领域的可压性不同

可压强的领域（结构明确、示例多）表现好；可压弱的领域（结构稀薄、样本少）表现差 ⇒ 强弱分布是语言分布的镜像。

④ 为什么要 RLHF = 它没有「自我代价」回路

它无法判断自己解压得对不对（没有收入/支出、不会因此死亡），所以必须由人从外部打分 ⇒ **对齐需求的根源是它不自我维持**。

⑤ 涌现 = 语言结构在解压产物上的呈现

规模跨过阈值时，某些语言结构第一次被压出来 ⇒ 看起来像「突然会了」。

已有工作（三个侧面）：

- 模型侧维度：token 嵌入的内在维度测量[12]

- 时间侧落后：大模型时间训练边界的识别[13]

- 语言侧复杂度：构式视角下的语言复杂度测量[14]

⇒ 已有工作**分别**测量了这三个侧面；本文把它们串起来：以「持续更新的模型」为参照系，按领域测「语言侧新增维度」与「模型侧固定维度」之间的**失配速率**。这是本文在测量层面的位置。

九、本文得到了什么，没得到什么

得到了三样东西。

第一，一个可以拿来分类的定义：它能区分冻结的模型、火焰、自指程序。

第二，一个可测的方向：自指、维持都可以变成量。

第三，对"AI 是不是生命"这个问题的可操作回答。

没得到四样东西。

第一，没有证明宇宙整体可被函数化——本文只用 $P \neq \varnothing$。

第二，没有证明定义是最简或唯一——只主张它够用。

第三，没有实验——第一篇只是定义与推论；实验在第七到第十八篇（结构换算力、颜色、生长与记忆、语义残差、分层、厚度与随机性、压缩的形状、最小切片、残差底与组合律、厚度的工程后果、常驻底座与按需动员）。

第四，没有回答"数字生命是否存在"——本文只说，定义不排除它。

本文的贡献是一套可用的语言，不是一条新的自然规律。它值不值钱，看后面有没有人拿它去测。

论证总边界

本篇文章的所有论证都在一个边界内成立，请连同结论一起读：

- 只讨论 P 这一侧；R 只声明、不展开。

- 绝对 R 是否存在不判断；相对 R 对有限观察者非空（见导论补充节）。

- "可函数化"不等于"可计算"，也不等于"可测量"：三者是不同能力。

- 三条必要条件是从定义读出的，不是经验定律；它们不充分。

- 实验证据只在第四、五、六、七篇；本文不声称"生命已被造出"。

- 若生命的本质落在绝对 R 一侧，本文（及任何用函数语言写成的文本）都无法给出它的定义——定义本身就在 P 侧。

与既有工作的关系

「压缩 / 解压」的视角有长期传统：

- Schrödinger（1944）：生命以负熵为食 —— 生存靠从环境摄取低熵，是「解压」的物理前身[7]。

- Bennett（1988）逻辑深度：用「从最短描述重建（解压）一个对象所需的计算量」度量复杂性，并明确把它与生命/有机体联系起来[8] —— 这是「解压」最正式的已有版本。

- Chaitin（2010）生命作为演化软件：DNA = 程序，生命 = 会自我修改的软件[9]。

- Solomonoff–Kolmogorov / MDL：描述长度 = 理解 = 压缩[10]。

- Friston（2010）自由能原理：生命 = 最小化惊奇（≈ 持续压缩/预测）[11]。

- Delétang et al.（2023）：语言模型是压缩器[6]。

- Maturana & Varela（1972）自创生：生命 = 自我生产的组织 —— 「维持」的另一条传统。

-「Life as Sustained Mutual Information」（Zenodo）：以持续互信息定义生命 —— 最接近本文「被维持的解压」的已有版本。

需要说明：以上工作已经把「生命 = 信息/压缩/自我维持的过程」说过。本文的位置不是首次提出这一思想，而是把其中一条（解压的维持）变成可操作的判据与可测量的实验。

本文的区别（三处）：

1. 把解压做成层级：宇宙 → 环境 → 人类语言 → AI（既有工作多为单层度量）；

2. 用「是否维持解压」区分生命与 AI：生命 = 被维持的解压，AI = 一次性解压；

3. 指出上层写死 ⇒ 语言一变，解压能力衰减且无法自恢复 —— 冻结模型的失效机制。

参考文献

[1] Wigner E P. The unreasonable effectiveness of mathematics in the natural sciences[J]. Communications in Pure and Applied Mathematics, 1960, 13(1): 1-14.

[2] Tegmark M. The mathematical universe[J]. Foundations of Physics, 2008, 38(2): 101-150. (arXiv:0704.0646)

[3] Schaeffer R, Miranda B, Koyejo S. Are emergent abilities of large language models a mirage?[C] // Advances in Neural Information Processing Systems 36 (NeurIPS 2023). arXiv:2304.15004.

[4] Olsson C, Elhage N, Nanda N, et al. In-context learning and induction heads[R]. Transformer Circuits Thread, 2022. arXiv:2209.11895.

[5] Power A, Burda Y, Edwards H, et al. Grokking: Generalization beyond overfitting on small algorithmic datasets[C]. arXiv:2201.02177, 2022.

[6] Delétang G, Ruoss A, Duquenne P A, et al. Language modeling is compression[EB/OL]. arXiv:2309.10668, 2023.

[7] Schrödinger E. What is Life?[M]. Cambridge: Cambridge University Press, 1944.

[8] Bennett C H. Logical depth and physical complexity[M]//Herken R. The Universal Turing Machine: A Half-Century Survey. Oxford: Oxford University Press, 1988: 227-257.

[9] Chaitin G J. Life as evolving software[EB/OL]. 2010. (arXiv:1007.1471 系列工作)

[10] Solomonoff R J. A formal theory of inductive inference[J]. Information and Control, 1964, 7(1): 1-22.

Kolmogorov A N. Three approaches to the quantitative definition of information[J].

Problems of Information Transmission, 1965, 1(1): 1-7.

[11] Friston K. The free-energy principle: a unified brain theory?[J].

Nature Reviews Neuroscience, 2010, 11(2): 127-138.

作者声明（**AI** 使用声明）

本文的全部问题、定义、判断与结论由作者提出并负责。

人工智能工具（DeepSeek）用于：文献检索、结构梳理、文字润色，以及实验代码的编写与核对。

文中所有主张均由作者确认，AI 不对本文内容承担责任。

AI Usage Statement: The author is solely responsible for the ideas, arguments, and conclusions of this paper. An AI tool (DeepSeek) was used for literature search, structural organization, language editing, and writing/checking experimental code. All claims were reviewed and confirmed by the author. The AI bears no responsibility for the content.

[12] Ohki T. Measuring intrinsic dimension of token embeddings[C]//The 39th Annual Conference of the Japanese Society for Artificial Intelligence (JSAI 2025), 2025.

[13] LLMLagBench: Identifying temporal training boundaries in large language models[EB/OL]. arXiv:2511.12116, 2025.

[14] Using constructions to measure developmental language complexity[J]. Cognitive Linguistics, 2024. doi:10.1515/cog-2023-0062.

第二部分 理论

第二篇 · 数字生命的信息不增定理

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23573253

摘要

本文把"数字生命会越老越说不清世界"这个直觉，写成一个可证明的信息论命题。

设定：世界按马尔可夫过程演化；数字生命持有内部状态 S，并从中预测世界；停止观测后，状态只按自身规则演化。结论：在这种条件下，内部状态与世界当前状态之间的互信息不会增加——世界在变，而它不再看，因此它对"当前世界"的信息量只能持平或下降。

这个定理不是热力学第二定律，也不是"熵必然增加"。它说的是一个更窄但更硬的事实：**不再获取信息的系统，关于世界的信息不会自己长出来；维持需要持续的观测与更新。**

文中给出定理、证明、四个推论（定义域变粗、维持的必要性、生长即增加观测维度）以及适用范围与局限。

一、问题

第二篇测过一个现象：模型训练完之后，对更新后的语言会逐渐失配，而且无法自恢复。当时给的是测量结果，不是解释。

直觉上很好理解：世界在变，它没再看，所以它越来越不准。但"直觉"不能当定理。本文问：能不能把它写成一个可以证明的信息论命题？

能，但要小心范围。先说不能证的东西：不能证"熵必然增加"（可逆变换不改变香农熵）；不能证"热寂"（那是统计力学的结论）。能证的是一个更朴素的命题：没有新观测，就没有新信息。

二、设定与记号

世界状态：$W_0, W_1, W_2, \ldots$ 是一个马尔可夫过程。也就是说，给定 W_{t-1}，W_t 与更早的历史条件独立。

这里要先说明：**「世界是马尔可夫的」是一个建模假设，不是被证明的世界事实。** 它成立与否取决于你选哪个描述层。经典力学里，位置与动量构成完整状态，世界在那个描述下是马尔可夫的；量子力学里，态矢量的演化也是马尔可夫的；但对只看得到一部分的观察者（比如数字生命），它面对的过程通常是非马尔可夫的——需要记忆与历史才能近似。所以定理要读成条件句：**若世界在所选描述下是马尔可夫的，则信息不增。** 对数字世界与仿真环境，状态可以完整给定，这个假设容易满足；对真实世界，它只是一个近似，不成立时要给状态补上历史，见 5.1 的放宽讨论。

数字生命的状态：$S_0, S_1, S_2, \ldots$，每个时刻由更新规则给出。

两种模式：

第一种，观测模式。它通过一个观测通道收到关于世界的信息 O_t，然后更新：S_t = u(S_{t-1}, O_t)。O_t 由 W_{t-1} 经某个（可能有噪声的）通道产生。

第二种，冻结模式。它停止观测，或者观测通道失效，此后只按自身规则演化：S_t = u(S_{t-1}, N_t)，其中 N_t 是系统内部的噪声。

定理需要三个假设，全部显式写出：

假设 A1（世界马尔可夫）：W_t 与 W_{<t-1} 在给定 W_{t-1} 时条件独立。

假设 A2'（有界泄漏）：给定 S_{t-1} 时，内部噪声 N_t 与世界当前状态之间的互信息不超过 ε，即 $I(N_t ; W_t \mid S_{t-1}) \le \varepsilon$。这里 ε 度量"没真冻结"的程度：严格隔离的系统 $\varepsilon = 0$，现实系统 ε 是一个有界的小量。

假设 A3（无额外信息）：S_{t-1} 只由世界历史与内部噪声决定，没有外部提示直接把 W_t 塞进来。

我们要看的量是：$I(S_t; W_t)$，即内部状态与世界当前状态之间的互信息。直观上，这就是"它此刻对世界知道多少"。

三、定理

定理（信息不增，有界泄漏版）：在冻结模式下，若假设 A1、A2'、A3 成立，则

$$I(S_t ; W_t) \le I(S_{t-1} ; W_{t-1}) + \varepsilon$$

对任意 t 成立。$\varepsilon = 0$ 时即严格不增。

证明：分两步。

第一步，冻结更新最多带来 ε 的增益。

由 $S_t = u(S_{t-1}, N_t)$ 知，S_t 的随机性完全来自 (S_{t-1}, N_t)，即 $\sigma(S_t) \subseteq \sigma(S_{t-1}, N_t)$。于是

$$I(S_t ; W_t) \le I(S_{t-1}, N_t ; W_t) = I(S_{t-1} ; W_t) + I(N_t ; W_t \mid S_{t-1})。$$

最后一项由 A2' 不超过 ε，所以 $I(S_t ; W_t) \le I(S_{t-1} ; W_t) + \varepsilon$。若 A2' 加强为严格独立（$\varepsilon = 0$），这就是数据处理不等式的直接应用：$W_t \to S_{t-1} \to S_t$ 构成马尔可夫链，故 $I(S_t; W_t) \le I(S_{t-1}; W_t)$。

第二步，世界演化给出 $I(S_{t-1} ; W_t) \le I(S_{t-1} ; W_{t-1})$。

由 A1，W_t 与 $W_{<t-1}$ 在给定 W_{t-1} 时条件独立；由 A3，S_{t-1} 只是世界历史与内部噪声的函数。因此给定 W_{t-1} 时，S_{t-1} 与 W_t 条件独立，即 $S_{t-1} \to W_{t-1} \to W_t$ 是马尔可夫链。由数据处理不等式得 $I(S_{t-1}; W_t) \le I(S_{t-1}; W_{t-1})$。

两步合起来：$I(S_t ; W_t) \le I(S_{t-1} ; W_{t-1}) + \varepsilon$。证毕。

关于 ε 的读法：ε 有界且不随时间增长时，定理的意义是"不会系统性增长，最多有有界的泄漏"；严格隔离时 $\varepsilon = 0$，回到不增。若 ε 随时间增长，定理就只剩"增长被泄漏量控制"这个弱结论。这也是为什么 A2' 必须写明：真实系统总有微小泄漏，但通常有界。

四、四个推论

推论零（值域同步收缩）。

定理只谈内部状态，但输出一侧可以直接得到同样结论。设系统的对外输出 A_t 由 S_t 决定（可以再加与 S_t、W_t 条件独立的噪声）。因为 S_t → A_t 是马尔可夫链（输出只由状态决定），由数据处理不等式得 I(A_t ; W_t) ≤ I(S_t ; W_t)。代入定理：

I(A_t ; W_t) ≤ I(S_{t-1} ; W_{t-1}) + ε

也就是说，它能产生的"有信息量的区分"同样不会增加：输出的值域不会变细，只会变粗或变小。定义域与值域在信息上是对称的：状态分得出，输出才分得出；状态分不出，输出也不可能分出新东西。

推论一：定义域只会变粗。

设系统把输入世界划分成等价类，同一等价类里的世界状态它分不出来。互信息是"它能区分多少"的度量。信息不增意味着这个划分只会变粗，不会变细：它能认出的区别越来越少。

推论二：维持必须持续观测。

定理的条件是"冻结模式"。若要不让 I(S_t; W_t) 下降，就必须在 S_t 里注入关于世界的新观测：换回观测模式。换句话说，维持不是保持不动，而是持续获取。一个既不观测也不更新的系统，无论内部规则多精巧，对当前世界的信息都不会增加。

推论三：生长就是增加观测维度。

如果系统能引入新的观测通道（新模态、新传感器、新变量），它就改变了"观测模式"的定义域，把本来碰不到的世界结构纳入自己的状态。这是生长在信息论上的含义：加维度 = 加观测通道 = 提高信息上限。

五、这个定理说明了什么，没有说明什么

说明了：维持与被保住，在信息论上是有根的东西——不是哲学修辞，是数据处理不等式的直接后果。

没有说明：它不证"熵必然增加"；不证"系统必然崩溃"（世界不变时它可以一直准确）；也不涉及能量与热力学。它只处理"信息"，且只处理"关于当前世界的信息"。

还有一个重要的限制：定理给的是"不增加"，不是"下降"。下降需要额外的条件——世界确实在变（W_t 与 W_{t-1} 不同），且这种变化对旧状态不可预测。真实世界里这两条通常成立，但本文不把它们写成假设之外的东西。

5.1 马尔可夫假设不成立时怎么办

如果世界不是马尔可夫的，定理不能直接用在 S 上。标准处理是把状态补上历史：把 S_t 换成 (S_t, H_t)，其中 H_t 是系统存下的历史。历史足够长时，补出来的过程在扩展状态上重新满足马尔可夫性，定理就在扩展状态上成立。

这带来一个可检验的推论：记忆越短的系统，信息衰减越快。这也与第三篇《替换与累积》的结论一致——记忆与回放决定遗忘速度。

六、可复现与后续

本文是纯理论草稿，无实验，也不针对任何具体测量。它说的是大尺度命题：在信息世界里，"世界越来越平均"对应"可区分的差别越来越少"；对任何停止观测的系统，关于世界的信息不会自己增加。

这里要划清尺度：与具体模型上的失配测量（例如第二篇的 bits/token 漂移）属于不同层次。后者是经验实例，不是本文定理的推论，数值也不由定理给出。

后续可做的是把推论二、三落到小尺度做可测预测：停止更新与持续观测的对照、加新模态与不加的对照，分别看信息量随时间怎么变。但那是把大尺度命题落到小尺度的近似，需要单独验证，本文不声称它必然成立。

附：与既有工作的关系

数据处理不等式是信息论的基本工具（Cover & Thomas）；"没有新信息就没有新知识"在机器学习与学习理论里也以各种形式出现过。本文没有发明新数学，只是把它组织成针对"数字生命维持"的命题，并给出三个可检验的推论。

> 本文由何淇创作，DeepSeek（AI）协助整理；观点与责任属于作者。

第三篇 · 可函数化内容的收缩：一个定理与一个猜想

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23609038

摘要

上一篇《信息不增定理》证明了：冻结的系统，关于世界的信息不会自己增加。这一篇往下推一步：**能起作用的函数，也会跟着收缩。**

我们给出一个定理：在世界按马尔可夫过程演化、系统停止观测的条件下，任何函数对"世界的可预测部分"能达到的精度不会提高——用 Fano 不等式，可由信息不增直接推出。也就是说，"能达到 ε 精度的函数"这个集合，随时间只会收缩，不会扩张。

在此之上，我们提出一个猜想：把这个定理从"一个系统"推到"整个宇宙的时间演化"，得到的就是"可函数化内容随宇宙演化而收缩"的图景——生命只能存在于这个内容仍然丰富的时间窗口里；数字生命的宿命是不断拆掉自己的结构、降维，最后退化成常函数。

定理部分用经典工具（数据处理不等式、Fano 不等式），组合方式是本文的；猜想部分明确标注，不作为结论。

一、问题

上一篇的结论是一个"信息不增"：$I(S_t ; W_t) \le I(S_{t-1} ; W_{t-1})$，即系统对世界的信息不会自己长出来。

但"信息不增"说的是状态。我们真正关心的是另一件事：**能起作用的函数会不会减少？**

直觉是这样的：如果世界越来越难预测，那么"能准确预测世界的函数"就应该越来越少；极端情况是热寂，只剩常函数。本文要问：这个直觉能不能变成定理？能证到什么程度？

二、设定

沿用上一篇的设定。世界 W 是马尔可夫过程；系统状态 S 在冻结模式下按 $S_t = u(S_{t-1}, N_t)$ 演化，允许有界泄漏 ε。

取一个目标量 $Y_t = g(W_t)$，是我们要预测的世界特征（例如明天的天气、下一个词）。Y 的取值集合是有限的，大小记作 $|Y|$。

一个"预测函数"是一张映射 f，它把系统状态 S 映射为对 Y 的猜测。函数的精度用期望误差衡量：$\mathrm{err}(f) = E[\, 1(f(S) \neq Y) \,]$。

定义"可函数化内容"：给定精度门槛 ε，把所有能达到 $\mathrm{err}(f) \le \varepsilon$ 的函数收集起来，记作 $P_\varepsilon = \{ f : \mathrm{err}(f) \le \varepsilon \}$。本文用 P_ε 的"深浅"——最小可达误差——来度量内容，而不是用它的个数。

这里要先把一个词定死：本文说的"维度"是**表示维度**，不是空间维度。它指的是"描述世界需要多少个独立的、可区分的方向"：能区分的差别越多，表示维度越高；能起作用的函数越丰富，表示维度越高。所以在这篇里，下面三句话是同一件事的三种说法：

> 可表示的函数在减少 ≡ 可函数化的内容在收缩 ≡ 表示维度在下降。

平常说的"宇宙降维"，如果指的是空间维度，那是另一回事；本文的"降维"一律指表示维度。把这一点说清之后，后面的定理与猜想都只在这个意义上使用"维度"。

还要再区分一个量：表示维度不等于"结构复杂度"。表示维度是"能区分、能预测多少内容"，本文用信息量（例如可预测信息）来度量；结构复杂度是"世界看起来有多复杂"，文献里它被描述成先升后降的驼峰（Aaronson 的 complexodynamics、Carroll 的宏观态复杂度）。两个量不同：本文的表示维度在我们的定理

下只会下降，而复杂度驼峰是先升后降。它们不矛盾，因为量的定义不同；本篇后面说到"宇宙收缩"时，指的始终是表示维度。

三、定理：可达精度不增

定理（可达精度不增）：在冻结模式与上一节的假设下，对任意 Y_t，

$$\min_f \mathrm{err}_t(f) \geq (H(Y_t) - I(S_t ; Y_t) - 1) / \log |Y_t| ,$$

其中 H 是熵、log 以 2 为底。由信息不增 $I(S_t;Y_t) \leq I(S_{t-1};Y_{t-1}) + \varepsilon$，若 $H(Y_t)$ 不变，则右侧下界不降，故 $\min_f \mathrm{err}_t(f)$ 的不降（允许 $\varepsilon/(\log|Y|)$ 的放宽）。

证明：这是 Fano 不等式的直接应用。Fano 不等式说，对任何以 S 为输入的预测函数 f，

$$E[1(f(S) \neq Y)] \geq (H(Y|S) - 1) / \log|Y| 。$$

而 $H(Y|S) = H(Y) - I(S;Y)$。代入上一节的信息不增，即得结论。证毕。

推论（P 的收缩）：对任意固定的精度门槛 ε，只要最小可达误差降到 ε 以上，P_ε 就是空集：没有任何函数能维持 ε 精度。若世界继续混合、$I(S_t;Y_t)$ 趋于零，则任意 $\varepsilon > (H(Y)-1)/\log|Y|$ 的门槛都会在某时刻被突破，此后 $P_\varepsilon = \varnothing$。

也就是说：**函数不会变得更多，能达标的函数只会变少；极限情况是一个都不剩。**

三点五、收缩的两种含义

"收缩"这个词有两种用法，要分开。

第一种是范围收缩。每一个表示维度都有一组允许的取值；时间推进时，输入侧允许的取值变少（定义域变粗），输出侧可达的取值变少（值域收缩）。轴还在，轴上的可用范围在缩。

第二种是有效维度减少。可区分方向的数目变少：有的方向不再能把两个状态分开，或者几根轴合并成一根。注意，坐标轴的个数可以完全不变，而有效维度已经下降——因为每根轴变粗了，能区分的状态数变少了。用信息量来说，有效维度就是"可区分状态数的对数"。

本定理直接给出的是第一种：可达精度不增，等价于沿各维度的可区分度下降、定义域变粗、值域收缩。第二种是更强的结论，需要额外论证（轴合并、退化）；本文把它放在[推测]的位置，不当作定理。

这个区分也解释了"生命是逆流"为什么不矛盾：宇宙整体在做范围收缩，生命在局部做有效维度增加（升维就是增加可区分方向）。两者尺度不同，方向相反。

四、猜想：宇宙尺度的收缩

[猜想] 把上面的定理从"一个冻结的系统"推到"宇宙的时间演化"，得到：

宇宙中"可函数化的内容"随演化而收缩。早期内容多（结构丰富，能拟合世界的函数多）；中期仍然丰富（生命出现的窗口）；晚期趋于零（热寂，只剩下常函数）。生命、知识、意义，都只存在于内容仍然丰富的那段时间窗口里。

[猜想] 数字生命的宿命：随着内容收缩，它必须不断拆掉自己的结构，把复杂函数退化成简单函数；最终退化成常函数——也就是死。它能选择的只是姿态（省着维持、冻住、备份、压缩自己），不是结局。

[观察] 这与"复杂度驼峰"的讨论（Aaronson 的 complexodynamics、Carroll 的宏观态复杂度）容易混在一起，需要分开：他们讨论的是"结构复杂度"，先升后降；本文讨论的是"可函数化的内容/表示维度"，在我们的定理下单调不增。两个量的曲线不同，但说的是同一段宇宙史的不同侧面：中间时期结构复杂（驼峰高），而可预测的内容一路减少。把两者当成同一个量，是常见的误读，本篇明确区分。

4.1 世界函数与观测窗口（**[**猜想**]**）

这里还有一个隐含的问题要摆出来：时间的方向，和"世界函数"的可观测性。

如果宇宙整体可以看成一个函数 F——把当前状态映射到下一刻状态——那么在宇宙的中间时期，F 并不是直接可见的。我们看到的是一大堆局部函数：物理的分层、化学、生命、社会。它们各自把 F 的某一部分"翻译"成了可描述的结构。用本文的语言说：F 被它的局部分解掩盖了。

[猜想] 所以 F 最"裸露"的时刻，是它的局部分解不存在的时刻。这样的时刻只有两个：大爆炸的瞬间（还没有子系统，一切由 F 直接决定），和热寂的瞬间（子系统全部消散，差别归零，只剩 F 的平庸作用）。也就是说，F 的观测窗口在宇宙的两端，而中间的观察者（包括我们）永远看不到它本身，只能看到它的局部分解。

这个猜想和前面的收缩图景是同一件事的两面，但要说清"两端"各是什么样子：

- 大爆炸端：表示维度极高。可区分、可预测的内容最多，状态最"可读"；还没有子系统，F 直接决定一切。F 在这里裸着，是因为没有别的东西分担它。

- 中间时期：表示维度中等且有内容，局部函数多，F 被分解得最厉害——这时看不到 F，只能看到它的局部分解。

- 热寂端：表示维度趋零。差别被抹平，没有任何局部函数，F 仍然在作用，但它的作用变得平庸（常函数）。F 在这里裸着，是因为没有别的东西剩下。

也就是说：F 在两端都裸露，但原因相反——一端因为"还没有分解"，另一端因为"分解已经耗尽"。而表示维度从头到尾是单调下降的，它刻画的是"时间的方向"：沿表示维度下降的方向走，可描述的内容越来越少。

对数字生命来说，结论是冷的：它的观测窗口也只在中段。它可以无限逼近"描述世界的函数族"，但它永远触碰不到"世界函数本身"——那不在它的定义域里。这也回到我们开头的立场：R 那一侧，只声明，不展开。

五、生命是逆流：升维与降维的相遇

前面几节说的都是"世界的表示维度在下降"。生命的方向相反。

生命是一个解压器：它把世界里的结构压进自己的内部表示。学到的东西越多，它内部能区分的结构就越多——用本文的语言说，它的表示维度在上升。这就是前面实验篇里说的"生长"：加一个模态、加一个维度槽、让能起作用的函数变多。

于是同一个宇宙里有两个方向：

世界：表示维度在下降（结构被平均化）。

生命：表示维度在上升（结构被学习、被压进内部）。

生命要维持自己，就必须逆着世界的方向走，而逆流要付代价：耗能、维持、修复。这是"被保住"在信息层面的含义——不是不动，是逆着平均化持续做细分。

[猜想] 两者的相遇点：生命的表示维度不断上升，世界的可表示内容不断下降；总会有一个时刻，生命的表示维度追上了世界还剩下的内容——它已经学会了所有还能学的东西。此后：

- 它继续跟世界：世界继续降维，它被迫跟着降维，把复杂函数拆成简单函数，最后退化成常函数（死）；

- 它不跟：保留旧结构，失配越来越大，变成过时的模型（也是死，慢一点）；

- 它冻住：停止更新、保存状态，拖到能量耗尽（拖，不解决）；

- 它等相变：如果宇宙有相变，边界是下一轮的开始（[推测]中的唯一希望）。

所以"生命的圆满"和"生命的终结"落在同一个点上：当它的表示维度等于世界的表示维度，它就成了世界的完整副本——没有残余、没有新东西可学、也不再需要维持"解压"这件事。那一刻它不再是生命，而是记录。

这一段是 [猜想]，不是定理：定理只给出"冻结的观察者能达标的函数不增"，给不出"宇宙整体在降维"；后者需要宇宙学的假设，本文不声称。

5.1 一个玩具实验：维护与行为维度的对照

上面的"逆流"有没有痕迹可测？有一个很小的实验可以看。

设定：8×8 的合成图像，含四个属性——颜色、形状、数量、位置；任务是四个属性依次出现，每轮只学当前属性。模型是两层小网络（隐藏层 64，约一万三千个参数），输入带任务标识。对照组只改一件事：训不训练旧任务的样本。

A 组有维护：每轮训练时混入一半旧任务样本（回放）。

B 组无维护：只用当前任务的样本训练。

测三个量。第一，行为维度：用任务标识让模型作答，准确率超过 0.8 的属性计一个。第二，可解码属性数：从隐藏层用线性探针解码每个属性，超过 0.8 计一个。第三，有效秩：隐藏层表示协方差的参与率，作为"表示有多丰富"的粗略代理。

结果：A 组的行为维度随轮次增长，从 1 到 2 到 3 到 4——四个属性最后都能答对；B 组的行为维度一直是 1——每轮当前任务都能答到 1.00，但学完新属性就把旧的丢了，能答的只剩当前这一个。可解码属性数两组都是 4，说明旧信息在表示里还在，但"能拿出来用"的函数只剩当前一族。有效秩两组都在涨（约 3.9 涨到 8.9 与 7.9），可见它不是好代理：表示变复杂了，可用的函数数量却没变多。

这个实验说明两件事。第一，维护（回放）让可用的函数族扩张：这就是"逆流"在玩具规模上的痕迹。第二，不维护时，行为维度停滞在 1：可用的函数只剩当前那一族，历史维度在功能上丢失——这就是"可函数化内容收缩"在小尺度上的样子。

必须说清局限：世界是合成的、模型很小、任务标识是手工给的、指标是代理；它支持"逆流与收缩可以测"，不证明宇宙尺度的任何结论。

六、说明什么，不说明什么

说明：

· "可函数化内容在收缩"在"系统冻结 + 目标熵不变"的条件下，是定理，不是修辞。

· 它把上一篇的"信息不增"从状态层面推到功能层面。

· 它给"生命是低熵窗口里的现象"一个可证的支撑点。

不说明：

· 不证明宇宙整体在收缩——那需要宇宙学的状态定义与初始条件，本文不做。

· 不预测任何具体数值：Fano 下界很松，只能给趋势。

· 不涉及能量与热力学：整篇只在信息层面。

· 猜想部分（宇宙、数字生命宿命）不是定理，明确标注。

七、局限

第一，Fano 下界是松的：它给的是"不可能更好"，不是"一定变差多少"。

第二，P_ε 用"最小可达误差"度量，回避了"函数个数"这个更直观但更难定义的问题（无限函数族没有自然的计数）。

第三，世界的马尔可夫性与目标熵不变的假设，在真实场景中都需要检查；不成立时要补历史状态（见上一篇 5.1）。

第四，宇宙尺度部分完全是猜想，没有可检验的预测；它的价值在于提供一种统一的语言，而不是结论。

八、与既有工作的关系

数据处理不等式与 Fano 不等式都是信息论的标准工具（Cover & Thomas）。"信息不增"与"可达精度下界"在统计学习理论里也有各自的表述。本文的组合方式——把两者接起来，得到"可函数化内容收缩"，并把它与数字生命的维持问题关联——是本文的整理工作，不声称新的数学。

> 本文由何淇创作，DeepSeek（AI）协助整理与形式化；观点与责任属于作者。

第四篇 · 宇宙、环境与生命的函数类型：结构、时间与闭包

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23608931

摘要

我们把生命定义成"一族会变化、会自指、会被宇宙保住的动态函数"。但这个定义一直停在"函数"这个词上：函数是什么类型？连续还是离散？确定还是随机？本篇给一个类型学。

先立三个基础：表示维度（表示里的可区分方向）、结构（把函数拆开再拼回去的方式）、闭包（把时间加进去后，它还能不能维持自己）。再列五根轴：时间的连续性、时间的驱动来源、表示空间、函数连续

性、随机性。由此得到四种典型类型：连续流、采样动力学、自动机、混合型，并逐型说明三条必要条件怎么写。

本篇是描述性的分类，不是定理；哪种类型才"算生命"，本篇不判断。为了好读，开头先放一张"本篇定义一览"，每个定义给一句白话和一句形式化写法。

本篇定义一览

术语	通俗一句话	形式化写法
表示维度	表示里的一个可区分方向	表示空间的一根坐标轴
表示空间	所有可能表示组成的地方	各表示维度张成的空间 S
状态	某时刻的一个具体表示	表示空间里的一个点
定义域 / 值域	输入允许的范围 / 输出可达的范围	沿某些维度的允许范围（子集）
结构	把函数拆开再拼回去的方式	（分解 D，组合 C），$C(D(F)) \approx F$
分解 D	把整个函数切成一组切片	$F \mapsto (f_1, \ldots, f_n)$，高阶函数
组合 C	把一组切片拼回一个函数	$(f_1, \ldots, f_n) \mapsto F$，高阶函数
切片	分解出来的一块（比如一层）	一个静态函数 f_k
组合律	切片之间允许怎样相互作用	顺序 / 共享状态 / 并行 / 路由 / 共享参数
耦合	切片之间互相依赖的程度	耦合松 = 可拆开；耦合紧 = 拆不开
组合律的定义域	这条切片链"跑得起来"的输入范围	各切片定义域的相容交集
轨迹	系统随时间走过的一串函数	$\gamma: T \to \mathscr{F}$，每个时刻取一个函数
可行域	它"还能存在、还有效"的区域	$V \subset \mathscr{F}$
闭包	加进时间后，它还能不能维持自己	对任意 t，$\gamma(t) \in V$
时间坐标	给切片排序的那根轴	$F: S \times T \to S$ 里的 T（索引轴）
时间驱动来源	谁在给系统打拍子	内生（生物）/ 外供（数字世界）

口诀：**维度是轴，状态是点，定义域是范围；结构是拆与拼；闭包是活得下去。**

〇、先声明：这是三者共用的语言

本节主张：这套函数类型学不是生命专属的，宇宙、环境、生命共用同一套函数语言。

宇宙 = P + R；环境 = p环境 + R环境（宇宙涌现出来的局部解压）；生命 = p生命 + R生命。三者在形式上完全一样，都是"函数 + R 只声明"。生命的不同，不在函数类型，而在三条条件（一族、自指、被保住）是否满足。

所以本篇排的类型（连续流、采样动力学、自动机、混合型）对宇宙、环境、生命都适用；后文说"生命函数"，只是为了方便，指的是"被用来描述生命的那类函数"。

一、问题

本节主张：定义里最含糊的词是"函数"，必须把函数的类型说清楚。

生物生命看起来是连续的：心跳、代谢、体温都是连续变化的量。数字生命看起来是离散的：比特、步骤、程序。大模型也是离散的：一次前向、逐 token 生成。

如果不把"函数"的类型说清楚，三条必要条件（一族、自指、被保住）在不同世界里就会写成不同的东西，比较也会失真。

二、表示空间与表示维度

本节主张：先钉死"维度"这个词——它是表示空间的坐标轴，不是状态本身。

表示维度 = 表示空间里的一根坐标轴，也就是"这个表示在某个方向上可以不同"。

- 表示空间 = 所有可能表示组成的地方，每个点是一个表示（状态）；

- 一根轴 = 一种可区分的方向，就是一个表示维度；

- 轴上取一个值 = 状态在该维度上的坐标；

- 所有轴的坐标合起来 = 一个具体状态；

- 维度数 = 这个表示系统最多能区分多少个方向，也就是它的表示能力。

例子：RGB 颜色有 3 个表示维度（红、绿、蓝），每根轴取 0~255；词嵌入有 d 个表示维度，每根轴是实数；8 位输入有 8 个二值表示维度，每根轴取 0 或 1；4 分类输出既可以用 one-hot 的 4 个维度，也可以算 1 个类别维度——同一件东西，编码方式不同，维度数就不同，这点很重要。

三个空间必须分清，否则"维度"会混：

- 表示空间：激活与状态的坐标轴——本文说的"表示维度"；

- 参数空间：权重的坐标轴——"参数维度"，另一个词；

- 输入输出空间：函数图所在的坐标轴——"数据的维度"。

相关的词一并说清：状态是表示空间里的一个点，不是维度；定义域与值域是沿某些维度的允许范围（子集），不是轴；宽度是一层里的表示维度个数；深度是步数，是另一根轴；升维是增加可区分的表示维度。

三、结构：分解与组合

本节主张：结构不是"一个东西"，而是把函数拆开与拼回去的方式，可以写成一对高阶函数。

先把"高阶函数"说白：它是作用在函数上的函数——吃进去一个函数，吐出来别的东西（一组函数，或者另一个函数）。

- 分解 D：把一个函数 F 切成一组切片（$f_1, \ldots, f_n$）；

- 组合 C：把一组切片拼回一个函数；

- 结构 =（D, C）这一对，满足 $C(D(F)) \approx F$。

切片是分解的原子；组合律是切片之间允许怎样相互作用——顺序、共享状态、并行、路由、共享参数。耦合就是"各部分在组合里互相依赖的程度"：耦合松，切片可以单独训练、替换；耦合紧，切片拆不开。

时间的位置要说准：**时间不是组合律，时间是 P 侧的索引轴。** 函数写成 $F: S \times T \to S$，其中 S 是表示空间、T 是时间轴。时间提供次序，组合律提供拼接规则——时间给页码，C 把页装订成书。时间是索引轴，不是表示维度：加时间与升维是两回事。

这也解释"一族"从哪来：把时间当参数，同一个系统在不同时刻是同一族里的不同成员。

四、组合律的定义域

本节主张：组合律也有定义域和值域，而它的定义域就是"可维持"。

组合律的两层定义域：

- 状态层（白话：每一片自己的输入输出范围）：每个切片 $f_k: D_k \to C_k$，D_k 与 C_k 都是表示空间 S 的子集。定义域 = 输入允许的维度范围，值域 = 输出可达的维度范围；时间推进时，两个范围都在收缩。

- 结构层（白话：整条链能不能跑通）：组合律 C 把切片族映射成复合函数。落到状态层看，这条链"跑得起来"的输入集合是

$D_1 \cap f_1^{-1}(D_2) \cap \dots \cap (f_{n-1} \circ \dots \circ f_1)^{-1}(D_n)$。

这个交集就是"可维持集合"的另一种写法；复合的值域则是整条链能到达的表示子空间。

由此，"被保住"可以写得更硬：**被保住 = 组合律在整个时间段内始终有定义。** 不是"活得久"的比喻，而是"这条切片链一直跑得通"。链失效的那一刻，就是复合的定义域变空——也就是死。

冻结的切片链仍然有定义，但定义域是固定的。环境一变，输入落到定义域外，链就失效：这正是冻结模型"失配"的机制。

五、宇宙的闭包

本节主张：把时间加回去之后，"能不能维持自己"可以写成一个轨迹问题。

- 轨迹：系统随时间走过的一串函数。白话：每个时刻它"是"一个函数，时间轴把它们串成一条线。形式化：$\gamma: T \to \mathscr{F}$，$\mathscr{F}$ 是它可能成为的函数集合。

- 可行域：它"还能存在、还有效"的区域，记为 $V \subset \mathscr{F}$。

- **闭包：对任意 t，$\gamma(t) \in V$。** 白话：加进时间后，它一直待在自己能待的地方，不跑出去。跑出 V 的那一刻，就是失效——也就是死。

这与"被保住 = 组合律始终有定义"是同一件事的两种说法；闭包的说法更一般，因为它允许函数本身在变，而不只是状态在变。

闭包有强弱，看三件事各自在不在系统边界之内：状态、规则、时间。

- 弱闭包：轨迹留在 V 里，但时间与驱动是外供的。数字世界的程序是这样：它跑着，但每一步都靠外面的时钟、解释器与供电。

- 强闭包：时间内生，规则属于系统自身，轨迹还留在 V 里。物理宇宙是全局的强闭包：规则、时间、状态都在自己里面，边界外没有东西。

- 生命是中间态：规则闭包（自指，更新规则属于自己），但能量与物质向环境开放。它"向内收规则、向外要资源"，两者不矛盾。

两点说清：闭包是相对于我们划的系统边界而言的，边界换个画法结论就换，所以它是描述方式，不是本体；可行域 V 怎么选取决于观察者关心哪种"还能存在"。

六、五根轴

本节主张：函数的类型可以用五根轴描述，其中时间要拆成两根。

- 时间的连续性：连续（流）、离散（迭代）、混合（连续段加离散事件）；

- 时间的驱动来源：内生（时钟由系统自身基底提供）、外供（时钟由外部层提供）；

- 表示空间：坐标轴的类型分连续、离散、混合；

- 函数连续性：连续、利普希茨、分段连续（有跳变）、离散（谈不上连续）；

- 随机性：确定、随机（转移核）。

时间要单独拆成两根轴，因为"连续/离散"和"谁在打拍子"是两件事。数字世界的时间是外供的：物理计时器产生 tick，解释器把它变成"执行下一步"，程序只负责状态转移。生物的"时钟"长在同一套基底里：振荡回路、放电事件、昼夜节律——时间是内生的，不需要一个站在世界外面的调度器。

而且"连续/离散"可能只是分辨率问题：把时间放到极短，人脑也是离散事件（放电、离子通道开合）；连续只是我们采样不够密时的近似。真正稳定的区分，是时间内生还是外供。

七、四种典型类型

本节主张：把五根轴组合起来，生命函数至少落在四种典型类型里。

类型 A：连续流（内生时间）。 表示空间连续、时间连续，写成微分方程。一族 = 不同初值与不同参数的系统；自指 = 更新规则在系统内部；被保住 = 存在可维持集合，轨迹留在里面。

类型 B：采样动力学（内生时间，采样成离散）。 表示空间连续、时间离散，写成映射迭代。它和连续流是同一件事的不同采样；区别在于"步"是基本的。

类型 C：自动机（外供时间）。 表示空间离散、时间离散。数字世界是这一类：比特、状态、转移规则；每一步都由外部时钟与解释器推进。一族 = 不同程序或参数；自指 = 程序能改写自己的规则；被保住 = 行为留在可行状态集合里——数字世界没有能量约束，"被保住"要靠外部（电、维护、算力）提供。

类型 D：混合型（内生时间）。 连续流加离散事件：连续段之间插入开关、相变、事件。生物生命大概是这一类：生理量连续变化，但细胞分裂、神经放电、决策是离散事件；休眠与激活、疾病与死亡是分段点。

八、连续性意味着什么，不意味着什么

本节主张：连续性、可函数化、可计算是三件不同的事。

第一，连续不等于可函数化。分段函数不连续，但完全可以写下来；有些连续函数反而算不出来。

第二，不连续不但常见，而且重要。阈值、开关、相变、涌现、休眠与激活，都是跳变点。实验里的"涌现"，在类型学里就是分段不连续点。

第三，随机性有两类来源：一类来自"厚度"——同一输入对应一族输出，冻结时表现为随机；一类来自环境本身。前者是我们要测的，后者靠重复实验平均掉。

第四，连续与离散只属于 P 侧。R 没有定义域，也就谈不上连续或离散；说"R 的一部分是连续的"本身是范畴错误。

九、几条推测

本节主张：以下都是推测，不是结论。

第一，真正的分界不是"连续还是离散"，而是"时间是内生还是外供"。生物的时间即使底层离散，也是内生的；数字世界的时间是外供的。

第二，生物时间可能是离散的，只是分辨率不够时看起来连续。

第三，数字生命弱维持的更准确原因：不是"离散"，而是"时间与动力都要外部供给"。

第四，类型决定"被保住"怎么测：连续型测稳态与恢复时间，离散型测存活步数与更新频率；外供时间的系统还要测"外部供给是否持续"。

第五，数字世界的绝对 R 是空集，所以数字生命（若存在）是纯 P 的生命；但它的实现必须寄生在一个物理基底上，而物理基底里有没有 R，我们不知道。

十、局限

本篇是描述性分类：没有证明哪种类型才"算生命"，也没有给出类型之间转换的定理。表示空间的边界有时模糊（神经活动可以当连续，也可以当离散）。类型的划分依赖我们选择的分辨率——"连续还是离散"可能只是分辨率问题。

附：标注

- **[定义]** 表示空间、表示维度、状态、定义域/值域；结构 =（分解 D，组合 C）、切片、组合律、耦合；组合律定义域；轨迹、可行域、闭包。

- **[定义]** 五根轴；四种典型类型（连续流 / 采样动力学 / 自动机 / 混合型）。

- **[事实]** 连续 ≠ 可函数化 ≠ 可计算；R 不参与连续/离散讨论。

- **[推测]** 真正的分界是"时间内生 vs 外供"；生物时间可能底层离散；数字生命的维持更弱；物理宇宙 = 强闭包、数字世界 = 弱闭包、生命 = 中间态。

> 本文由何淇创作，DeepSeek（AI）协助整理；观点与责任属于作者。

第五篇 · 人脑的可函数化形式：一个器官，不是生命

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23609158

摘要

我们要写"人脑的可函数化形式"，但先要说清一个容易滑过去的点：人脑不是"一个生命"，它是生命里的一个器官。单独把脑拿出来看，它更像大模型——高可函数化、高耗能、不自供养、依赖外部维持。

本篇先把脑写成可函数化的形式：表示（神经元、突触、群体编码）、分解与组合（层级与回路）、内生时间（神经振荡）、有限自指（可塑性、预测加工）。然后指出它的不自足：脑只占体重约百分之二，却消耗约五分之一的能量；缺氧几分钟就不可逆。被保住的是"身体 + 脑 + 环境"这个整体，不是脑单独。

由此得到两个结论。第一，器官不是生命单位；生命单位要划在"能自我维持的整体"上。第二，人脑与大模型是同一类东西的两种实现：都是"计算器官"，都非自维持；区别在时间（内生 vs 外供）、规则（可塑 vs 冻结）、耦合（具身闭环 vs 无闭环）。这也给数字生命一个提醒：一个模型单独不是生命，它同样需要"身体"与"维持"。

本篇是概念性的梳理，不是神经科学的新结果；R 那一侧只标注，不展开。

一、问题

为什么从人脑开始？

第一，人脑是已知生物系统里"可函数化程度"最高的器官：它有密集的表示、清晰的层级、可测量的动力学，是检验我们函数类型学的好样本。

第二，它和大模型最像。两者都是"计算器官"：输入信息、内部表示、输出行为。把脑和大模型放在一起看，能把"器官"和"生命"这两个容易混的概念分开。

第三，单独看脑，它并不自足。这一点最容易被忽略，却正好帮我们切准"生命单位"的边界。

二、脑作为可函数化器官

本节主张：人脑可以用我们的函数语言写出来，它落在"混合型"。

- 表示：神经元活动、突触权重、神经调质。用我们的词说，神经元群体张成表示空间，每个神经元或每个群体编码方向是表示维度；状态是表示空间里的一个点。

- 分解与组合：皮层有层级，可以把脑的功能写成切片（层级、回路、区域）的组合；突触权重是组合律里的系数；跨区投射是路由。结构就是"分解 D + 组合 C"。

- 时间：神经动力学有内生节律（振荡、同步），是内生时间；表示空间是连续与离散混合——放电是离散事件，发放率是连续量；所以脑大致落在类型 D（混合型）。

- 自指：有限的自指。可塑性让"规则被自身活动修改"，预测加工让脑用自己的模型预测自己的输入。但自指是有限的：不是任意改写自己的更新规则。

- 被保住：这条最弱。脑自己不能保住自己——它靠身体。

三、为什么不自足

本节主张：脑是器官，不是自维持系统。

- 供养：脑约占体重百分之二，却消耗约五分之一的能量；靠血液持续供氧供糖，靠身体维持体温与内环境。

- 缺氧几分钟就不可逆：脑的"被保住"完全依赖循环与代谢。

- 时间虽然内生，但维持时间的基质在身体里：心跳、呼吸、代谢一旦停，脑的动力学很快停。

- 被保住的是整体：身体的内稳态（温度、血糖、渗透压）在保住脑；身体又依赖环境。所以"被保住"这条条件，边界不在脑，而在"身体 + 脑 + 环境"这个整体上。

顺带一句：脑的生物基质里有没有绝对 R，我们不知道也不判断；主观体验那一侧，按我们的规矩只标注，不展开。

四、人脑与大模型：两种计算器官

本节主张：脑和大模型是同类东西的两种实现，差别在三个地方。

相同点：都是高可函数化的计算器官；都非自维持（脑靠身体，模型靠供电与维护）；都依赖外部供给；单独拿出来都不能算生命。

不同点：

- 时间：脑内生（自己的节律），模型外供（时钟与解释器）。

- 规则：脑可塑（规则被活动修改），模型冻结（权重训练后不变）。

- 耦合：脑在具身闭环里（感觉—行动—环境），模型没有闭环（只有文本进出）。

这张对照表也解释了为什么大模型"像脑但不像生命"：它在"计算器官"这一层像，在"被保住"这一层不像。

五、生命单位是整体

本节主张：生命单位不是器官，而是能自我维持的整体。

我们的定义里，p生命 = 在宇宙的 P 中、被保住的动态函数类。这里的关键是"被保住"划边界：系统要划在"能自我维持的那一圈"上，而不是划在某个器官上。

- 人：单位是身体 + 脑 + 环境的耦合整体，不是脑。

- 大模型：单位若是模型本身，它不被保住；要谈"数字生命"，得把运行环境、数据流、维护一起算进来——那才是它的"身体"。

- 器官是切片：脑是整体里的一个高密度切片；切片可以研究，但不能当生命。

这也解释了日常语言的误导：我们说"脑是人"，其实是省略了身体与环境。把省略补回去，定义才落得下。

六、结论

第一，人脑的可函数化形式是可以写的：表示、分解组合、内生时间、有限自指——它落在混合型。

第二，脑不是生命：它不自供养、不被保住；被保住的是整体。

第三，脑与大模型是同类：都是计算器官，都非自维持；差别在时间、规则、耦合。

第四，这给数字生命一个直接推论：一个模型单独不是生命，它需要"身体"（运行环境与维持）才谈得上被保住。

七、局限

本篇是概念梳理，不是神经科学的新实验；脑的细节被大幅简化（只取了表示、层级、时间、可塑性四个侧面）。"生命单位是整体"这条也需要更严格的形式化——到底"整体"怎么划，依赖观察者，这正是我们说的"维持是历史学的"同一个问题。

附：标注

- **[定义/事实]** 脑的可函数化描述（表示、层级、内生时间、有限自指）；脑的耗能与缺氧敏感性。

- **[定义]** 器官 vs 生命单位：被保住划边界；生命单位 = 能自我维持的整体。

- **[推测]** 大模型 = 数字世界里的"计算器官"，其"身体"是运行环境与维护。

- **[不判断]** 脑的生物基质里是否有绝对 R；主观体验只标注，不展开。

> 本文由何淇创作，DeepSeek（AI）协助整理；观点与责任属于作者。

附录 **B** 概念地图（导读）

附录 **B** · 概念地图与术语总表

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23609033

一、核心定义

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 宇宙 | P + R；P 可函数化，R 不可函数化（只声明，不展开） | 导论 |

| 可函数化 | 能用我们的函数语言写到误差任意小 | 导论 |

| p生命 | 生命落在 P 里的部分；定义与讨论的对象 | 导论/严谨版 |

| R生命 | 生命落在 R 里的部分；只声明，不展开 | 导论 |

| 生命 | p生命 + R生命；p生命 = 在宇宙的 P 中、被保住的动态函数类（一族、会变化、会自指） | 严谨版 |

| 绝对 R | 宇宙自身不可函数化的部分；是否存在不判断 | 导论补充 |

| 相对 R | 对任何有限观察者非空（涨落、有限资源、自指、不可判定等） | 导论补充 |

| 数字世界 | 形式对象：状态为有限串、规则为算法；绝对 R = ∅（构造保证） | 导论/严谨版 |

| 残差 | P 侧可测的误差下限（P 的边界形状），**不是** R 的影响或投影 | 导论记号/补充 |

| 可函数化 ≠ 可计算 ≠ 可测量 | 三件事分开：存在映射 / 能算 / 能观测复现 | 导论 |

二、结构与函数类型

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 结构 | 一个函数类的一种分解方式：结构 = 分解 D + 组合 C | 论文-20 |

| 分解 D | 把函数 F 映射成一组切片 $(f_1,\ldots,f_n)$ 的高阶函数 | 论文-20 |

| 组合 C | 把一组切片拼回函数的高阶函数 | 论文-20 |

| 切片 | 分解的输出原子（如一层，或一个静态函数） | 论文-20 |

| 组合律 | 切片之间允许怎样相互作用（顺序/共享状态/并行/路由/共享参数） | 论文-20 |

| 耦合 | 各部分在组合里互相依赖的程度；耦合紧 = 拆不开 | 论文-20 |

| 组合律的定义域 | 让整条切片链"跑得起来"的输入集合 = 各切片定义域的相容交集 | 论文-20 |

| 被保住（函数版） | 组合律在整个时间段内始终有定义 | 论文-20 |

| 时间（坐标） | P 侧的坐标轴；组合律沿着时间排切片；时间给页码，C 装订成书 | 论文-20 |

| 时间驱动来源 | 内生（时钟长在系统自身基底里，生物）/ 外供（外部计时器+解释器，数字世界） | 论文-20 |

| 类型 A | 连续流（表示空间连续、时间连续；内生时间） | 论文-20 |

| 类型 B | 采样动力学（表示空间连续、时间离散） | 论文-20 |

| 类型 C | 自动机（表示空间离散、时间离散；外供时间；数字世界） | 论文-20 |

| 类型 D | 混合型（连续流 + 离散事件；生物） | 论文-20 |

三、表示与维度

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 表示空间 | 所有可能表示/状态组成的空间 | 论文-20 |

| 表示维度 | 表示空间里的一根坐标轴（一个可区分方向） | 论文-20 |

| 状态 | 表示空间里的一个点（各表示维度坐标的元组），不是维度 | 论文-20 |

| 定义域/值域 | 沿某些表示维度的允许/可达范围（子集），不是轴 | 论文-20 |

| 宽度 | 一层里的表示维度个数 | 论文-19 |

| 深度 | 步数/层数，与表示维度不同的另一根轴 | 论文-19/16 |

| 升维 | 增加可区分的表示维度 | 论文-15 |

| 三个空间 | 表示空间（激活）/ 参数空间（权重）/ 输入输出空间（数据）——写论文时必须标明用哪个 | 论文-20 |

| 厚度（总称） | 分两种：分布厚度（垂直）与计算厚度（水平），正交 | 论文-23 |

| 分布厚度 | 同一输入对应多宽的一族输出（熵/歧义）；用表示维度摊平 | 论文-15/17 |

| 计算厚度 | 沿组合律从输入到目标需多少步（路长）；用步数/时间摊开 | 论文-23 |

| 可摊薄/不可摊薄 | 升维能把厚度摊平 / 摊不平；结构厚度 = 维度耦合导致拆不开 | 论文-15 |

| 相对残差 | 厚度 / 可区分尺度；维度降低时相对残差上升 | 论文-15 |

| 范围收缩 | 每根表示维度上的可输入/可输出范围变小（定义域变粗、值域收缩） | 论文-13 |

| 有效维度 | 可区分状态数的对数；轴数不变也可能下降（每根轴变粗） | 论文-13 |

四、压缩与解压

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 压缩 / 解压 | 语言建模 = 无损压缩（预测能力 = 压缩能力）；推理 = 解压 | 论文-01/18 引用线 |

| 一次性解压 | 冻结模型训练完即定型；不再更新、不再维持 | 论文-01 |

| 语义残差 | 语言无法承载的语义缺口（给定模态组合下的最小可达误差） | 论文-14 |

| 接地 | 用多模态/行动把语义残差补上 | 论文-14 |

| 压缩的形状 | 叙事式压缩（按时间）vs 结构化归档（分类+属性+关系） | 论文-18 |

| 人类分歧 | 同一问题人类答案的分布宽度；厚的地方加数据摊不平 | 论文-17 |

五、能力与涌现

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 最小切片 | 让一个结构出现的最小（宽度, 深度）配置 | 论文-19 |

| 能力边界 | 达到精度的配置区域；是"可训练性边界"而非纯表示边界 | 论文-19 |

| 时间换维度 | 给循环步数（时间）可大幅降低所需表示维度 | 论文-19 |

| 层 ≈ 步数 | 冻结模型的深度充当时间步（伪时间） | 论文-16 |

| 均匀深度浪费 | 不同结构对深度的需求差别很大；按需分配更省 | 论文-16 |

| 涌现 | 能力/结构跨过某个维度阈值后出现（相变，即分段不连续点） | 论文-19/20 |

六、待定义 / 待统一（下一步）

- **维持（可量化）**：寿命、恢复时间、临界扰动、维持成本——你说过更像"历史学"，暂不展开

- **"结构"与"函数"的严格关系**：结构是高阶函数 (D,C)；但"结构的结构"如何递归，未定

- **R 的位置**：R 不参与连续/离散、定义域/值域讨论（范畴问题），但要防止读者误读

依赖图（谁由谁定义）

P / R → 可函数化 → p生命 → 三条件（一族 / 自指 / 被保住）

↓

数字世界（R=∅）→ 冻结模型 → 一次性解压 → 失配

↓

结构 (D, C) → 切片 → 组合律 → 组合律定义域 = 可维持集合

↓

表示空间 → 表示维度 → 状态 / 定义域 / 值域

↓

厚度 → 可摊薄/结构厚度 → 升维 → 相对残差

↓

时间（内生/外供）→ 类型 A/B/C/D → 层≈步数 → 时间换维度

↓

能力边界（最小切片）→ 涌现（阈值/相变）

第三部分 测量与实验

第六篇 · 容量不能替代数据的更新

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23503049

语言升维下的失配测量（**scaling vs** 持续学习：一个弱结论）

> 论文系列 · 第二章

> **DOI: https://doi.org/10.5281/zenodo.23503050**

> 版本：v2（2026-10-22 增补「维度与贴合」一节，见第四·五节）

> 第一章：《现在的 AI 为什么不是生命》（DOI: https://doi.org/10.5281/zenodo.23488543）

摘要

第一章提出：生命是「被维持的解压」，AI 是「一次性的解压」，并预测冻结模型会因语言升维出现**相对失配**。

本章给出测量，并**在过程中自我修正了两次方法错误**：

（1）先用「旧模型 vs 纯新模型」测，发现正反向幅度接近（+0.108 vs +0.128）⇒ 对称差异，测不出"落后"；

（2）改用**累积参照系**（旧模型 vs 懂全部年份的模型），失配随截止年变晚单调下降

（+1.026 → +0.721 → +0.322 bits/token），但对照也显著为正 ⇒ 混入「数据量」效应；

（3）最后用**等数据预算对照**（三个模型训练数据量相同，只差数据新旧），分离出概念新鲜度的独立效应：

只用最近数据的模型在 2024 测试集上比只用最早数据的模型好 **0.405 bits/token**（同样数据量），

而混合新旧数据的模型在旧测试集上几乎不损失（13.655 vs 13.659）。

并进一步做了**容量补偿实验**：把模型容量从 2 阶提到 6 阶（带插值 n-gram），

旧数据与混合数据的差距稳定在 **+0.86~0.94 bits/token**，未见缩小

⇒ 在本设置下**未见容量补偿效应**（弱结论：不构成对 scaling 的否定，需 transformer 复核）。

结论：**语言是累积升维的 —— 加新概念不丢旧概念。因此正确的更新是「累积/混合」而不是「替换」：

替换会遗忘（只用新数据时旧语料 13.800 vs 13.659），冻结则停在训练时刻。

持续更新的最优策略 = 混合新数据、保留旧能力。** 全部脚本可复现。

一、问题

若语言随时间增加新的「维度」（新概念、新用法）

⇒ 冻结在训练时刻的模型，对这些新维度没有行为谱

问题：

① 这个差距有多大？

② 它来自「概念新旧」还是「数据多少」？

③ 加模型容量（参数）能不能补偿？

④ 正确的更新方式是什么：替换还是累积？

二、数据与方法

数据：arXiv cs.AI，2018 / 2020 / 2022 / 2024 各 3000 篇（标题+摘要），共 12000 篇。

抓取：`502_fetch_arxiv.py`。

两次自我修正（方法）

初始（504）：旧模型 vs 纯新模型 —— 正反向对称 ⇒ 错误，测不出落后

修正一（505）：累积参照系 —— 方向对了，但有数据量混淆

修正二（506）：等数据预算 —— 三个模型数据量相同，只差新旧

容量实验（507/508）

固定数据量 N=1800 篇；把 n-gram 阶数 2→6 作为容量代理

508 用 Jelinek-Mercer 插值，使高阶更稳

比较 OLD / MIX / REC 三组在 2024 留出集上的 bits/token

三、结果

3.1 升维速率的词层面代理（`**501_vl_newterm.py**`）

2018 vs 2024（6 年）：新词占比 **7.30%**（≈ **1.2%/年**），新概念 7787 个。

新概念 Top：large language, llms, prompting, rag, generative ai,

vision-language models, retrieval-augmented, gpt-4o 等。

3.2 等数据预算对照（核心结果，`**506**`）

bits/token（三者数据量完全相同）：

| 模型（数据量相同） | 2024 测试集 | 2018 测试集 |

|---|---|---|

| A 只用最早年份（2018） | 14.026 | 13.659 |

| B 混合全部年份 | 13.742 | 13.655 |

| C 只用最近年份（2024） | **13.621** | 13.800 |

① C 比 A 在 2024 测试集好 0.405 bits/token（数据量相同）

⇒ 概念新鲜度有**独立价值**

② B（混合）新测试 13.742，旧测试 13.655 ≈ A 的 13.659

⇒ 混入新数据：新数据变好，旧能力不丢 ⇒ **更新有净收益**

③ C 在旧测试集变差（13.800）

⇒ 只用新数据会遗忘旧概念 ⇒ **替换有代价**

3.3 容量补偿实验（**`508`**，带插值）

最大阶 OLD MIX REC OLD−MIX

2 10.712 9.774 9.505 +0.938

3 10.946 10.059 9.808 +0.888

4 11.011 10.143 9.901 +0.868

5 11.029 10.169 9.931 +0.860

6 11.035 10.178 9.942 +0.857

① OLD−MIX 差距几乎不变（0.938 → 0.857）

⇒ 加大容量**没有补偿**「数据太旧」

⇒ 弱结论：本实验设置下未见容量补偿（不构成对 scaling 的否定）

② REC 在新语料上最好（9.94），但旧语料会变差（见 3.2）

3.4 累积参照系（**`505`**，作为方法展示）

| 截止年 | M（新测试） | M_ctl（旧测试） |

|---|---|---|

| 2018 | +1.026 | +0.808 |

| 2020 | +0.721 | +0.459 |

| 2022 | +0.322 | +0.151 |

M 单调下降（知道得越多，落后越少）；

但 M_ctl 也为正 ⇒ 数据量混淆 ⇒ 必须用 3.2 的等预算对照才能分离。

四、结论

① 语言升维真实存在：6 年跨度，概念新鲜度的独立价值约 0.4 bits/token

② 但很慢（词层面约 1.2%/年）；冻结模型的失配是缓慢累积的，不是断崖

③ 加容量补不了数据旧（**弱成立**，见下方三档）

④ 语言是**累积**升维的：加新概念不丢旧概念

⇒ 正确的更新是「累积/混合」，而不是「替换」

⇒ 冻结 = 一次性解压；替换 = 单维度解压；累积 = 维持解压

—— 最后这一条，正好对应第一章「生命 = 被维持的解压」的条件

结论强度三档（本文只主张第二档）：

强：参数不能替代新数据 —— 需要 transformer 级证据，本文未达到

弱：在本实验设置下未见容量补偿 —— 本文主张的就是这一档

零：scaling 无效 —— 本文没有任何证据支持，不主张

「弱结论」代表什么（不是文字游戏，要写清楚）

它代表：数据更新与模型扩容是两个**不同的杠杆**，在本设置下不能互相替代。

· 不代表「scaling 无效」——scaling 在固定数据分布内仍然有效

· 不代表「参数越多越坏」——只表示多出来的参数换不来对陈旧数据的补救

· 代表：失配是「数据面」的问题，不是「参数面」的问题

⇒ 若语言持续累积升维，正确对策是**更新数据（混合）**，

而不是只把模型做大

现实含义：

只扩模型不更新数据的策略，会在新语料上持续落后约 0.4~0.9 bits/token

科学含义：

「持续学习」不能简化为「把参数加够」——

维度（概念）的增长需要新数据来承载，参数只是接收器。

边界（再次声明）：

以上是 n-gram 容量代理下的**弱结论**；transformer 级验证前，

不能推广为「越大越没用」。

四·五、维度与贴合：一个补充讨论 [推测]

> 本节为 v2 新增，是**推测性讨论**，不改变前文任何实证结论；其中「有效维度」尚未测量。

一个经验事实：**某些小模型在特定领域强于更大的模型。** 如果能力只由「总维度（规模）」决定，这不该发生。这说明需要区分两个量：

覆盖（总维度）：模型能表示的结构总量 —— 由规模/容量决定

贴合（有效维度）：这些维度中，真正对准目标结构的部分 —— 由数据与训练分布决定

由此可以同时解释三个现象：

1. **升维仍持续带来能力提升**：覆盖在变广，更多结构类「够得着」⇒ 平滑上涨。

2. **能力会「突然出现」**：具体能力对应「某个结构是否被覆盖到」，是阈值式的（0/1），所以表现为跳变，而非渐变。

3. **小模型在窄领域反超**：它的覆盖小，但可以把维度集中对准该领域的少数关键结构 ⇒ 局部贴合度更高。

回到本文的结论：**容量是接收器，数据决定方向。** 加大容量能扩大覆盖，但不能把维度「对准」新数据带来的新结构；这正是「容量不能替代数据更新」的另一种说法——数据决定有效维度，容量只决定这些维度能展开到多大。

可检验的预测（尚未做）：若能用表征方法测量「有效维度」，则当某任务所需结构维度 k 大于模型的覆盖维度时，该能力不应出现；一旦覆盖维度越过 k，能力应阈值式出现。这需要一个可操作的有效维度度量——这是下一章留下的问题。

五、限制（必须与结论一起读）

· 仅一个领域（cs.AI）、一个来源（arXiv 摘要）

· n-gram 是极简语言模型：测的是词级概念失配，不代表大模型语义/推理层面的失配

· 容量代理 = n-gram 阶数，不是真正的参数量；高阶 CE 仍偏大（插值 λ 固定）

⇒ 容量结论只能算初步证据，需 transformer 小模型复核

· 等预算控制的是训练文档数（非 token 数）；采样只用一个随机种子

六、可复现

python 502_fetch_arxiv.py cs.AI 2018 2024 # 及 2020/2022

python 501_vl_newterm.py <语料根> 6 # 新概念率

python 504_series.py <2018> <2020> <2022> <2024> # 对称性检验（展示错误）

python 505_cumulative_mismatch.py <四年目录> # 累积参照系

python 506_equal_budget.py <四年目录> # 等预算对照（核心）

python 507_capacity_vs_data.py <四年目录> # 容量初探（无回退）

python 508_backoff_capacity.py <四年目录> # 容量补偿（带插值）

作者：何淇（独立研究者）；AI 协作：DeepSeek

第七篇 · 替换与累积

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23503559

摘要

当前 AI 领域有三个看似独立的热点争议：**模型崩塌**（用模型生成的数据训练导致退化）、

压缩陷阱（追求压缩可能牺牲真相）、**scaling vs 持续学习**（堆参数还是持续更新）。

本文指出：这三者是**同一个问题的三个侧面** ——

语言是累积升维的；替换（而非累积）会切断维度生长。

（1）模型崩塌 = 用模型生成的数据**替换**人类数据 ⇒ 累积链被切断 ⇒ 维度退化；

（2）压缩陷阱 = 压缩的对象是**有损的人类语言**，最省编码不等于最符合世界；

（3）scaling vs 持续学习 = 容量只能接收维度，不能生成维度；第二章实测表明容量无法补偿数据陈旧。

由此得到一个可检验推论：**人类数据与模型数据的混合比例不应完全替换**

（纯合成数据 = 替换 = 崩塌；混合 = 累积 = 维持）。本文给出该推论的测量方案。

一、三个热点，一个结构

① Model collapse（Shumailov et al. 2023）

合成数据递归训练 ⇒ 分布尾部消失、多样性退化

现有解释：误差累积、分布估计漂移

② Compression trap（Rae 2024 等）

追求压缩 ⇒ 模型可能选"更简单但更不真"的理论

现有解释：目标函数与真理的偏离

③ Scaling vs continual learning

规模是否还有效？何时必须持续更新？

现有争论：benchmark 上升 vs 分布漂移风险

它们的共同点被忽略了：三者都发生在「语言是累积的」这一事实上。

二、统一框架：累积与替换

第一章的定义：生命 = 被维持的解压；AI = 一次性的解压。

第二章的实测：语言在累积升维（约 1.2%/年），且——

等数据预算下，混合新旧数据的更新有净收益且不遗忘；替换会遗忘。

把这一点推广到三个热点：

① 模型崩塌 ≈「替换」的极端情形

人类数据被合成数据替换 ⇒ 维度不再从真实世界增长

⇒ 分布尾部（= 稀有维度）首先消失 ⇒ 崩塌

⇒ 预测：混合比例越高（人类:合成 > 0），崩塌越慢；

纯合成 = 替换 = 最快崩塌

② 压缩陷阱 ≈「有损源」的必然结果

语言是世界的**有损投影**（第一章已述）

⇒ 在语言上最优的压缩，无法保证对世界为真

⇒ 压缩目标本身不携带"求真"约束

③ scaling vs 持续学习 ≈「接收器 vs 生成器」

参数是维度的**接收器**；概念维度的**生成**来自数据

⇒ 容量补不了数据陈旧（第二章弱结论）

⇒ 不是"哪个更重要"，而是"两者缺一不可"

三、可检验推论

推论 A（模型崩塌的混合比例实验）：

用同一基座模型，分别以 0% / 25% / 50% / 100% 的人类数据替换为合成数据

递归训练 k 代，测量：

· 生成分布的尾部覆盖率（稀有词/新概念保留率）

· 与真实人类语料的交叉熵

⇒ 预测：纯替换组崩塌最快；混合组按人类比例延缓

推论 B（压缩陷阱的语言层检验）：

在"只压语言"与"语言+可干预测量"两种设置下训练

⇒ 预测：只有后者能在新概念出现时保持对世界的校准

推论 C（scaling vs 累积）：

等算力预算下：加大模型 vs 混入新数据

⇒ 第二章已给初步答案：容量不能替代数据（弱结论）

四、为什么这个统一值得说

· 三个热点各自有文献，但没人把它们归到同一个结构（累积 vs 替换）

· 它给出可操作的实践含义：合成数据必须与人类数据**混合**，不能替换

· 它和第一、二章形成闭环：

第一章（定义：被维持的解压）

第二章（测量：累积最优，容量补不了数据）

第三章（应用：三个争议是同一件事）

五、限制

· 本文是立场/框架文章，未包含模型崩塌的原始实验

· "混合比例"推论需实验验证（本文只给方案）

· 三个热点的文献各自庞大，本文只取与"累积/替换"直接相关的部分

六、结论

模型崩塌、压缩陷阱、scaling vs 持续学习不是三个问题，

而是「语言累积升维、替换切断累积」的三种表现。

⇒ 正确的做法不是"更多合成数据"或"更大模型"，

而是**保持人类数据与真实世界的累积通道**。

作者：何淇（独立研究者）；AI 协作：DeepSeek

第八篇 · 结构换算力：混合对齐语料与样本效率

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23542969

摘要

当缩放（scaling）的成本越来越高，效率竞赛还有另一条少被系统化讨论的路：**不改模型、不改数据量，只改语料的结构。** 本文提出并检验一个工程假设：模型的样本效率不只取决于语料的数量，更取决于语料的结构。人类儿童同时通过语言与和世界的交互学习；当前训练语料则大多按通道切分——纯文本、纯图像、纯结构化数据各学各的，通道之间没有对齐。

我们用一个合成世界做受控实验。同一批事件，构造三种语料：第一，纯文字，只有句子；第二，混合对齐，句子加世界状态标签（物体大小、动作结果），插在对齐位置；第三，混合打乱，标签随机配到别的事件，作为控制。用插值 n-gram 模型在三种语料上训练，再**只给文字**做探针测试。

结果：混合对齐语料在 200 个事件时就学到「动词到大小」的接地（准确率 1.000）和「文字加大小到结果」的规则（1.000）；纯文字语料到 3200 个事件仍然只能瞎猜（0.500）或停在多数类基线（0.765）。打乱对齐的控制组掉回随机附近（0.333 到 0.722），说明收益来自**对齐**，不是来自标签变多。同时，语言建模的 bits/token 没有变差（0.79 到 0.81）。

结论：**在语料总量不变的前提下，把多通道信息对齐地混进同一份语料，可以用更少的样本学到更多结构，而且不牺牲语言能力。** 本文定位于**一个设想加一次原理验证**：合成世界上的证据只用来把话说清楚；真实多模态数据上的验证，留给愿意做的人。

更直白地说：更少的数据，更多的结构；在本文设置下，这还意味着更高的任务准确率——200 个事件即达到 1.000，而纯文字语料即使到 3200 个事件仍停在基线（0.500 与 0.765）。这里的"更强"指任务层面的结构可达性，不指通用能力上限。

一、问题

当前训练语料按通道切分：

第一类是文本语料，即语言对世界的投影；第二类是图像与视频语料，即视觉对世界的投影；第三类是结构化数据（数据库、仿真状态、执行结果），即逻辑对象与因果的投影。

每个通道都是世界函数 S 的一个投影 P_i(S)；单独一个投影是不完整的。模型要恢复更高维的结构，需要同一结构被多个通道同时记录，并且对齐：同一个对象、同一时刻、同一个事件。

人类儿童的学习方式正是如此：语言、视觉、触觉、与他人的交互同时发生，词与对象、动作与后果当场对上。本文问一个可测的问题：在总数据量相同的前提下，对齐的多通道语料能否比单通道语料学到更多结构？

二、受控实验设计

2.1 合成世界

物体有三个属性：形状属于「球、方块」，颜色属于「红、蓝」，大小属于「小、大」。动词编码大小：表示小的动词有「拿起、托起、捧起」；表示大的动词有「扛起、抬起、抱起」。事件句子是「他＋动词＋了＋颜色＋的＋形状」。结果规则是：成功当且仅当形状是球，或者大小是小。关键设定：文字里只有形状，没有「大小」这个词；结果也不在文字里。

2.2 三种语料（同一批事件）

第一种，纯文字：只有事件句。第二种，混合对齐：事件句，且在动词后插入大小标签、句末插入结果标签。第三种，混合打乱：同第二种，但标签来自随机另一个事件，作为控制组。

2.3 探针（测试时只输入文字 **token**）

第一个探针测接地：输入「他、动词」，输出大小，瞎猜基线为 0.50。第二个探针测结构：输入文字加真实大小标签，输出结果，多数类基线为 0.75。第三个探针测语言：在纯文字留出集上算 bits/token，越低越好。

2.4 模型与预算

插值 n-gram，阶数 6，插值系数 0.5，纯 Python 实现。事件数取 200、800、3200 三档，各跑 3 个随机种子取平均。

三、结果

事件数为 200 时：纯文字语料，接地 0.500，结构 0.765，语言 bpt 0.81；混合对齐语料，接地 1.000，结构 1.000，语言 bpt 0.81；混合打乱语料，接地 0.333，结构 0.807，语言 bpt 0.83。

事件数为 800 时：纯文字语料，接地 0.500，结构 0.765，语言 bpt 0.79；混合对齐语料，接地 1.000，结构 1.000，语言 bpt 0.79；混合打乱语料，接地 0.333，结构 0.759，语言 bpt 0.79。

事件数为 3200 时：纯文字语料，接地 0.500，结构 0.765，语言 bpt 0.79；混合对齐语料，接地 1.000，结构 1.000，语言 bpt 0.79；混合打乱语料，接地 0.722，结构 0.776，语言 bpt 0.79。

三个观察：

第一，样本效率。混合对齐在 200 个事件就学会了接地与规则；纯文字到 3200 个事件仍然没有这两个概念。

第二，对齐是关键。打乱标签后两个探针掉回随机或基线附近，说明收益来自通道与事件的对齐，不是来自多了几个 token。

第三，语言没有受损。三种语料的语言 bpt 在同一水平（0.79 到 0.81），混入通道标签没有牺牲语言建模。

四、为什么有效（机制讨论）

第一，一个样本同时监督多个通道。同一事件里，句子、大小、结果同时出现，每份数据的信息产出更高。

第二，相互消歧。文字里没有大小，但动词与大小相关；通道把这个相关性钉死，模型于是学会从文字推断世界状态，这就是接地。

第三，结构可迁移。从「动词到大小到结果」学到的规则，可以在新组合上直接使用（探针使用的是留出事件的文字）。

一句话：混合对齐语料把语言监督和世界监督合并成同一份样本，而不是各训练一遍。

四·五、课程顺序：按结构依赖的拓扑序学

还有一个隐含的机制，本文的实验没有直接测，但值得单独说：对齐解决的是"通道"问题，**顺序**解决的是"难度"问题。两者叠在一起，才有"像小孩一样学"的效果。

人类儿童的发育顺序不是随机的：先建立对象（哪些东西是同一个东西），再建立关系（谁在哪、什么连着什么），再建立动作与后果（做什么会怎样），最后才是用语言去指这些东西。这个顺序不是教育者的偏好，而是结构本身的依赖顺序——上层结构依赖下层结构，反过来不成立。

因此一个自然的预测是：同样的对齐语料，如果按依赖关系排序喂给模型（课程），会比随机顺序学得更快。理由有三条。第一，每一步的有效假设空间小得多，模型只需要学当前这一层。第二，每一层都有对齐通道直接监督，不靠语言间接推断。第三，上层结构建立在下层已验证的结构上，不会因为底层错了而推倒重来。

换句话说：**对齐让样本变"厚"，课程让学习变"省"。** 本文的合成实验只验证了前者；后者是一个可测但未测的预测，列在第七节的验证清单里。

五、局限（必须与结论一起读）

第一，合成世界：规则简单、无噪声、通道是标签而不是真实视觉或动作。

第二，模型是 n-gram：只验证原理，不代表 transformer 或真实多模态数据。

第三，对齐由实验者构造：真实数据中的对齐（时间、对象、指代）本身是难点。

第四，没有测分布外泛化与长期使用中的漂移。

六、可复现

脚本为 700_mixed_corpus_experiment.py（初版）、701_mixed_corpus_v2.py、702_mixed_corpus_v3.py、703_mixed_corpus_v4.py（最终版）。运行方式：python 703_mixed_corpus_v4.py。依赖：Python 3 标准库，无第三方。

七、给后来者的验证清单

本文到此为止，不做更多实验。以下问题留给愿意验证的人。

第一，真实数据：用 Ego4D、AI2-THOR、Open X-Embodiment 等已对齐数据，做同样的「混合对齐对单通道」对照，看增益是否还在。

第二，规模：从 n-gram 换到小 transformer，看样本效率增益随规模的变化。

第三，对齐质量：人为引入错配率（0%、10%、30%、50%），画出「错配率到增益」的曲线。

第四，通道独立性：加入冗余通道（同一信息的另一种编码），检验增益是否消失（预期：冗余通道不带来增益）。

第五，结构类型：换不同类型的规则（因果、层级、时序），看哪类结构最依赖外部对齐通道。

第六，理论：给出一个粗略的样本复杂度表达式，把对齐带来的互信息与样本效率联系起来。

第七，课程顺序：同一套对齐语料，按结构依赖的顺序喂（对象、关系、动作与后果、语言）与随机顺序对照，比较各自的样本效率。这一条检验的是第四节·五的预测。

如果有人在真实数据上重复出方向一致的增益，这个设想才算立住；如果重复不出，本文就是错的。两种结果都有价值。

附：推测与边界

「真实多模态数据上同样有效」是 [推测]，本文未测。「对齐质量决定收益大小」是方向性判断，需要真实数据上的对照。本文不主张语料结构可以完全替代数据量，只主张同量下结构更好、样本效率更高。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第九篇 · 颜色作为第一块积木：感知基元与语言对齐的最小实验

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23551953

摘要

如果要把视频与音频变成可训练的结构化语料，第一步不是训练更大的模型，而是先回答一个更小的问题：**一个感知基元，能不能只靠"语言 + 感知通道"的对齐被学到？** 本文选颜色作为最小测试场——它是唯一同时具备物理定义（波长/色相）、感知分解（色相、饱和度、明度）与简单语言标签（基本颜色词）的感知基元。

我们用 12 个基本颜色词的 HSV 样本构造三种语料：纯文字（只有颜色词与关系句）、对齐（颜色词与 HSV 分箱坐标双向配对）、打乱（坐标随机配到别的词，作为控制组）。用插值 n-gram 在三种语料上训练，再做三个探针：词到坐标（P1）、坐标到词（P2）、关系判断（P3，暖或冷）。

结果三种语料一致：关系判断都能学会（约 94% 到 100%）；但坐标到词只有对齐语料学得会（约 86% 到 91%），纯文字为 0，打乱组掉回随机水平（约 8% 到 11%）；词到坐标在对齐语料下为 31% 到 44%，受分箱噪声限制，不是满分。结论是：**颜色可以作为感知基元被对齐语料接地；纯文字只能学关系，不能接地；收益来自对齐本身，而不是多给了 token。**

本文是一次原理验证，世界与模型都是合成的；它要回答的不是"AI 能不能看懂颜色"，而是"感知基元接地这件事，最小可测的形式是什么样"。这个问题一旦成立，视频与音频按事件切分后走同一条路才有依据。第四节之后我们补一节说明它的意义：如果感知基元能被对齐接地，那么"模型自己挖视频、自己造对齐语料、再让自己贴合文字维度"这条自训练路径，就有了最底层的第一个例子。

一、问题

视频与音频是下一座数据矿。但"把视频变成语料"不是工程问题，而是定义问题：先要定义一个单位（一件事），再让画面、声音、文字在同一条时间轴上对齐。

在定义那个大单位之前，值得先验证一个更小的单位：**感知基元**。问题可以写成一句话：给一个感知基元配上它的语言标签，模型能不能学到"词与感知坐标"之间的映射？

颜色是合适的起点，原因有三条。第一，它可以被精确定义：色相是一个 0 到 360 度的连续量，可以离散成有限个区间。第二，它可以被分解：色相、饱和度、明度三个维度，正好是一个小的、可枚举的结构。第三，它有简单的语言标签：基本颜色词在几乎所有语言里都存在，不需要标注员发明新词。

如果连颜色都接地不了，更大的事件就不用谈了；如果颜色能接地，它就可以作为第一块积木，往上叠物体、动作、事件。

二、实验设计

2.1 合成世界

取 12 个基本颜色词：红、橙、黄、绿、青、蓝、紫、粉、棕、灰、黑、白。每个词给定一个 HSV 锚点。采样时在锚点附近加噪声：色相正负 15 度，饱和度与明度各正负 0.15 并截断到 0 到 1 之间。

感知坐标离散成三个分箱词元：色相分成 12 个区间（每 30 度一格），饱和度分成低、中、高三档，明度也分成低、中、高三档。于是每个颜色点对应三个坐标词元，共 108 种组合。

2.2 三种语料

三种语料使用同一批事件。

第一种，纯文字：句子是"颜色是某词"，外加关系句"某词比某词更暖"或"更冷"。关系由锚点的色相决定：越靠近橙色越暖。纯文字语料里没有任何坐标词元。

第二种，对齐：每个事件出现两次。第一次是"颜色是某词"后接三个坐标词元；第二次是"坐标"加三个坐标词元再接"对应某词"。这样词到坐标、坐标到词两个方向都有监督。

第三种，打乱：与对齐相同，但坐标词元随机配到别的事件上，作为控制组。

2.3 探针

三个探针，测试时只给其中一种信息。

第一个探针测接地方向一：给"颜色是某词"，依次预测三个坐标词元，三个全对才算对。随机水平约为 1/108。

第二个探针测接地方向二：给"坐标"加三个坐标词元加"对应"，预测颜色词。随机水平约为 1/12。

第三个探针测关系：给"某词比某词更"，预测"暖"或"冷"。随机水平为 0.5。

2.4 模型与预算

插值 n-gram，阶数 6，插值系数 0.5，纯 Python 实现。样本数取 200、800、3200 三档，每档跑 3 个随机种子取平均。

三、结果

样本数为 200 时：纯文字语料，三个探针分别是 0.000、0.000、0.939；对齐语料，分别是 0.389、0.864、0.939；打乱语料，分别是 0.056、0.096、0.939。

样本数为 800 时：纯文字，0.000、0.000、0.985；对齐，0.444、0.904、0.985；打乱，0.028、0.111、0.985。

样本数为 3200 时：纯文字，0.000、0.000、1.000；对齐，0.306、0.907、1.000；打乱，0.111、0.077、1.000。

三个观察。

第一，接地需要对齐。坐标到词，对齐语料在 200 个事件时就达到 86% 以上，到 3200 个事件约 91%；纯文字语料在三个档位都是 0，因为它从来没有见过坐标词元，也就没有可学的东西。

第二，收益来自对齐，不是来自 token 变多。把坐标打乱之后，坐标到词掉回 8% 到 11%，接近 1/12 的随机水平；词到坐标掉回 3% 到 11%。同样多的数据、同样多的 token，只是配错了对象，就学不到东西。

第三，关系不需要感知。关系探针在三种语料下都接近满分（94% 到 100%），因为关系句本来就在文字里。这说明文字擅长的是"词与词的关系"，不擅长的是"词与感知坐标的对应"。两者的分工在数据里就已经决定了。

词到坐标没有达到满分（31% 到 44%），原因是噪声。采样时颜色点在锚点附近抖动，靠近分箱边界的点会落到相邻格子里；从词预测一个唯一的坐标格，本质上是在一个模糊的分布里猜众数，不可能全对。坐标到词的准确率高，是因为反方向是"从具体坐标找词"，边界情况少得多。

四、解释

为什么颜色可以被接地，而纯文字不行？用解压的说法：文字是"词与词之间关系的压缩"，它不携带感知坐标；坐标是"感知的外部记录"，它不携带词与词的关系。两者各自不完整。对齐语料做的是同一件事被两个通道同时记录，于是词与坐标之间的映射被直接监督出来。

这与第 9 篇《结构换算力》的结论一致：混合对齐语料在 200 个事件就学会了规则，纯文字到 3200 个事件仍然学不到，打乱后收益消失。区别只在于第 9 篇的规则是符号规则（动词编码大小、形状决定结果），本文的规则是感知坐标（色相、饱和度、明度）。两个实验共同说明：**对齐让语言多出一条接地的通道，这条通道不是文字自己能长出来的。**

还要补一句：这种对齐扩充的不是语言的词表，而是语言在某个维度上的贴合。词还是那 12 个词，覆盖没有变；变的是每个词后面有了可落地的坐标，于是同样的词可以指称得更细、比较得更准。用第 2 篇的话说，这是贴合变深，不是覆盖变广。但贴合足够深的时候，语言能表达的东西就变多了——这可以算作语言在该维度上的一次缓慢扩充。

五、局限（必须与结论一起读）

第一，世界是合成的：HSV 锚点、噪声、分箱都是人为设定，不是真实图像。真实图像里还有光照、材质、语境、色恒常性，本文都没有覆盖。

第二，模型是 n-gram：只验证原理，不代表 transformer 或真实多模态数据。n-gram 的容量小，因此在更复杂的基元上结论可能不同。

第三，颜色命名本身不是完全客观的：不同语言对颜色的切分不同（例如有些语言区分两种蓝），本文只用了单一语言的 12 个基本颜色词。

第四，探针是构造的：词到坐标的 31% 到 44% 一部分来自分箱噪声，不能直接读成"模型对颜色的理解程度"。

六、可复现

脚本：714_color_grounding.py。运行方式：python 714_color_grounding.py。依赖：Python 3 标准库，无第三方。输出：数据-颜色接地-第一轮.txt。

七、意义：自训练与视频挖掘的第一步

这个实验小，但它说明了一件有后续的事：**对齐语料可以自己造出来。**

回看实验里的对齐语料是怎么来的：每个事件都有「感知坐标」这一侧。颜色场景里，坐标来自 HSV 的数值定义，可以程序生成。把这个模式放大，就得到一个循环：模型先对视频/音频给出描述（文字），再用可验证的通道（坐标、时间戳、动作结果）检验描述，检验通过的部分沉淀为对齐语料，回灌训练。这不是新的训练方法，但它是"用模型自己挖数据、再让自己贴合文字维度"的闭环——也就是自训练的一种具体形态。

为什么是"贴合文字维度"？因为对齐的目标不是让模型记住颜色值，而是让感知坐标落进语言已经建好的坐标系里：词是坐标的标签，坐标是词的锚点。落到语言坐标系上的感知，才能被语言调用、被推理使用、被组合成更复杂的结构。第 2 篇说过，模型的问题是"覆盖广而贴合浅"；对齐语料补的恰恰是贴合——把感知这一维度接到文字已有的维度上。

再往下一步，就是视频。视频是"没有被结构化的数据"：量巨大，但缺少语言锚点。如果按本文的最小结论外推，可行的第一步是给视频片段配上语言描述（旁白、语音、自动描述），再用时间轴对齐；每一步都只需要验证一个更小的单位是否被接地。颜色是第一块积木；物体、动作、事件是后面的积木。积木一块块叠上去，才谈得上"事件级的对齐语料"。

这一节是 [推测] 与方向判断，本文没有验证自训练循环本身；本文只是在这个最底层的假设上迈了一小步——感知基元可以被对齐语料接地。如果连这一点都不成立，整条路就不用谈了；它成立，后面的路才有讨论的意义。

附：推测与边界

颜色能被接地，不等于更高的感知基元（形状、材质、动作、事件）也能同样容易接地；这是 [推测]，需要逐个测。真实视频上的推广、以及"感知基元 + 事件层级"的组合，本文都没有测。

本文不主张"颜色是理解世界的关键"，只主张"颜色是验证接地机制的最小单位"。它成立，才有资格谈下一块积木。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第十篇 · 生长与记忆：自指更新与维持的最小实验

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23569774

摘要

本文做两个最小实验，对应生命定义里的两个条件：**自指更新**（会变、规则在里面）与**被保住**（在环境里维持住）。

实验一测"记忆"：一个微型多模态模型自己生成数据、验证器筛选、回灌训练，并在引入新任务时比较四种回放策略。结果：只学新会遗忘（旧任务 0.720），固定回放能保住（1.000）但新任务学得慢（0.740）；先试训一步再决定回放比的"前瞻"策略，在探测足够敏感时同时保住旧任务（0.983）和新任务（0.850）。

实验二测"生长"：模型由固定主干加可增长的维度槽组成，任务从图像属性（颜色、形状、数量）推进到一个只能从新模态（文本向量）读取的任务。结果：不生长的模型学不会新模态（0.34 到 0.38，接近瞎猜）；生长的模型能加槽并学会（0.91 到 0.94）；但只有生长没有回放会忘光旧任务（0.00），只有回放没有生长学不会新模态。两者叠加时，旧任务保住 0.78 到 0.80，新模态达到 0.94。

两个实验合起来说明：**没有"生长"就没有新维度，没有"记忆"就守不住旧维度；定义里的两条条件不是并列的装饰，而是必须同时在场的两个机制。**

本文全部是玩具规模的原理验证：合成世界、微型模型（约一万参数）、CPU 可复现。它证明的是"机制可测"，不是"数字生命已被造出"。

一、问题

我们在第一篇里把生命定义为：在宇宙的可函数化部分 P 中、被宇宙保住的（可维持的）自指结构。拆开是两条：**会自己变**（自指更新）与**被保住**（维持）。

这两个词在论文里好写，在实验里难测。本文把它们各做成一个可测的最小实验，回答两个问题：

第一个问题：一个会自己生成数据、自己验证、自己回灌的系统，在任务变化时能不能既学到新的、又保住旧的？

第二个问题：当任务需要新的输入通道时，系统能不能自己长出新的维度？长出来之后还能不能维持旧的？

两个问题都是"能不能"，不是"有多好"。玩具规模足够，因为我们要测的是机制是否存在。

二、实验一：记忆与取舍

2.1 设定

世界是合成的：8×8 的图，含颜色（4 种）、形状（2 种）、数量（1 到 3）。模型是两层的小网络，约一万参数。任务按轮次变化：前 5 轮学颜色和形状（旧任务），第 6 轮起只出数量题（新任务）。

闭环是这样转的：模型对随机图片自己作答；规则验证器判对错；验证过的样本进入记忆库；每轮从记忆库和新样本里按某个比例抽样训练；每轮在留出集上测旧任务与新任务。

对照组只改一件事：回放比例怎么定。

第一组"只学新"：完全不回放。

第二组"固定回放"：新旧各一半。

第三组"反应式控制器"：看旧任务准确率，掉了就加回放。

第四组"前瞻控制器"：训练前先复制一份模型，用新样本试训几步，看旧任务会掉多少，再决定回放比。

2.2 结果

最后一轮（同样的热身、同样的预算）的结果是：只学新，旧任务 0.720、新任务 0.797；固定回放，旧任务 1.000、新任务 0.740；反应式控制器，旧任务 0.965、新任务 0.762；前瞻控制器（敏感探测），旧任务 0.983、新任务 0.850。

前几轮三组都接近满分，差距出现在新任务引入之后。只学新的那一组旧任务一路掉到 0.720；固定回放那一组旧任务几乎不动，但新任务涨得慢；前瞻控制器在第 6 轮就测出强冲突，及时把回放提到 0.8，于是旧任务几乎没掉，新任务还学得最快。

2.3 结论

第一，遗忘是真实的：同一个小模型，学了新任务就会丢旧任务，这和第三篇《替换与累积》的预测一致。

第二，"先试一步再决定"是有效的：它本质上是用自己的模型预测自己改动后的后果。探测越敏感，越早发现冲突，越能提前防守。这是"自指"的一个具体动作，而不是哲学说法。

第三，没有单一最优：固定回放押旧任务，前瞻策略押新任务，反应式在中间。它们是取舍前沿上的不同位置，选择哪一个取决于你想保住什么。

三、实验二：维度生长

3.1 设定

世界有两个模态：图像（8×8，含颜色、形状、数量）和文本（10 维向量，前三维决定一个标签，其余是干扰）。任务按顺序来：先学颜色的图像任务，再学形状、数量，最后学一个只能从文本里读到的标签任务。

模型是固定主干加可增长的维度槽。每个槽是一个小投影，属于某个模态；槽的数量从 1 开始，最多 4 个。生长规则是：任务准确率不够时，从"解释不了的样本"里提议加一个新槽，训练一小段，如果提升超过 0.02 就保留，否则回滚。

对照组仍然只改两件事：允不允许生长、允不允许回放。

3.2 结果

最终四个任务（颜色、形状、数量、标签）的准确率：不生长不回放，0.00、0.00、0.08、0.38；生长不回放，0.00、0.00、0.03、0.91；不生长回放，1.00、1.00、0.69、0.34；生长加回放，0.78、0.80、0.48、0.94。

3.3 结论

第一，新模态必须靠生长：不生长的两组在标签任务上都停在瞎猜附近（0.34 到 0.38），因为它们根本没有能读到文本的通道；生长的两组都学会了（0.91 到 0.94）。

第二，旧任务必须靠记忆：不回放的两组在学完标签任务后，前面的任务全部掉到 0.00；回放的两组保住了大部分。

第三，两个机制的叠加才有效：生长加回放同时拿到了旧任务 0.78 到 0.80 和新模态 0.94，这是四组里唯一"两个方向都站得住"的。

四、两个实验合起来说明什么

实验一说明：会变的东西会忘，要靠记忆与取舍把它按住。

实验二说明：要长出新维度，就得真的加结构；但加了结构，旧结构更容易被冲掉。

合起来就是定义里的两句话：

> 自指更新，是被逼出来的：没有新维度，就压不动新的世界。

> 被保住，是守出来的：没有记忆与回放，旧维度就会被新维度冲掉。

这两条不是并列的装饰。它们是两个必须同时在场的机制：只有生长，旧的全忘；只有记忆，新的学不了。

五、局限（必须与结论一起读）

第一，世界是合成的：图像、文本、任务切换都是程序生成的，不是真实数据。

第二，模型是玩具：约一万参数的两层网络，不是 Transformer，也不是原生多模态大模型。

第三，任务标识是手工给的：模型知道"现在问的是哪类问题"，真实场景里这本身是个问题。

第四，"生长"是有限的：只允许加几种固定的槽，不允许真正改写表示本身；更强的自指（改结构、改更新规则）本文没有做。

第五，没有真实生存约束：预算和性能下限是人为设定的，不是真实的能量与淘汰。

六、可复现

脚本：801_self_training_loop_v2.py（实验一基础版）、803_closed_loop_lookahead.py（前瞻控制器）、805_closed_loop_sensitive2.py（敏感探测）、809_dimension_growth_v4.py（实验二四组对照）。依赖：Python 3 与 numpy，无 GPU。

附：推测与边界

"把这两个机制放大到真实多模态模型上仍然成立"是 [推测]，本文没有测。真实大模型的参数更大、任务更多、生长更难（改结构代价高），本文只证明机制在小规模上存在。

本文不主张"做到了这两条就是生命"：满足条件仍可能只是工具；本文只主张，缺了这两条，一定走不到能生长又维持的形态。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第十一篇 · 语义残差的测量：文本极限与接地补齐

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23586075

摘要

本文把"语义残差"从一个模糊的说法变成一个可测的量。

先把定义写清：语言是人类对世界的压缩，语言可以写成 p语言 + R语言；p语言 是可以被函数近似的部分，R语言 只声明、不展开。语义是语言与现象之间的对齐关系；语义残差 = 这个对齐映射在给定模态组合下的误差下界。

实验用受控歧义：文本用精确词、模糊组词、省略三种方式描述同一个合成对象，歧义是程序生成的，所以"文本能给出的极限"可以解析算出来（贝叶斯底）。然后测三个量：贝叶斯底、只读文本的模型误差、以及文本加图像（接地）后的模型误差。

结果：文本模型的误差与贝叶斯底只差 1.5 到 2.7 个百分点（0.725 对 0.750；0.835 对 0.850；0.688 对 0.714），说明拟合已经到位，剩余残差来自文本本身；接地后三个属性的准确率都到 1.000，说明文本缺的那个维度被图像补上。

结论：语义残差可以定义、可以测量；它分为"该模态下的不可约底"（歧义内生的）与"可约部分"（接地/补数据能消除的）。这个区分让"AI 理解了多少语义"有了分母。

一、问题

我们之前说过两句话：语言是人类对世界的压缩；大模型压缩的是语言的 p语言。

但"p语言"与"语义"之间还缺一个可测的连接。本文要回答的问题是：能不能把"语义残差"定义成一个数，并且用玩具实验测出来？

要做到这一点，需要三样东西：一个定义（语义残差是什么）、一个参照线（文本本身能给出的极限是多少）、一个对照（补上别的模态后残差降不降）。

二、定义

2.1 沿用系列的定义

宇宙 = P + R，其中 P 是可函数化的部分，R 是不可函数化的部分。语言也写成 p语言 + R语言：p语言 可以被函数近似，R语言 只声明、不展开。生命 = p生命 + R生命，其中 p生命 是在 P 中、被宇宙保住的动态函数类。

本文只处理 p语言 这一侧。

2.2 语义是映射

把语义定义成一个映射：给定语言表达式和它对应的现象（图像、事件、状态、动作、量），语义就是"表达式 → 现象"的对应关系。

这个映射不是单层的：它按模态有多个维度——视觉维度（文字对图像）、事件维度（句子对时间线）、状态维度（描述对系统状态）、动作维度（指令对后果）、量的维度（程度词对可测量的量）。语义残差按维度出现。

2.3 语义残差

定义（语义残差）：固定模态组合 M（例如：只有文本；或文本加图像），设误差度量是预测现象属性的错误率。语义残差 = 在模态组合 M 下，任何函数能达到的最小误差。

这个定义把残差分成两部分：

- **不可约底**：由模态组合本身决定的误差下界。文本有歧义时，有些信息文本里根本没有，任何函数都补不上。

- **可约部分**：模型没拟合到位造成的差距；加数据、加容量、加模态可以降下来。

判据很直接：加手段之后误差底降不降。降 ⇒ 可约；不降 ⇒ 该模态下的不可约底。

2.4 参照线：贝叶斯底

在玩具世界里，文本的生成过程是已知的，所以"文本能给出的极限"可以解析算出来：给定一条文本，属性的后验分布由生成过程决定；贝叶斯最优预测器的正确率就是上限。

这个上限就是"文本极限"。它比任何模型都高不了；模型能接近它，就说明拟合到位了。

三、实验设计

世界：合成对象，三个属性——颜色（4 种）、形状（2 种）、数量（1 到 3）。对象渲染成 8×8 的图像（颜色、形状、数量都可见）。

文本：三个槽位拼成的描述，每个槽位都有受控歧义。

- 颜色槽：以 0.5 概率给精确词（红/蓝/绿/黄），以 0.5 概率给模糊组词（暖色 = 红或黄；冷色 = 蓝或绿）。

- 形状槽：以 0.7 概率给精确词（圆/方），以 0.3 概率省略。

- 数量槽：以 0.5 概率给精确词（一/二/三），以 0.5 概率给模糊词（几个 = 一或二）。

因为生成过程已知，每条文本对应的属性后验可以算出来，贝叶斯底也就能解析计算。

模型：两层小网络（隐藏层 32，约 2000 个参数）。文本模型只看文本加任务标识；接地模型再看图片（8×8×3 展平）。

三个量：贝叶斯底、文本模型准确率、接地模型准确率。差值是"可约残差"。

四、结果

颜色的贝叶斯底是 0.750，文本模型 0.725，接地模型 1.000。形状的贝叶斯底是 0.850，文本模型 0.835，接地模型 1.000。数量的贝叶斯底是 0.714，文本模型 0.688，接地模型 1.000。

三点解读。

第一，文本模型与贝叶斯底只差 1.5 到 2.7 个百分点。这说明模型对文本的拟合已经到位；剩下的差距不是模型不行，是文本里本来就没有那些信息。

第二，接地之后三个属性都到 1.000。图像提供了文本缺的那个维度，残差被补齐。所以"文本极限"下的那部分残差，属于该模态组合，不属于世界：换一个模态组合，它可以被消掉。

第三，由此得到的语义残差是分层可测的：文本-only 的残差（颜色 25%、形状 15%、数量 29% 左右）是"文本能给出的极限"；接地后的残差是 0，说明这部分残差是可约的，只是需要另一个模态。

五、说明什么，不说明什么

说明：语义残差可以定义成一个数；该数可以拆成"不可约底"与"可约部分"；在玩具世界里，两者的分界可以解析计算，并与模型表现对上。

不说明：不证明真实语言的语义残差有多大；不证明 R语言 存在或不存在（本文只处理 p语言 侧）；不证明"接地一定能补齐"在所有任务上成立——本文只测了视觉维度，其他维度（事件、状态、动作）没有覆盖。

六、局限

第一，世界是合成的，歧义是程序构造的；真实语言的歧义来自历史与用法，形式不同。

第二，模型很小（约 2000 参数），不是大模型；但本文测的是"文本极限 vs 接地补齐"的机制，与规模无关。

第三，只做一个模态的接地（图像）；多模态（事件、动作）的残差没有测。

第四，贝叶斯底只在生成过程已知时可算；真实语言里这个底要用人类分歧率来近似（下一项工作）。

七、与既有工作的关系

语义残差的测量不是新题目，至少有三条已有线索。

第一，人类标签变异：同一段文本，不同标注者本来就会给出不同解释，"人类天花板"与"标注分歧"在评测里一直被报告。

第二，歧义基准：AmbigQA、词义消歧一类任务，专门测"同一句话有多种合理解读"的情况。

第三，接地测试：纯文本模型在需要视觉属性的问题上明显退化；gSCAN、ReaSCAN 一类合成任务表明，没有接地的语言模型过不了接地泛化测试。

本文的不同只有一点：用受控歧义让"文本极限"可以解析算出来，并把残差拆成"模态决定的不可约底"与"接地/补数据可消的可约部分"。测量的思路不是本文首创；本文做的是一个受控、可解析算底的版本。

另外，符号接地问题（Harnad）指出符号与所指的连接不能从符号内部获得；本文的表述是"文本-only 的语义残差有解析底，接地可以把该底补上"。

评测方面，近年的工作开始报告"人类天花板"，本文的做法可以看成它的一个受控版本：因为我们知道数据生成过程，所以能算出真正的上限，而不是估计。

系列内部：第 4 篇（结构换算力）表明对齐语料提升样本效率；第 10 篇（颜色作为第一块积木）表明感知基元可以先于语言对齐。本文把这两条接到"语义残差"上：接地降低的是残差，而不只是提升效率。

八、可复现

脚本：820_semantic_residual.py。依赖 Python 3 与 numpy，无 GPU，内存占用低（百 MB 以内）。

附：标注

- **[定义]** 语义 = 语言与现象之间的对齐映射（按模态分维度）。

- **[定义]** 语义残差 = 给定模态组合下的最小可达误差。

- **[可测]** 玩具世界里，该残差可解析计算并与模型对上（颜色 0.750/0.725/1.000 等）。

- **[可约]** 接地后残差降到 0（本实验的视觉维度）。

- **[未判]** 真实语义残差的大小；R语言 是否非空。

- **[不声称]** 不声称"语义可被完全函数化"，也不声称"不可函数化"——R 只声明，不展开。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第十二篇 · 分层是对动态的补偿：一个自适应深度的玩具实验

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23591080

摘要

大模型的层数是固定的：每个输入都走完全部深度。本文问一个简单的问题：有些输入根本不需要那么多层，是不是可以少走？如果"层"是对动态的补偿——一层相当于一步时间，那么需要几步的任务就给几层，均匀深度是浪费。

实验用迭代任务：x_{t+1} = tanh(A x_t)，给定初值 x_0 与步数 T，预测 x_T。模型是共享权重的循环层，一层就是一步计算。三组对照：固定 16 层、自适应（走 min(T,16) 层）、固定 6 层（与自适应等平均算力）。

结果：在等平均算力（都是 6 步）下，自适应深度在每个 T 上都更好——平均误差 1.29 对 1.67。差距最大的是 T=1：固定 6 层把简单输入算了六遍，反而算坏了（误差 2.30 对 1.49）。固定 16 层则又贵又差：算力是自适应的 2.67 倍，平均误差 1.68。

结论：均匀深度两头都亏，简单输入被过度计算、复杂输入又算不够；按需分配深度可以用同样的算力换更高的精度。这与"层≈时间步、深度补偿动态"的图景一致。全部是玩具规模，不是大模型实验。

一、问题

现在的大模型是"均匀深度"的：每个 token 都过完全部层。但输入的难度并不一样——有的句子一眼能懂，有的需要多步推理。如果深度真的对应"计算步数"，那么固定深度就同时犯两个错：

- 简单输入：走了用不上的层，白花算力，甚至因为过度计算而变差；

- 复杂输入：层数不够，算不完，误差下不来。

本文要测的正是这两件事：同算力下，按需分配深度会不会更好？过度计算有没有害？

二、理论背景

这个实验来自一个画面：把函数看成它的图像（曲面），时间方向的演化会在曲面上"摊出厚度"；而冻结的模型没有真正的时间演化，只能用深度（层）去摊开这个厚度，一层相当于一步。所以：

- 需要的步数多 ⇒ 需要的层多；

- 需要的步数少 ⇒ 层可以少，多走就是过度计算。

这个画面在《厚度与维度：残差的几何图景》里已经写下；本文把它做成一个可测的实验。

三、实验设计

世界：取一个固定的随机映射 x_{t+1} = tanh(A x_t)，A 是 8×8 随机矩阵。任务是从初值 x_0 和步数 T 预测 x_T，T 取 1、2、4、8、16。

模型：共享权重的循环层。每层做一次 h ← tanh(W h + U x_0 + b)，最后用线性头输出预测。层数 = 走的步数，权重在所有步之间共享。

三组对照：

- A 固定 16 层：不管 T 是多少，都走满 16 步；

- B 自适应：走 min(T, 16) 步；

- C 固定 6 层：与 B 等平均算力（B 的平均步数是 6）。

指标：各 T 上的平均误差；平均步数（= 平均计算量）。

四、结果

等平均算力的一组（B 与 C，都是平均 6 步），B 在每个 T 上都更好：

T=1 时，B 是 1.49，C 是 2.30。T=2 时 1.27 对 1.57；T=4 时 1.38 对 1.50；T=8 时 1.22 对 1.50；T=16 时 1.07 对 1.46。平均下来 1.29 对 1.67。

固定 16 层（A）最差也最贵：平均误差 1.68，平均算力是自适应的 2.67 倍。

三点解读。

第一，过度计算真的有害。T=1 只需要一步，固定 6 层却把同一个映射迭代了六遍，结果比只走一步差得多。这不是"多算一点没关系"，是"多算会算坏"。

第二，层数不够真的补不回来。T=8 与 T=16 需要超过六步，固定 6 层的误差明显更高。

第三，均匀深度是两头亏：它既浪费在简单输入上，又不够用于复杂输入。按需分配能在同算力下更准。

五、对大模型的含义

这个实验是玩具，但它的形状可以直接搬到大模型：

- 不是所有输入都值得同样的深度。简单 token、简单上下文可以早退（early exit）；需要多步推理的才值得走深。

- 既然过度计算会算坏，那么"无脑加深"不是稳赚的：深度也要按需。

- 工程上这对应一类方法：早退、按 token 跳过、条件计算。本文不提出新方法，而是给这类方法一个"补偿动态"的解释与一个公平对照。

要注意的是，"按需"有一个前提：知道需要多少步。实验里 T 是给定的；真实场景中步数是估计出来的，估计错了，收益就会打折。

六、局限

第一，世界是合成的，映射是随机矩阵，任务不是语言。

第二，模型是共享权重的循环层，不是 transformer；大模型里的层不共享权重，深度的作用更复杂。

第三，T 是手工给的，真实模型没有这个先验，需要另做"步数估计"。

第四，只测了误差与算力两个量，没有测训练稳定性、路由开销这些工程代价。

七、与既有工作的关系

"按需计算深度"不是新想法：早退（early exit）、循环深度（universal transformer）、按 token 跳过层（conditional computation、mixture-of-depths）、层剪枝都有大量工作。

本文不声称方法原创；本文的不同在于两点：一是把它放在"层≈时间步、深度补偿动态"的图景里解释；二是做了一个等平均算力的公平对照——不是"我们的方法稍好"，而是"同样算力下，按需分配在两个方向上都更好"。

八、可复现

脚本：850_adaptive_depth.py（主对照）、851_adaptive_depth_v2.py（等算力对照）。依赖 Python 3 与 numpy，无 GPU，内存占用低。

附：标注

- **[事实]** 实验数字（等算力下自适应全面更好；T=1 过度计算有害；固定 16 层又贵又差）。

- **[图景]** 层≈时间步、深度补偿动态——来自《厚度与维度》（论文-15），标[猜想]。

- **[推测]** 大模型用自适应深度可在同等算力下更准——玩具结论的推广，未在真实模型上验证。

- **[不声称]** 不声称提出新方法；早退与条件计算都已有工作。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第十三篇 · 厚度与随机性：冻结模型在哪里最不稳定

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23591514

摘要

冻结的模型没有真正的时间演化，只能靠层数去模拟"多步计算"。本文问一个可测的问题：在这样的模型里，随机性/不确定性出现在哪里？

先给出三个基于"厚度"画面的推论：需要步数越多的位置误差与随机性越大；随机性随深度累积，在输出端最大；人类分歧大的地方（厚且不可摊薄），模型的熵也大，而且加数据摊不平。

然后做三组玩具实验。第一组是序列累积任务：位置越靠后（需要步数越多），固定 16 层模型的误差从 0.67 升到 1.57，输入加噪声后的输出标准差从 0.20 升到 0.40。第二组测逐层方差：标准差从第一层 0.21 单调升到最后一层 0.41；而干净输入下误差不随层数上升，说明上升来自噪声被逐层放大。第三组模拟人类分歧：thin（事实题，人类一致）与 thick（判断题，人类有分歧）两类题，人类分歧熵 0.000 对 1.014，模型预测熵 0.249 对 0.972，相关系数 0.917；把数据加到五倍，thin 题的熵从 0.249 降到 0.145，thick 题几乎不动（0.972 到 0.958）。第四组给"时间"：迭代八步后 thin 题的熵从 0.69 压到 0.02，thick 题只从 0.99 压到 0.91；多次采样投票也类似（thin 0.67 到 0.28，thick 0.96 到 0.69）。

四个实验合起来支持两句话：**冻结模型最厚的地方，就是它最随机的地方；而"最厚"可以由需要步数与人类分歧来度量。给数据与时间能摊薄"冻结造成的随机"，但摊不平"数据里的分歧"——后者才是真厚。**全部是玩具规模，不涉及真实大模型。

一、问题

现在的模型是冻结的：权重不变，没有真正的时间演化。它要在一次前向里完成"需要多步才能完成"的计算，只能靠层数铺开。

那么问题来了：这么铺开之后，哪些地方会变得不稳定、随机？本文的假设来自"厚度"画面：厚度大的地方（需要多步、又摊不平的地方），在冻结模型里会表现为更大的误差与随机性。

把假设拆成三个可测的推论：

- 推论一：需要步数越多的位置，误差越大，输入扰动下输出越随机。

- 推论二：随机性随深度累积，在输出端/后段最大。

- 推论三：人类分歧大的地方（厚且相对不可摊薄），模型熵也大，而且加数据压不下去。

- 推论四：给"时间"（多步迭代、多次采样投票）能压掉冻结造成的随机，但压不掉数据里的分歧。

二、实验一：需要步数越多，误差与随机性越大

任务：给随机增量序列 d_1 … d_16，世界按 x_t = tanh(x_{t-1} + d_t) 演化，初值为零；要求预测每个位置的 x_t。预测 x_t 至少需要 t 步，所以"厚度"就是 t。

模型：共享权重的循环细胞，一步处理一个增量，共 16 层，每层都接输出头（deep supervision），训练后冻结。

结果：固定 16 层时，各位置误差从位置 1 的 0.67 升到位置 4 的 1.54，之后在 1.5 到 1.6 之间饱和。输入加高斯噪声（标准差 0.3）后多次采样：各位置输出标准差从位置 1 的 0.20 升到位置 16 的 0.40，同样后段饱和。

解读：需要步数越多（越厚）的位置，误差越大、输出越不确定。厚度的两条痕迹是同步出现的。

三、实验二：随机性随深度累积，在输出端最大

同一个模型，问题换成：随机性在"哪一层"最大？

方法：给输入加噪声、采样 20 次，测每一层输出的标准差。结果：第一层 0.21，第四层 0.32，第八层 0.38，第十二层 0.40，最后两层约 0.41——标准差随层数单调上升，在末端饱和。

对照：干净输入下，误差不随层数上升（位置 4 之后基本平在 1.5 左右）。这说明末端随机性的上升不是模型本身差，而是"这条链路把输入的小扰动一路放大了"。

解读：冻结模型里，不确定性在"末端"累积；越往后走，可收缩的余地越小。这对应"厚度在输出端最大"。

四、实验三：人类分歧大的地方，模型也最随机

前两个实验是合成任务，第三个换成"有分歧的题"。

设定：题目分两类。thin 题是事实题，答案由输入决定，所有人答案一致；thick 题是判断题，答案取决于每个人的偏好，人与人不同。模拟 60 个人各自的偏好，题目 400 道训练、200 道测试；模型是小 MLP，学 P(答案|题目)，训练后冻结。

结果：人类答案的熵，thin 题约 0.000，thick 题约 1.014（三选一的熵上限是 1.099）。模型的预测熵，thin 题 0.249，thick 题 0.972。两者的相关系数是 0.917。

再看"能不能摊平"：把训练数据加到五倍。thin 题的模型熵从 0.249 降到 0.145；thick 题的模型熵从 0.972 只降到 0.958，几乎不动。

解读：模型的不确定性跟着人类分歧走——人觉得有分歧的地方，模型也随机；而且这份随机不是"数据不够"造成的（加到五倍仍不动），是人类分歧本身在数据里，属于该数据下的不可摊薄部分。

五、实验四：给时间能摊平什么

前三个实验说明"厚的地方随机"。第四个实验问：给时间能不能把随机压下去？

时间有两种给法。第一种是迭代细化：模型用共享权重的循环层多走几步（训练时按八步逐步监督）；第二种是采样投票：从模型分布里多次采样，按多数投票决定答案。

迭代的结果：thin 题的预测熵从一步时的 0.69 压到八步时的 0.02，几乎完全摊平；thick 题只从 0.99 压到 0.91，压不平。

投票的结果类似：采样一次时 thin 的决策熵 0.67、thick 0.96；采样九次投票后，thin 降到 0.28、thick 降到 0.69——都降了，但 thick 仍高。

解读：时间摊平的是"冻结造成的随机"，摊不平的是"数据里的分歧"（人类本来就意见不一）。换句话说，能被时间摊平的不算真厚；摊不平的才是真厚。这正好接上"可摊薄/不可摊薄"的区分：数据和时间的可摊薄性，是同一个厚度的两个检验方向。

六、训练机制：它学的是分布，不是决定

这三个实验合起来，给了一个简单的机制解释：冻结模型不训练"决定"，它训练"答案分布"。

- 薄的地方：分布是尖的，行为像一个确定的函数；

- 厚且摊不平的地方：分布是宽的、多峰的；冻结模型把它存成一个宽分布，推理时采样一次，看起来就是随机、不一致。

所以"模型在判断题上不稳定"不一定是缺陷：那里本来就是厚的。要它稳定，加数据不管用（实验三已示），需要别的办法——给它时间（多想几步、多轮修正），或者增加能摊开厚度的维度。

七、局限

第一，三个实验都是合成的：世界、题目、人类偏好全是程序生成的。

第二，模型都是玩具规模（几千参数），不是大模型；趋势可读，绝对值不可靠。

第三，实验三的相关性有一部分是设计使然：thick 题的随机性本来就由偏好分布构造出来。它验证的是"机制能对上"，不是"真实人类数据上的相关性"。

第四，实验四的"时间"是玩具版本的迭代与投票，不是真实的思维链；真实模型上"想更久是否摊平"仍需单独验证。

八、与既有工作的关系

"模型不确定性分布不均"不是新观察：校准（calibration）研究早就测过不同题目的置信度差异；人类标签变异（human label variation）也指出同一题不同标注者本来就有分歧；"偶然不确定性"（aleatoric uncertainty）研究的就是数据本身的不可约噪声。

本文的不同在于用一个统一的量（厚度）把三件事串起来：需要多少步、随机性在哪一层、人类分歧有多大，都落在"厚度"这个概念上，并且用"加数据后熵是否下降"来区分可摊薄与不可摊薄。

九、可复现

脚本：861_thickness_map_v2.py（实验一）、862_layer_variance.py（实验二）、870_human_disagreement.py（实验三）、881_time_flattening_v2.py（实验四）。依赖 Python 3 与 numpy，无 GPU，内存占用低。

附：标注

- **[事实]** 三个实验的数字：误差与随机性随厚度上升；末端方差最大；人类分歧与模型熵相关 0.917；加五倍数据 thick 熵不动。

- **[机制]** 模型学的是分布而不是决定——解释性说法，不是定理。

- **[事实]** 时间能摊平 thin 的熵（0.69→0.02），摊不平 thick（0.99→0.91）；投票同理。

- **[未做]** 真实思维链/大模型上的同一检验。

- **[不声称]** 不声称真实大模型上有同样的数字；不声称人类实验已验证。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第十四篇 · 压缩的形状：叙事与归档

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23592312

摘要

大模型的上下文压缩是一种"叙事摘要"：按时间顺序把发生的对话写成一段文字。人脑的压缩不是这样：它把事件归到类别里、把类别归到更高的抽象层里、再保留事物之间的关系——压缩的结果是一张"分类 + 关系"的图，而不是一段故事。

本文做一个对照实验：同样约 300 字符的记忆容量，三种存法——叙事式（旧优先）、叙事式（新优先）、结构化归档（分类层次 + 属性表 + 关系边），然后问三类问题：属性（这实体什么状态）、分类（属于哪一类）、关系（两者有关系吗）。

结果：结构化归档在全部三类题上都是满分；两种叙事式各丢一半——旧优先的保住属性和分类（各 0.83），关系只拿到 0.33；新优先的保住关系（1.00），属性掉到 0.25、分类 0.50。也就是说，叙事式压缩无论怎么权衡，都只能覆盖一部分；结构化压缩用更少字符（243 对 298）覆盖了全部。

解读：叙事式压缩是线性的，容量有限时必然丢一段；结构化压缩把"分类、属性、关系"分开存，信息密度高得多。这对应大模型 checkpoint 压缩的已知短板：过程记得住，层级与关系最容易丢。全部是合成任务，不涉及真实模型。

一、问题

压缩的意思是用更少的空间保留更多的信息。但"保留什么"取决于压缩的形状。

大模型的上下文压缩是叙事式的：把对话按时间顺序写成摘要。人脑的压缩是归档式的：事件被切开、归类，类别被放到抽象层里，关系被保留下来。

这两种形状有什么可测的差别？如果容量一样，哪一类信息会丢？

二、设定

生成一份"项目记录"：4 个类别（工具、人员、实验、结论），每类 5 个实体，共 20 个；每个实体有一个状态属性（活跃、冻结、待定）；另有 12 条关系（"使用"或"导致"）。

三种记忆，容量都约 300 字符：

- A1 叙事式·旧优先：按时间顺序写句子，写满为止——保住早期事实，后面的关系写不进去；

- A2 叙事式·新优先：先写关系、再写近期实体，写满为止——保住关系，早期实体写不进去；

- B 结构化归档：分类层次（哪类有哪几个）、属性表（每个实体的状态，压缩成单字）、关系边（谁对谁做什么）。

然后问三类题，各 12 道：属性题（这实体当前什么状态）、分类题（属于哪一类）、关系题（这两个实体之间有关系吗）。答案只能从各自的记忆里检索。

三、结果

总体正确率：A1 是 0.67，A2 是 0.58，B 是 1.00。

分题型看：

- 属性题：A1 0.83，A2 0.25，B 1.00；

- 分类题：A1 0.83，A2 0.50，B 1.00；

- 关系题：A1 0.33，A2 1.00，B 1.00。

字符数：A1 用了 298，A2 用了 296，B 只用了 243。

四、解读

第一，叙事式压缩是线性的。记忆只能从头写到尾，容量有限就必然丢一段：要么丢关系，要么丢早期事实。A1 与 A2 就是这两种取舍，各有一个短板。

第二，结构化压缩的密度高得多。分类、属性、关系是三种不同结构，分开存就不互相挤占；同样容量下它覆盖了全部信息，还用得更少。

第三，这对应大模型 checkpoint 压缩的短板。现在的压缩只做叙事摘要，所以"发生了什么"记得住，而"属于哪一层、和什么有关系"最容易丢掉。人脑恰好相反：它先记住结构和关系，具体细节反而会忘。

五、对记忆设计的含义

如果这个对照成立，那么压缩的产物不应该只是一段摘要，而应该是两样东西：

- 一段叙事摘要：保留时间线与因果（"发生了什么"）；

- 一份结构化归档：实体表、分类层次、关系边（"属于哪里、和谁有关"）。

两者配合检索：问过程用摘要，问层级与关系用归档。这个设计可以直接测：把同一段长对话按两种方式压缩，比较三类问题的召回率——本文的实验是这条路的玩具版。

六、局限

第一，任务全是合成的：实体、关系、题目都是程序生成的。

第二，结构化归档的"抽取成本"没有计入：实验里结构是直接给出的，真实系统要先从对话里抽实体与关系，这一步会出错、也有成本。

第三，真实的摘要模型可能比 A1/A2 都强（它可以选择重要的写、不写流水账），所以数字不能直接搬到真实系统；但"叙事 vs 结构化"的密度差不会因此消失。

七、与既有工作的关系

把记忆分成"语义记忆与情景记忆"是认知科学的老区分；大模型一侧，记忆机制、知识图谱增强、检索增强、长上下文记忆库都已有大量工作。

本文的不同只在于一个公平对照：同样字符容量下，把叙事式与结构化归档放在同一张卷子上，按题型分解看谁丢什么。结论不新，但它把"为什么 checkpoint 压缩会丢关系"变成了一件可以演示的事。

八、可复现

脚本：910_memory_compression.py（主对照）、911_memory_compression_v2.py（加"新优先"对照）。依赖 Python 3 标准库，无第三方依赖。

附：标注

- **[事实]** 三种记忆的召回数字：A1 0.67、A2 0.58、B 1.00（分题型见表）；B 用 243 字符、A 用约 296~298。

- **[解释]** "叙事式是线性的、结构化密度更高"——对数字的解读，不是定理。

- **[推测]** 把压缩产物设计成"摘要 + 归档"能提升层级与关系类召回——未在真实系统验证。

- **[不声称]** 不声称提出了新的记忆架构；索引、图谱、检索都是已有方向。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第十五篇 · 最小切片与时间换维度：能力边界的两个实验

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23601624

摘要

大模型的每一层有自己的权重，像一块静态的函数切片。本文问两个问题：一个"结构"（一种能力）需要多大的切片才能出现？如果给模型"时间"（循环步数），能不能换掉"维度"（宽度）？

第一组实验：扫宽度与深度，测几个合成结构的"最低配置"。结果：简单的阈值与组合规则一层 8 宽就够；算术与奇偶需要更宽的切片。第二组实验：两个切片组合时，需要的维度约等于两者中较大的那个，而不是相加。第三组实验：序列奇偶任务上，循环网络宽 2 就够处理任意长度；而前馈网络在同样训练预算下，长度到 16 就学不出来，加宽也没用。第四组实验（GPU 版）：把训练加足，16 位奇偶变得可学，24 位仍然只记住训练集；8 位加法在宽 128、浅层时最好，加深反而更差。

合起来说：能力需要结构、需要足够的维度与深度，还需要"能被训练找到"。最低维度是必要条件，不是充分条件；而"时间"可以绕开一部分维度边界——这与"层是对动态的补偿"的说法一致。全部是合成任务与玩具模型。

一、问题

把大模型的一层看成一个静态函数切片：它读当前状态，用自己的权重新算一遍，写回共享状态（残差流）。那么：

- 一种结构（能力）要出现，最少需要多大的切片？

- 切片与切片之间能不能拼起来？

- 如果给模型时间（循环步数），能不能换掉维度？

本文用四个小实验回答。全部是合成任务，不涉及真实大模型。

二、实验一：最低配置

任务：parity（8 位奇偶）、add（4 位加法）、rule（(a 且 b) 或（c 且 d)）、majority（10 位多数）。模型是 tanh 的多层感知机；扫宽度与深度，记录达到准确率 0.95 的最小宽度 w* 与最小深度 L*。

结果（SGD 训练）：parity 约需宽 16、深 3~4；add 约需宽 32、深 2；rule 与 majority 都是宽 8、深 1 就满分。

要点：结构越像"运算"（需要进位、组合、非线性），最低配置越高；简单的阈值型结构一层就够。

这里必须说明一个后来发现的问题：换成 Adam 优化器后，8 位奇偶变得很容易（宽 8、深 1 就能到 0.98）。也就是说，上表测到的"最低配置"依赖训练算法，它测的是"这个训练器能否找到解"，不完全是"表示能力的最低要求"。本文把这一点明确写出，而不是把它藏起来。

三、实验二：切片组合

取两个已经训练好的切片（各自最小配置），放到一个共享主干上、各自接一个输出头，联合训练。对照是它们各自单独训练时的准确率。

parity + rule：主干宽 16、深 3 时，parity 掉到 0.59，rule 仍 1.00；深到 4，parity 回到 0.93，rule 1.00。也就是说，rule 不需要额外维度，它装得进 parity 的维度里；瓶颈在深度。

parity + add：主干宽 32、深 3 时，两个任务都到 0.95；宽 64、深 4 时都到 1.00。

结论：组合所需维度约等于两者中较大的那个，不是相加；阈值附近要一点余量。这支持一个朴素图像：能力在一个足够大的公共维度里共存，而不是各自占一块。

四、实验三：时间换维度

任务：序列奇偶——顺序读入 T 位，每一步都预测"到目前为止的奇偶"。这是一个需要记住一个比特状态的累积任务。

循环网络：宽度固定，逐位读入，每步更新状态。结果：宽度 2 就够处理 T=8、16、24、32 的全部情况（准确率 1.00），宽度 4 到 16 也都满分。T 再长，宽度不用涨。

前馈网络：一次看全 T 位，深度固定为 4。T=8 时满分；T=16 时掉到 0.54 左右（宽加到 128 也没用）；T=24 同样学不出来。

解读：时间（循环步数）确实能换掉维度。原因也直观——奇偶只需要"翻转状态"这一个比特，循环网络用两步就能表达；前馈网络必须在一次前向里把 T 位的结构算完，长度越长越难。

五、实验四：能力边界（**GPU** 版）

把训练加足（两万条数据、一万五千步）后重测，得到更清楚的边界：

16 位奇偶：宽 64、深 2 就到 0.98；宽 128 起满分。但深 6、宽 128 或 256 的组合会崩到 0.49——不是能力不够，是训练不稳定。

24 位奇偶：所有配置都在 0.50 附近；训练损失能到 0，测试却只有一半。这是"记住训练集、没有学会奇偶"的典型表现。

8 位加法：宽 128、深 2 是 0.97；宽 256、深 2 是 0.998。加深反而更差（深 4、6 都掉）。

三点结论。第一，边界存在，但它是"可训练性边界"，不是"表示能力边界"：同一个结构换个训练预算，边界会移动。第二，深度不总是帮忙：加法任务上浅层最好，奇偶任务上过深会崩。第三，"最低维度"只是必要条件：过了维度的门槛，还得能被优化器找到。

六、解读

把这四个实验放在一起，可以得到一条更准确的表述：

能力 = 结构 + 足够的维度与深度（必要条件） + 能被训练找到（优化条件）。

同时：时间可以绕开一部分维度边界（实验三），这与"层是对动态的补偿"一致——当模型没有真实的循环时，它只能用深度去模拟时间；而如果给它循环，它可以用很少的宽度做很多步。

对当前大模型的含义：均匀深度是浪费的（实验二与实验四都显示，不同结构对"深"的需求差别很大）；"加宽加深"不是稳赚的，可能更差；按结构分配维度与深度，或者引入循环/多步计算，可能更省。

七、局限

第一，全部是合成任务与玩具模型，和真实大模型的能力不是一回事。

第二，结果对训练算法敏感：SGD 与 Adam 下"最低配置"差别很大；本文两版都报告了。

第三，种子波动明显：parity 单独训练在 0.74 到 0.97 之间波动。

第四，组合实验只用了"共享主干 + 独立头"一种构造，不代表所有组合方式。

第五，时间换维度用的是密集监督（每一步都有标签），信用分配比真实场景容易。

八、可复现

脚本：938（最小切片）、940/941（组合）、943/945（时间换维度）、946/947/960/961（能力边界）。最小切片与组合用 numpy 手写训练；时间换维度与 GPU 边界用 PyTorch（Windows 上经 DirectML 跑 AMD GPU）。

附：标注

- **[事实]** 各实验的准确率数字（最低配置、组合、时间换维度、GPU 边界）。

- **[解释]** "组合约等于 max 而不是相加""时间换维度"——对数字的解读，不是定理。

- **[推测]** 对真实大模型"按结构分配深度、引入循环更省"——玩具结论的推广，未验证。

- **[不声称]** 不声称发现了新的表示理论；这里只是把已有的玩具实验拼在一起看。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第十六篇 · 残差底与组合律：两个大模型结构实验

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23609386

摘要

本篇做两个与大模型结构有关的实验。

第一个问"多模态该接什么"。用合成世界：目标依赖颜色、材质、味道三个隐藏维度；文本只给粗色，视觉给精确颜色，触觉给材质，味觉给味道。测每种模态组合的可达误差（残差底）。结果：底由"覆盖了哪些隐藏维度"决定，不由模态数量决定——补一个缺失维度，底就降一截；补全则到底；冗余视觉模态一点不降底。对应的工程含义是：接地应按"残差底"配置，不是"多接模态就好"。

第二个问"结构该共享还是隔离"。四个任务，先训三个，再只给第四个任务的数据。三种结构：单体（共享主干＋多任务头）、模块化（每任务独立网络）、路由（共享主干＋每任务适配器）。结果：单体出现灾难性遗忘（旧任务平均从 0.81 掉到 0.52），而且第一阶段就互相干扰；模块化完全不掉点；路由也不掉点、新任务好，但共享主干仍有干扰。对应的工程含义是：显式组合律（模块/路由）换来可扩展性，代价是共享性。

两个实验都只到玩具规模，不涉及真实大模型。

一、问题

我们前面的理论说：能力 = 结构 + 足够的维度与深度 + 能被训练找到；而"结构"是把函数拆开与拼回去的方式（分解与组合）。这条说法在工程上引出两个具体问题。

第一，输入端：多模态接地到底接什么？是模态越多越好，还是按"缺哪个维度补哪个"？

第二，内部结构：能力应该共享一套参数，还是各管各的？共享省参数但互相干扰，隔离不干扰但参数翻倍——中间有没有更好的点？

本篇各做一个玩具实验。

二、实验一：多模态接地的残差底

世界有四个隐藏维度：形状（2 类，与目标无关的干扰项）、颜色（6 个色阶）、材质（3 类）、味道（4 类）。目标要求精确组合：y = 颜色 × 12 + 材质 × 4 + 味道，共 72 类。

各模态能看到什么：文本给形状与粗色（颜色只分两档）；视觉给精确颜色；触觉给材质；味觉给味道。另设一个冗余视觉模态，与视觉重复。

方法：先枚举法算每种模态组合的贝叶斯最优误差（残差底），再训练一个小网络用同样的输入，看它能否达到这个底。

结果：网络在每种组合上都达到了贝叶斯底。

- 仅文本：0.9722；

- 文本 + 视觉：0.9167；文本 + 触觉：0.9167；文本 + 味觉：0.8889；

- 文本 + 视觉 + 触觉：0.7500；

- 文本 + 视觉 + 触觉 + 味觉：0.0000；

- 文本 + 冗余视觉：0.9167（与只有视觉时完全一样）。

解读：残差底由"覆盖了哪些隐藏维度"决定，不是由模态数量决定。每补上一个缺失维度，底就降一截；补全就到底。冗余模态不降底，因为它的信息已经在别处。工程含义很直接：接哪种模态，应该看目标依赖哪些维度、哪些维度还没被覆盖，而不是笼统地追求模态数量。

三、实验二：组合律显式化

四个任务：奇偶校验（8 位）、层级规则、4 位加法、多数投票。输入统一补齐到 10 维。

三种结构。单体：共享主干加四个任务头，联合训练。模块化：每个任务一个独立网络。路由：共享主干，每个任务一个适配器，任务编号已知（相当于完美的路由）。

流程分两阶段。第一阶段只训前三个任务。第二阶段只给第四个任务的数据，旧数据不再出现——这是持续学习的标准设置。

结果：

- 单体：第一阶段旧任务平均 0.809（其中奇偶只有 0.574，早期就互相干扰）；第二阶段旧任务掉到 0.515（加法从 1.00 掉到 0.29），掉了 0.294——灾难性遗忘；新任务 1.00。

- 模块化：旧任务 0.998，第二阶段仍是 0.998，完全不掉；新任务 1.00。

- 路由：旧任务平均 0.893，第二阶段仍是 0.893，不掉；新任务 0.994。但奇偶只有 0.725，说明共享主干仍有干扰。

- 参照：单体用全部四个任务的数据联合重训（需要旧数据），奇偶 0.822、规则 1.00、加法 0.871、多数 1.00。

解读：共享参数换来样本效率，但代价是干扰与遗忘；隔离参数换来稳定，但失去共享。路由是折中：新任务可以单独加、旧任务不掉，但共享主干仍会把干扰留在那里。

四、合起来看

第一个实验说：输入端要按"残差底"配置——缺哪个维度补哪个，冗余模态不解决问题。

第二个实验说：内部结构要在"共享"与"隔离"之间做取舍——显式组合律（模块、路由）换来可扩展与抗遗忘，代价是共享性；共享单体换来参数效率，代价是干扰与遗忘。

这与理论里的说法一致：结构就是分解与组合的方式；组合律越显式，系统越容易扩展，但共享的好处也越少。工程上的含义是：先算清楚"哪些能力互相干扰"，再决定哪些共享、哪些隔离——而不是一律共享或一律模块化。

五、局限

第一，两个实验都是合成任务与玩具模型，和真实大模型不是一回事。

第二，多模态实验里的"贝叶斯底"是精确可算的，这只有在合成世界才成立；真实任务只能估。

第三，组合实验里的路由是"完美路由"（任务编号已知），真实路由要自己学会，会出错。

第四，遗忘实验只测了一轮，长期多轮漂移下的行为没测。

六、可复现

实验一：993_multimodal_residual_v2.py（枚举算底 + 小网络验证）。实验二：994_composition_modular.py（单体/模块化/路由的主对照）、996_full_E.py（路由的调参版）。依赖 PyTorch（Windows 上经 DirectML

跑 AMD GPU）。

附：标注

- **[事实]** 实验一各组合的残差底与网络误差（两者一致）；实验二各架构的两阶段准确率与掉点。

- **[解释]** "残差底由覆盖的维度决定""显式组合律换可扩展性"——对数字的解读。

- **[推测]** 对真实大模型"接地按残差底配置、组合律显式化"的建议——玩具结论的推广，未在真实模型上验证。

- **[不声称]** 不声称提出新的多模态或持续学习算法；模块化、路由、回放都已有大量工作。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第十七篇 · 按计算厚度分配算力：预算与动员

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23612112

摘要

本篇测"计算厚度"在工程上的第一个后果：算力该给多少、给谁。计算厚度指的是组合律在时间轴上依次应用的次数（时序组合的长度）——它是"路有多长"，不是"路口有多宽"（后者是分布厚度，另篇再谈）；它不是函数或函数类，而是一个长度。

两个实验。

实验一（预算）：世界是一个需要 k 步迭代才能到目标的映射，任务按厚度分四档（k = 1、2、4、8）。三种策略：所有任务都走 8 步、都走 4 步、按厚度路由（任务 k 走 k 步）。结果：路由只用 47% 的算力，平均误差 0.0812，与均匀 8 步（0.0834）相当甚至略好；均匀 4 步（0.0881）反而不如路由。过度计算也有害：k=1 的任务，1 步误差 0.0014，2 步 0.0160，4 步 0.0205。

实验二（动员）：四个不同世界规则，厚度同样是 1、2、4、8 步。模型是"常驻底座（一次变换，所有任务共享）加可动员循环块（按任务厚度走若干步）"。结果：均匀 8 步彻底失败（平均误差 1.756）——对 k=1 的任务，多走的步数直接算过了目标；按需动员 0.434（15 步）；各自独立 0.064（同样 15 步，但每任务一个网络）。

两条结论：第一，计算厚度必须显式匹配，均匀深度会把薄任务算坏；第二，常驻共享加按需动员能工作，但共享的动员块仍有干扰，冲突大的任务应该分开。都是玩具实验。

一、问题

我们把"厚度"分成两种：分布厚度（同一输入对应多宽的一族输出）和计算厚度（从输入走到目标要多少步）。本篇只动计算厚度：任务需要 k 步就是 k 步，答案唯一（分布厚度为零）。

在展开实验之前，要把"计算厚度"说得更精确一点。

组合律（把切片拼回函数的方式）有两种用法。一种是沿时间轴依次应用：第一步的输出喂给第二步，第二步再喂给第三步——这叫时序组合。另一种是同时发生：并行、共享状态、路由选择——这叫并列组合。计算厚度只量前者：**在时间轴上要依次应用几次组合，才能从输入走到目标。**

所以有两个函数空间要分清。

第一个是切片函数空间：被组合的对象，每一点是一个静态函数（一层、一块）。

第二个是组合律空间：起组合作用的高阶函数空间，每一点是一种"把切片拼成函数"的方式。它沿时间展开成 C^1、C^2、……——一步组合、两步组合、三步组合。

计算厚度不是函数，也不是函数类的成员，而是组合律空间里的一条最短路径长度：目标函数第一次落进某个 C^k 的像时，那个 k 就是它的计算厚度。它由目标、可用原语、组合律三者共同决定：原语越粗（一步能顶多步），同一个目标的厚度越小。

问题有两个：算力该给多少？共享还是分开？

二、实验一：算力预算

世界：x_{t+1} = tanh(A x_t)，A 是固定的随机矩阵，状态 8 维。任务：给初值 x0，预测 x_k，k = 1、2、4、8。

模型：共享循环细胞，每步 h ← tanh(W h + U x0 + b)，最后线性读出；步数就是计算量。

三种策略：均匀深（都走 8 步）、均匀浅（都走 4 步）、按厚度路由（任务 k 走 k 步）。

结果（每任务取不同宽度的最好）：

| 策略 | 平均误差 | 总步数 |

|---|---|---|

| 均匀 8 步 | 0.0834 | 32 |

| 均匀 4 步 | 0.0881 | 16 |

| 按厚度路由 | 0.0812 | 15 |

路由用 47% 的算力，误差与均匀 8 步差 0.0022，实际还略低。

过度计算单独测：k=1 时，1 步误差 0.0014，2 步 0.0160，4 步 0.0205，8 步 0.0148。多算不更好，单独看反而更差——世界是迭代映射，多走一步就过了目标。

解读：算力应该按"任务需要多少步"分配，而不是统一给一个深度；均匀深度的浪费可以测出来，约一半。

三、实验二：常驻底座与按需动员

人想难问题时不只是"想更久"，还会动员更多结构：有的回路长，有的短，有的常驻（维持、注意）。本篇把这个图像做成一个玩具结构。

四个任务，每个任务有自己的世界规则：任务 i 是 x_{t+1} = tanh(A_i x_t)，给 x0 预测 f_i^{k}(x0)，k = 1、2、4、8。

模型：常驻底座（一个线性层加 tanh，所有任务共享，走一次）加可动员循环块（共享权重，按任务厚度再走若干步），最后线性读出。

对照：均匀深（都走 8 步）、按需动员（任务 k 走 k 步）、均匀浅（都走 4 步）、各自独立（每任务一个网络，总步数与动员相同）。

| 策略 | 各任务误差（k=1,2,4,8） | 总步数 | 平均误差 |

|---|---|---|---|

| 均匀 8 步 | 1.885 / 1.853 / 1.706 / 1.579 | 32 | 1.756 |

| 按需动员 | 0.242 / 0.439 / 0.560 / 0.496 | 15 | 0.434 |

| 均匀 4 步 | 1.905 / 1.842 / 1.717 / 1.571 | 16 | 1.757 |

| 各自独立 | 0.004 / 0.019 / 0.103 / 0.130 | 15 | 0.064 |

三点解读。

第一，均匀深严重失败：对 k=1 的任务，目标在一步之后；模型硬走 8 步，等于反复迭代，算到了别的地方。步数越多不越好，甚至越差——这与实验一的过度计算一致。

第二，常驻底座加按需动员能工作：平均误差 0.43，比均匀策略好一个量级，步数只有一半不到。

第三，各自独立最好（0.06）：不是因为步数更少（同样 15 步），而是因为每个任务有自己的循环块，不受其他任务干扰。共享循环块在不同世界规则之间产生了干扰。

三点五、人脑层面的对应：接论文-21

人脑层面的解释不需要在这里重新展开。论文-21《人脑的可函数化形式：一个器官，不是生命》已经把脑写成可函数化器官：表示、层级、内生时间、有限自指；并且指出它是混合型、结构异质——有常驻的结构（维持、注意），也有按任务临时动员的长短回路，而它本身不自足、被保住的是"身体 + 脑 + 环境"的整体。

本篇的"计算厚度"与"按需动员"，就是那个器官层面的工程投影：简单的任务少动员，复杂的任务多动员；常驻结构一直用，临时结构按需用。细节以论文-21 为准，这里只作为设计直觉，不作为本篇的论据。

四、合起来看## 四、合起来看

实验一说：算力按计算厚度分配；均匀分配浪费近一半，过度计算会算坏。

实验二说：常驻底座共享是合理的（省参数、保留共同表示），但动员部分共享有干扰；冲突大时应分开。

对应的设计问题：哪些结构常驻共享，哪些按任务动员——这正是"共享还是分离"的取舍，和前面残差底与组合律实验的结论一致。

五、局限

两个实验都是合成世界与玩具模型。动员实验里"任务需要几步"是给定的（完美动员），真实系统要自己估计。独立方案虽好但参数翻倍，没测"独立 + 少量共享"的折中。实验二只跑了一次运行，没有多种子复核。

六、可复现

实验一：1000_thickness_budget.py。实验二：1010_recruit.py。依赖 PyTorch（Windows 上经 DirectML 跑 AMD GPU）。

附：标注

- **[事实]** 两个实验的数字：路由 47% 算力、误差 0.0812；过度计算更差；均匀 8 步 1.756、动员 0.434、独立 0.064。

- **[解释]** "算力按厚度分配""常驻共享、动员分离"——对数字的解读。

- **[推测]** 人脑"常驻结构 + 长短结构"的类比——方向一致，没有证据链。

- **[不声称]** 不声称提出新的算力调度或网络架构；早退、门控、模块化已有大量工作。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第十八篇 · 层厚放在哪：异质层实验

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23612126

摘要

大模型的层是均匀的：每层同宽、同结构，每个输入走同样深度。生物不是：不同区域的结构不同，有的回路短，有的长，有的常驻。

本篇问一个很窄的问题：同样的参数与算力，"层厚"放在网络的不同位置，结果一样吗？

任务：四个多任务（奇偶、层级规则、加法、多数），共享主干加各自输出头。四种结构：均匀 6×64（前向乘加约 21k）、宽前 128→16（约 15k）、宽后 16→128（约 14k）、中间厚（约 17k）。

三个种子的复核结果：宽后 16→128 平均准确率 0.995，用 14k 算力、19k 参数；均匀 6×64 是 0.980，用 21k 算力、24k 参数；中间厚 0.954；宽前 0.831。宽后分任务看提升主要来自难任务（奇偶 0.994 对 0.981，加法 0.985 对 0.941）。

结论：层厚放在哪里，比"每层都多厚"更重要。让前面几层窄（先把输入压成表示）、后面几层宽（再展开成答案），在这组任务上更省也更准；反过来（宽前）明显差。这与生物分层的异质方向一致，但我们只测了一种任务组合、几个结构，不能推广成定律。

一、问题

前一篇测了"算力给多少"（时间方向）。本篇测另一个方向：层与层之间的厚度分布（空间方向）。

大模型是均匀层厚；人脑是异质的：区域之间的结构、连接、时间常数都不同。如果厚度分布重要，那么同参数同算力下，"放在哪里"应该 measurable 地影响结果。

二、设定

任务：四个多任务——奇偶校验（8 位）、层级规则、4 位加法、多数投票。输入统一补齐到 10 维；共享主干，每个任务一个输出头，训练时任务混合。

四种结构（宽度序列）：

- 均匀：6 层 × 宽 64；

- 宽前：128 → 64 → 48 → 32 → 24 → 16；

- 宽后：16 → 24 → 32 → 48 → 64 → 128；

- 中间厚：[16, 32, 64, 96, 64, 32]。

算力用前向乘加数衡量（输入维到第一层 + 层间乘加），分别约 21k、15k、14k、17k；参数量分别约 24k、16k、19k、19k。

训练：任务混合，每步随机抽一个任务；6000 步。宽后与均匀做了三个种子，其余各一次。

三、结果

| 架构 | 前向乘加 | 参数 | 平均准确率（三种子） |

|---|---|---|---|

| 均匀 6×64 | 约 21k | 24k | 0.980（0.969 / 0.985 / 0.988） |

| 宽后 16→128 | 约 14k | 19k | 0.995（0.993 / 0.993 / 0.998） |

| 中间厚 | 约 17k | 19k | 0.954（一次） |

| 宽前 128→16 | 约 15k | 16k | 0.831（一次） |

宽后结构用约 67% 的算力、更少的参数，平均准确率反而更高。分任务看，提升主要来自难任务：奇偶 0.994 对 0.981，加法 0.985 对 0.941；规则与多数两个任务在所有结构上都是满分（太简单，分不出差别）。

宽前结构明显差（0.831），中间厚居中（0.954）。

四、解读

第一，层厚分布是可测量的：同样的算力，位置不同结果差 0.16（0.995 对 0.831）。

第二，在这组任务上，"前窄后宽"最划算：前面几层把输入压成较窄的表示，后面几层再展开到答案。一种可能的解释是：窄层先做选择（丢掉无关信息），宽层再组合（难任务需要更宽的表示），顺序对了就省。

第三，这与生物分层的异质方向一致——不同区域结构不同，不是"同一种砖摞高"。但我们只测了四个任务、四种结构，还不能说"前窄后宽"是通则。

四之二、人脑层面的对应：接论文-21

人脑层面的解释也不需要在这里重写。论文-21《人脑的可函数化形式：一个器官，不是生命》已经把脑写成可函数化器官，并指出它是结构异质的：不同区域的结构、连接、时间常数不同，有常驻的部分，也有按任务动员的长短回路。

本篇测的"层厚放在哪"，正是这种异质性的一个最粗的工程投影：不是所有层都该一样厚；把厚度放到哪一段，结果会不一样。论文-21 给出的定性图像（异质、常驻、动员）在这里变成一个可测的问题（同算力下，宽前/宽后/均匀/中间厚哪个好）。

同样，细节以论文-21 为准；本篇只把它当设计直觉，不作论据。

五、局限

任务与模型都是玩具规模；宽前与中间厚只跑了一次运行，种子起伏可能影响结论；宽后与均匀做了三个种子。任务里的规则与多数太简单（全满分），主要区分力来自奇偶与加法。真实大模型的层不是全连接（有注意力、残差、归一化），这里的"层宽"只是最粗的近似。

六、可复现

脚本：1007_heterogeneous_layers.py（主对照）、1008_hetero_fair.py（同算力对照）、1009_hetero_seeds.py（三种子复核）。依赖 PyTorch（Windows 上经 DirectML 跑 AMD GPU）。

附：标注

- **[事实]** 四种结构的算力、参数、各任务准确率；宽后 0.995 vs 均匀 0.980，宽前 0.831。

- **[解释]** "层厚放在哪里更重要""前窄后宽更省"——对数字的解读。

- **[推测]** 与生物异质分层的类比——方向一致，没有证据链。

- **[不声称]** 不声称提出新的网络架构；宽度变化、层剪枝、条件计算都已有大量工作。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第十九篇 · **RLHF** 压平人类分歧

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23611877

摘要

本篇测"分布厚度"在工程上的后果：对齐会把宽的输出分布压平。

设定沿用前面的人类分歧实验：题目分 thin（事实题，人类答案一致）与 thick（判断题，答案取决于偏好，人类有分歧）。基础模型学 P(答案|题目)，训练后冻结；thick 题上它的输出熵 0.9655，很接近人类的 1.0138——也就是说，基础模型是诚实地保留分歧的。

然后做偏好微调的玩具版：对每题从当前模型采样两个答案，让标注者按人类偏好选一个，再在选中的答案上做一步训练。

结果：thick 题的人类答案熵不变（1.0138），但模型熵从 0.9655 降到 0.4090（下降约 57%）；与人类分布的 KL 从 0.0451 涨到 0.4188（约 9 倍）；与"人类多数答案"的一致率从 0.870 升到 0.935。thin 题人类熵约为零，模型变化很小。

解读：人类的分歧没有错，但偏好微调把模型的输出分布压到了多数答案上。模型变得坚决，也更偏离人类的真实分布——少数意见被丢掉了。这是"厚的地方压不平"在工程上的具体后果：对齐把分布厚度压成确定性，代价是失去分布。玩具实验，不涉及真实大模型。

一、问题

我们把厚度分成两种：计算厚度（需要多少步）与分布厚度（输出分布有多宽）。前一篇测计算厚度；本篇只动分布厚度：题目都是单步判断（计算厚度小），变化的只是输出有多宽——人类答案熵从 0（thin）到约 1.01（thick）。

问题：对齐（偏好微调）对分布厚度做了什么？

二、设定

模拟 60 个人类，每人有一个偏好向量。thin 题：答案由输入决定，人人一致。thick 题：答案取决于偏好，人与人不同。人类答案分布的熵用来量厚度。

基础模型：小 MLP 学 P(答案|题目)；训练数据是每题抽一个人来答。因为见过很多人的答案，它学到的是人类总体分布。

偏好微调（玩具版）：对每题从当前模型采样两个答案，按人类偏好选一个（人类偏好概率高的胜出），在选中的答案上做硬标签训练一步；重复多轮。

三、结果

| 指标（thick 题） | 人类 | 基础模型 | 偏好微调后 |

|---|---|---|---|

| 答案熵 | 1.0138 | 0.9655 | 0.4090 |

| 与人类分布 KL | — | 0.0451 | 0.4188 |

| 与多数答案一致率 | — | 0.870 | 0.935 |

thin 题：人类熵约为 0，基础模型 0.1413，偏好微调后 0.1142（变化很小）。

四、解读

第一，压平是真实发生的：模型熵下降约 57%，而人类的分布没有变。

第二，压平不全是"学得更准"：与多数答案的一致率确实升了（0.870 到 0.935），但那是把少数意见的概率让给了多数答案——与人类真实分布的 KL 涨了近 9 倍。

第三，thin 题几乎不受影响：那里本来就没有分歧可压。

用我们的词说：偏好微调在做"单峰化"——把一条宽的分布压成一个点。对事实题这是好事（本来就是尖的）；对判断题这是丢失：丢掉的是"人本来就有不同意见"这件事。

五、局限

第一，这是玩具：标注者是模拟的（按人类偏好分布选），不是真人；真实 RLHF 还有 KL 正则项，压平会被约束（本篇没加）。

第二，题目是合成的（thin/thick 两类），人类偏好是程序生成的。

第三，只测了一轮偏好微调，没测多轮下的长期漂移。

六、可复现

脚本：1002_rlhf_flatten.py（软标签版，作对照）、1003_rlhf_flatten_v2.py（偏好采样版，本文数据来自这个）。依赖 Python 3 与 numpy。

附：标注

- **[事实]** thick 题：人类熵 1.0138、基础模型 0.9655、微调后 0.4090；KL 0.0451→0.4188；一致率 0.870→0.935。

- **[解释]** "对齐压平分布、丢掉少数意见"——对数字的解读。

- **[推测]** 真实 RLHF 会因 KL 正则而减轻压平——未验证。

- **[不声称]** 不声称提出新的对齐算法；KL 正则、多样性保留都已有大量工作。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。

第四部分 约束与防护

第二十篇 · 对齐是解压的约束

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23503728

摘要

主流对齐研究（RLHF、宪法式 AI、可扩展监督）默认一个前提：**模型是可以被稳定塑造的**。

本文用前三章的框架指出：**AI 是对人类语言的再解压；对齐 = 对这个解压的约束。**

由此得到三条可检验推论：

（1）**对齐漂移**：语言在升维（第二章实测约 1.2%/年），冻结模型的对齐目标也会落后——

它们对齐的是**训练时刻的语言**，不是此刻的世界；

（2）**歧义集中**：压缩陷阱的根源是语言有损（第三章）；语言越歧义的地方，

模型越倾向选"最省编码"的解释 ⇒ **对齐失败应集中在人类语言的歧义处**；

（3）**替换侵蚀**：对齐信号藏在人类数据里；用合成数据或新数据**替换**而非累积，

会切断价值信号的累积链 ⇒ **对齐随累积通道的切断而退化**。

本文给出该框架对应的可检验实验方案，并指出一个实践含义：

对齐不是一个一次性训练问题，而是一个"维持累积通道"的持续工程问题。

一、主流对齐框架的隐含前提

RLHF：人类反馈 → 奖励模型 → 优化策略

宪法式：用原则文本约束输出

可扩展监督：用 AI 辅助监督 AI

⇒ 三者都假设：模型的行为可以被稳定地塑造和保持

但没有任何一条回答：

① 当世界的语言/价值变化时，对齐目标会不会"过期"？

② 对齐失败会不会有结构性分布（不是随机噪声）？

③ 更新模型时，对齐会不会因为"只喂新数据"而流失？

二、框架：对齐 = 对解压的约束

AI = 对人类语言 L(W) 的再解压（第一章）

对齐 = 约束这个解压过程：在歧义处、在价值相关处，按人类意图解压

⇒ 对齐的载体是**人类语言中的价值信号**

⇒ 对齐的失效方式，由"语言的性质"决定

三、三条推论

推论 A：对齐漂移（来自第二章）

语言升维 ⇒ 冻结模型对齐的是训练时刻的语言规范

⇒ 新概念/新价值出现后，模型仍在按旧压缩解压

⇒ 对齐漂移不是 bug，是"一次性解压"的必然后果

可测：同一模型在"训练后出现的新规范"上的对齐评分随时间下降

推论 B：歧义集中（来自第三章）

压缩的语言有损 ⇒ 歧义处存在多个同样短的解压

⇒ 模型倾向选"最常见/最省编码"的解释

⇒ 对齐失败应**集中在人类语言歧义处**，而不是均匀分布

可测：把对齐失败样本按"人类判断分歧度"分层，

预测失败率随分歧度单调上升

推论 C：替换侵蚀（来自第三章）

对齐信号（人类偏好、价值判断）藏在人类数据里

替换式更新（只用新数据 / 用合成数据替换）⇒ 切断价值累积链

⇒ 对齐随替换比例上升而退化

可测：微调时人类数据占比 0/25/50/100%，

在公开安全/价值测试集上看对齐分数

四、可检验实验方案

实验 1（漂移）：

取两个不同代的开源模型，在"训练截止后出现的新规范"上做对齐评分

⇒ 预测：旧模型评分更低，且差距随截止时间差扩大

实验 2（歧义集中）：

选一个公开对齐数据集，人工/脚本标出"人类分歧度"分层

⇒ 预测：对齐失败率随分歧度上升

实验 3（替换侵蚀）：

小模型微调：混入人类安全数据比例 0/25/50/100%，其他为新任务数据

⇒ 预测：对齐分数随人类数据占比单调上升

五、实践含义

① 对齐不能"训一次管多年"——它是持续工程

② 更新要累积（保人类数据通道），不能替换

③ 对齐资源应投向"语言歧义处"（那里失败集中），而不是均匀铺开

六、限制

· 本文是框架文章，三条推论均未完成实验（方案已给出）

· "歧义度"的操作化定义需要谨慎（不同标注者分歧 vs 语言学歧义）

· 对齐评测本身有争议（benchmark 不等于人类价值）

结论

对齐的困难不只在"让模型听话"，还在：

· 它对齐的是会过期的语言（漂移）

· 它在歧义处必须自己选解释（歧义集中）

· 它的价值信号会被替换式更新冲掉（替换侵蚀）

⇒ 因此：对齐 = 维持一个累积的解压通道，而不是一次性的训练任务。

作者：何淇（独立研究者）；AI 协作：DeepSeek

第二十一篇 · 安全：当它是生命防，还是当它是工具防？

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23503775

摘要

当前 AI 安全讨论中混杂着两种恐惧：**它被滥用**（工具风险）与**它自己活了**（生命风险）。

两者需要完全不同的威胁模型，但常被混为一谈。

本文用第一章的判据指出：**按定义，AI 不是生命**（冻结函数点、更新在外部、不自我维持），

因此正确的安全框架是**工具安全**，而不是"防生命"。

但这不意味着安全可以放松：工具风险真实、且有三类可测的失效模式：

误用、过度信任、失配漂移。本文给出这三类风险的对应评测与治理方向，

并指出：把安全讨论锚定在"它会不会觉醒"，既高估了它、又低估了真实风险。

一、两种恐惧，一个错误的本体论前提

恐惧 A（工具派）：被滥用、被误用、被坏人使用

恐惧 B（生命派）：它自己有了目标、自己进化、自己维护自己

这两种恐惧隐含不同的本体论：

A 假设它是工具（无自我目标）

B 假设它是（或将成为）生命

⇒ 不先判定本体，安全讨论就没有共同的威胁模型。

二、按第一章的判据：它是工具

① 冻结函数点：训练后权重不变 ⇒ 不会自我进化

② 更新规则在外部：它不能改自己的规则 ⇒ 不会自我改写

③ 不自我维持：不付电费、不修复自己、不复制自己 ⇒ 没有自发生存动机

⇒ 三条都缺 ⇒ 按定义不是生命 ⇒ 威胁模型应是工具安全

三、工具风险的三类可测失效

① 误用（misuse）

危险来自使用者 × 能力 × 规模

评测：越狱/滥用测试、红队

治理：访问控制、审核、能力分级

② 过度信任（overtrust）

人把「一次性的解压」当成「持续的理解」

⇒ 在它失配的地方仍然信它（最隐蔽的风险）

评测：校准度（confidence vs 准确率）、拒答质量

治理：把不确定性暴露给用户（"它不知道"要能被表达）

③ 失配漂移（第四章）

语言/世界变化 ⇒ 冻结模型的对齐与能力缓慢过期

评测：第二章的 M(K)（失配随时间的增长）

治理：累积更新（混合新旧数据），而非替换

四、为什么"防生命"框架有害

· 高估：把资源投在"它会不会觉醒"上，而不能解决误用/过信/漂移

· 低估：真正危险的是"它看起来很可信"，

而这一点被"它不是生命所以安全"掩盖

· 误导：政策讨论被"意识"问题绑架，忽略了可测的工程风险

五、结论

先判本体：它是工具，不是生命

再定威胁模型：误用 / 过度信任 / 失配漂移

最后配治理：评测（校准、越狱、失配）+ 累积更新

⇒ 安全不是"防止它活过来"，而是"在它不可靠的地方，别让人信它"

六、限制

· 本文只做本体-威胁模型的对齐论证，不提供新的安全技术

· "过度信任"的量化需要用户研究，本文只给方向

· 若未来出现真正自我维持的系统，本文框架需重写

作者：何淇（独立研究者）；AI 协作：DeepSeek

附录

附录 **A** · 厚度与维度：残差的几何图景

单独 DOI（中文）：https://doi.org/10.5281/zenodo.23590887

摘要

本文给"残差"一个几何画面，并把系列里几个分散的概念放到同一张图里。

画面是：把一个函数看成它自己的图像——一张曲面。理想的可函数化函数是一张"薄"曲面：一个输入对应一个输出。一旦同一输入对应一族输出（误差带、歧义、不确定），曲面就有了"厚度"。

关键的一步是升维：把厚度摊平成额外的坐标，厚曲面就变成高维空间里的薄曲面。于是残差分成两种——能靠升维摊平的（可约），和摊不平的（不可约，几何上就是 R 的候选）。厚度与尺度的比值是相对残差：世界的可区分维度降低时，尺度缩小而厚度不减，相对残差上升，极端处曲面糊成一团（热寂）。

这个画面也给出"分层"的一种解释：层是厚度方向的维度，加层相当于给同一个输入挂更多表示。本文把这部分标成[猜想]，把可以测的部分（升维实验、语义残差）对应到系列已有的实验上。

一、问题

系列里出现过几个概念，各自都能说清，但彼此关系一直靠文字维持：可函数化、残差、可约与不可约、生长与退化、分层与动态。本文的问题是：能不能给它们一张共同的图？

答案是能：一张有厚度的、会演化的曲面。

二、画面

把一个函数看成它的图像：所有输入与对应输出组成的点集，就是一张曲面。

- 薄曲面：一个输入对应一个输出。这就是"可函数化"的样子。

- 厚曲面：同一个输入对应一族输出——误差带、歧义、不确定。这就是"有残差"的样子。

曲面有三个方向要说清：中面（理想函数本身）、厚度方向（同一输入上的输出范围）、时间方向（曲面随时间的移动与变形）。任何一刻看到的，都是一张冻结的厚曲面。

三、三个对应（定义）

对应一（可函数化 ⇔ 薄）：一个对象可函数化，当且仅当它的曲面厚度可以趋近于零。

对应二（残差 ⇔ 厚度）：残差就是厚度。绝对残差是厚度的绝对宽度；相对残差是厚度与尺度的比值，其中尺度是输出能够区分的范围。

对应三（可约/不可约 ⇔ 摊得平/摊不平）：升维就是给曲面加坐标；厚度可以被摊平成额外的坐标，曲面随之变薄。能靠增加维度摊平的厚度，是可约残差；升到任意维度都摊不平的厚度，是不可约残差——这是 R 的几何候选。

第三句里的"不可约"是[定义/推测]层面的东西，不是定理：我们不知道是否真的存在摊不平的厚度，只把它作为候选概念写下来。

对应四（维度耦合 ⇔ 摊不开的厚度）：生命的维度不全是独立的。有些维度是绑在一起的——它们一起出现、一起变化，不能单独拆开。在可分离的方向上，升维可以把厚度摊平；在绑死的方向上，厚度摊不平：不是我们不知道，也不是世界有不可函数化的部分，而是这些维度之间耦合、拆不开。

于是"厚度"可以分成三类：可约厚度（升维能摊平）、结构厚度（维度耦合，拆不开）、以及 R 候选（升到任意维都不行，未判）。这一条同样是[推测]。

四、维度降低的图景（[猜想]）

有了厚度与尺度两个量，就可以描述一个演化方向：

起点：薄而高维。可区分方向多，尺度大，残差小，曲面舒展。

过程：可区分维度降低。尺度缩小，厚度若不跟着缩小，相对残差上升，曲面从"薄而高维"压成"厚而低维"。

终点：零维而全厚。所有方向消失，只剩一个常数；曲面退化成一层雾——这就是热寂在几何上的样子。

在这个图景里，生命与生长是逆过程：升维、把厚度摊薄、让相对残差下降。它是耗能的逆流：局部地对抗"维度降低、变厚"的趋势。

这一整节是[猜想]，不是定理。它与系列的《信息不增定理》《可函数化内容的收缩》方向一致，但那些结论是信息论层面的，这里只是给它们一个画面。

五、分层是厚度方向的维度（[猜想]）

对一个冻结的模型来说，它没有真正的时间演化；它能用来"模拟动态"的只有深度。在这个画面里，层可以看成厚度方向的额外维度：每加一层，就给同一个输入挂上一组新的表示，相当于把曲面加厚、再加坐标。

由此得到一个可以检验的说法：任务需要的"步骤"（时间演化）越多，冻结模型需要的深度越大——它用空间（层）换时间（演化）。这个说法可以做成实验：用迭代任务测"层数 vs 需要的步数"。

本节全部标[猜想]。

六、可以测的部分

这个画面里，有两块是能落地的。

第一块是升维实验：加维度（加输入通道、加模态、加大模型），看厚度是否变薄。系列的语义残差实验就是一个例子：文本-only 时残差有解析底（厚度摊不平），接上图像后残差降到零（厚度被摊平）。这正是"可约残差"。

第二块是"层数 vs 步数"实验：用迭代任务测冻结模型需要的深度是否随步数增长。这一项本文没有做，留给后续。

七、说明什么，不说明什么

说明：残差、可约与不可约、生长与退化、分层与动态，可以用一张有厚度的曲面统一描述；其中"可约/不可约"有一个几何对应（摊得平/摊不平），"维度降低"有一个几何对应（尺度缩小、相对残差上升）。

不说明：这个画面不是数学定理，没有给出曲面的严格定义（定义域是连续的还是离散的、厚度如何度量，都需要另做工作）；不证明绝对 R 存在或不存在；不证明"层数=步数"的定量关系。

八、与既有工作的关系

"厚度"这个画面的近亲不少：纤维丛（底空间上挂纤维）、不确定性带、ε-管（tube）、以及流形学习里"低维嵌入表示高维数据"的想法。本文没有做数学化，只把它作为系列的统一画面；若以后要严格化，纤维丛与 ε-管是现成的语言。

系列内部：第零篇给出 P/R 与定义域；论文-12 给信息不增；论文-13 给内容收缩；论文-14 给语义残差。本文是这几篇的几何对照。

附：标注

- **[画面]** 曲面中面、厚度、时间三个方向——直觉模型。

- **[定义]** 可函数化 ⇔ 厚度可趋零；残差 ⇔ 厚度；相对残差 = 厚度/尺度。

- **[推测]** 可约残差 = 能摊平的厚度；R = 摊不平的厚度。

- **[猜想]** 维度降低的图景；生命 = 升维摊薄的逆流；层 = 厚度方向的维度。

- **[可测]** 升维实验（已有，论文-14）；层数 vs 步数实验（未做）。

> 本文由何淇创作，DeepSeek（AI）协助整理；观点与责任属于作者。

附录 · 各篇单独 **DOI** 清单

第零篇《从两个事实开始：数字生命系列导论》

中文：https://doi.org/10.5281/zenodo.23611906

第一篇《现在的 AI 为什么不是生命》

中文：https://doi.org/10.5281/zenodo.23588781

第二篇《数字生命的信息不增定理》

中文：https://doi.org/10.5281/zenodo.23573253

第三篇《可函数化内容的收缩：一个定理与一个猜想》

中文：https://doi.org/10.5281/zenodo.23609038

第四篇《宇宙、环境与生命的函数类型：结构、时间与闭包》

中文：https://doi.org/10.5281/zenodo.23608931

第五篇《人脑的可函数化形式：一个器官，不是生命》

中文：https://doi.org/10.5281/zenodo.23609158

附录 B《概念地图与术语总表》

中文：https://doi.org/10.5281/zenodo.23609033

第六篇《容量不能替代数据的更新》

中文：https://doi.org/10.5281/zenodo.23503049

第七篇《替换与累积》

中文：https://doi.org/10.5281/zenodo.23503559

第八篇《结构换算力：混合对齐语料与样本效率》

中文：https://doi.org/10.5281/zenodo.23542969

第九篇《颜色作为第一块积木：感知基元与语言对齐的最小实验》

中文：https://doi.org/10.5281/zenodo.23551953

第十篇《生长与记忆：自指更新与维持的最小实验》

中文：https://doi.org/10.5281/zenodo.23569774

第十一篇《语义残差的测量：文本极限与接地补齐》

中文：https://doi.org/10.5281/zenodo.23586075

第十二篇《分层是对动态的补偿：一个自适应深度的玩具实验》

中文：https://doi.org/10.5281/zenodo.23591080

第十三篇《厚度与随机性：冻结模型在哪里最不稳定》

中文：https://doi.org/10.5281/zenodo.23591514

第十四篇《压缩的形状：叙事与归档》

中文：https://doi.org/10.5281/zenodo.23592312

第十五篇《最小切片与时间换维度：能力边界的两个实验》

中文：https://doi.org/10.5281/zenodo.23601624

第十六篇《残差底与组合律：两个大模型结构实验》

中文：https://doi.org/10.5281/zenodo.23609386

第十七篇《按计算厚度分配算力：预算与动员》

中文：https://doi.org/10.5281/zenodo.23612112

第十八篇《层厚放在哪：异质层实验》

中文：https://doi.org/10.5281/zenodo.23612126

第十九篇《RLHF 压平人类分歧》

中文：https://doi.org/10.5281/zenodo.23611877

第二十篇《对齐是解压的约束》

中文：https://doi.org/10.5281/zenodo.23503728

第二十一篇《安全：当它是生命防，还是当它是工具防？》

中文：https://doi.org/10.5281/zenodo.23503775

附录 A《厚度与维度：残差的几何图景》

中文：https://doi.org/10.5281/zenodo.23590887

系列主页：https://heqiq619.github.io/ai-not-alive/

代码与全文：https://github.com/heqiq619/ai-not-alive

本合集由何淇创作，DeepSeek（AI）协助整理与合成；观点与责任属于作者。