一个自学习的 LLM 模型

——冻结、成长与切换

何淇 • 与 DeepSeek 协作

数字生命系列 • 散论（草稿）

日期：2026-11-08

定位：观察与实验记录，不是论文。带［推测］处没有证据，只是推演。

本节主张

一个权重冻结的模型，不是不能学，而是学习的部位换了地方：权重不动，门（gate）动、新层动。

这篇散论记录一组实验，回答三个问题：

它怎么知道现在该用哪套本领（切换）？它怎么长出新的本领（成长）？它怎么不把旧的弄丢（固化）？

结论先行：

- 加层：能学到新东西
- 加门：新任务学得动，旧任务不丢
- 门自己选：给几个样本，试一遍就知道用哪个

一、问题

- 全参数微调
  - 学新任务 → 旧任务忘光
- 完全冻结
  - 不遗忘，但也不会新东西

中间路线：冻结大部分，只改一小部分。这篇关心的是机制，不是某个具体架构。

实验规模：

- 模型：GPT-2 小模型（6 层，d=128，seq=128）
- day1：莎士比亚（先把底座训好）
- day2：Python 代码（不同分布）
- 指标：day1 PPL / day2 PPL

二、预备：模型、加层、门

2.1 模型与加层

- 底座：6 层，day1 上训好，之后冻结
- 加层：末尾加 6 层（共 12 层）
  - 新层零初始化（起点=旧模型）
  - 只训新层，或只训新层+门

2.2 门的三个作用

（沿用论文-47 的提法）

① 轻量适配
  - 对每层输出做缩放
  - 参数少，改的是"信息流权重"

② 步骤分配
  - 门=0 时该层被跳过
  - 决定"这次用几层、用哪几层"

③ 模式切换
  - 不同任务用不同门
  - 等于给同一个模型准备多套"用法"

本篇的 GPT-2 实验，三个作用都用上了：门缩放（适配）、门关掉新层（步骤分配）、旧门/新门两套（模式切换）。

三、实验一：只加层，能学新的，但旧的有损

- 底座冻结，加 6 层，只训新层
- 数据：day2 代码，不回放

指标	训练前	训练后
day1 PPL（旧）	4.64	**19.56**
day2 PPL（新）	1386.72	**4.27**

· 新任务：1386 → 4.27，学得很好
· 旧任务：4.64 → 19.56，明显退化
⇒ 加层能学新东西；但"学新的"和"保住旧的"是两件事

四、实验二：加门，学新的，不丢旧的

4.1 两套门

· 旧任务的门：旧层 = 1，新层 = 0
  · 新层被跳过（步骤分配）
  · 输出严格等于原模型
· 新任务的门：初始全 1，可学
· 训练：只训新 6 层 + 新门，day2，不回放

4.2 结果

评估	PPL
旧任务，用旧门	**4.64（和训练前一模一样）**
新任务，用新门	**4.04（1386 → 4.04）**
旧任务，用新门	22.35
新任务，用旧门	1386.72

学到的门：

· 旧层：0.97 / 0.97 / 0.99 / 0.81 / 0.63 / 0.49
· 新层：0.64 / 0.81 / 0.86 / 0.89 / 1.12 / 1.25
⇒ 新任务把部分旧层关小，把新层开大

4.3 这说明了什么

· 加层能学新东西：4.04 是证据
· 旧任务不丢：旧门把新层全关掉，函数严格不变
· 门同时干了三件事：
  · 适配（缩放）
  · 步骤分配（跳过新层）
  · 模式切换（两套门）

一个坑：第一版里新层门初始为 0，"零初始化 + 门 0"让梯度变成 0，新层学不动；把门初始改成 1 才正常。

五、实验三：门自己选

给几个带标签样本，比较两套门的损失，选小的：

```
· 旧任务：旧门 loss 1.33 < 新门 4.45 → 选旧门 ✓
· 新任务：新门 loss 4.07 < 旧门 6.56 → 选新门 ✓
⇒ 5 个样本就够，不需要人写描述
```

更早的合成任务实验里，只给输入 x 时路由会失败（准确率 0.46~0.50）；给了样本之后追上 oracle（0.942）。

```
· 人认出"这是数学题"，靠的是看结构
· 模型认出"该用哪套门"，靠的是试样本
⇒ 都是"自己识别"，不是别人告诉
```

六、合成：成长、固化、切换

```
① 成长：加新层（实验一/二）
② 固化：旧门保底，新层对旧任务关闭（实验二）
③ 切换：给样本，自己试哪套门（实验三）
```

对应到人：

```
· 肌肉记忆：训练完就冻结的回路
· 意图选回路：先有目标，再选回路
· 睡眠回放：把新旧拉平（前面单独做过）
· 蒸馏：把学成的内化进单一模型
  · 教师 12 层+门 → 学生 8 层/无门
  · day2 PPL：2.18 / 2.83（教师 4.50）
  · 代价：失去可加性
```

七、人的对照

```
· 冻结骨干：基础回路
· 门：当前任务的调质（可适配、可分配步骤、可切换模式）
· 新层：新学会的本领
```

- 冻结新层：肌肉记忆
- 5 个样本选门：看结构认类型

差别只在"意图"的来源：人靠目标和上下文，模型靠样本或描述。

八、边界

- 样本必须能区分任务
- 两套门之外，多任务会组合爆炸
- 玩具模型结论不能直接外推到大模型
- 加层的位置（前/中/后）在玩具模型上有影响，大模型上待验证

九、结论

- 加层：能学到新东西
- 加门：新任务学得动（4.04），旧任务不丢（4.64）
- 门自己选：5 个样本就够
- 三件事合起来：加维度 → 用门保底 → 按样本切换

一句话：**冻结不是停止学习，而是把学习搬到门和新层上；成长、固化、切换，三件事可以分开做，也可以合起来做。**

附：实验文件

· add6_only.py	只加层（day1 4.64→19.56 / day2 1386→4.27）
· gated6_selfselect.py	加层+门+自选门（旧 4.64 / 新 4.04）
· gate_v15_fewshot_selection.py	5 样本自己试出正确的门
· gate_v8_text_routing.py	描述选门
· gate_v4~v7_*.py	只给输入的路由失败记录
· sleep_interleave*.py	睡眠回放
· distill_compress.py	蒸馏
· README.md	汇总