工程笔记 03：门的复用与组合

何淇 • 与 DeepSeek 协作

数字生命系列 • 工程笔记 03（草稿）

日期：2026-11-08

定位：实验记录，不是论文。数字都是本机实际跑的。

本节主张

上一篇（工程笔记 02）把"加层 + 门 + 现场选门"跑通了。这篇问下一步：**门能不能复用、能不能组合？**

三个实验：

```
① 门会不会累积（交替会话）
② 一个门能不能同时服务两个任务（联合训练）
③ 共享门 + 每任务小偏移，能不能接近专精
```

结论先行：

```
· 门不累积：交替会话，累积臂 ≈ 重置臂
· 联合训一个门：能用，但是折中（6.24 / 40.33）
· 共享门 + 小偏移：接近专精（4.58 / 27.27）
⇒ 组合能力 = 共享结构 + 少量特化，
  不是"多个门平均分"
```

一、设置

```
· 底座：6 层 GPT-2（d=128, seq=128）
  · 先在 day1（莎士比亚）上训好，全程冻结
· 门：每层一个 128 维缩放向量
  · h = h + g·(block(h) − h)
  · g 可学，参数量 6×128 = 768
· day1：莎士比亚；day2：Python 代码
· 指标：day1/day2 验证集 PPL
· CPU 上跑，每臂几百到一千六百步
```

二、实验一：门不累积

【问题】如果让门在多个会话里连续更新（不重置），它会不会把前面的任务"记住"？

【做法】

```
· 会话序列：S1 代码 → S2 莎翁 → S3 代码 → S4 莎翁
· 每会话 600 步，只训门
· 对照臂：
  A 累积：门接着上次状态继续训
  B 重置：每会话把门重置为 1
```

【结果】

会话	累积臂 day1/day2	重置臂 day1/day2
S1 代码	14.91 / 30.46	14.99 / 30.56
S2 莎翁	4.57 / 1266	4.56 / 1436
S3 代码	14.81 / 29.65	14.74 / 30.50
S4 莎翁	4.59 / 1263	4.57 / 1463

【解释】

```
· 累积臂 ≈ 重置臂（数字几乎一样）
· 门在两套配置之间来回切：
  · 代码：门均值约 0.78，std 0.76
  · 莎翁：门均值约 1.00，std 0.15
· 交替训练没有变好：
  · S3 的代码 PPL 没比 S1 低
  · S4 的莎翁 PPL 没比 S2 低
⇒ 门是临时配置，不会自己沉淀
```

注意：这个实验里"时间"被压掉了（会话之间没有间隔，每次几百步一把覆盖）。所以只能说明"这种训练方式下不沉淀"，不能说明门本身不能沉淀。

三、实验二：联合训一个门

【问题】单训 A、单训 B、A+B 联合训一个门，差别多大？

【做法】

```
· J：A+B 数据各半，训一个门，800 步
```

· SA：只训 A，800 步
· SB：只训 B，800 步

【结果】

门	day1（莎翁）	day2（代码）
J 联合 A+B	6.24	40.33
SA 只训 A	4.55	1430.5
SB 只训 B	15.92	29.41

【解释】

· 联合门两个任务都能用（6.24 / 40.33）
· 但和各自专精比是折中（4.55 / 29.41）
⇒ 一个门装不下两个任务的差异
· 门容量只有 768 参数

四、实验三：共享门 + 每任务小偏移

【问题】如果"大部分共享、每任务只加一点方向修正"，能不能接近专精？

【做法】

· g_A = g_shared + δ_A
· g_B = g_shared + δ_B
· δ 初始 0，g_shared 初始 1
· A/B 数据交替，各用自己的门，共 1600 步

【结果】

方案	day1	day2
联合训一个门	6.24	40.33
单训门（专精）	4.55	29.41
共享门 + 小偏移	**4.58**	**27.27**

· g_shared 均值 0.879
· δ_A 均值 +0.142，δ_B 均值 -0.126
⇒ 偏移很小，但足够把两个任务分开

【解释】

```
· 基础结构共享，每个任务只加一点方向性修正
· 效果几乎等于分开训（day2 甚至更好）
⇒ 这就是"A 能力和 B 能力的组合"的自然形态
· 比"联合训一个门"好得多
```

五、工程补偿：现场选门

上一篇的 5 样本现场选门，在这里也成立：

```
· 不指望门自己沉淀
· 每次新任务：给 k 个带标签样本
  · 对每个候选门算损失
  · 选最小的
⇒ 用"现场配置"替代"长期记忆"
· 成本：k 个样本 + k×门数 次前向
· 局限：只能选已有门；需要少量标签
```

六、边界

```
· 只有 6 层小模型、三组任务，结论不能直接外推
· 门容量很小（768 参数），联合门折中受此限制
· 实验压掉了"时间"，看不到慢漂移
· "共享 + 偏移"只试了一组数据配比
```

七、结论

```
① 门不累积（这种训练方式下）
② 一个门硬扛两个任务：折中
③ 共享门 + 小偏移：接近专精
④ 现场选门 = 不依赖积累的工程补偿
```

一句话：**组合能力不是"多个门平均"，而是"共享一套底子 + 每个任务一点方向偏移"；门不会自己沉淀，但可以现场重选。**

附：实验文件

```
· gatelock_accum.py            门累积（交替会话，累积 vs 重置）
· gate_joint.py                联合门 vs 单训门
· gate_shared_offset.py        共享门 + 每任务小偏移
· gatelock_accum_results.json / gate_joint_results.json /
gate_shared_offset_results.json
· 相关：工程笔记 02（加层 + 门 + 5 样本选门）；散论《关系与门》
```