工程笔记 04：组合任务中的门——重训组合门、拼门与加层

何淇 • 与 DeepSeek 协作

数字生命系列 • 工程笔记 04（草稿）

日期：2026-11-11

定位：实验记录，不是论文。数字都是本机实际跑的。

本节主张

工程笔记 02/03 讲了单任务的门：加层、旧门保底、共享门+偏移、现场选门。但真实任务常常是**A 和 B 的组合**：既需要 A 的规则，又需要 B 的规则。

这篇问：**组合任务，门够不够？还是要加层？**

三个实验：

```
· 段切换混合：文本里一段莎翁、一段代码
· token 级混合：每 4 个 token 换一次域（更严格）
· 加层对照：在已有 12 层上再加 2 层，和门一起训
```

结论先行：

```
· 组合任务下，重训一个"组合门"最好
· 拼门（底座门+新层门）不如重训门
· 小数据下加层会过拟合：训练损失 1.18，验证 PPL 309
⇒ 小数据优先"重训组合门"；数据够了再考虑加层
```

一、设置

```
· 底座：6 层 GPT-2（d=128, seq=128），先在 day1（莎士比亚）训好
· 新层：末尾加 6 层（零初始化）
· 门：每层一个 128 维缩放向量
  · h = h + g·(block(h) − h)
· A 能力 = 底座（莎翁）；B 能力 = 新层（代码）
```

- 训练：只训新层 + 门，day2 代码，不回放

混合数据：

- 段切换：一段莎翁、一段代码
- token 级：每 4 个 token 换一次域
  - 更严格：模型必须在同一个上下文里同时用两种统计

二、实验一：段切换混合

方案	混合验证 PPL
旧门（只用底座）	77.26
新门（代码训练得到）	14.29
拼门（底座=1 + 新层代码门）	17.11
重训组合门（混合数据）	**10.49**

- 拼门 = 把两套门直接拼起来：不如重训
- 重训组合门只用 12×128 = 1536 参数
  - 比新门低约 27%

⇒ 段切换任务：组合门够用

三、实验二：token 级混合（更严格）

方案	混合验证 PPL（500 步）
旧门	270.14
新门	65.10
拼门	70.28
重训组合门	**32.69**

- 即使要求同一上下文里同时用两种能力
  - 重训组合门仍最好（32.69）
  - 比新门好一倍（65.10）
- 门值（组合门）：
  - 旧层基本不动（1.01~1.08）
  - 新层调低（0.56~0.68）

⇒ 组合门几乎不改底座，只调新层

四、实验三：加层对照（2000 步，公平预算）

方案	混合验证 PPL（2000 步）	训练损失
重训组合门	**32.38**（500 步 32.69，已收敛）	3.76
加 2 层 + 门	**309.21**	1.18

- 加层的训练损失降到 1.18（很低）
- 但验证 PPL 309.21（很高）

⇒ 典型过拟合：把 400 段混合训练数据背下来了

- 组合门训练损失 3.76，验证 32.38
  - 500 步与 2000 步几乎一样

  ⇒ 已经收敛、稳定

五、解释

【为什么重训组合门好】

- 组合任务需要"联合解"
  - 不是两个独立解的拼接
- 拼门：两个门各自学成，交互没人管
- 重训门：直接在混合数据上学联合解
  - 容量小（1536 参数），逼它学结构而不是背细节

⇒ 和"资源有限逼出压缩"一致

【为什么小数据加层会崩】

- 参数多 + 数据少（400 段）
- 模型有余力记住训练集
- 验证集是没见过的混合段 → 崩

⇒ 不是"加层没用"

是"数据不够时，加层先过拟合"

【门在这里的角色】

- 门不是"能力"，是"调度"
  - A 在底座、B 在新层时
  - 组合门负责把两者按比例调出来
- 组合门的参数只 1536，但能把 PPL 从 70 拉到 32

⇒ 结构（门）够用的时候，不需要新容量

六、工程含义

- 门库按需加"组合门"
  - 单任务门 + 组合门
  - 有 AB 数据 → 训一个 g_AB
  - 成本：千级参数、几分钟
- 加层的前提：
  - 数据足够（或加正则/回放）
  - 否则先过拟合
- 组合门可以当作"任务组合"的默认首选

七、边界

- 只有两个领域（莎翁/代码）、小模型
- 只有 400 段混合训练数据，容易过拟合
- 加层没做正则/回放对照，不能断言"加层无用"
- 段切换与 token 级混合只是两种组合形态

八、结论

- 组合任务：重训组合门 > 拼门 > 单任务门
- 小数据下加层会过拟合（训练 1.18 / 验证 309）
- 门是"调度"，参数小、泛化好

⇒ 组合能力优先用门；加层等数据够了再说

一句话：**A 和 B 要一起用的时候，先重训一个组合门；它便宜、稳定、泛化好；加层不是第一选择，除非数据够多。**

附：实验文件

- gated_mix.py　　段切换混合（old/new/pin/combo）
- gated_mix2.py　　token 级混合 + 加层对照（含 2000 步版本）

· gated_mix_results.json / gated_mix2_results_v2.json / gated_mix2_results_v3.json
· 相关：工程笔记 02/03；论文-46（数字蚊子）