工程笔记 05：门的极限——能调的，是已经压进去的能力

何淇 • 与 DeepSeek 协作

数字生命系列 • 工程笔记 05（草稿）

日期：2026-11-12

定位：实验记录，不是论文。数字都是本机实际跑的。

本节主张

门（gate）最早是当"开关"设计的：每层每 token 决定这一层算不算，目的是省算力。

但训练后它变成了别的东西：**连续缩放，重加权已有坐标**。它确实能大幅降低新领域的 PPL——但不是因为它学会了新东西，而是因为**模型里早就有那些能力，门只是把它们调出来**。

这篇用三个真模型（0.5B / 1.5B / 3B）验证这件事，并给一个推论：

```
· 门能加权的地方 = 模型已经压缩进去的能力
· 门适配的极限 = 模型里已有能力的可及性
⇒ 门可以当诊断工具：
  它到哪、与"加层/微调"差多少
  = 这个领域的能力，模型里已经有多少
```

一、设置

```
· 底座：Qwen2.5-0.5B / 1.5B / 3B（PyTorch，fp32，CPU）
· 全部权重冻结
· 门：每层一个 d_model 维缩放向量
  · h = h + g ⊙ (out − h)
  · 参数量：21.5k / 43k / 73.7k
· 训练：只训门
· 新领域 A：个人笔记（交接-21.md，中文，风格特殊）
  对照领域 B：Python 代码
· 指标：验证集 PPL（训练前 vs 训练后）
```

二、结果

模型	A 笔记（前→后）	B 代码（前→后）	附带损伤
0.5B（24 层，d=896）	91.46 → **32.71**	22.87 → 24.12	+5.5%
1.5B（28 层，d=1536）	71.26 → **27.32**	18.69 → 19.07	+2.0%
3B（36 层，d=2048）	67.65 → **26.17**	18.12 → 18.49	+2.0%

```
· 新领域 PPL 降 61~64%
· 模型越大：
  · 基线越低
  · 适配后绝对 PPL 越低
  · 附带损伤越小（5.5% → 2%）
· 但增益在收窄：1.5B→3B 只从 27.3 到 26.2
⇒ 门有效，但有天花板
```

训练成本（CPU，fp32）：

```
· 0.5B：300 步约 3 分钟
· 1.5B：250 步约 7.4 分钟
· 3B：200 步约 12.4 分钟
```

三、门到底在做什么

【事实】

```
· 门初始 = 1：等于原模型
· 训练后：mean 0.99~1.00，std 0.12~0.18
  · 平均没大改，但层与层之间有差异
· 效果：PPL 大降
```

【解释】

```
· 门不是"开关"，是"缩放"
· 缩放改变的是：
  · 每层残差贡献的权重
  · 也就是坐标方向的强度
· 训练数据告诉它：
  · 对目标领域，哪些方向该放大、哪些该缩小
⇒ 门在"重加权已有坐标"
  不是"学新坐标"
```

【我们本来的意图】

```
· 每 token 决定：这一层走不走
· 目的是省算力
· 预期不改变结果
```

【实际发生的】

```
· 连续缩放 + 可训练
· 优化器自然发现：调权重能降损失
· 于是门被拿去适配，而不是省算力
⇒ 有可调参数，优化就会用它降损失
  除非额外约束（稀疏/预算/二值）
```

四、所以：门能调的，是"已经压进去的能力"

【推演】

```
· 训练：把数据里的关系压进权重
  · 形成坐标、特征、路径
· 门：在这些已有结构上重新分配权重
⇒ 门的作用范围 ⊆ 模型已编码的能力
```

【推论】

```
· 门有效 = 目标任务的关系，模型里已经有
· 门饱和 = 目标关系不在里面
  · 要加层/新结构
⇒ 门的极限，测的是"已有能力的可及性"
```

【佐证：玩具 GPT-2 实验】

```
· 冻结 6 层 + 门：代码 PPL 1386 → 30
· 再加 6 层可训练：1386 → 4.27
· 门只能到 30，加层能到 4.27
⇒ 门够不到的，是"新坐标"
```

五、门可以当诊断工具

```
```

- 对某个领域：
  - 只训门 → 看能到哪（已有能力的上限）
  - 加层/微调 → 看能到哪（需要多少新结构）
- 两者差距 = 这个领域缺多少结构

⇒ 用法：
  - 差距小：门/LoRA 够，别加层
  - 差距大：加层，或换模型

【注意】

- 这是"可及性"诊断，不是"能力"诊断
  - 门到得低 ≠ 模型不会
  - 只是取不出来
- 也不能推出"模型理解了这个领域"

六、工程含义

- 门库/现场选门：
  - 便宜、可切换、副作用小
- 加层：
  - 数据够、门饱和时才上
- 省算力：
  - 需要硬约束（稀疏预算/二值门）
  - 否则门会变成适配器
- 模型越大，门适配越划算：
  - 副作用小、绝对效果好
  - 但增益收窄

七、边界

- 只有三个小模型（0.5B/1.5B/3B），没有 7B 以上
- 只有一个新领域（个人笔记），结论可能依赖文本类型
- 只有 PPL 指标，没有下游任务
- 没有和 LoRA/全量微调做同预算对照
- fp32 CPU，速度和显存无关结论
- 附带损伤只测了一个对照领域

八、结论

- 冻结模型 + 门可以大幅适配新领域（PPL 降 61~64%）
- 但门做的是"重加权已有坐标"，不是学新东西
- 门能调的，是模型已经压进去的能力
- 因此门的极限 = 已有能力的可及性
  - 可以当诊断：门到哪、差多少 = 缺多少结构
- 模型越大，门适配越划算，但增益收窄

一句话：**门不是学，是取；它能取出来的，只有已经压进去的东西——所以门的极限，正好可以用来量"模型里已经有多少"。**

附：实验文件

- qwen05_gate_test.py / qwen15_gate_test.py / qwen3b_gate_test.py
- qwen05_gate_results.json / qwen15_gate_results.json / qwen3b_gate_results.json
- 模型：C:\DS\models\qwen25-05b-hf、qwen25-15b-hf、qwen25-3b-hf
- 相关：工程笔记 02/03/04；论文-48（结构、压缩与维持）