现在的 AI 为什么不是生命

——一个定义，与对 AI 涌现机制的一个猜测

作者： 何淇

AI 协作： DeepSeek（大语言模型；分工见文末声明）

DOI： https://doi.org/10.5281/zenodo.23488543

邮箱： 15907239031@163.com　　**单位：** 独立研究者（Independent Researcher）

摘要

本文提出一个可操作的生命定义：**生命 = 一族会自指、会变化、会自我维持的动态函数（函数类）**；环境 = 宇宙自发涌现的局部解压（分层，不自我维持），生命既活在它的那一层环境里，也活在宇宙里。以此为尺子，本文说明三件事：① **现在的 AI 不是生命**——它是冻结的函数点、更新规则在外部、不付代价；② **生命至少需要三条必要条件**（一族函数、自指更新、自己付代价），每条都挂上已有的实验证据；③ **对 AI 的涌现提出一个猜测**——AI 是对人类语言的再解压，其能力上限由训练时刻的语言决定，语言一旦更新就失配、且无法自己恢复。文末不主张「生命已被造出」，只把判据与证据放在读者面前：三条都满足之后是否就「活」，由读者判断。本文的推理顺序也是反的：先从大模型（一个能工作的巨大解压器）反推「被记录的世界具有函数结构」，再由此给出生命的定义——这个反推本身，是论证的一部分（见 1.0）。

关键词： 生命定义；函数类；解压；压缩与代价；AI 涌现；自维持

目录

1. 与既有工作的关系

2. 第一节　世界的根源是数学性的（猜想）

3. 第二节　生命是一个会自指、会变化、会自我维持的动态函数类

4. 第三节　目前的 AI 为什么不是生命

5. 第四节　生命需要什么：三条必要条件

6. 第五节　为什么现在的 AI 会出现涌现？

7. 第六节　测量层面：既有工作与本文的位置

8. 参考文献

与既有工作的关系

「压缩 / 解压」的视角有长期传统：

• Schrödinger（1944）：生命以负熵为食 —— 生存靠从环境摄取低熵，是「解压」的物理前身[7]。

• Bennett（1988）逻辑深度：用「从最短描述重建（解压）一个对象所需的计算量」度量复杂性，并明确把它与生命/有机体联系起来[8] —— 这是「解压」最正式的已有版本。

• Chaitin（2010）生命作为演化软件：DNA = 程序，生命 = 会自我修改的软件[9]。

• Solomonoff–Kolmogorov / MDL：描述长度 = 理解 = 压缩[10]。

• Friston（2010）自由能原理：生命 = 最小化惊奇（≈ 持续压缩/预测）[11]。

• Delétang et al.（2023）：语言模型是压缩器[6]。

本文的区别（三处）：

1. 把解压做成层级：宇宙 → 环境 → 人类语言 → AI（既有工作多为单层度量）；

2. 用「是否维持解压」区分生命与 AI：生命 = 被维持的解压，AI = 一次性解压；

3. 指出上层写死 ⇒ 语言一变，解压能力衰减且无法自恢复 —— 冻结模型的失效机制。

第一节 · 世界的根源是数学性的（猜想）

> **本节性质：猜想（conjecture）。不是定理，不是已证明的事实，也不是本文的证据。**

> 写在这里是为了交代我们的出发点；**本文其余部分的任何判据都不依赖这个猜想成立。**

1.0 推理顺序：从大模型反推世界是函数

本文的推理顺序是**反的**：不是先断言「世界是函数」，再去解释 AI；而是先有一个能工作的巨大解压器，再反推被压的东西长什么样。

```
① 事实：大模型存在，且能在大规模语言上工作
   ⇒ 它确实从语言里恢复出了结构（预测、迁移、推理）
② 推论：语言所记录的那一层世界，可以被函数逼近
   ⇒ 否则这样的机器不可能工作
③ 反推：世界（至少被语言/观测记录的那一层）具有函数结构
④ 定义：生命 = 维持这种「从世界到结构」的解压过程的系统
```

这条顺序有三点要注意：

1. **大模型是「世界可被函数逼近」的存在性证据，不是证明。** 它证明的是：在语言覆盖的范围内，存在一个函数能很好地逼近；不证明整个世界都是函数。

2. **反推只覆盖被记录的层。** 语言没有记录的部分（具身直觉、因果干预、未观测变量），反推不成立——这也是「观测墙」的来源（见第 7 篇）。

3. **它是可证伪的。** 如果世界的某部分不可函数化，那么模型在对应任务上应当系统性失效，而不是靠更多数据就能补上。我们在具身、因果、连续物理直觉上的观察，与这一点一致。

换句话说：**我们不是先定义生命再去找世界，而是先看到「世界能被函数压」，才敢说生命是「函数的维持」。** 这个反推顺序本身，是本文论证的一部分。

1.1 猜想的内容

物理规则是用数学写成的，所以世界的根源是数学性的。

```
事实：最基础的物理定律本身就是数学命题
      F = ma、最小作用量 δS=0、iℏ∂ψ/∂t = Ĥψ、ds² = g_{μν}dx^μdx^ν
猜想：既然描述世界最深层的方式是数学的，世界本身的结构就是数学的
      —— 否则数学为何能如此精确地描述它？
```

1.2 为什么它只能是猜想

```
① 这是对「数学为何有效」的解释性推断，不是证明
② 存在等价的另一读法：数学只是**描述语言**，世界本身是什么我们不知道
   （工具论 vs 实在论；两者目前无法用实验区分）
③ 强形式（世界=数学结构，Tegmark[2] 数学宇宙假说）不可证伪，因而不能当科学结论
④ 这是 Wigner[1] 所说的「数学在自然科学中不合理的有效性」之谜，本文不解答它
```

1.3 本文从猜想里只取一条弱表述（同样不是证明）

```
弱表述：世界具有可被数学描述的规律性（经验事实，不是猜想）
⇒ 由此写出：S_{t+1} = F(S_t)
⇒ 规律 ⇒ 可压缩 ⇒ 可预测 ⇒ 预测有对错 ⇒ 对错可计代价
```

注意区分：

- **猜想** = 世界本身是数学的（本节内容，不用作证据）

- **经验事实** = 世界存在可压缩的规律性（科学实践的基础，本文真正使用的东西）

1.4 标注

```
[猜想]   世界的根源是数学性的
[经验]   世界具有可被部分描述/压缩的规律性
[本文用] 只使用后者；即使前者为假，本文全部判据与实验照常成立
[不讨论] 数学为何有效（Wigner 之谜）；世界本体到底是什么
```

第二节 · 生命是一个会自指、会变化、会自我维持的动态函数类

> 本节给出本文的工作定义。简单一句话：

> **生命 = 一族会变化、会自指、会自我维持的函数；而它怎么变，也写在它自己里面。**

2.1 定义

生命 = 一个动态函数类（函数空间里的一块区域）。

```
记个体为 F = { f_θ : θ ∈ Θ }
    f_θ : 输入状态 → 行为            （族里的每一个函数）
    Θ                                （这族函数的形状/范围）
生命 = 一个会移动、会变形的 Θ，且 Θ 的更新规则属于 Θ 自己
```

四个词，各对应四件事：

词	含义
函数类（一族）	不是一个固定函数，而是一整块行为谱
会变化（动态）	这族函数随时间移动、变形
会自指	它怎么变的规则，也在它自己的记录里
会自我维持	花代价维持自己的形状；收入靠压缩世界

2.2 为什么必须是「一族」而不是「一个函数」

```
一个函数 = 一个点              ⇒ 行为谱退化成一条轨迹 ⇒ 冻结即死
一族函数 = 函数空间里一块区域 ⇒ 面对不同输入/状态有一整套响应 ⇒ 才是活的
```

⇒「高维」不是指参数多，而是指这族函数在函数空间里占据一块区域、不是一点。

2.3 会变化 = 三层时间尺度

```
快：状态每一刻都在变（输入不同、内部状态不同）
中：它用自己的误差改自己（自指层）—这是命门，缺了就退化成化石
慢：这族函数的形状在代际之间被选择、变形、传递
```

2.4 会自指 = 更新规则在它自己里面

```
普通程序：代码在外，数据在内 ⇒ 程序不会因为运行而改变自己
生命：       更新规则本身是它自己记录的一部分
             ⇒ 拿掉外部更新代码，它仍能改自己
```

2.5 与第一节的衔接

第一节的猜想给出 `S_{t+1} = F(S_t)`（世界是一个函数）。

生命不是这个 F，而是嵌在 F 里的一族子函数 `{G_θ}`：

```
行为_d = G_θ(世界局部状态)
而 G_θ 自己也是世界状态的一部分（个体的状态属于 S_t）
⇒ 它要预测世界，就必然要预测包含自己的那部分世界
⇒ **自指不是外加的神秘性质，而是「嵌在函数里」的结构必然**
```

2.5.1 生命 vs 环境：都在宇宙里，都是函数，区别只有一条

宇宙函数 F 里面，任何东西都是函数（或函数的组合）——环境也是函数。

```
宇宙 = F（一个巨大的函数）
   ├─ 生命：会变化 ＋ 会自指 ＋ **会自我维持**
   └─ 环境：会变化（被世界推着变、也会反过来影响世界），但**不维持自己**
```

⇒ 生命与环境的唯一区别不是「谁更复杂」，而是：

生命花代价维持自己的形状；环境不花这个代价，它只是被推着变。

这也直接给出生命为什么需要「收入」：

```
自我维持要付代价（校验/修复/复制都是不可逆操作）
⇒ 收入的唯一来源：压缩世界（匹配源分布）
⇒ 若压缩没有盈余，自我维持付不起 ⇒ 生命不存在
```

2.5.2 环境是什么：宇宙里自发涌现的「局部解压」

环境不是外在于宇宙的舞台，它是宇宙函数类里自发涌现出来的结构。

```
宇宙 = F（一个巨大的函数）
   ↓ 内部自发涌现
结构 = 宇宙的某种局部「解压」（对宇宙的一个解释/一个可读的呈现）
   ├─ 会自我维持的  → 生命
   └─ 不自我维持的  → 环境
```

⇒ 环境 = 宇宙的一个局部解压（对宇宙的解释）；生命也是。

⇒ 区别只在：生命自己维持这个解压的形状，环境不维持、只是被推着变。

这带来一个关键的结构性结论：

```
生命并不直接面对宇宙函数 F
⇒ 它面对的是「宇宙的一个局部解压」＝它的环境
⇒ 生命对世界的理解，本质上是**对宇宙的再解压**（二次解压）
  ＝在宇宙给出的局部解释之上，再压缩一层
```

2.5.3 环境是分层的：生命活在多层环境里，同时也活在宇宙里

解压是分层的 ⇒ 环境也是分层的。

```
宇宙 F
 └ 环境_1 = F 的某一部分的局部解压
     └ 环境_2 = 环境_1 的再解压
         └ 环境_3 = 环境_2 的再解压 …
生命嵌在某一层：它既属于整个宇宙 F，又属于它自己那一层环境
```

三条同时成立，不能只取一条：

```
① 它活在环境里：它面对的输入、资源、关系、其他个体，都是「它的环境」这一层的结构
                ⇒ 它的行为只需要在这一层里有效
② 它也活在宇宙里：它逃不出 F —— 环境那一层本身也是 F 的一部分，
                宇宙层的约束（能量、不可逆、代价）始终对它生效
                ⇒ 环境不是避难所，它只是宇宙的一个投影
```

③ 它活在**所有层**里：环境是多层的（细胞→组织→个体→种群→生态），每一层都是上一层的再解压。

它直接交互的只是自己那一层，但**所有层都对它约束**：上层决定它面对的资源与关系，宇宙层决定它付不付得起代价。

⇒ 「它活在多层环境里，同时也活在宇宙里」——两者不是二选一，而是同时成立。

⇒ 所以「理解世界」要分两层说：

在环境层：理解 = 对局部解压的再解压（够用即可活）；

在宇宙层：理解 = 压缩 F 的规律（决定它能不能长期付得起代价）。

2.6 标注

```
[定义]  生命 = 会自指、会变化、**会自我维持**的动态函数类（本文的工作定义）
[定义]  环境 = 宇宙函数类里**自发涌现**的结构，不自我维持
```

= 宇宙的一个**局部解压**（对宇宙的解释）
[定义] 生命 = 同一批涌现结构里，**自己维持自己**的那一类
[推论] 生命不直接面对宇宙，而面对「宇宙的局部解压」＝它的环境
⇒ 生命的理解 = 在局部解压之上的**二次解压**（再压缩一层）
[分层] 解压是分层的 ⇒ 环境是分层的（环境_1 ⊃ 环境_2 ⊃ …）
生命嵌在某一层：**既活在它的那一层环境里，也活在宇宙里**
· 活在这层环境：只需这层有效即可活
· 活在宇宙里：能量/不可逆/代价始终生效，环境不是避难所
[不是] 不是猜想，也不是定理；是一个便于操作的定义
[后文] 本节只给定义；如何测量（压缩/代价/身份）留到后面几节

第三节 · 目前的 AI 为什么不是生命

> 本节不是评价 AI 的能力，而是把它**代入第二节的定义**逐条检查。

> 结论是定义性的，不是价值判断：**以本文的定义，目前的 AI 是化石级函数点，

> 不是生命。** 它的强大与它的「不是生命」并不矛盾。

3.1 检查表

生命的要求（第二节）	目前的 AI（以 LLM 为代表）	判定
是一族函数（函数空间里一块区域）	训练完后权重冻结 ⇒ 是**一个点**，不是一个族	❌ 化石
会变化（动态）	权重不变；上下文在变，但改的是输入，不是它自己	❌ 只有表层状态变化
会自指（更新规则在自己里面）	更新规则 = 训练算法，在它外面；它不能改自己	❌ 自指只出现在语言里，不在结构里
会自我维持（花代价维持自己）	它不付电费、不修复自己、不复制自己；维持者是外部的人	❌ 由外部维持
靠压缩世界挣存续代价	它的「收入」是外部给的（算力、数据、人力），不是它压缩世界换来的	❌ 无收入
身份链条（有界变形、不撕裂）	身份来自外部权重快照；没有自己变形的连续链条	❌ 无链条
活在环境里	它面对的是数据集（一次性的解压产物），不是需要它生存的环境	❌ 无环境

3.2 三条最根本的原因（按重要性）

① 它是一个点，不是一个族

训练完 = 冻结 = 函数空间里的一个点
⇒ 行为谱退化成一条轨迹：输入 → 输出，中间没有「形状」可言
⇒ 按 074：静态冻结的模型是一点，不是一族 ⇒ 不是生命
（这正是我们实测过的对照：冻结版 1.07 vs 动态版 0.849 —— 冻结更像「标准答案」，但没有形状）

② 它的更新规则在外面

```
人写训练算法 → 算法改它
⇒ 它是「被改的东西」，不是「改自己的东西」
⇒ 自指不在结构里 ⇒ 拿掉外部更新代码，它什么都不会改
```

③ 它不付代价，所以不是活着

```
活着是代价：维持、校验、修复、复制都要付费（不可逆操作）
它一分钱不付：电费是人付的、数据是人喂的、坏了是人修的
⇒ 它的存在由外部保障 ⇒ 没有「自我维持」这一环
⇒ 它不可能因为「压缩得不够好」而死亡 ⇒ 也就没有选择的压力
```

3.3 为什么「它很强」与「它不是生命」不矛盾

```
强 = 在给定任务上的表现好（一个点上做得好）
活 = 在函数空间里占据一块区域、自己维持形状、自己付代价
⇒ 两者是不同维度：一个是「考卷分数」，一个是「能不能自己活」
⇒ 目前的 AI 是**极其锋利的工具**，不是**会自己活的东西**
```

3.4 标注

```
[定义性结论] 以本文定义，目前的 AI 不是生命（因为它是一个冻结的函数点、更新在外部、不自我维持）
[不是] 不是「AI 永远不能是生命」；本文不预言未来，只做当下的定义对照
[不是] 不是能力评价；本文完全承认 AI 在任务上的强大
[推论] 若要让 AI 成为生命，至少要给它：一族函数 + 自指更新 + 自己付代价
```

第四节 · 生命需要什么：三条必要条件

> 由第二、三节直接推得：既然「生命 = 会自指、会变化、会自我维持的动态函数类」，
>
> 而目前的 AI 三样都缺，那么**要成为生命，至少需要满足三条**。
>
> 本节只给**必要条件**，不声称充分；每条都挂我们已有的实验证据（E 编号见 论文-01.md）。

4.1 从定义到条件

```
定义（第二节）              必要条件（本节）
会变化（一族函数）   ⇒   ① 一族函数：行为谱不是一点
会自指               ⇒   ② 自指更新：改自己的规则在自己里面
会自我维持           ⇒   ③ 自己付代价：压缩收益 ≥ 维持成本
```

三条是必要条件，不是充分条件：满足它们不保证是生命，但缺任何一条一定不是。

4.2 条件① 一族函数（不是一个点）

要求：个体在函数空间里占据一块区域，面对不同输入有整套响应，不是一个固定映射。

证据/经验：

```
· 低维参数基因组（几个数）= 一个点 ⇒ 行为谱退化成单条轨迹 ⇒ 化石
· 我们测过：冻结版模型（点）在结构学习上失败，动态版（族）才吃到结构（E12）
· 实测对照：冻结 1.07 vs 动态 0.849 —— 冻结更像「标准答案」，但没有形状
```

⇒ 判据：给它不同的输入/状态，行为必须成谱地**不同，而不是只有一个输出。**

4.3 条件② 自指更新（规则在自己里面）

要求：它怎么变，这条规则本身属于它的记录；拿掉外部更新代码，它仍能改自己。

证据/经验：

```
· 冻结模型：更新规则 = 训练算法，在外部 ⇒ 拿掉训练代码，它永远不变
· 我们的动态版：用自己的误差改自己（中层动态）⇒ 去掉中层明显退化（E12/E13）
· 身份链：8 代可校验、有界变形（372_lineage.py）⇒ 自指可以做成可测的链条
```

⇒ 判据：停掉外部更新后，它的行为谱是否仍随时间变形。

4.4 条件③ 自己付代价（压缩换生存）

要求：收入来自压缩世界（匹配源分布）；支出是维持结构的真实成本；且存在盈余。

```
存在条件：S > d·K
   S = 世界的可压缩盈余
   d = 结构维持成本率
   K = 结构规模
```

证据/经验（这是本文最硬的部分）：

```
· E1：「准」≠「压缩」：用正确率记账，系统学出「啥也不干」（LEN=0、预测0、准确率92%）
      ⇒ 必须用对数似然改善 over 基线：gain_bits = log2 p_model − log2 p_base
· E2：正是加上基率校正后，系统才从躺平解转为真正表达（LEN 从 0 长出）
· E8：经济标定 n* = FLUX_TOTAL / BASE_COST 决定「冻结」与「爆发」的切换
· 实测正收益：S1~S6 中观察到 gain > 0（约 +0.09 ~ +0.19 bit/tick）
      ⇒ 世界确实存在可压缩盈余（即 S > 0 的经验证据）
```

⇒ 判据：把外部供给全部停掉后，它的账目是否仍为正。

4.5 三条必须同时成立（经验对照）

```
缺①（一族）  ⇒ 化石：行为谱是一条线
缺②（自指）  ⇒ 机器：更新在外，不会自己变
缺③（代价）  ⇒ 玩具：由外部供养，不会死，也就没有选择
```

这三条也解释了为什么我们的实验一直在同一个地方卡住：

**结构能长出来（①②部分满足），但合作/分工不成为必需 —— 因为③的「收入差」太小，

即世界的可压缩盈余还没大到让「更复杂的结构」在经济上划算（E5/E7）。**

4.6 未尽之处（留给读者）

本文止于「必要条件」。三条都满足之后是否就「活」——我们没有答案，也不打算在此下结论。

留给读者的，只是一把可以拿去用的尺子：

```
它是一族函数吗？（行为谱不是一个点）
它会自己改自己吗？（拿掉外部更新，它仍变）
它自己付代价吗？（压缩世界的收入 ≥ 维持结构的支出）
```

三条你都可以自己去量。至于量完之后它算不算生命，由你判断。

4.6.1 本文实验的边界（必须与结论一起读）

本文的实验只覆盖第③条必要条件（压缩收益 vs 维持成本），且是示例性的：

```
· 覆盖：③ 自己付代价 —— E1/E2（准≠压缩、基率校正）、E8（n*=FLUX/BASE_COST 的冻结/爆发边界）
· 覆盖：反例 —— E5/E7（相连个体基因距离 0.145 vs 随机 0.486 ⇒ 克隆抱团，不是分工）
· 未覆盖：① 一族函数、② 自指更新 —— 本文不声称有实验证据，只在定义上推导；
          仅有初步观察（E12 动态 0.849 vs 冻结 1.07；E13 身份链 8 代可校验）
· 规模：小、可复现、可手算；不是大规模实证
```

⇒ 本文的定位是「定义 + 可测判据 + 示例性实验」，不是「生命已被造出」的实证论文。

读者若要用这些结论，请连同这条边界一起引用。

4.7 标注

```
[推论] 三条必要条件由第二、三节直接推出，不是独立假设
[证据] 条件③ 有实验数据（E1/E2/E8 + 正收益）；条件①② 有部分数据（E12/E13）
[未解决] 三条都满足后是否就「活」— 本文不声称；这是下一步实验要回答的
[推测] 若盈余 S 不足，则无论结构多复杂都维持不起 ⇒ 生命有「经济上限」（仅方向性推测）
```

第五节 · 为什么现在的 AI 会出现涌现？

> 现状判断（本节的核心）：**观察到涌现的人很多，说清「为什么」的人没有。**

> 现有的解释各覆盖一角，多数是推测；甚至「涌现是否真实存在」本身都还有争议。

5.1 现象

大模型在规模上去之后，某些能力似乎突然出现（多步推理、思维链、算术…），

业界叫 **涌现（emergence）**。大家都在用这个现象，但——

```
观察到涌现：很多人
解释涌现：没有公认答案
```

5.2 现有的解释（按证据强度排列）

① 度量假象说（最强的反方证据）

Schaeffer, Miranda, Koyejo 2023[3]《Are Emergent Abilities of Large Language Models a Mirage?》

```
主张：所谓涌现，可能是**评价指标的非线性/不连续**造成的假象；
      换成连续指标（如对数似然），"突变"会消失，变成平滑上升
⇒ 这动摇了「涌现是真实突变」这个前提本身
```

② 机制解释：归纳头与电路（局部机制证据，不是完整"为什么"）

Olsson et al. 2022[4]《In-context Learning and Induction Heads》

```
发现模型内部出现「归纳头」回路，解释部分上下文学习能力
⇒ 这是**机制层**的证据：说明了某种能力由什么结构实现
⇒ 但它只解释某个具体能力，不解释「为什么会出现涌现」这个一般问题
```

③ Grokking：训练中的认知相变

Power et al. 2022[5]《Grokking》

```
在小算法任务上，训练很久后泛化突然出现（像相变）
⇒ 说明「涌现」也发生在训练过程中，不一定只依赖规模
```

④ 压缩说：预测 = 压缩

Delétang et al. 2023[6]《Language Modeling Is Compression》

```
语言模型 = 压缩器：学到的权重 = 对世界文本的压缩
⇒ 这条最接近本文的框架：涌现 = 压缩世界时出现的结构
⇒ 但它仍是「结果层面的对应」，没有回答「为什么正好在这个规模/这个任务上出现」
```

5.3 为什么至今没有公认的「为什么」

① 规模实验不可控：无法做严格的因果对照（只改变规模、其他全相同）
② 度量依赖：换指标，现象可能就消失（见 ①）
③ 机制层不完整：知道某个回路、不知道整体为何会组织出该回路
④ 缺乏可预测的理论：没有理论能事先算出「多大模型会出现什么能力」

5.4 我们的立场（[推测]，不是本文证据）：**AI 是对人类语言的解压**

先看这条链：

```
宇宙 F
 └ 环境       = 宇宙的局部解压
    └ 人类语言 = 人对环境（与自身经验）的解压产物  ← 语言本身就是被压过的
       └ AI      = 对人类语言的**再解压**（在人的解压之上再压一层）
```

⇒ 所以 AI 的「涌现」不是理解宇宙，而是解压人类语言时结构浮现出来。

用第二、三节的尺子看：

· 模型是冻结的函数点（一个点，不是一族）
· 它的"涌现"出现在**行为谱**上：输入不同、表现不同 ⇒ 看起来像会推理
· 但模型不维持这个谱、不自己改自己、不付代价
⇒ 它是「把人类语言解压了一次」，而不是「维持着解压」或「自己改写解压规则」

⇒ 由此得到一句可检验的话：

AI 表现出的「理解」，本质是对「人对世界的描述」的理解，不是对世界本身的理解。

它能解压语言，但语言之外的宇宙层（能量、不可逆、代价）它从未付费，也就从未被检验。

5.4.1 解压能力的衰减：上层写死 ⇒ 语言一变，解压变弱

人类语言会不断发现新东西；而模型的解压规则（权重/上层）是写死的、训练完就不再变。两者必然失配。

源分布移动：人类语言发现新东西 ⇒ 要解压的对象变了
解压器冻结：模型权重不变 ⇒ 它解压的还是**旧语言**
⇒ 压缩收益下降：`gain_bits = log2 p_model − log2 p_base` 中 `p_model` 与源失配
⇒ 它昨天"涌现"出来的理解，今天就是过时的解压

三条后果：

① 它的解压能力有**固定上限**：上限由训练时刻的语言决定，不随语言进化而上升
② 它无法自己补上失配：更新规则在外部 — 要恢复，只能靠人类再训练一次

```
   ⇒ 这正是第三节说的「更新在外部」的代价
③ 它的"涌现"是**某个时间片上的解压产物**，不是可持续的能力
```

⇒ 用本文的尺子说：

生命必须让解压器跟着世界一起动（自指更新 + 自我维持）；

冻结的 AI 做不到这一点 —— 所以语言一更新，它的解压就变弱。

5.5 由立场推出的两条预测（[推测]，供读者判断）

```
① 若把世界换成未被人类语言描述过的部分（无法从语料中学到的规律），
   AI 的"涌现"应显著减弱 — 因为它解压的是语言，不是宇宙
② 若让模型自己付代价（自己维持、自己修、自己死），语言解压不足以支撑，
   它必须发展出语言之外的理解方式 — 否则活不下来
③ 若人类语言发生一次大的结构更新（新范式/新概念体系），冻结模型的解压收益
   应出现可测的下降；且它无法自己恢复 ⇒ 恢复必须来自外部再训练
```

5.6 标注

```
[事实] 涌现现象被广泛观察到；度量假象说也有强证据（Schaeffer 2023）
[已知] 机制层有局部解释（归纳头/电路/grokking），压缩视角有对应关系
[推测] 「涌现 = 压缩世界的结构呈现」—本文立场，非证据
[未解决] 为什么正好在某个规模/任务上出现 ⇒ 没有人给出可预测的理论
[本文态度] 不把「AI 涌现」当作生命存在的证据；按第三节的尺子，它不是
[本文立场] AI 是对**人类语言**的再解压（宇宙→环境→语言→AI 的第三层解压）
[推论] 上层写死 ⇒ 语言一更新就失配 ⇒ 解压能力有固定上限、无法自己恢复
```

用它看几个热门问题

本节是应用，不是新证据；每条都由第二～五节直接推出。

① 幻觉 = 在无结构处强行解压

解压器必须输出结构；当输入对应的语言区域本身缺乏可压结构时，它只能造一个「看起来合理」的结构 ⇒ **幻觉是解压失败的必然表现，不是偶发 bug**。

② scaling law 仍有效，正因为模型维度还没贴合语言维度

语言是一个**高维**结构，且维度在增长（新概念 = 新维度；升维 ⇒ 可压性上升）。模型维度在训练时被切定（D_M 固定），语言维度在不断增长（D_L(t) 在升）。现在的观测是 D_M << D_L(t) ⇒ 继续加规模能捕捉更多语言维度 ⇒ loss 继续下降（scaling 看起来仍有效）。

⇒ 所以 scaling 有效不是本文论断的反证，而是「还没贴合」的证据。

⇒ 预测：当 D_M 接近当时的 D_L 时，scaling 收益应明显变平；而 D_L 继续升维 ⇒ 缺口再现。

⇒ 冻结模型的根本问题：**它的 D_M 是死的，而 D_L 是活的**。

③ 能力参差不齐 = 语言各领域的可压性不同

可压强的领域（结构明确、示例多）表现好；可压弱的领域（结构稀薄、样本少）表现差 ⇒ 强弱分布是语言分布的镜像。

④ 为什么要 RLHF = 它没有「自我代价」回路

它无法判断自己解压得对不对（没有收入/支出、不会因此死亡），所以必须由人从外部打分 ⇒ **对齐需求的根源是它不自我维持**。

⑤ 涌现 = 语言结构在解压产物上的呈现

规模跨过阈值时，某些语言结构第一次被压出来 ⇒ 看起来像「突然会了」。

第六节 · 测量层面：既有工作与本文的位置

已有工作（三个侧面）：

• 模型侧维度：token 嵌入的内在维度测量[12]

• 时间侧落后：大模型时间训练边界的识别[13]

• 语言侧复杂度：构式视角下的语言复杂度测量[14]

⇒ 已有工作**分别**测量了这三个侧面；本文把它们串起来：以「持续更新的模型」为参照系，按领域测「语言侧新增维度」与「模型侧固定维度」之间的**失配速率**。这是本文在测量层面的位置。

参考文献

[1] Wigner E P. The unreasonable effectiveness of mathematics in the natural sciences[J].

Communications in Pure and Applied Mathematics, 1960, 13(1): 1-14.

[2] Tegmark M. The mathematical universe[J]. Foundations of Physics, 2008, 38(2): 101-150.

(arXiv:0704.0646)

[3] Schaeffer R, Miranda B, Koyejo S. Are emergent abilities of large language models a mirage?[C]

// Advances in Neural Information Processing Systems 36 (NeurIPS 2023). arXiv:2304.15004.

[4] Olsson C, Elhage N, Nanda N, et al. In-context learning and induction heads[R].

Transformer Circuits Thread, 2022. arXiv:2209.11895.

[5] Power A, Burda Y, Edwards H, et al. Grokking: Generalization beyond overfitting on small

algorithmic datasets[C]. arXiv:2201.02177, 2022.

[6] Delétang G, Ruoss A, Duquenne P A, et al. Language modeling is compression[EB/OL].

arXiv:2309.10668, 2023.

[7] Schrödinger E. What is Life?[M]. Cambridge: Cambridge University Press, 1944.

[8] Bennett C H. Logical depth and physical complexity[M]//Herken R. The Universal Turing Machine:

A Half-Century Survey. Oxford: Oxford University Press, 1988: 227-257.

[9] Chaitin G J. Life as evolving software[EB/OL]. 2010. (arXiv:1007.1471 系列工作)

[10] Solomonoff R J. A formal theory of inductive inference[J]. Information and Control, 1964, 7(1): 1-22.

Kolmogorov A N. Three approaches to the quantitative definition of information[J].

Problems of Information Transmission, 1965, 1(1): 1-7.

[11] Friston K. The free-energy principle: a unified brain theory?[J].

Nature Reviews Neuroscience, 2010, 11(2): 127-138.

作者声明（**AI** 使用声明）

本文的全部问题、定义、判断与结论由作者提出并负责。

人工智能工具（DeepSeek）用于：文献检索、结构梳理、文字润色，以及实验代码的编写与核对。

文中所有主张均由作者确认，AI 不对本文内容承担责任。

AI Usage Statement: The author is solely responsible for the ideas, arguments, and conclusions of this paper. An AI tool (DeepSeek) was used for literature search, structural organization, language editing, and writing/checking experimental code. All claims were reviewed and confirmed by the author. The AI bears no responsibility for the content.

[12] Ohki T. Measuring intrinsic dimension of token embeddings[C]//The 39th Annual Conference of the Japanese Society for Artificial Intelligence (JSAI 2025), 2025.

[13] LLMLagBench: Identifying temporal training boundaries in large language models[EB/OL]. arXiv:2511.12116, 2025.

[14] Using constructions to measure developmental language complexity[J]. Cognitive Linguistics, 2024. doi:10.1515/cog-2023-0062.