论文-14 · 语义残差的测量：文本极限与接地补齐

何淇 · 与 DeepSeek 协作

数字生命系列 · 实验篇 5（内部编号第 14 篇）

日期：2026-10-24

摘要

本文把"语义残差"从一个模糊的说法变成一个可测的量。

先把定义写清：语言是人类对世界的压缩，语言可以写成 p语言 + R语言；p语言 是可以被函数近似的部分，R语言 只声明、不展开。语义是语言与现象之间的对齐关系；语义残差 = 这个对齐映射在给定模态组合下的误差下界。

实验用受控歧义：文本用精确词、模糊组词、省略三种方式描述同一个合成对象，歧义是程序生成的，所以"文本能给出的极限"可以解析算出来（贝叶斯底）。然后测三个量：贝叶斯底、只读文本的模型误差、以及文本加图像（接地）后的模型误差。

结果：文本模型的误差与贝叶斯底只差 1.5 到 2.7 个百分点（0.725 对 0.750；0.835 对 0.850；0.688 对 0.714），说明拟合已经到位，剩余残差来自文本本身；接地后三个属性的准确率都到 1.000，说明文本缺的那个维度被图像补上。

结论：语义残差可以定义、可以测量；它分为"该模态下的不可约底"（歧义内生的）与"可约部分"（接地/补数据能消除的）。这个区分让"AI 理解了多少语义"有了分母。

一、问题

我们之前说过两句话：语言是人类对世界的压缩；大模型压缩的是语言的 p语言。

但"p语言"与"语义"之间还缺一个可测的连接。本文要回答的问题是：能不能把"语义残差"定义成一个数，并且用玩具实验测出来？

要做到这一点，需要三样东西：一个定义（语义残差是什么）、一个参照线（文本本身能给出的极限是多少）、一个对照（补上别的模态后残差降不降）。

二、定义

2.1 沿用系列的定义

宇宙 = P + R，其中 P 是可函数化的部分，R 是不可函数化的部分。语言也写成 p语言 + R语言：p语言 可以被函数近似，R语言 只声明、不展开。生命 = p生命 + R生命，其中 p生命 是在 P 中、被宇宙保住的动态函数类。

本文只处理 p语言 这一侧。

2.2 语义是映射

把语义定义成一个映射：给定语言表达式和它对应的现象（图像、事件、状态、动作、量），语义就是"表达式 → 现象"的对应关系。

这个映射不是单层的：它按模态有多个维度——视觉维度（文字对图像）、事件维度（句子对时间线）、状态维度（描述对系统状态）、动作维度（指令对后果）、量的维度（程度词对可测量的量）。语义残差按维度出现。

2.3 语义残差

定义（语义残差）：固定模态组合 M（例如：只有文本；或文本加图像），设误差度量是预测现象属性的错误率。语义残差 = 在模态组合 M 下，任何函数能达到的最小误差。

这个定义把残差分成两部分：

- **不可约底**：由模态组合本身决定的误差下界。文本有歧义时，有些信息文本里根本没有，任何函数都补不上。

- **可约部分**：模型没拟合到位造成的差距；加数据、加容量、加模态可以降下来。

判据很直接：加手段之后误差底降不降。降 ⇒ 可约；不降 ⇒ 该模态下的不可约底。

2.4 参照线：贝叶斯底

在玩具世界里，文本的生成过程是已知的，所以"文本能给出的极限"可以解析算出来：给定一条文本，属性的后验分布由生成过程决定；贝叶斯最优预测器的正确率就是上限。

这个上限就是"文本极限"。它比任何模型都高不了；模型能接近它，就说明拟合到位了。

三、实验设计

世界：合成对象，三个属性——颜色（4 种）、形状（2 种）、数量（1 到 3）。对象渲染成 8×8 的图像（颜色、形状、数量都可见）。

文本：三个槽位拼成的描述，每个槽位都有受控歧义。

- 颜色槽：以 0.5 概率给精确词（红/蓝/绿/黄），以 0.5 概率给模糊组词（暖色 = 红或黄；冷色 = 蓝或绿）。

- 形状槽：以 0.7 概率给精确词（圆/方），以 0.3 概率省略。

- 数量槽：以 0.5 概率给精确词（一/二/三），以 0.5 概率给模糊词（几个 = 一或二）。

因为生成过程已知，每条文本对应的属性后验可以算出来，贝叶斯底也就能解析计算。

模型：两层小网络（隐藏层 32，约 2000 个参数）。文本模型只看文本加任务标识；接地模型再看图片（8×8×3 展平）。

三个量：贝叶斯底、文本模型准确率、接地模型准确率。差值是"可约残差"。

四、结果

颜色的贝叶斯底是 0.750，文本模型 0.725，接地模型 1.000。形状的贝叶斯底是 0.850，文本模型 0.835，接地模型 1.000。数量的贝叶斯底是 0.714，文本模型 0.688，接地模型 1.000。

三点解读。

第一，文本模型与贝叶斯底只差 1.5 到 2.7 个百分点。这说明模型对文本的拟合已经到位；剩下的差距不是模型不行，是文本里本来就没有那些信息。

第二，接地之后三个属性都到 1.000。图像提供了文本缺的那个维度，残差被补齐。所以"文本极限"下的那部分残差，属于该模态组合，不属于世界：换一个模态组合，它可以被消掉。

第三，由此得到的语义残差是分层可测的：文本-only 的残差（颜色 25%、形状 15%、数量 29% 左右）是"文本能给出的极限"；接地后的残差是 0，说明这部分残差是可约的，只是需要另一个模态。

五、说明什么，不说明什么

说明：语义残差可以定义成一个数；该数可以拆成"不可约底"与"可约部分"；在玩具世界里，两者的分界可以解析计算，并与模型表现对上。

不说明：不证明真实语言的语义残差有多大；不证明 R语言 存在或不存在（本文只处理 p语言 侧）；不证明"接地一定能补齐"在所有任务上成立——本文只测了视觉维度，其他维度（事件、状态、动作）没有覆盖。

六、局限

第一，世界是合成的，歧义是程序构造的；真实语言的歧义来自历史与用法，形式不同。

第二，模型很小（约 2000 参数），不是大模型；但本文测的是"文本极限 vs 接地补齐"的机制，与规模无关。

第三，只做一个模态的接地（图像）；多模态（事件、动作）的残差没有测。

第四，贝叶斯底只在生成过程已知时可算；真实语言里这个底要用人类分歧率来近似（下一项工作）。

七、与既有工作的关系

语义残差的测量不是新题目，至少有三条已有线索。

第一，人类标签变异：同一段文本，不同标注者本来就会给出不同解释，"人类天花板"与"标注分歧"在评测里一直被报告。

第二，歧义基准：AmbigQA、词义消歧一类任务，专门测"同一句话有多种合理解读"的情况。

第三，接地测试：纯文本模型在需要视觉属性的问题上明显退化；gSCAN、ReaSCAN 一类合成任务表明，没有接地的语言模型过不了接地泛化测试。

本文的不同只有一点：用受控歧义让"文本极限"可以解析算出来，并把残差拆成"模态决定的不可约底"与"接地/补数据可消的可约部分"。测量的思路不是本文首创；本文做的是一个受控、可解析算底的版本。

另外，符号接地问题（Harnad）指出符号与所指的连接不能从符号内部获得；本文的表述是"文本-only 的语义残差有解析底，接地可以把该底补上"。

评测方面，近年的工作开始报告"人类天花板"，本文的做法可以看成它的一个受控版本：因为我们知道数据生成过程，所以能算出真正的上限，而不是估计。

系列内部：第 4 篇（结构换算力）表明对齐语料提升样本效率；第 10 篇（颜色作为第一块积木）表明感知基元可以先于语言对齐。本文把这两条接到"语义残差"上：接地降低的是残差，而不只是提升效率。

八、可复现

脚本：820_semantic_residual.py。依赖 Python 3 与 numpy，无 GPU，内存占用低（百 MB 以内）。

附：标注

- **[定义]** 语义 = 语言与现象之间的对齐映射（按模态分维度）。

- **[定义]** 语义残差 = 给定模态组合下的最小可达误差。

- **[可测]** 玩具世界里，该残差可解析计算并与模型对上（颜色 0.750/0.725/1.000 等）。

- **[可约]** 接地后残差降到 0（本实验的视觉维度）。

- **[未判]** 真实语义残差的大小；R语言 是否非空。

- **[不声称]** 不声称"语义可被完全函数化"，也不声称"不可函数化"——R 只声明，不展开。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。