论文-16 · 分层是对动态的补偿：一个自适应深度的玩具实验

何淇 · 与 DeepSeek 协作

数字生命系列 · 实验篇 6（内部编号第 16 篇）

日期：2026-10-24

摘要

大模型的层数是固定的：每个输入都走完全部深度。本文问一个简单的问题：有些输入根本不需要那么多层，是不是可以少走？如果"层"是对动态的补偿——一层相当于一步时间，那么需要几步的任务就给几层，均匀深度是浪费。

实验用迭代任务：x_{t+1} = tanh(A x_t)，给定初值 x_0 与步数 T，预测 x_T。模型是共享权重的循环层，一层就是一步计算。三组对照：固定 16 层、自适应（走 min(T,16) 层）、固定 6 层（与自适应等平均算力）。

结果：在等平均算力（都是 6 步）下，自适应深度在每个 T 上都更好——平均误差 1.29 对 1.67。差距最大的是 T=1：固定 6 层把简单输入算了六遍，反而算坏了（误差 2.30 对 1.49）。固定 16 层则又贵又差：算力是自适应的 2.67 倍，平均误差 1.68。

结论：均匀深度两头都亏，简单输入被过度计算、复杂输入又算不够；按需分配深度可以用同样的算力换更高的精度。这与"层≈时间步、深度补偿动态"的图景一致。全部是玩具规模，不是大模型实验。

一、问题

现在的大模型是"均匀深度"的：每个 token 都过完全部层。但输入的难度并不一样——有的句子一眼能懂，有的需要多步推理。如果深度真的对应"计算步数"，那么固定深度就同时犯两个错：

- 简单输入：走了用不上的层，白花算力，甚至因为过度计算而变差；

- 复杂输入：层数不够，算不完，误差下不来。

本文要测的正是这两件事：同算力下，按需分配深度会不会更好？过度计算有没有害？

二、理论背景

这个实验来自一个画面：把函数看成它的图像（曲面），时间方向的演化会在曲面上"摊出厚度"；而冻结的模型没有真正的时间演化，只能用深度（层）去摊开这个厚度，一层相当于一步。所以：

- 需要的步数多 ⇒ 需要的层多；

- 需要的步数少 ⇒ 层可以少，多走就是过度计算。

这个画面在《厚度与维度：残差的几何图景》里已经写下；本文把它做成一个可测的实验。

三、实验设计

世界：取一个固定的随机映射 x_{t+1} = tanh(A x_t)，A 是 8×8 随机矩阵。任务是从初值 x_0 和步数 T 预测 x_T，T 取 1、2、4、8、16。

模型：共享权重的循环层。每层做一次 h ← tanh(W h + U x_0 + b)，最后用线性头输出预测。层数 = 走的步数，权重在所有步之间共享。

三组对照：

- A 固定 16 层：不管 T 是多少，都走满 16 步；

- B 自适应：走 min(T, 16) 步；

- C 固定 6 层：与 B 等平均算力（B 的平均步数是 6）。

指标：各 T 上的平均误差；平均步数（= 平均计算量）。

四、结果

等平均算力的一组（B 与 C，都是平均 6 步），B 在每个 T 上都更好：

T=1 时，B 是 1.49，C 是 2.30。T=2 时 1.27 对 1.57；T=4 时 1.38 对 1.50；T=8 时 1.22 对 1.50；T=16 时 1.07 对 1.46。平均下来 1.29 对 1.67。

固定 16 层（A）最差也最贵：平均误差 1.68，平均算力是自适应的 2.67 倍。

三点解读。

第一，过度计算真的有害。T=1 只需要一步，固定 6 层却把同一个映射迭代了六遍，结果比只走一步差得多。这不是"多算一点没关系"，是"多算会算坏"。

第二，层数不够真的补不回来。T=8 与 T=16 需要超过六步，固定 6 层的误差明显更高。

第三，均匀深度是两头亏：它既浪费在简单输入上，又不够用于复杂输入。按需分配能在同算力下更准。

五、对大模型的含义

这个实验是玩具，但它的形状可以直接搬到大模型：

- 不是所有输入都值得同样的深度。简单 token、简单上下文可以早退（early exit）；需要多步推理的才值得走深。

- 既然过度计算会算坏，那么"无脑加深"不是稳赚的：深度也要按需。

- 工程上这对应一类方法：早退、按 token 跳过、条件计算。本文不提出新方法，而是给这类方法一个"补偿动态"的解释与一个公平对照。

要注意的是，"按需"有一个前提：知道需要多少步。实验里 T 是给定的；真实场景中步数是估计出来的，估计错了，收益就会打折。

六、局限

第一，世界是合成的，映射是随机矩阵，任务不是语言。

第二，模型是共享权重的循环层，不是 transformer；大模型里的层不共享权重，深度的作用更复杂。

第三，T 是手工给的，真实模型没有这个先验，需要另做"步数估计"。

第四，只测了误差与算力两个量，没有测训练稳定性、路由开销这些工程代价。

七、与既有工作的关系

"按需计算深度"不是新想法：早退（early exit）、循环深度（universal transformer）、按 token 跳过层（conditional computation、mixture-of-depths）、层剪枝都有大量工作。

本文不声称方法原创；本文的不同在于两点：一是把它放在"层≈时间步、深度补偿动态"的图景里解释；二是做了一个等平均算力的公平对照——不是"我们的方法稍好"，而是"同样算力下，按需分配在两个方向上都更好"。

八、可复现

脚本：850_adaptive_depth.py（主对照）、851_adaptive_depth_v2.py（等算力对照）。依赖 Python 3 与 numpy，无 GPU，内存占用低。

附：标注

- **[事实]** 实验数字（等算力下自适应全面更好；T=1 过度计算有害；固定 16 层又贵又差）。

- **[图景]** 层≈时间步、深度补偿动态——来自《厚度与维度》（论文-15），标[猜想]。

- **[推测]** 大模型用自适应深度可在同等算力下更准——玩具结论的推广，未在真实模型上验证。

- **[不声称]** 不声称提出新方法；早退与条件计算都已有工作。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。