论文-17 · 厚度与随机性：冻结模型在哪里最不稳定

何淇 · 与 DeepSeek 协作

数字生命系列 · 实验篇 7（内部编号第 17 篇）

日期：2026-10-24

摘要

冻结的模型没有真正的时间演化，只能靠层数去模拟"多步计算"。本文问一个可测的问题：在这样的模型里，随机性/不确定性出现在哪里？

先给出三个基于"厚度"画面的推论：需要步数越多的位置误差与随机性越大；随机性随深度累积，在输出端最大；人类分歧大的地方（厚且不可摊薄），模型的熵也大，而且加数据摊不平。

然后做三组玩具实验。第一组是序列累积任务：位置越靠后（需要步数越多），固定 16 层模型的误差从 0.67 升到 1.57，输入加噪声后的输出标准差从 0.20 升到 0.40。第二组测逐层方差：标准差从第一层 0.21 单调升到最后一层 0.41；而干净输入下误差不随层数上升，说明上升来自噪声被逐层放大。第三组模拟人类分歧：thin（事实题，人类一致）与 thick（判断题，人类有分歧）两类题，人类分歧熵 0.000 对 1.014，模型预测熵 0.249 对 0.972，相关系数 0.917；把数据加到五倍，thin 题的熵从 0.249 降到 0.145，thick 题几乎不动（0.972 到 0.958）。第四组给"时间"：迭代八步后 thin 题的熵从 0.69 压到 0.02，thick 题只从 0.99 压到 0.91；多次采样投票也类似（thin 0.67 到 0.28，thick 0.96 到 0.69）。

四个实验合起来支持两句话：**冻结模型最厚的地方，就是它最随机的地方；而"最厚"可以由需要步数与人类分歧来度量。给数据与时间能摊薄"冻结造成的随机"，但摊不平"数据里的分歧"——后者才是真厚。**全部是玩具规模，不涉及真实大模型。

一、问题

现在的模型是冻结的：权重不变，没有真正的时间演化。它要在一次前向里完成"需要多步才能完成"的计算，只能靠层数铺开。

那么问题来了：这么铺开之后，哪些地方会变得不稳定、随机？本文的假设来自"厚度"画面：厚度大的地方（需要多步、又摊不平的地方），在冻结模型里会表现为更大的误差与随机性。

把假设拆成三个可测的推论：

- 推论一：需要步数越多的位置，误差越大，输入扰动下输出越随机。

- 推论二：随机性随深度累积，在输出端/后段最大。

- 推论三：人类分歧大的地方（厚且相对不可摊薄），模型熵也大，而且加数据压不下去。

- 推论四：给"时间"（多步迭代、多次采样投票）能压掉冻结造成的随机，但压不掉数据里的分歧。

二、实验一：需要步数越多，误差与随机性越大

任务：给随机增量序列 d_1 … d_16，世界按 x_t = tanh(x_{t-1} + d_t) 演化，初值为零；要求预测每个位置的 x_t。预测 x_t 至少需要 t 步，所以"厚度"就是 t。

模型：共享权重的循环细胞，一步处理一个增量，共 16 层，每层都接输出头（deep supervision），训练后冻结。

结果：固定 16 层时，各位置误差从位置 1 的 0.67 升到位置 4 的 1.54，之后在 1.5 到 1.6 之间饱和。输入加高斯噪声（标准差 0.3）后多次采样：各位置输出标准差从位置 1 的 0.20 升到位置 16 的 0.40，同样后段饱和。

解读：需要步数越多（越厚）的位置，误差越大、输出越不确定。厚度的两条痕迹是同步出现的。

三、实验二：随机性随深度累积，在输出端最大

同一个模型，问题换成：随机性在"哪一层"最大？

方法：给输入加噪声、采样 20 次，测每一层输出的标准差。结果：第一层 0.21，第四层 0.32，第八层 0.38，第十二层 0.40，最后两层约 0.41——标准差随层数单调上升，在末端饱和。

对照：干净输入下，误差不随层数上升（位置 4 之后基本平在 1.5 左右）。这说明末端随机性的上升不是模型本身差，而是"这条链路把输入的小扰动一路放大了"。

解读：冻结模型里，不确定性在"末端"累积；越往后走，可收缩的余地越小。这对应"厚度在输出端最大"。

四、实验三：人类分歧大的地方，模型也最随机

前两个实验是合成任务，第三个换成"有分歧的题"。

设定：题目分两类。thin 题是事实题，答案由输入决定，所有人答案一致；thick 题是判断题，答案取决于每个人的偏好，人与人不同。模拟 60 个人各自的偏好，题目 400 道训练、200 道测试；模型是小 MLP，

学 P(答案|题目)，训练后冻结。

结果：人类答案的熵，thin 题约 0.000，thick 题约 1.014（三选一的熵上限是 1.099）。模型的预测熵，thin 题 0.249，thick 题 0.972。两者的相关系数是 0.917。

再看"能不能摊平"：把训练数据加到五倍。thin 题的模型熵从 0.249 降到 0.145；thick 题的模型熵从 0.972 只降到 0.958，几乎不动。

解读：模型的不确定性跟着人类分歧走——人觉得有分歧的地方，模型也随机；而且这份随机不是"数据不够"造成的（加到五倍仍不动），是人类分歧本身在数据里，属于该数据下的不可摊薄部分。

五、实验四：给时间能摊平什么

前三个实验说明"厚的地方随机"。第四个实验问：给时间能不能把随机压下去？

时间有两种给法。第一种是迭代细化：模型用共享权重的循环层多走几步（训练时按八步逐步监督）；第二种是采样投票：从模型分布里多次采样，按多数投票决定答案。

迭代的结果：thin 题的预测熵从一步时的 0.69 压到八步时的 0.02，几乎完全摊平；thick 题只从 0.99 压到 0.91，压不平。

投票的结果类似：采样一次时 thin 的决策熵 0.67、thick 0.96；采样九次投票后，thin 降到 0.28、thick 降到 0.69——都降了，但 thick 仍高。

解读：时间摊平的是"冻结造成的随机"，摊不平的是"数据里的分歧"（人类本来就意见不一）。换句话说，能被时间摊平的不算真厚；摊不平的才是真厚。这正好接上"可摊薄/不可摊薄"的区分：数据和时间的可摊薄性，是同一个厚度的两个检验方向。

六、训练机制：它学的是分布，不是决定

这三个实验合起来，给了一个简单的机制解释：冻结模型不训练"决定"，它训练"答案分布"。

- 薄的地方：分布是尖的，行为像一个确定的函数；

- 厚且摊不平的地方：分布是宽的、多峰的；冻结模型把它存成一个宽分布，推理时采样一次，看起来就是随机、不一致。

所以"模型在判断题上不稳定"不一定是缺陷：那里本来就是厚的。要它稳定，加数据不管用（实验三已示），需要别的办法——给它时间（多想几步、多轮修正），或者增加能摊开厚度的维度。

七、局限

第一，三个实验都是合成的：世界、题目、人类偏好全是程序生成的。

第二，模型都是玩具规模（几千参数），不是大模型；趋势可读，绝对值不可靠。

第三，实验三的相关性有一部分是设计使然：thick 题的随机性本来就由偏好分布构造出来。它验证的是"机制能对上"，不是"真实人类数据上的相关性"。

第四，实验四的"时间"是玩具版本的迭代与投票，不是真实的思维链；真实模型上"想更久是否摊平"仍需单独验证。

八、与既有工作的关系

"模型不确定性分布不均"不是新观察：校准（calibration）研究早就测过不同题目的置信度差异；人类标签变异（human label variation）也指出同一题不同标注者本来就有分歧；"偶然不确定性"（aleatoric uncertainty）研究的就是数据本身的不可约噪声。

本文的不同在于用一个统一的量（厚度）把三件事串起来：需要多少步、随机性在哪一层、人类分歧有多大，都落在"厚度"这个概念上，并且用"加数据后熵是否下降"来区分可摊薄与不可摊薄。

九、可复现

脚本：861_thickness_map_v2.py（实验一）、862_layer_variance.py（实验二）、870_human_disagreement.py（实验三）、881_time_flattening_v2.py（实验四）。依赖 Python 3 与 numpy，无 GPU，内存占用低。

附：标注

- **[事实]** 三个实验的数字：误差与随机性随厚度上升；末端方差最大；人类分歧与模型熵相关 0.917；加五倍数据 thick 熵不动。

- **[机制]** 模型学的是分布而不是决定——解释性说法，不是定理。

- **[事实]** 时间能摊平 thin 的熵（0.69→0.02），摊不平 thick（0.99→0.91）；投票同理。

- **[未做]** 真实思维链/大模型上的同一检验。

- **[不声称]** 不声称真实大模型上有同样的数字；不声称人类实验已验证。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。