论文-19 · 最小切片与时间换维度：能力边界的两个实验

何淇 · 与 DeepSeek 协作

数字生命系列 · 实验篇 9（内部编号第 19 篇）

日期：2026-10-24

摘要

大模型的每一层有自己的权重，像一块静态的函数切片。本文问两个问题：一个"结构"（一种能力）需要多大的切片才能出现？如果给模型"时间"（循环步数），能不能换掉"维度"（宽度）？

第一组实验：扫宽度与深度，测几个合成结构的"最低配置"。结果：简单的阈值与组合规则一层 8 宽就够；算术与奇偶需要更宽的切片。第二组实验：两个切片组合时，需要的维度约等于两者中较大的那个，而不是相加。第三组实验：序列奇偶任务上，循环网络宽 2 就够处理任意长度；而前馈网络在同样训练预算下，长度到 16 就学不出来，加宽也没用。第四组实验（GPU 版）：把训练加足，16 位奇偶变得可学，24 位仍然只记住训练集；8 位加法在宽 128、浅层时最好，加深反而更差。

合起来说：能力需要结构、需要足够的维度与深度，还需要"能被训练找到"。最低维度是必要条件，不是充分条件；而"时间"可以绕开一部分维度边界——这与"层是对动态的补偿"的说法一致。全部是合成任务与玩具模型。

一、问题

把大模型的一层看成一个静态函数切片：它读当前状态，用自己的权重新算一遍，写回共享状态（残差流）。那么：

- 一种结构（能力）要出现，最少需要多大的切片？

- 切片与切片之间能不能拼起来？

- 如果给模型时间（循环步数），能不能换掉维度？

本文用四个小实验回答。全部是合成任务，不涉及真实大模型。

二、实验一：最低配置

任务：parity（8 位奇偶）、add（4 位加法）、rule（(a 且 b) 或（c 且 d)）、majority（10 位多数）。模型是 tanh 的多层感知机；扫宽度与深度，记录达到准确率 0.95 的最小宽度 w* 与最小深度 L*。

结果（SGD 训练）：parity 约需宽 16、深 3~4；add 约需宽 32、深 2；rule 与 majority 都是宽 8、深 1 就满分。

要点：结构越像"运算"（需要进位、组合、非线性），最低配置越高；简单的阈值型结构一层就够。

这里必须说明一个后来发现的问题：换成 Adam 优化器后，8 位奇偶变得很容易（宽 8、深 1 就能到 0.98）。也就是说，上表测到的"最低配置"依赖训练算法，它测的是"这个训练器能否找到解"，不完全是"表示能力的最低要求"。本文把这一点明确写出，而不是把它藏起来。

三、实验二：切片组合

取两个已经训练好的切片（各自最小配置），放到一个共享主干上、各自接一个输出头，联合训练。对照是它们各自单独训练时的准确率。

parity + rule：主干宽 16、深 3 时，parity 掉到 0.59，rule 仍 1.00；深到 4，parity 回到 0.93，rule 1.00。也就是说，rule 不需要额外维度，它装得进 parity 的维度里；瓶颈在深度。

parity + add：主干宽 32、深 3 时，两个任务都到 0.95；宽 64、深 4 时都到 1.00。

结论：组合所需维度约等于两者中较大的那个，不是相加；阈值附近要一点余量。这支持一个朴素图像：能力在一个足够大的公共维度里共存，而不是各自占一块。

四、实验三：时间换维度

任务：序列奇偶——顺序读入 T 位，每一步都预测"到目前为止的奇偶"。这是一个需要记住一个比特状态的累积任务。

循环网络：宽度固定，逐位读入，每步更新状态。结果：宽度 2 就够处理 T=8、16、24、32 的全部情况（准确率 1.00），宽度 4 到 16 也都满分。T 再长，宽度不用涨。

前馈网络：一次看全 T 位，深度固定为 4。T=8 时满分；T=16 时掉到 0.54 左右（宽加到 128 也没用）；T=24 同样学不出来。

解读：时间（循环步数）确实能换掉维度。原因也直观——奇偶只需要"翻转状态"这一个比特，循环网络用两步就能表达；前馈网络必须在一次前向里把 T 位的结构算完，长度越长越难。

五、实验四：能力边界（GPU 版）

把训练加足（两万条数据、一万五千步）后重测，得到更清楚的边界：

16 位奇偶：宽 64、深 2 就到 0.98；宽 128 起满分。但深 6、宽 128 或 256 的组合会崩到 0.49——不是能力不够，是训练不稳定。

24 位奇偶：所有配置都在 0.50 附近；训练损失能到 0，测试却只有一半。这是"记住训练集、没有学会奇偶"的典型表现。

8 位加法：宽 128、深 2 是 0.97；宽 256、深 2 是 0.998。加深反而更差（深 4、6 都掉）。

三点结论。第一，边界存在，但它是"可训练性边界"，不是"表示能力边界"：同一个结构换个训练预算，边界会移动。第二，深度不总是帮忙：加法任务上浅层最好，奇偶任务上过深会崩。第三，"最低维度"只是必要条件：过了维度的门槛，还得能被优化器找到。

六、解读

把这四个实验放在一起，可以得到一条更准确的表述：

能力 = 结构 + 足够的维度与深度（必要条件） + 能被训练找到（优化条件）。

同时：时间可以绕开一部分维度边界（实验三），这与"层是对动态的补偿"一致——当模型没有真实的循环时，它只能用深度去模拟时间；而如果给它循环，它可以用很少的宽度做很多步。

对当前大模型的含义：均匀深度是浪费的（实验二与实验四都显示，不同结构对"深"的需求差别很大）；"加宽加深"不是稳赚的，可能更差；按结构分配维度与深度，或者引入循环/多步计算，可能更省。

七、局限

第一，全部是合成任务与玩具模型，和真实大模型的能力不是一回事。

第二，结果对训练算法敏感：SGD 与 Adam 下"最低配置"差别很大；本文两版都报告了。

第三，种子波动明显：parity 单独训练在 0.74 到 0.97 之间波动。

第四，组合实验只用了"共享主干 + 独立头"一种构造，不代表所有组合方式。

第五，时间换维度用的是密集监督（每一步都有标签），信用分配比真实场景容易。

八、可复现

脚本：938（最小切片）、940/941（组合）、943/945（时间换维度）、946/947/960/961（能力边界）。最小切片与组合用 numpy 手写训练；时间换维度与 GPU 边界用 PyTorch（Windows 上经 DirectML 跑 AMD

GPU）。

附：标注

- **[事实]** 各实验的准确率数字（最低配置、组合、时间换维度、GPU 边界）。

- **[解释]** "组合约等于 max 而不是相加""时间换维度"——对数字的解读，不是定理。

- **[推测]** 对真实大模型"按结构分配深度、引入循环更省"——玩具结论的推广，未验证。

- **[不声称]** 不声称发现了新的表示理论；这里只是把已有的玩具实验拼在一起看。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。