论文-23 · 厚度的三个工程后果：算力预算、层厚分配与偏好压平

何淇 · 与 DeepSeek 协作

数字生命系列 · 实验篇 11（内部编号第 23 篇）

日期：2026-10-25

摘要

前面几篇把"厚度"讲成一个概念。但严格说，它是两个方向上的东西，必须分开：分布厚度是"同一输入对应多宽的一族输出"（垂直方向），计算厚度是"从输入走到目标要应用多少次组合"（水平方向）。两者正交：奇偶校验步数多但答案唯一，判断题步数少但人类有分歧。

本篇用三个实验各测一件事，并让实验设计本身把两种厚度区分开。

实验一（计算厚度）：把"厚度"操作化为任务需要的迭代步数（k=1、2、4、8）。三种策略对比：均匀 8 步、均匀 4 步、按厚度路由。结果：按厚度路由只用 47% 的算力，误差 0.0812，与均匀 8 步（0.0834）相当甚至略好；过度计算也有害（k=1 时 1 步误差 0.0014，2 步 0.0160，4 步 0.0205）。

实验二（层厚分配）：同样的参数与算力，把"层厚"放在不同位置。四种结构：均匀 6×64、宽前 128→16、宽后 16→128、中间厚。结果：宽后 16→128 用约 67% 的算力达到平均 0.995（三个种子 0.993/0.993/0.998），高于均匀 6×64 的 0.980（21k 算力）；宽前只有 0.831。也就是说，层厚放在哪里，比"层都多厚"更重要。

实验三（分布厚度）：沿用人类分歧设定。基础模型学到的是人类的答案分布（thick 题熵 0.9655，接近人类 1.0138）；偏好微调（从模型采样两个答案、按人类偏好选一个、在选中答案上训练）后，thick 题熵降到 0.4090，与人类分布的 KL 从 0.0451 涨到 0.4188，与人类多数答案一致率从 0.870 升到 0.935。人类分歧没变，模型被压平了。

文末诚实记录一个未收敛的探索：长上下文里的"lost in the middle"。三个正式实验都是玩具规模。

一、问题：两种厚度

"厚度"在我们的文章里承担了两个意思，本篇先把它们拆开：

- 分布厚度：同一时刻、同一输入，输出是一族还是一个点。宽度 = 输出分布有多宽（熵、歧义）。它在垂直方向上，用表示维度去摊平。

- 计算厚度：沿组合律从输入走到目标，最少要应用多少次组合。长短 = 路有多长（步数）。它在水平方向上，用时间（步数）去摊开。

两者正交。奇偶校验：计算厚度高，分布厚度为零。判断题：计算厚度低，分布厚度高。（两者都高的例子：需要多步推理的判断。）

| 实验 | 测哪种厚度 | 操作化方式 | 另一维度 |

|---|---|---|---|

| 实验一 算力预算 | 计算厚度 | 任务需要 k 步 | 输出确定（分布厚度零） |

| 实验二 层厚分配 | 计算厚度的分配 | 层的宽度序列 | 输出确定 |

| 实验三 RLHF | 分布厚度 | 人类答案熵 | 单步判断（计算厚度小） |

二、实验一：按计算厚度分配算力

本实验只动计算厚度：任务需要 k 步就是 k 步，答案唯一。

世界：x_{t+1} = tanh(A x_t)，A 固定，状态 8 维。任务：给初值 x0，预测 x_k，k = 1、2、4、8。

模型：共享循环细胞，每步 h ← tanh(W h + U x0 + b)，最后线性读出。步数就是计算量。

三种策略：均匀深（都走 8 步）、均匀浅（都走 4 步）、按厚度路由（任务 k 走 k 步）。

结果（每任务取不同宽度的最好）：

- 均匀 8 步：误差 0.0834，共 32 步；

- 均匀 4 步：误差 0.0881，共 16 步；

- 按厚度路由：误差 0.0812，共 15 步。

路由用 47% 的算力，误差与均匀 8 步差 0.0022，实际还略低。

过度计算单独测：k=1 时，1 步误差 0.0014，2 步 0.0160，4 步 0.0205，8 步 0.0148。多算不更好，单独看反而更差——世界是迭代映射，多走一步就过了目标。

三、实验二：层厚分配（把厚度放在哪）

本实验也不动分布厚度，但换一个问法：同一笔参数与算力，把"层厚"放在网络的不同位置，结果一样吗？

任务：四个多任务（奇偶、层级规则、加法、多数），共享主干加各自输出头，训练时任务混合。

四种结构（尽量同算力，前向乘加数见括号）：均匀 6×64（21k）、宽前 128→16（15k）、宽后 16→128（14k）、中间厚 [16,32,64,96,64,32]（17k）。

三个种子的结果（平均准确率）：

- 均匀 6×64：0.980（21k 算力，24k 参数）；

- 宽后 16→128：0.995（14k 算力，19k 参数）；

- 中间厚：0.954（一次运行）；

- 宽前 128→16：0.831（一次运行）。

宽后结构用约 67% 的算力、更少的参数，平均准确率反而更高；分任务看，提升主要来自难任务（奇偶 0.994 对 0.981，加法 0.985 对 0.941）。宽前结构明显差，中间厚居中。

解读：层厚放在哪里，比"每层都多厚"更重要。让前面几层窄（先把输入压成表示）、后面几层宽（再展开成答案），比均匀层厚更省也更准。这与生物的分层异质（不同区域结构不同）方向一致，但我们只测了这一种任务组合，不能推广成定律。

四、实验三：**RLHF** 压平人类分歧

本实验只动分布厚度：题目都是单步判断，计算厚度小；变化的是输出有多宽——人类答案熵从 0（thin）到约 1.01（thick）。

设定：60 个模拟人类，各有偏好；thin 题答案由输入决定，thick 题答案取决于偏好。基础模型是小网络，学 P(答案|题目)，训练后冻结。

偏好微调玩具版：对每题从当前模型采样两个答案，按人类偏好选一个，在选中的答案上训练一步。

结果：

- thick 题：人类熵 1.0138，基础模型熵 0.9655（接近），偏好微调后 0.4090（下降约 57%）；

- 与人类分布的 KL：0.0451 → 0.4188（约 9 倍）；

- 与人类多数答案的一致率：0.870 → 0.935；

- thin 题：熵接近零，变化很小。

人类分歧没变，模型被压平到多数答案上：变得坚决，但丢掉了少数意见。

五、一个没有收敛的探索：**lost in the middle**

我们原想解释长上下文里的"lost in the middle"：距离越远检索越差。做了三版玩具 transformer（标记 + 回看第 d 个词，d=1~16，层数 1~4），结果不干净：不同距离的难度不单调（d=4、d=8 两层就满分，d=16 四层只有 0.49，d=1 反而要四层）。距离本身不等于计算厚度，中间还混着位置关系可学性、训练分布覆盖等因素。记录在此，作为下次的入口。

六、合起来看

| | 实验一（算力预算） | 实验二（层厚分配） | 实验三（RLHF） |

|---|---|---|---|

| 动的厚度 | 计算厚度（步数） | 计算厚度的空间分配 | 分布厚度（输出宽度） |

| 操作化 | 任务 k 步 | 层宽序列 | 人类答案熵 |

| 结论 | 步数按需分配；多算会算坏 | 把厚度放在后层更划算 | 对齐把分布压平、丢少数意见 |

| 资源 | 时间（步数） | 空间（层宽） | 空间（维度/信息） |

三条建议：算力按计算厚度分配；层的厚度按"前窄后宽"分配（至少在这类任务上）；对齐时为分布厚度保留余地，别把多解压成一个点。

七、局限

三个实验都是合成世界与玩具模型：实验一只测计算厚度（输出确定），实验三只测分布厚度（单步判断），"两者都高"的情形没有单独测；实验二的"宽后更好"只测了一种任务组合、四个结构，不能推广成定律。RLHF 的偏好标注是模拟的。层厚实验里宽前与中间厚只跑了一次运行，种子起伏可能影响结论，宽后与均匀做了三个种子复核。

八、可复现

实验一：1000_thickness_budget.py。实验二：1007_heterogeneous_layers.py、1008_hetero_fair.py、1009_hetero_seeds.py。实验三：1003_rlhf_flatten_v2.py。lost in the middle：1001、1004、1005。依赖 PyTorch（Windows 经 DirectML 跑 AMD GPU）。

附：标注

- **[事实]** 三个实验的数字：路由 47% 算力、误差 0.0812；宽后 0.995 vs 均匀 0.980（14k vs 21k 算力）；RLHF 后 thick 熵 0.4090、KL 0.0451→0.4188、一致率 0.870→0.935。

- **[解释]** "算力按厚度分配""层厚放在后层更省""对齐压平分布"——对数字的解读。

- **[推测]** 层厚异质性与生物分层的类比——方向一致，但本篇没有证据链。

- **[负面结果]** lost in the middle 三版玩具实验未收敛。

- **[不声称]** 不声称提出新的算力调度、异质网络或对齐算法；早退、门控、KL 正则都已有大量工作。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。