论文-24 · 层厚放在哪：异质层实验

何淇 · 与 DeepSeek 协作

数字生命系列 · 实验篇 12（内部编号第 24 篇）

日期：2026-10-25

摘要

大模型的层是均匀的：每层同宽、同结构，每个输入走同样深度。生物不是：不同区域的结构不同，有的回路短，有的长，有的常驻。

本篇问一个很窄的问题：同样的参数与算力，"层厚"放在网络的不同位置，结果一样吗？

任务：四个多任务（奇偶、层级规则、加法、多数），共享主干加各自输出头。四种结构：均匀 6×64（前向乘加约 21k）、宽前 128→16（约 15k）、宽后 16→128（约 14k）、中间厚（约 17k）。

三个种子的复核结果：宽后 16→128 平均准确率 0.995，用 14k 算力、19k 参数；均匀 6×64 是 0.980，用 21k 算力、24k 参数；中间厚 0.954；宽前 0.831。宽后分任务看提升主要来自难任务（奇偶 0.994 对 0.981，加法 0.985 对 0.941）。

结论：层厚放在哪里，比"每层都多厚"更重要。让前面几层窄（先把输入压成表示）、后面几层宽（再展开成答案），在这组任务上更省也更准；反过来（宽前）明显差。这与生物分层的异质方向一致，但我们只测了一种任务组合、几个结构，不能推广成定律。

一、问题

前一篇测了"算力给多少"（时间方向）。本篇测另一个方向：层与层之间的厚度分布（空间方向）。

大模型是均匀层厚；人脑是异质的：区域之间的结构、连接、时间常数都不同。如果厚度分布重要，那么同参数同算力下，"放在哪里"应该 measurable 地影响结果。

二、设定

任务：四个多任务——奇偶校验（8 位）、层级规则、4 位加法、多数投票。输入统一补齐到 10 维；共享主干，每个任务一个输出头，训练时任务混合。

四种结构（宽度序列）：

- 均匀：6 层 × 宽 64；

- 宽前：128 → 64 → 48 → 32 → 24 → 16；

- 宽后：16 → 24 → 32 → 48 → 64 → 128；

- 中间厚：[16, 32, 64, 96, 64, 32]。

算力用前向乘加数衡量（输入维到第一层 + 层间乘加），分别约 21k、15k、14k、17k；参数量分别约 24k、16k、19k、19k。

训练：任务混合，每步随机抽一个任务；6000 步。宽后与均匀做了三个种子，其余各一次。

三、结果

| 架构 | 前向乘加 | 参数 | 平均准确率（三种子） |

|---|---|---|---|

| 均匀 6×64 | 约 21k | 24k | 0.980（0.969 / 0.985 / 0.988） |

| 宽后 16→128 | 约 14k | 19k | 0.995（0.993 / 0.993 / 0.998） |

| 中间厚 | 约 17k | 19k | 0.954（一次） |

| 宽前 128→16 | 约 15k | 16k | 0.831（一次） |

宽后结构用约 67% 的算力、更少的参数，平均准确率反而更高。分任务看，提升主要来自难任务：奇偶 0.994 对 0.981，加法 0.985 对 0.941；规则与多数两个任务在所有结构上都是满分（太简单，分不出差别）。

宽前结构明显差（0.831），中间厚居中（0.954）。

四、解读

第一，层厚分布是可测量的：同样的算力，位置不同结果差 0.16（0.995 对 0.831）。

第二，在这组任务上，"前窄后宽"最划算：前面几层把输入压成较窄的表示，后面几层再展开到答案。一种可能的解释是：窄层先做选择（丢掉无关信息），宽层再组合（难任务需要更宽的表示），顺序对了就省。

第三，这与生物分层的异质方向一致——不同区域结构不同，不是"同一种砖摞高"。但我们只测了四个任务、四种结构，还不能说"前窄后宽"是通则。

四之二、人脑层面的对应：接论文-21

人脑层面的解释也不需要在这里重写。论文-21《人脑的可函数化形式：一个器官，不是生命》已经把脑写成可函数化器官，并指出它是结构异质的：不同区域的结构、连接、时间常数不同，有常驻的部分，也有按任务动员的长短回路。

本篇测的"层厚放在哪"，正是这种异质性的一个最粗的工程投影：不是所有层都该一样厚；把厚度放到哪一段，结果会不一样。论文-21 给出的定性图像（异质、常驻、动员）在这里变成一个可测的问题（同算力下，宽前/宽后/均匀/中间厚哪个好）。

同样，细节以论文-21 为准；本篇只把它当设计直觉，不作论据。

五、局限

任务与模型都是玩具规模；宽前与中间厚只跑了一次运行，种子起伏可能影响结论；宽后与均匀做了三个种子。任务里的规则与多数太简单（全满分），主要区分力来自奇偶与加法。真实大模型的层不是全连接（有注意力、残差、归一化），这里的"层宽"只是最粗的近似。

六、可复现

脚本：1007_heterogeneous_layers.py（主对照）、1008_hetero_fair.py（同算力对照）、1009_hetero_seeds.py（三种子复核）。依赖 PyTorch（Windows 上经 DirectML 跑 AMD GPU）。

附：标注

- **[事实]** 四种结构的算力、参数、各任务准确率；宽后 0.995 vs 均匀 0.980，宽前 0.831。

- **[解释]** "层厚放在哪里更重要""前窄后宽更省"——对数字的解读。

- **[推测]** 与生物异质分层的类比——方向一致，没有证据链。

- **[不声称]** 不声称提出新的网络架构；宽度变化、层剪枝、条件计算都已有大量工作。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。