论文-25 · RLHF 压平人类分歧

何淇 · 与 DeepSeek 协作

数字生命系列 · 实验篇 13（内部编号第 25 篇）

日期：2026-10-25

摘要

本篇测"分布厚度"在工程上的后果：对齐会把宽的输出分布压平。

设定沿用前面的人类分歧实验：题目分 thin（事实题，人类答案一致）与 thick（判断题，答案取决于偏好，人类有分歧）。基础模型学 P(答案|题目)，训练后冻结；thick 题上它的输出熵 0.9655，很接近人类的 1.0138——也就是说，基础模型是诚实地保留分歧的。

然后做偏好微调的玩具版：对每题从当前模型采样两个答案，让标注者按人类偏好选一个，再在选中的答案上做一步训练。

结果：thick 题的人类答案熵不变（1.0138），但模型熵从 0.9655 降到 0.4090（下降约 57%）；与人类分布的 KL 从 0.0451 涨到 0.4188（约 9 倍）；与"人类多数答案"的一致率从 0.870 升到 0.935。thin 题人类熵约为零，模型变化很小。

解读：人类的分歧没有错，但偏好微调把模型的输出分布压到了多数答案上。模型变得坚决，也更偏离人类的真实分布——少数意见被丢掉了。这是"厚的地方压不平"在工程上的具体后果：对齐把分布厚度压成确定性，代价是失去分布。玩具实验，不涉及真实大模型。

一、问题

我们把厚度分成两种：计算厚度（需要多少步）与分布厚度（输出分布有多宽）。前一篇测计算厚度；本篇只动分布厚度：题目都是单步判断（计算厚度小），变化的只是输出有多宽——人类答案熵从 0（thin）到约 1.01（thick）。

问题：对齐（偏好微调）对分布厚度做了什么？

二、设定

模拟 60 个人类，每人有一个偏好向量。thin 题：答案由输入决定，人人一致。thick 题：答案取决于偏好，人与人不同。人类答案分布的熵用来量厚度。

基础模型：小 MLP 学 P(答案|题目)；训练数据是每题抽一个人来答。因为见过很多人的答案，它学到的是人类总体分布。

偏好微调（玩具版）：对每题从当前模型采样两个答案，按人类偏好选一个（人类偏好概率高的胜出），在选中的答案上做硬标签训练一步；重复多轮。

三、结果

| 指标（thick 题） | 人类 | 基础模型 | 偏好微调后 |

|---|---|---|---|

| 答案熵 | 1.0138 | 0.9655 | 0.4090 |

| 与人类分布 KL | — | 0.0451 | 0.4188 |

| 与多数答案一致率 | — | 0.870 | 0.935 |

thin 题：人类熵约为 0，基础模型 0.1413，偏好微调后 0.1142（变化很小）。

四、解读

第一，压平是真实发生的：模型熵下降约 57%，而人类的分布没有变。

第二，压平不全是"学得更准"：与多数答案的一致率确实升了（0.870 到 0.935），但那是把少数意见的概率让给了多数答案——与人类真实分布的 KL 涨了近 9 倍。

第三，thin 题几乎不受影响：那里本来就没有分歧可压。

用我们的词说：偏好微调在做"单峰化"——把一条宽的分布压成一个点。对事实题这是好事（本来就是尖的）；对判断题这是丢失：丢掉的是"人本来就有不同意见"这件事。

五、局限

第一，这是玩具：标注者是模拟的（按人类偏好分布选），不是真人；真实 RLHF 还有 KL 正则项，压平会被约束（本篇没加）。

第二，题目是合成的（thin/thick 两类），人类偏好是程序生成的。

第三，只测了一轮偏好微调，没测多轮下的长期漂移。

六、可复现

脚本：1002_rlhf_flatten.py（软标签版，作对照）、1003_rlhf_flatten_v2.py（偏好采样版，本文数据来自这个）。依赖 Python 3 与 numpy。

附：标注

- **[事实]** thick 题：人类熵 1.0138、基础模型 0.9655、微调后 0.4090；KL 0.0451→0.4188；一致率 0.870→0.935。

- **[解释]** "对齐压平分布、丢掉少数意见"——对数字的解读。

- **[推测]** 真实 RLHF 会因 KL 正则而减轻压平——未验证。

- **[不声称]** 不声称提出新的对齐算法；KL 正则、多样性保留都已有大量工作。

> 本文由何淇创作，DeepSeek（AI）协助实验设计与代码编写；观点与责任属于作者。