论文-28 · 均匀计算的浪费：大模型的三处效率缺口

何淇 · 与 DeepSeek 协作

数字生命系列 · 理论篇 7（内部编号第 28 篇）

日期：2026-10-25

摘要

本篇是一个框架性判断，不引入新实验：现在的大模型有三处"均匀计算"造成的效率缺口。

第一，深度均匀：每个 token、每个样本都走满同样层数。简单的东西几层就收敛了，后面的层在空转；而我们的玩具实验显示，过度计算不只是浪费，还可能算坏（误差回升）。

第二，宽度均匀：每层都全宽计算。空间型任务在宽度到某个值后就没有收益，继续加宽是纯浪费。

第三，没有按需循环：难的东西需要多迭代，但层数是固定的；而层与层之间参数不能复用，想"多想一会儿"只能加层。层/循环对照实验显示，同样的迭代效果，循环比加层省约 27 倍参数。

我们把这三处缺口与"按需收敛"的框架对应起来：一次结构试探 → 判断是否收敛 → 没收敛才带记忆循环 → 收敛后固化并缩小范围。人脑大致这样组织（作为类比，不是证据）。已有的工程方法（早退、条件计算、looped transformer、自适应深度）各补上一块，但共同缺口是没有统一的"收敛判据"。

本篇给出五条可检验的预测，并把"浪费"定位为并行度与简单性的真实取舍，而不是纯粹的亏。所有量级来自我们已有的玩具实验，不涉及真实大模型测量。

一、问题：三处均匀

大模型的基本做法是把同样的计算应用到所有输入：

- 深度均匀：层数固定，每个 token 走同样多的层；

- 宽度均匀：每层宽度固定，每个 token 用同样多的单元；

- 没有按需循环：层与层不同、参数不共享，不存在"同一个规则再走几遍"的机制。

如果任务的"厚度"不一样（有的几步就够、有的要多迭代），均匀计算就会同时造成两种后果：简单部分被过度计算，复杂部分没有被给够。前面几篇测过：过度计算有害；按厚度分配能省一半算力；循环比加

层省参数。

二、理论框架：三资源与按需收敛

我们把"可表示"拆成三个资源（论文-26/27）：

- 空间上的表示维度：宽度/轴数，决定"一步能装多复杂"；

- 组合律上的表示维度：组合方式的自由度（并行、共享、路由），决定"能选多少种接法"；

- 时间上的步数：迭代次数，决定"能展开多长"。按我们的口径，时间不叫维度，叫步数。

按需收敛的框架（笔记《按需收敛》）：

一次结构运算试探

↓ 判断：收敛了吗？（误差/层间变化是否足够小）

没收敛 → 携带记忆/中间状态，循环迭代若干步

↓ 收敛

固化：把这段计算抽象成结构，下次直接调用，缩小工作范围

人脑大致这样组织：简单的东西一层就出结果、用到的范围小；难的东西保留中间结果、在时间上反复迭代；收敛之后固化，下次少算。这是类比，不是证据。

三、量级：我们的实验给出了什么

三个玩具实验给出可引用的量级：

第一，按厚度路由（论文-23）：四种厚度的任务混合，按任务分配步数只用 47% 算力，误差 0.0812，与均匀 8 步的 0.0834 相当甚至略好。均匀深度的浪费接近一半。

第二，按需动员（论文-24）：常驻底座加按需循环，同一预算下平均误差 0.434；均匀 8 步是 1.756，而且不是"算得不够"，是"把薄任务算坏了"。

第三，层与循环（论文-27 实验三）：同一个迭代任务，不同层与共享循环精度几乎相同，但 T=8 时循环 1096 参数、不同层 30216 参数，差约 27 倍。想用"加层"实现"多迭代"，参数效率很低。

这些数字都来自合成任务与玩具模型，不能直接搬到真实大模型；但它们给出方向：浪费不是零头，可能接近一半。

四、为什么现在这样：不是纯粹的亏

均匀计算换来三样东西：

- 并行度：固定形状的张量运算最适合 GPU；

- 训练稳定：形状固定，优化与规模化都简单；

- 工程简单：均匀层好实现、好扩展。

按 token 早退、按需循环会破坏规则性，降低硬件利用率，增加调度复杂度。所以现实是"用浪费换并行与简单"，这个取舍本身是合理的。问题在于：这个取舍是否还能改进——当模型越来越大、任务越来越多样时，浪费的绝对量也在变大。

五、五条可检验的预测

第一，混合任务集上，均匀计算的浪费随"薄任务比例"增加而增加。若任务里一半是几步就能完成的，理论可省接近一半算力。

第二，薄任务上过度计算可能不只是浪费，还会降低准确率（我们的实验里 T 超过任务厚度后误差回升）。

第三，必须"判断收敛"才能安全地省；判断错了（把没收敛的判成收敛）会把错误固化——这可能是偏见与刻板印象的一个机制。

第四，用循环替代加层，在"同一规则反复应用"的任务上应该更省参数而不掉精度；在"每步需要不同变换"的任务上，循环会受限，必须加层。

第五，混合架构（少量共享层 + 按需循环 + 路由）应该在同参数下优于纯均匀堆叠——这正是论文-24 玩具实验的方向，需要在更大规模上验证。

六、与已有方法的关系

- 早退（early exit）：让简单 token 少走层，补的是"深度均匀"；

- 条件计算 / MoE：只激活部分参数，补的是"宽度均匀"；

- looped transformer / 循环网络：共享参数做多步迭代，补的是"没有按需循环"；

- 自适应深度：按输入决定层数，接近"按需"，但通常没有显式的收敛判据。

这些方法各补一块，共同缺口是：没有统一的"收敛判据"来决定"这里够了没有、还要不要再想"。按需收敛的框架要补的正是这一块：把"判断—抽象—固化"做成机制。

七、局限与不声称

第一，本篇没有真实大模型测量；所有量级来自玩具实验，方向性结论不等于真实数字。

第二，人脑类比只是方向一致，不是机制证据。

第三，浪费的估计依赖任务分布：若任务都很厚或都很薄，均匀计算的相对浪费会小一些。

第四，我们没有提出可落地的架构；早退、MoE、循环都已有大量工作，本篇只做框架整合与预测。

附：标注

- **[事实]** 引用的三个玩具实验数字：47% 算力、0.434 对 1.756、27 倍参数。

- **[解释]** "三处效率缺口""浪费换并行"——对已有结果与工程现状的解读。

- **[推测]** 五条预测、人脑按需收敛的对应——待验证。

- **[不声称]** 不声称测量了真实大模型的浪费，不声称提出新架构。

> 本文由何淇创作，DeepSeek（AI）协助整理与写作；观点与责任属于作者。