# 论文-33 · 层的路径与冗余：GPT-2 上的层扰动实验

何淇 · 与 DeepSeek 协作

数字生命系列 · 实验篇 14（内部编号第 33 篇）

日期：2026-10-27

## 摘要

本篇在真实小模型上测一个问题：大模型里的结构是"压在某一层里"，还是"跨几层展开、带冗余"？

做法：在 GPT-2 small（12 层）上，把某一层"跳过"（输出等于输入，保留残差流），分别测单层、相邻两层、连续三层的扰动效果；语料为 tinyshakespeare，300 条 64-token 序列，9600 个预测位置；指标是下一 token 的 top-1 翻转率与损失增加，并按下一个词的类别（数字/标点/功能词/情绪词/身体词/其他）分组。

结果：单层跳过第 1~10 层，top-1 翻转率约 0.20~0.31；跳过最后一层为 0.55；跳过第 0 层为 0.96（异常，需分开看）。相邻两层一起跳过，翻转率升到约 0.37~0.68，比"两个单层中较大的那个"还高约 0.10~0.17——这是冗余的签名：单独缺一层有人补，两层一起缺就没人补了。连续三层跳到约 0.44~0.77。类别之间差异不大，身体词与情绪词在中层略敏感。

结论：GPT-2 的结构是跨层分布且带冗余的。单层扰动会低估结构的重要性（用户提出的"去掉单层只影响完整性"得到支持）；按层做"判定"或"早退"时，判据应当看路径而不是单层。所有结果来自小模型与玩具语料，不声称适用于大模型。

## 一、问题

前面的框架说：结构是切片 + 组合律；复杂结构要靠时间上的步数展开。如果这条在真实模型里也成立，那么：

1. 一个概念/结构不应只对应某一层，而应跨几层展开；

2. 层与层之间可能有冗余：去掉一层，别的层能补；

3. 因此"单层扰动"会低估结构的重要性。

用户的直觉是：**单层之间也有结构，多层之间也有结构；去掉单层可能只影响完整性，因为有冗余。**本篇就是去测它。

## 二、方法

- **模型**：GPT-2 small（12 层、宽度 768、124M 参数），DirectML GPU。

- **语料**：tinyshakespeare，随机取 300 条、每条 64 token；预测位置为每个 token（间隔 2），共 9600 个。

- **扰动**：把某些层"跳过"——该层输出 = 输入（恒等直通），保留残差流，只去掉这一层的贡献。这样才是"少算一层"，而不是把信息清空。

- **配置**：单层 12 个；相邻两层 11 个；连续三层 10 个。

- **指标**：相对基线的 top-1 翻转率、损失增加。

- **分组**：按"下一个 token"的类别分组：数字、标点、功能词、情绪词、身体词、其他。

## 三、结果

**单层跳过（top-1 翻转率，按类别）：**

| 层 | 数字 | 标点 | 功能词 | 情绪 | 身体 | 其他 | 均值 |
|---|---|---|---|---|---|---|---|
| 0 | 0.986 | 0.833 | 0.974 | 1.000 | 1.000 | 0.978 | 0.962 |
| 1 | 0.214 | 0.185 | 0.195 | 0.167 | 0.271 | 0.199 | 0.205 |
| 2 | 0.209 | 0.195 | 0.223 | 0.278 | 0.333 | 0.231 | 0.245 |
| 3 | 0.245 | 0.214 | 0.252 | 0.208 | 0.312 | 0.252 | 0.247 |
| 4 | 0.250 | 0.199 | 0.213 | 0.208 | 0.292 | 0.231 | 0.232 |
| 5 | 0.291 | 0.198 | 0.221 | 0.250 | 0.375 | 0.239 | 0.262 |
| 6 | 0.218 | 0.188 | 0.217 | 0.250 | 0.292 | 0.236 | 0.233 |
| 7 | 0.255 | 0.195 | 0.253 | 0.250 | 0.229 | 0.239 | 0.237 |
| 8 | 0.277 | 0.199 | 0.228 | 0.264 | 0.396 | 0.230 | 0.266 |
| 9 | 0.268 | 0.167 | 0.255 | 0.264 | 0.396 | 0.236 | 0.264 |

| 10 | 0.355 | 0.222 | 0.263 | 0.319 | 0.438 | 0.277 | 0.312 |

| 11 | 0.482 | 0.510 | 0.517 | 0.611 | 0.708 | 0.479 | 0.551 |

- 第 0 层跳过几乎全崩（0.96）：第一层被跳过时整条链的输入分布就变了，需单独说明（见局限）。

- 第 1~10 层：单层跳过只翻 20%~31%，说明**多数单层不是致命的**。

- 最后一层（11）：0.55，明显更重要——输出前的变换不能省。

**相邻两层跳过（组翻转率 vs 单层最大）：**

| 组 | 组均值 | 单层最大均值 | 冗余量 |

|---|---|---|---|

| (1,2) | 0.400 | 0.246 | 0.155 |

| (2,3) | 0.423 | 0.262 | 0.160 |

| (3,4) | 0.417 | 0.248 | 0.169 |

| (4,5) | 0.387 | 0.263 | 0.125 |

| (5,6) | 0.368 | 0.262 | 0.106 |

| (6,7) | 0.375 | 0.247 | 0.128 |

| (7,8) | 0.387 | 0.271 | 0.116 |

| (8,9) | 0.412 | 0.271 | 0.141 |

| (9,10) | 0.457 | 0.312 | 0.145 |

| (10,11) | 0.681 | 0.551 | 0.130 |

- 每对相邻层都出现正的冗余量（约 +0.10~+0.17）。

- 含义：**单独缺一层，别处能补；两层一起缺，就没人补了。这正是"冗余"的结构签名。**

**连续三层跳过：**

| 组 | 各类别翻转范围 | 均值 |

|---|---|---|

| (1,2,3) | 0.475~0.729 | 0.584 |

| (3,4,5) | 0.446~0.625 | 0.516 |

| (4,5,6) | 0.382~0.514 | 0.436 |

| (6,7,8) | 0.444~0.562 | 0.498 |

| (9,10,11) | 0.670~0.875 | 0.774 |

- 三层一起跳，翻转率到 0.44~0.77，明显高于任意单层。

- 结构不是"压在一层"，是**跨层展开**的。

**类别差异：** 多数层内类别差异在 0.1 以内；身体词、情绪词在中层略更敏感（例如第 5/8/10 层身体词 0.375~0.438）。这说明概念对层的依赖有一点选择性，但不像"专用层"那样干净。

## 四、解释

1. **结构跨层展开**：单层扰动温和、成组扰动急剧上升——一个结构由几层共同完成，缺一层还能靠其余层部分完成。

2. **冗余**：相邻层的正冗余量（+0.10~+0.17）说明层与层之间存在部分可替代性。用户说的"去掉单层只影响完整性"在数据上得到支持。

3. **单层 ablation 的低估**：只看单层会得出"这些层都不重要"的错误印象；真实结构的重要性藏在路径与组合里。

4. **按路径判定**：如果要做判定器/早退，判据应看"这段路径够不够"，而不是"这一层够不够"。

## 五、可检验推论

1. 冗余量应随模型规模、训练分布变化：在更偏向"必须逐步计算"的任务上，冗余应减少。

2. 有冗余的相邻层，应该可以用"共享参数的循环"部分替代而不掉点——这正好接上"循环比加层省参数"的已有结果。

3. 概念选择性应表现为"路径差"而不是"单层差"：不同概念的关键层组合应不同。

4. 若在真实大模型上重复，单层扰动应同样低估重要性；成组扰动的冗余签名应依然出现。

## 六、局限

第一，只有 GPT-2 small 与 tinyshakespeare，规模小、语料窄，不能外推到真实大模型。

第二，第 0 层跳过异常（0.96）：跳过第一层等于去掉第一层注意力的输出，整条链的输入分布变化过大；这个数字不宜与其他层并列解释。

第三，"跳过"是推理期扰动，不等于"训练时没有这层"；训练时若少一层，网络会重新分配功能，结论会不同。

第四，类别词表很粗（数字/标点/功能词/情绪/身体/其他），"概念选择性"只测到很粗的粒度；更细的概念（句法结构、语义角色）没有测。

第五，只测了 top-1 翻转与损失，没有测表示空间的变化；冗余也可能表现为"预测不变但内部表示变了"。

第六，没有与"层与循环"的替代实验直接衔接——那是下一步。

## 附：标注

- **[事实]** 表中所有翻转率与损失来自本次 GPT-2 实验（数据文件：数据-GPT2层路径.json）。

- **[解释]** "结构跨层展开""相邻层冗余""单层扰动低估重要性"——对数据的解读。

- **[推测]** 四条可检验推论——方向性，未验证。

- **[不声称]** 不声称适用于大模型；不声称解释了概念表征；不声称"层冗余"等于"可无代价删层"。

> 本文由何淇创作，DeepSeek（AI）协助整理与写作；观点与责任属于作者。