论文-34 · 语言结构作为自变量：GPT-2 上的三组实验

何淇 · 与 DeepSeek 协作

数字生命系列 · 实验篇 15（内部编号第 34 篇）

日期：2026-10-27

摘要

前面的实验（论文-33、以及本篇的早期版本）是从"脑结构"出发设计的：层、循环、判定、维持。但这些机制不是大模型被训练出来的方式——大模型是被语言塑形的。本篇换一个自变量：**语言结构强度**（用完整模型预测的熵作为代理，分低/中/高熵三组），重做三组实验。

第一组，层冗余 × 语言结构：跳过单层或相邻两层，看 top-1 翻转率。结果：低熵（语言可预测）位置的翻转率明显低于高熵位置（单层 0.49~0.50 vs 0.76~0.77；两层 0.48~0.53 vs 0.74~0.76）。语言结构强的位置更容忍删层。

第二组，判定器特征对比：同一预算下比较四种 halt 特征——A 置信度、B 跨层路径一致性、L 语言结构特征（词类、位置、重复、首层熵）、A+L。结果：L 在较深的预算下最好（深度 8：0.161 vs A 0.153）；路径特征 B 没有优势。

第三组，按语言结构早退：用 L 特征决定退出，在相同平均深度下比按置信度早退略好（深度 8~10 高出约 0.5~0.8 个点）。

结论：**"语言结构强度"是比"脑机制"更合适的自变量**——语言越可预测，位置越早收敛、越容忍删层、越适合早退；而"内部路径是否稳定"这个脑结构式的判据，在语言层框架下并不带来额外信息。所有结果来自 GPT-2 small 与 tinyshakespeare，不声称适用于大模型。

一、为什么换自变量

前面我们一直把大模型当"一个器官"来测：它有几层、能不能循环、何时收敛、能不能早退。这些问法来自对大脑结构的类比。但大模型不是被脑机制训练的，它是被语言训练的——语言的结构（句法、语义、叙事、常识）塑形了它的表示与组合方式。

所以更合适的自变量是**语言结构强度**：一个位置在语言上有多可预测、结构有多强。我们用它重做三组实验，检验一个统一的说法：

> 语言结构强的位置，会更早收敛、更容忍删层、更适合早退。

二、方法

- **模型**：GPT-2 small（12 层、768 宽、124M），DirectML GPU。

- **数据**：tinyshakespeare，300 条 64-token 序列，取预测位置（间隔 2），共 9600 个。

- **语言结构强度**：用完整模型在该位置的下一个词分布熵作为代理，取三分位分三组（低熵=可预测、中熵、高熵=不可预测）。

- **实验 A（层冗余）**：跳过单层（2/6/10）与相邻两层（2-3/6-7/10-11），统计相对基线的 top-1 翻转率，按熵组比较。

- **实验 B（判定器）**：每层训练 halt 判定器，特征四组：A=置信度/熵；B=跨层路径（相邻层一致、KL、趋势、cos 变化）；L=语言结构（词类、位置、重复、首层熵）；A+L。标签=该层预测是否正确。比同平均深度下的准确率。

- **实验 C（早退）**：用 B 中学到的判定器做退出策略，比较不同特征下的准确率—深度曲线。

三、结果

3.1 实验 **A**：层跳过 × 语言结构（**top-1** 翻转率）

跳过层	低熵（可预测）	中熵	高熵（不可预测）
[2]	0.491	0.694	0.771
[6]	0.502	0.690	0.763
[10]	0.498	0.689	0.763
[2,3]	0.484	0.653	0.737
[6,7]	0.534	0.698	0.760
[10,11]	0.697	0.911	0.957

- 所有配置下，低熵组的翻转率都明显低于高熵组（典型：单层 0.49 vs 0.77）。

- 含义：**语言结构强的位置，删掉一两层也不影响预测**——冗余（或语言先验的补位）集中在这里。

- 末两层（10,11）的跳过对所有组都更伤，但低熵组仍更稳。

3.2 实验 **B**：判定器特征对比（同平均深度下的准确率）

| 深度 | A 置信度 | B 路径 | L 语言 | A+L | B+L |

|---|---|---|---|---|---|

| 3 | 0.149 | 0.148 | 0.150 | 0.147 | 0.148 |

| 5 | 0.154 | 0.147 | 0.153 | 0.151 | 0.153 |

| 8 | 0.153 | 0.152 | **0.161** | 0.159 | 0.159 |

| 10 | 0.158 | 0.156 | 0.160 | 0.160 | 0.159 |

- 浅预算（深度 3~5）：各特征基本持平。

- 深预算（深度 8~10）：L（语言结构特征）最好（0.161 vs 0.153），A+L、B+L 次之。

- **B（跨层路径）始终没有优势**——我们早期"判定要看路径"的预测，在语言层框架下依然不被支持。

3.3 实验 **C**：按语言结构早退

- 用 L 特征做退出判定：在相同平均深度（8~10 层）下，准确率比按置信度早退高约 0.5~0.8 个点。

- 与完整模型（12 层，准确率约 0.169）相比，早退到平均 10 层可保住约 0.16（掉不到 1 个点）。

- 与实验 A 一致：语言结构强的位置，退出更安全。

四、解释

1. **语言结构强 ⇒ 早收敛**：可预测的位置，模型不需要深层计算，语言先验几乎决定了答案；不可预测的位置需要更多层，且更难判对。

2. **语言结构强 ⇒ 冗余高**：删层对低熵位置影响小，因为其他地方（语言先验、冗余层）能补位；这解释了论文-33 里"单层可跳、成组才崩"的现象——冗余不是均匀分布的，它集中在语言结构强的地方。

3. **为什么路径特征没用**：在大模型里，"收敛"不是内部状态的稳定，而是"语言层面已确定"——所以置信度（≈语言可预测性的读数）已经够用，内部路径的稳定性没有额外信息。

4. **判定器要看语言层**：与其看"内部算完了没有"，不如看"语言结构够不够强、够不够确定"——这是把"判定"从机制层移到语言层。

五、可检验推论

1. 语言结构强（低熵）的位置，早退掉点应显著小于高熵位置——可在更难的语料上复测。

2. 层冗余的分布应随语料变化：语言结构更强的领域（如程式化文本）冗余应更高。

3. 若判定器加入更强的语言结构特征（依存句法、上下文重复模式），应进一步接近 oracle。

4. 换更大模型：语言结构强度的作用应保持，且高熵位置的"需要更深"应更明显（因为大模型的深层能力更强）。

六、局限

第一，模型极小（GPT-2 small）、语料窄（tinyshakespeare），整体准确率仅 17%，不能外推到真实大模型。

第二，语言结构强度用"熵三分位"做代理，比较粗；词类/位置/重复特征也很粗。

第三，熵是按位置算的，同一位置的"语言结构"其实依赖上下文长度与质量，未做更细的控制。

第四，判定器训练标签是"预测是否正确"，与"退出后最终答案是否正确"不完全等价。

第五，我们没有测真正的语言结构标注（依存树、篇章结构），只用统计代理。

第六，这是对"语言层"的初步实验设计，结论是方向性的；我们对大模型的理解有限，不声称超过已有的 early-exit / 语言模型分析研究。

七、与已有工作的位置

- early exit / adaptive computation：本实验的贡献是用"语言结构强度"分组，而不是按层或按 token 类别分组。

- 语言模型的内部分析（探针、熵、可预测性）：本实验把"可预测性"当作自变量，而不是当作解释变量。

- 与论文-33（层路径与冗余）的关系：论文-33 说明结构跨层展开且带冗余；本篇说明冗余集中分布在语言结构强的位置。

附：标注

- **[事实]** 三张表的数字来自本次 GPT-2 实验（数据文件：数据-语言层实验.json）。

- **[解释]** "语言结构强⇒早收敛/冗余高/可早退"——对数据的解读。

- **[推测]** 四条可检验推论——方向性，未验证。

- **[不声称]** 不声称适用于大模型；不声称路径特征永远无用（只在本次设置下没优势）；不声称"语言结构"已被严格定义。

> 本文由何淇创作，DeepSeek（AI）协助整理与写作；观点与责任属于作者。