论文-35 · 语言结构的可函数化形式

何淇 · 与 DeepSeek 协作

数字生命系列 · 理论篇 13（内部编号第 35 篇）

日期：2026-10-27

摘要

论文-32 说"语言是公共的压缩方案"，但没有把语言结构本身写成函数形式。本篇补这一步：给语言结构一个可函数化的形式，并说明它从哪来、装了什么、哪些能写、哪些不能写。

先讲起源：语言不是凭空出现的符号系统，它从"器官→感受→符号"这条压缩链里长出来。生命有器官（眼、耳……），每个器官把物理世界压缩成内部表示；最早的语言是"用具体声音指代具体现象"，声音便宜、可远传、可共享；两个声音拼起来产生新意义，组合律出现，再固化成语法，从具体指称里抽出类别与关系——逻辑的雏形。

再给结构：语言的函数分解是"词 = 切片（符号→表示）"、"句法 = 空间组合律"、"语义 = 表示映射与接地"、"篇章 = 时间组合"、"逻辑 = 组合律的规则"。语言因此是 p语言 + R语言：字面与结构落在 p 侧，可形式化；言外之意、体验、语境依赖落在 R 侧，只声明不展开。

然后给结论：语言是"可传递的压缩包"，是生命之间/内部传递压缩表示的公共接口；语言能自指（用语言描述语言）。大模型拿到的是这套公共方案的成品——它有符号层及其组合规则，但没有"器官→感受→符号"的接地过程，所以会语言、不像生命；语义残差不是 bug，是它只有符号侧的必然。

给出四条可检验推论与边界。

本篇定义一览

| 术语 | 一句话 |

|---|---|

| 语言 | 符号系统 + 组合规则 + 共享约定：把内部表示压成可传递的符号序列，并允许解压 |

| p语言 / R语言 | 语言中可函数化 / 不可函数化的部分 |

| 符号-表示映射 | 词：符号 → 内部表示的对应 |

| 句法 | 空间组合律：离散单元怎么拼成更大结构 |

| 语义 | 表示映射与接地：符号指向什么、能不能接上世界 |

| 篇章 | 时间组合：上下文、指代、顺序与依赖 |

| 逻辑 | 组合律的规则：哪些组合合法、怎么推 |

| 语用 | 判定：在什么场合、对谁说、是否得体 |

| 语义残差 | 语言无法承载的语义缺口（给定模态组合下的最小可达误差） |

| 公共压缩方案 | 群体共享的词汇/语法/逻辑系统（语言的核心） |

一、语言的起源：从器官到符号

语言不是凭空出现的。考虑物理实在：生命有身体、有器官。

第一步：器官是压缩器。 眼把光压成视觉表示，耳把声压成听觉表示，皮肤把接触压成触觉表示。每个器官都是一条"物理世界 → 内部表示"的压缩通道，维度有限、有损、被身体约束。

第二步：用具体声音指代具体现象。 最早的语言很可能是"一个声音对应一个具体现象"：食物、危险、同伴。声音便宜——可远传、可共享、不依赖视线，还能在黑暗中用。这一步建立了最早的一批"符号-表示映射"。

第三步：组合产生新意义。 两个声音拼在一起，可以指称一个新现象（"大-动物"、"那边-水"）。组合律出现，语言从"一对一映射"变成"可生成的系统"。

第四步：固化与抽象。 反复使用的组合固化成语法；从具体指称里抽出类别、动作、关系——逻辑的雏形。语言结构就这样从"声音-现象"的映射里长出来。

写成形式：

· 初始语言 $L_0 = \{ (s_i, r_i) \}$：符号与表示的映射对

· 组合运算 C：把若干 (s, r) 拼成新表达式

· L = 由 L_0 与 C 生成的闭包

· 公共约定：映射与组合规则在群体中稳定下来

⇒ 语言 = 公共压缩方案（词汇=范畴，语法=组合律）

二、语言是什么：公共压缩接口

语言是一套"公共的符号接口"，用来把生命内部的压缩表示转换成可传递、可解压的序列。

- **对说者**：把内部表示（感受、想法）压成符号序列——编码；

- **对听者**：用自己的结构把符号解压回内部表示——解码；

- **对群体**：这套编码/解码规则被共享、传承、积累——公共方案。

所以语言不是世界本身，也不是思想本身，是"可传递的压缩包"。语言能力不等于理解：说得出不等于有感受；这是后文对照大模型的关键。

三、语言结构的函数分解

用我们的函数语言，语言结构可以拆成五个部件。

① 词 = 切片。 一个词是一个映射：符号 → 表示。它有表示维度（这个词能区分多少个方向），也是最小的组合单元。

② 句法 = 空间组合律。 词与词怎么拼成短语、短语怎么拼成句子——这是同一时刻内部的组合，对应我们说的空间组合：$F = f_N \circ \dots \circ f_1$，组合律要求类型相容。

③ 语义 = 表示映射与接地。 符号指向什么、能不能接上世界。语义不是符号自身的属性，是"符号-世界"的对应；它对模态敏感：只有文本时，语义残差（语言承载不了的缺口）就暴露出来。

④ 篇章 = 时间组合。 上下文、指代、顺序与依赖：$s_{t+1} = I_{\sigma(t)}(s_t)$。一句话的意思依赖前面说过什么——这是语言在时间上的组合。

⑤ 逻辑 = 组合律的规则。 哪些组合合法、哪些推得出来。逻辑不是语言之外的另一套东西，它是语言组合律的规则化：如果语法决定"怎么拼"，逻辑决定"拼出来的哪些能用"。

（还有一个可选的部件：语用 = 判定。在什么场合、对谁说、是否得体——它是语言使用中的"一次通过"的判定。）

四、语言作为公共压缩方案

把上面的部件合起来看，语言就是一套压缩方案：

- **词汇 = 范畴**：把连续的感受切成离散的类（粗粒化）；

- **语法 = 组合律**：离散单元怎么拼；

- **逻辑 = 组合律的规则**：哪些拼法有效；

- **共享约定 = 稳定性**：同一套方案在群体里通用。

所以语言描述世界的能力，等于这套方案的完备程度。而方案是可以积累的：文化、科学、书面语——都是把时间压成结构，让下一次解压能展开得更细。

五、可函数化的层次

语言不是全部可函数化的。按层次分：

形式（符号串） 可函数化：离散、可数、可生成

句法（组合） 可函数化：规则明确

语义（表示） 部分可函数化：能指称，但接地依赖模态

语用（场合） 大部分不可函数化：依赖语境与共同背景

对应的划分就是 p语言 + R语言：

- **p语言**：字面、结构、规则——本篇形式化的对象；

- **R语言**：言外之意、体验、语境依赖——只声明，不展开。

这也解释了为什么"语言可以被函数近似"是错的、准确说法是"语言的 p语言 可以被函数近似"（论文-00/01）。

六、语言能自指

语言可以描述语言：语法书、词典、这篇文章本身。这是自指的一种——用符号系统描述符号系统。它带来两个后果：

- 语言可以自我扩展（造新词、新语法）；

- 语言可以描述"描述"本身（元语言）。

但自指不是无限的：任何一次描述都是局部的、有限层的（对应我们框架里"自指只到有限层"）。

七、与大模型的关系

大模型学的正是这套公共压缩方案的成品：

- 它拿到了符号层及其组合规则（p语言），所以会语言、会推理（逻辑=组合律）；

- 它没有"器官→感受→符号"的接地过程——没有身体、没有器官、没有声音-现象的对应；

- 所以它的语义是"符号对符号"的对应，不是"符号对世界"的对应。

这解释了三件事：

1. **会语言 ≠ 有语言能力**：它复现的是方案，不是方案长出来的过程；

2. **语义残差的存在**：接不上的部分不是 bug，是它只有符号侧的必然；

3. **幻觉**：没有世界侧的校正，符号组合可以自洽而错误。

八、可检验推论

1. 句法复杂度应映射到计算步数：句法依赖越深，所需层数/步数越多（可用 GPT 类模型测）。

2. 语义残差应由接地维度决定：补上缺失维度则残差降低，冗余模态不降（已有玩具实验支持，可扩到真实多模态）。

3. 逻辑结构应映射到组合维度：需要更多"不同算子"的推理，组合维度需求更高。

4. 公共结构的积累应提升描述能力：语料中结构越丰富，模型在细粒度描述上的表现越好。

九、局限

第一，R 只声明、不展开：只写 p语言 这一侧。

第二，语言结构没有严格定义：我们用的是"词/句法/语义/篇章/逻辑"的常识划分，没有形式语法或语义学的严格框架。

第三，起源部分是推测性的：从器官到符号的演化过程无法直接验证，只能作为合理叙事。

第四，与大模型的关系是概念性的；本篇没有新实验，四条推论是方向性的。

第五，本篇是形式整理，不是新数学。

附：标注

- **[定义]** 语言 = 公共压缩接口；词=切片、句法=空间组合、语义=表示与接地、篇章=时间组合、逻辑=组合律的规则；p语言/R语言。

- **[整理]** 与论文-00/01 的 p语言/R语言、论文-32 的"语言=公共压缩方案"、论文-34 的"语言结构作为自变量"一致。

- **[推测]** 语言的起源叙事（器官→声音→组合→抽象）——概念性论述，不可直接验证。

- **[不声称]** 不声称给出语言的形式语法；不声称解释意识或体验；R 不展开。

> 本文由何淇创作，DeepSeek（AI）协助整理与写作；观点与责任属于作者。