论文-42 · 层门控：从零训练与预训练后训练的两组结果（待复核）

何淇 · 与 DeepSeek 协作

数字生命系列 · 执行器工程 第四篇（内部编号第 42 篇）

日期：2026-11-01

状态：工程观察汇总——单种子为主、数据规模有限；结论保守，不作方法宣称。

摘要

这一篇把本系列关于"层门控"的实验放在一起，分成两族对照：

第一族：从零训练（门和模型一起长）

| 设置 | plain | 门控 | 用的层 | 代价 |

|---|---|---|---|---|

| 小模型 1.2M，字符级，1MB | 6.103（3 种子均值） | 6.028 | 2.97/6（50%） | ≈0 |

| GPT-2 small 124M 从头，1MB | 44.03 | 47.01 | 5.30/12（44%） | +6.8% |

| GPT-2 small 124M 从头，100MB | 4.892 | 5.023 | 5.81/12（48%） | +2.7% |

| Qwen2.5-1.5B 从头，100MB | 6.301 | 6.373 | 12.32/28（44%） | +1.1% |

第二族：预训练 + LoRA 后训练（不从头训练）

| 设置 | plain | 门控 | 用的层 | 代价 |

|---|---|---|---|---|

| Qwen2.5-7B 预训练 + LoRA，1MB | 7.01 | 9.71（目标 26） | 25.70/28（91.8%） | +38% |

| 同上（目标 24） | — | 12.93 | 24.01/28（85.8%） | +85% |

| 同上（目标 22） | — | 12.79 | 22.27/28（79.5%） | +82% |

结论：

1. 从零训练时，层门控在 1.2M~1.5B 规模上都便宜（省 44%~50% 层，代价 0~7%）；

2. 预训练 + LoRA 轻量后训练时，**层数压不下来（best 仍 80%~92%），PPL 没降反升（+38%~+85%）**，还出现一次门控塌缩（PPL 1243）；

3. 关键变量是"是否从头/共同训练"，不是参数量。

> 说明：3B 预训练 + LoRA 组也做过，结果与 7B 同类（层数压不动、PPL 上升），为避免重复不单列。

一、设置

所有实验共同点：

- 门：每层一个内容门 σ(W·h + b)，对 token 的输出写回做硬 0/1 决策；门开=放行、门关=跳过该层；

- 预算：拉格朗日乘子 λ 自适应，把平均开启层数压向目标；

- 数据（除小模型外）：tinyshakespeare（约 1MB）或 TinyStories 切片（100MB）；

- 评测：验证集 PPL，按 best 记录（并做早停）。

各实验差异：

| 实验 | 模型 | 初始化 | 适配 | 数据 | 步数 | 目标 |

|---|---|---|---|---|---|---|

| E1 | 6 层小模型 1.2M | 从头 | 全参 | 1MB 字符级 | 多组 | 3/6 层 |

| E2 | GPT-2 small 12 层 | 从头 | 全参 | 1MB 莎士比亚 | 3000 | 6/12 |

| E3 | GPT-2 small 12 层 | 从头 | 全参 | 100MB TinyStories | 10000 | 6/12 |

| E4 | Qwen2.5-1.5B 28 层 | 从头 | 全参（Adafactor） | 100MB TinyStories | 8000 | 14/28 |

| E5 | Qwen2.5-7B 28 层 | 预训练 | LoRA r=16 | 1MB 莎士比亚 | 2000 | 26/24/22 |

二、从零训练：门控便宜（**E1~E4**）

E1 小模型（**6** 层，**1.2M**，字符级）

- plain 3 种子均值 PPL 6.103（6.232 / 5.999 / 6.083）；

- 内容门 + 拉格朗日目标 3 层：PPL 6.028，平均 2.97/6 层（省约 50%）；

- 位置门（按 layer×position 固定表）：目标 3 层 → 6.038，平均 2.98 层。

- λ=0 自由训练时，模型自己选 5.3/24 层（更深的小模型）。

E2 GPT-2 small（12 层，124M）从头，1MB

| 组 | best PPL | 步数 | 平均层数 |

|---|---|---|---|

| plain | 44.03 | 1500 | 12 |

| joint_gate | 47.01 | 1000 | 5.30（44%） |

代价 +6.8%。门控在 λ≈0 时自己收敛到约 5.3 层（模型自选稀疏路径）。

E3 GPT-2 small 从头，100MB TinyStories

| 组 | best PPL | 步数 | 平均层数 |

|---|---|---|---|

| plain | 4.892 | 9000 | 12 |

| joint_gate | 5.023 | 9000 | 5.81（48%） |

代价 +2.7%。每层活跃率（final）：

`1.00, 0.82, 0.61, 0.01, 0.12, 0.35, 0.28, 0.25, 0.25, 0.45, 0.75, 0.74`

（第 0 层全开、第 3 层几乎不用、末两层回到 0.74~0.75）

E4 Qwen2.5-1.5B 从头，100MB TinyStories

| 组 | final PPL | best PPL | 平均层数 |

|---|---|---|---|

| plain | 6.301 | 6.501 @6500 | 28 |

| joint_gate | 6.373 | 6.113 @6500 | 12.32（44%） |

final 口径代价 +1.1%；best 口径门控组反而更低。每层活跃率显示**最后 9 层（L19~L27）几乎全部关闭**。

从 E1 到 E4，模型放大 1000 倍（1.2M → 1.5B），门控依然便宜。

三、预训练 + **LoRA** 后训练：没有压下来，也没有变好（**E5**）

3.1 结果（**Qwen2.5-7B**，**28** 层，**LoRA r=16**，**1MB**，**2000** 步）

| 组 | best PPL | 出现在 | 平均层数 | 相当于全层 |

|---|---|---|---|---|

| plain（28 层） | **7.01** | 250 步 | 28 | 100% |

| 目标 26 | 9.71 | 750 步 | 25.70 | 91.8% |

| 目标 24 | 12.93 | 750 步 | 24.01 | 85.8% |

| 目标 22 | 12.79 | 1000 步 | 22.27 | 79.5% |

3.2 最终值（说明不稳定）

| 组 | final PPL | final 平均层数 |

|---|---|---|

| plain | 7.91 | 28 |

| 目标 26 | **1243.19** | 20.00（崩） |

| 目标 24 | 13.82 | 23.62 |

| 目标 22 | 14.10 | 21.47 |

3.3 三个明确观察

观察 1：没有从头训练。[事实]

本次是预训练权重 + LoRA 后训练，主干计算路径由预训练决定。

观察 2：层数没有压下来。[事实]

目标 26/24/22 层，但 best 时刻只到 91.8% / 85.8% / 79.5%；对应每层平均活跃率 0.92 / 0.86 / 0.80，几乎没有层被真正关掉。

观察 3：PPL 没有降，反而升了。[事实]

三组 best PPL 比 plain 高约 38% / 85% / 82%；目标 26 组 final 直接崩到 1243（门控塌缩到 20 层）。

3.4 每层活跃率（目标 **26**，**best** 时刻）

```

1.00,0.96,0.99,0.89,0.88,0.97,0.96,0.90,0.96,0.97,0.87,0.81,0.93,0.64,

0.95,0.83,0.80,0.86,0.93,0.95,0.99,0.93,0.98,0.99,0.78,1.00,1.00,1.00

```

读法：门控几乎没有关层，只是把少数 token 的少数层调低一点；它对质量的贡献为负。

四、为什么两族结果差别这么大（解释，非事实）

[解释] 三点叠加：

1. **预训练模型的每层都被"用惯了"**：残差流默认每层都有贡献；跳过层等于改变函数，而 LoRA 低秩更新改不动这个结构。

2. **数据太少（1MB）**：7B 几百步就过拟合，学不到"关层后如何补偿"。

3. **门控不稳定**：λ 驱动下可以雪崩（25.7 → 20 层，PPL 1243）。

[推测] 从零训练时，模型从一开始就在"可能跳层"的约束下学习，会把计算集中到少数层（E4 的最后 9 层几乎全关就是证据）；预训练模型没有这个机会。

五、局限

- 单种子为主；数据规模有限（1MB 或 100MB 切片）；步数有限（多为欠训练）；

- 从零训练组的绝对 PPL 不代表模型真实能力（欠训练）；

- 仅 PPL，无下游任务；

- 7B 用 bf16 + batch 1，稳定性差；

- E5 的目标层数是人工设定，未做联合优化。

六、结论

1. **从零训练 + 门控**：在 1.2M~1.5B 规模上都便宜（省 44%~50% 层，代价 0~7%）；

2. **预训练 + LoRA + 小数据后训练**：层数压不下来、PPL 不降反升、且不稳定（7B，+38%~+85%，一次塌缩）；

3. 想用层门控省算力，**门控必须和模型一起训练**（或给足数据与适配容量），轻量后训练不行；

4. 这不构成"大模型不能压缩"的结论——只说明这种后训练方式不行。

附：标注

- **[事实]** 第二、三节所有 PPL/层数/活跃率（来自 results JSON）。

- **[解释]** 第四节原因分析。

- **[推测]** "从零训练会把计算集中到少数层"——由 E4 的层活跃率支持，但未在 7B 上验证。

- **[不声称]** 不声称门控优于全层、不声称新方法、不声称加速比可迁移。

- 3B 预训练 + LoRA 组结果与 7B 同类，未单列以避免重复。