论文-47 · 加层、回放与蒸馏：大模型睡眠巩固的方向观察（待复核）

何淇 · 与 DeepSeek 协作

数字生命系列 · 执行器工程 / 方向观察（内部编号第 47 篇）

日期：2026-11-04

状态：方向观察与最小实验——极小模型、字符级、单种子；只验证机制，不作方法宣称。

摘要

一个训练完成的模型，如何在不遗忘旧能力的前提下继续学新东西？本篇记录一组最小实验，并给出两个应用方向的判断。

基础是一个 1.21M 参数的字符级 6 层模型：day1 数据为莎士比亚，day2 为 Python 源码。主要观察：

1. **加层能学新能力，且比全参微调少遗忘**：全参微调 day2 时 day1 PPL 从 4.64 崩到 46.3；冻结基础加 6 层后 day1 为 18.2、day2 为 4.26；加层并回放 day1 后 day1 保到 4.83、day2 为 6.60。

2. **门有三个作用**：轻量适配（冻结模型只训门，PPL 44.31→24.59）、步骤分配（每 token 每层决定算不算）、模式切换（单模式回放时零和；双模式回放可两边都保）。

3. **极小回放可以接近全量回放**：100 条旧样本、10% 混合，day1 9.05、day2 5.02（对照：不回放 day1 18.2；全量回放 day1 4.78、day2 8.67）。

4. **蒸馏压缩可以打包**：教师（12 层 gated，已巩固）day1 6.96/day2 4.50，学生（8 层更宽、无门）day1 7.42/day2 2.18。

据此给出两个方向（都只到"可行"级别）：个人 AI 的睡眠巩固；大模型新语料的增量更新。并明确：实验是玩具规模，不声称优于现有做法。

一、问题

模型训练完、部署后，知识停在训练那一刻。要更新，有几条路：

- **外部记忆**：检索、上下文。便宜、无损，但不改变模型本身；

- **全参微调/继续训练**：便宜一些，但会灾难性遗忘（我们实测 day1 PPL 从 4.64 到 46.3）；

- **完全重训**：质量最好，但要全部旧数据 + 新数据，成本最高；

- **冻结旧模型 + 加层**：旧模型只做推理，新层学新东西。

本篇关心最后一条：加层能否承载新能力、如何防止干扰旧能力、如何把生长打包。

二、预备：模型、加层与门

2.1 基础模型

```

· 字符级语言模型：6 层 Transformer

· 宽度 d=128，4 个注意力头，MLP 隐层 512

· 参数量 1.21M

· 在 day1（莎士比亚）上从零训练到收敛

· 训练后冻结：参数不再更新

```

用这么小的模型，是为了让所有实验在 CPU 上几分钟跑完，把机制问题与规模问题分开看。

2.2"加层**"**是什么

```

· 基础模型 6 层，冻结

· 在它上面再接 6 层新的 Transformer

· 新层随机初始化

· 输入输出维度相同（128）

· 共享冻结的嵌入层、位置编码、最终 LayerNorm 和输出头

```

⇒ 总模型 12 层：

前 6 层 = 冻结的旧模型

后 6 层 = 新加的可训练层

```

**2.3"门"是什么**

门是每层一个很小的模块，决定这一层对当前 token 起多大作用：

```

· 每层一个线性层：Linear(d → 1)，d=128

· p = sigmoid(W·h + b)，一个 0~1 的数（h 是该层输入）

· 这一层前向变成：

h_out = h + p · (Block(h) − h)

· p≈1：这一层完整计算

· p≈0：这一层近似跳过

· 中间：按比例混合

⇒ 门不产生输出，只控制"这一层算多少"

```

门的位置逐实验说明：

- **后 6 层门**：只给新加 6 层加门，前 6 层不加（等价 p≡1）；

- **12 层全加门**：前 6 层（冻结权重）和后 6 层都加门，前 6 层的门也可训练。

门初始化：使开率起始约 0.5~0.9（接近开）。

**2.4** 训练流程

```

阶段 1（day1）：训练基础 6 层（无门）

阶段 2（day2）：冻结基础，只训新 6 层（可带门）

阶段 3（巩固）：混合 day1/day2 训练（可只训门）

阶段 4（蒸馏）：用混合数据训练一个稠密学生

```

## 三、门的三个作用

**3.1** 轻量适配

```

· 冻结模型，只训练门（论文-38：12 个门约 9k 参数）

· GPT-2 small 冻结 + 12 个门：PPL 103.1 → 64.1

· 我们的小实验：44.31 → 24.59

⇒ 门像一个极小的适配器，把冻结模型的层贡献重新加权

· 但它不能学新表示，只能重新组合已有层

```

**3.2** 步骤分配

```

· 每个 token、每一层：算还是不算

· 从零训练时门开率会学出结构：

· 第 0 层几乎全开

· 中高层对部分 token 关闭

· 我们 1.5B 从零训练的模型：最后 9 层几乎全关

⇒ 门在分配"这个 token 走几步"

```
```

3.3 模式切换

```

· 不同数据/模式之间切换层的开合

· 单模式回放：零和

· 只回放 day1：day1 恢复 4.72，day2 崩到 1415

· 双模式回放：两边都保

· day1 6.96（从 26.70 恢复），day2 4.50

⇒ 门能做切换，但要"两种模式都见过"才不零和

```

四、最小实验

4.1 单任务上加 **6** 层

在 day1 上训练 6 层基础模型，然后加 6 层：

| 组 | 配置 | 验证 PPL |

|---|---|---|

| A | 基础 6 层 | 4.34 |

| B | 冻结 6 + 后 6 层可训练（门只在后 6 层） | 4.16 |

| C | 冻结 6 + 后 6 层可训练（12 层全加门） | 4.17 |

| D | 冻结 6 + 后 6 层可训练（不加门） | 4.20 |

观察：加层带来约 3% 提升；门与无门差别在噪声内；新层门开率只有 0.16~0.5，说明额外深度用处不大。

4.2 持续学习（**day1 → day2**）

| 组 | 做法 | day1 PPL | day2 PPL |

|---|---|---|---|

| A | 基础（只见过 day1） | 4.64 | 1386.7 |

| B | 全参微调 day2 | 46.3 | 1.52 |

| C | 冻结 + 加 6 层（无门、无回放） | 18.2 | 4.26 |

| D | 冻结 + 加 6 层 + 回放 day1（各 50%） | 4.78 | 8.67 |

| L | 长期学（新层 + 12 层门，day2） | 26.3 | 3.76 |

| LR | 长期 + 回放 | 4.83 | 6.60 |

观察：全参微调 day2 最好但 day1 崩；加层遗忘更轻；回放让 day1 基本保住、day2 略差。

4.3 门作为切换器

在 L（长期学完）基础上冻结所有层，只训门：

| 组 | 做法 | day1 PPL | day2 PPL |

|---|---|---|---|

| REC | 只训门 + 回放 day1 | 4.72 | 1415.6 |

| D2 | 只训门 + 回放 day2 | 24.11 | 3.79 |

| DUAL | 只训门 + 双模式回放 | 6.96 | 4.50 |

| DUAL6 | 门只在后 6 层的双模式回放 | 6.11 | 4.48 |

观察：单模式切换零和；双模式回放能让门同时保住两边；门放后 6 层与 12 层差别很小。

4.4 极小回放 **vs** 极小约束

| 组 | 做法 | day1 PPL | day2 PPL |

|---|---|---|---|

| C | 不回放 | 18.2 | 4.26 |

| D | 全量回放（50%） | 4.78 | 8.67 |

| E2 | 100 条旧样本、混合 10% | 9.05 | 5.02 |

| E3 | 100 条旧样本 KL 约束（权重 1.0） | 4.70 | 29.74 |

观察：100 条样本就能显著缓解遗忘；极小回放和全量回放各有优劣（旧能力 vs 新能力）；KL 约束权重 1.0 太强。

4.5 蒸馏压缩

教师 = 12 层 gated（基础 + 6 新层，双模式回放巩固）：

| 模型 | day1 PPL | day2 PPL | 参数量 |

|---|---|---|---|

| 教师（12 层 gated） | 6.96 | 4.50 | ~2.5M |

| 学生 A（8 层，d=160，无门） | 7.42 | 2.18 | 2.68M |

| 学生 B（12 层，d=128，无门） | 7.44 | 2.83 | 2.55M |

观察：学生保留两边能力（day1 差约 6%、day2 更好），门被完全去掉。

五、两个方向

5.1 个人 **AI** 的睡眠巩固

```

· 每人一个"个人层"（新加层 + 门），共享底座

· 白天：上下文/记忆保存（短期、无损）

· 晚上：把当天语境训进个人层，只训个人层和门

· 少量回放共享数据防遗忘

· 定期蒸馏压缩个人层

· 好处：隔离、隐私（数据只进个人层）、可回滚

· 可行性：我们的加层+回放+蒸馏实验支持机制可行；

真实规模未验证

```

5.2 大模型新语料的增量更新

```

· 旧模型冻结，只做推理

· 新语料到达 → 在其上训新层

· 可连续更新，不必全量重训

· 层积累后定期蒸馏打包

· 这是"全量重训"的增量替代，不是免费午餐

· 适用边界：

· 领域扩展、同类型新语料：可行

· 需要旧模型从未具备的低层特征（全新语言/模态）：不够，

可能要改嵌入或重训底层

· 代价：前向变贵（多出的层）、蒸馏一次成本

```

两个方向都只到"可行"级别；我们的小实验只验证机制，不验证规模与真实收益。

六、与 **Google sleep framework** 的对照

Google 2026 年的睡眠框架（arXiv:2606.03979，*Language Models Need Sleep: Learning to Self-Modify and Consolidate Memories*）把运行分成清醒与睡眠两阶段：

- **Memory Consolidation**："Knowledge Seeding"——把较小自身的记忆向上蒸馏进更大的网络，在扩容同时保住知识；

- **Dreaming**：用 RL 生成合成数据课程，排练新知识、精炼旧能力。

| | Google sleep | 本篇 |

|---|---|---|

| 扩容方式 | 蒸馏进更大网络 | 冻结旧模型 + 加 6 层 |

| 防遗忘 | 向上蒸馏 + 回放 | 双模式回放（教门两种模式） |

| 巩固信号 | RL 生成合成数据 | day1/day2 混合数据 |

| 切换机制 | 无显式门 | 门（单模式零和） |

方向一致：都把"短期记忆 → 长期参数"当核心，都靠回放防遗忘。差异在机制。

七、方向判断与局限

判断（只在玩具规模上成立）

```

· 加层可以承载新能力，遗忘比全参微调轻

· 门是"细调旋钮"与"切换器"，不是能力开关

· 回放是关键；极小回放（100 条）就有明显效果

· 蒸馏可以把生长打包成固定大小、无门的模型

· "生长 → 巩固 → 打包"构成一个自洽循环

```

局限

```

· 极小模型（1.21M）、字符级、单种子

· day1/day2 分布差异极大（莎士比亚 vs 代码）

· 学生用硬标签混合数据训练，未用教师软标签或 RL 课程

· 没有在真实规模模型上验证

· "门放后 6 层略好"的差异在噪声内，不能当结论

```

结论

```

· 加层 + 回放 + 蒸馏是一条可行的持续学习循环

· 它的两个可能应用方向：个人 AI 的巩固、大模型的增量更新

· 两者都只到"可行"级别；真实价值需要真实规模验证

```

附：标注

- **[事实]** 第四、五节全部 PPL 数字（本地运行结果 JSON）。

- **[方向判断]** 第五节两个方向、第七节判断。

- **[不声称]** 不声称方法新颖；不声称可扩展到真实大模型；不声称优于全参微调/外部记忆。

- 相关：Google sleep framework [arXiv:2606.03979](https://arxiv.org/abs/2606.03979)；

[Google Research 博客](https://research.google/blog/the-sleep-framework-a-new-way-for-llms-to-retain-knowledge-in-continual-learning/)。

- 脚本：`continual_add.py`、`continual_time.py`、`continual_gate_dual.py`、`continual_gate_dual6.py`、`small_replay.py`、`distill_compress.py`、`gated_extend.py`、`gated_extend_nogate.py`；结果 JSON 同目录。