论文-49 • 门：结构上的可塑接口

何淇 • 与 DeepSeek 协作

数字生命系列 • 执行器工程（草稿）

日期：2026-11-12

定位：工程论文。汇总门的一系列实验，给出"门能做什么、不能做什么"的判断；带［推测］处为推演。

摘要

门（gate）最早是为省算力设计的：每层每 token 决定这一层算不算。但训练之后它变成了另一样东西：**连续缩放，重加权已有坐标**。

本篇把散落在工程笔记 01~05 里的门实验汇成一条线，回答三个问题：

```
① 门是什么：参与度控制（哪些层算、算多少、走哪条）
② 门能做什么：换任务、保旧、选择、组合、遗忘、生长
③ 门不能做什么：不能加新能力
```

核心判断：

```
· 门能调的，是模型已经压进去的能力
· 门的极限 = 已有能力的可及性
· 它不是"学"，是"取"
```

一、预备：给没看过前面的人

【我们在做什么】

```
· 大模型训练完，权重就固定了
· 想让它适应新任务，通常要重新训练（贵、会忘旧任务）
· 我们试的是另一条路：
   · 权重全部冻结，不动
   · 只加"门"：每层一个小的缩放参数
   · 只训练门（几万参数，几分钟）
⇒ 看这样能不能适应新任务、又不破坏旧能力
```

【PPL 是什么】

- PPL = 困惑度（perplexity）
- 衡量模型对一段文本"有多意外"
- 越低越好：
  - PPL 就相当于"平均有几个候选词在犹豫"
  - 降一半，说明模型对文本更熟了

【几个词】

- 冻结：权重不训练
- 门：每层一个缩放向量
  - h = h + g ⊙ (out − h)
  - g=1 等于原模型；调 g 就是调该层贡献
- 加层：在末尾新增可训练的层（学新东西）
- 旧门保底：旧任务用一套门（新层关闭），新任务用另一套
- 组合门：为"A+B 一起用"专门训的一个门
- 门库：每个任务一个门，用时选一个
- 共享门+偏移：一套共用门 + 每任务一点小修正

【实验规模】

- 玩具：6 层 GPT-2（莎翁/代码两种文本）
- 真模型：Qwen2.5 的 0.5B / 1.5B / 3B
  - 训练在 CPU 上

二、门是什么

【原始定义】

- 每层、每个 token 一个开/关决策
- 门开：这一层对该 token 计算并写回
- 门关：跳过，残差直通
- 目的：省算力（稀疏执行）

【两个面】

- 函数面：g = g(条件)
  - 算出来的开度，属于计算
- 参数面：g 的数值被保存
  - 训练后留在模型里，属于记忆

⇒ 同一个门，看哪面决定它是什么

【两级】

· 内容门：按 token 内容算（g=σ(W·h)）
  · 细粒度、动态
· 任务门：每任务一组缩放参数
  · 粗粒度、可切换
⇒ 本质相同：对"参与度"的控制
  只是单位不同（token / 任务）

【实现形式】

· 缩放：h = h + g ⊙ (out − h)
  · g 可以是标量、向量、每 token 的函数
· 可训练、可冻结、可切换

三、门能做什么

2.1 换任务：冻结模型 + 门

【玩具 GPT-2（6 层）】

· 冻结底座（莎翁上训好）
· 只训门（768 参数）
· 新任务（代码）：
  · PPL 1386 → 30 左右
· 加层（6 层可训练）：
  · PPL → 4.27
⇒ 门能大幅适配，但有下限

【真模型 Qwen2.5】

模型	门参数	新领域 PPL	对照领域 PPL
0.5B（24 层，d=896）	21.5k	91.46 → 32.71	22.87 → 24.12
1.5B（28 层，d=1536）	43k	71.26 → 27.32	18.69 → 19.07
3B（36 层，d=2048）	73.7k	67.65 → 26.17	18.12 → 18.49

· 新领域 PPL 降 61~64%
· 模型越大：附带损伤越小（5.5% → 2%）
· 增益收窄（1.5B→3B：27.3→26.2）
⇒ 门适配在真模型上成立

2.2 保旧：旧门保底

```
· 旧任务门：旧层=1，新层=0
  · 旧任务 PPL 4.64，完全不变
· 新任务门：可学
  · 新任务 4.04
⇒ 两套门，各管各的
  不遗忘不靠训练技巧，靠"不动它"
```

2.3 选择：5 样本现场选门

```
· 给新任务 5 个带标签样本
· 每套门算一遍损失，选最小
· 结果：旧任务选旧门、新任务选新门，全对
⇒ 不需要人写描述
  5 个样本就够
```

2.4 组合：需要 A+B 一起用

【实验（段切换混合 / token 级混合）】

方案	段切换 PPL	token 级 PPL
旧门（只用底座）	77.26	270.14
新门（代码门）	14.29	65.10
拼门（底座=1 + 新层代码门）	17.11	70.28
重训组合门	**10.49**	**32.69**

```
· 组合任务，重训一个组合门最好
· 拼门不如重训（联合解要整体学）
· 组合门只 1536 参数
```

【加层对照】

```
· 加 2 层 + 门一起训（2000 步）：
  · 训练损失 1.18（很低）
  · 验证 PPL 309.21（过拟合）
· 组合门 2000 步：32.38（稳定）
⇒ 小数据下加层会过拟合
```

2.5 共享门 + 小偏移

- g_A = g_shared + δ_A；g_B = g_shared + δ_B
- 结果：day1 4.58 / day2 27.27
  - 接近各自专精（4.55 / 29.41）
- δ 很小（+0.142 / −0.126）

⇒ 一套底子 + 每任务一点方向修正

2.6 遗忘与回放

- 会话间只训门：
  - 交替任务，累积臂 ≈ 重置臂（门不沉淀）
- 加"会话前衰减"：被训练覆盖，无效
- 加"回放"：
  - 新/旧任务都保住（6.1~6.4 / 37~43）
  - 但单任务峰值下降

⇒ 遗忘不是把门衰减
是决定"哪些经验值得反复用"

2.7 生长：卡住就长

- 固定 6 层 + 门：PPL 28.58（900 步）
- 卡住就加 2 层（8 层）：16.89
- 一开始就 8 层：7.32

⇒ 生长能涨，但同样容量下"提前给够"更好
生长适合"算力分批到货/难度未知"

四、门不能做什么

- 不能加新能力
  - 玩具：门到 30，加层到 4.27
  - 真模型：门适配有下限
- 不能创造新坐标
  - 门只重加权已有结构
- 不能省算力（除非加硬约束）
  - 训练后门变成连续缩放
  - 不做稀疏惩罚/预算，它不会自己保持二值

五、门的极限 = 已有能力的可及性

【推演】

- 训练：把数据里的关系压进权重
  - 形成坐标、特征、路径
- 门：在这些已有结构上重新分配权重

⇒ 门的作用范围 ⊆ 模型已编码的能力

【诊断用法】

- 只训门 → 看能到哪（已有能力上限）
- 加层/微调 → 看能到哪（需要新结构）
- 差距 = 这个领域缺多少结构

⇒ 差距小：门/LoRA 够
差距大：加层或换模型

六、工程建议

- 单任务、可全量训练：门不必要
- 多任务共存：门库 + 现场选门
- 任务成族：共享门 + 小偏移
- 组合任务：重训组合门（别拼）
- 省算力：要硬约束（稀疏预算/二值门）
- 加层：数据够、门饱和时才上
- 遗忘控制：靠回放，不靠衰减

七、与 MoE、适配器、蒸馏的关系

- MoE：token 级路由到专家
  - 门控是它的连续版本
- 适配器/LoRA：加低秩旁路
  - 门更小、更"接口"
- 蒸馏：把"模型+门"内化进新模型
  - 门的适应 → 固化进权重 → 新模型

⇒ 门在"结构—适配—固化"链条的中间

八、边界

- 实验多为小模型（6 层 GPT-2、0.5B~3B Qwen）
- 领域选择单一（个人笔记 / 代码 / 莎翁）
- 只有 PPL，没有下游任务

- 没有和 LoRA/全量微调做同预算系统对照
- "门当诊断"是推论，未系统验证

九、结论

- 门 = 参与度控制：哪些层算、算多少、走哪条
- 函数面是计算，参数面是记忆
- 能换任务、保旧、选择、组合、遗忘、生长
- 不能加新能力：门是"取"，不是"学"
- 门的极限 = 已有能力的可及性
  - 可当诊断：门到哪、差多少
- 工程：门库 + 选门 + 组合门 + 硬约束

⇒ 门是结构上的可塑接口

一句话：**门不是学，是取；它把模型里已有的能力按任务重新加权——所以能用多低，正好量出模型里已经有多少。**

附：实验文件

- gate_task_experiment.py ~ gate_v15_fewshot_selection.py（玩具实验）
- gated6_selfselect.py / add6_only.py（加层与门）
- gated_mix.py / gated_mix2.py（组合门）
- gate_joint.py / gate_shared_offset.py（联合与共享偏移）
- gatelock_accum.py / gate_decay.py（累积与遗忘）
- grow_trigger.py（生长）
- qwen05/15/3b_gate_test.py（真模型适配）
- C:\DS\experiments\README.md（汇总）
- 相关：工程笔记 01~05；散论《关系与门》