门：从可塑接口到重配比

> 何淇 · 与 DeepSeek（AI）协作

> 数字生命系列 · 执行器工程（汇总篇，取代论文-49 与工程笔记 03/04/05）

> 日期：2026-11-13

> 状态：草稿。数字来自已有实验记录（论文-44/49、工程笔记 01~05 及本次补充）；

> 标注：[事实] 有记录，[解释] 推演，[推测] 未验证。

一、起点：一个冻结模型，还能改什么

问题不是"怎么微调大模型"，而是：一个已经冻结的系统，如果还要继续用，它能改变的是什么？

拆开看，改变的方式至少三类：加参数（加层、加宽）、改参数（继续训练、LoRA）、以及**不改参数**的前提下，改变已有通路的参与程度。门是第三类：给每条通路一个系数，g=0 不参与，g=1 保持原样，g>1 放大。

所以门最早的定义很窄：**它是组合律上的参与度系数**——调的是"已有的东西用多少"，不是"新增什么"。

二、门是什么：两个面，三档粒度

[解释] 门有两个面：函数面（g 由条件算出来，属于计算）和参数面（g 的数值被保存下来，属于记忆）。同一个门，看哪面决定它是什么。

按粒度分三档：

逐层向量门（任务缩放）：每层一个 d 维向量，所有 token 共用。参数极少，学得快、稳、不易忘；但不随输入变，只能给每层一个全局倾斜。

token 标量门：每个 token 一个标量，只调整体增益。连方向都选不了；初始化不当会直接把模型弄坏（sigmoid 在 0 附近给出 0.5，等于一上来关掉一半通路）。

token 向量门：每个 token 一个 d 维缩放，能按输入选方向。表达力最强，也最容易只在新任务上好、把旧能力挤掉。

三档差别可归到三个坐标：共享范围（层/token）、表达形式（标量/向量）、是否依赖输入。它们不是三个东西，是同一机制的三个角落。

三、门能做什么

[事实] 以下数字来自已有实验。

3.1 换任务：冻结模型 + 门

玩具 6 层 GPT-2（莎翁上训好，冻结）：只训门（768 参数），新任务代码 PPL 1386 → 30 左右；加层（6 层可训练）到 4.27。门大幅适配，但有下限。

真模型 Qwen2.5：

| 模型 | 门参数 | 新领域 PPL | 对照领域 PPL |

|---|---|---|---|

| 0.5B（24 层，d=896） | 21.5k | 91.46 → 32.71 | 22.87 → 24.12 |

| 1.5B（28 层，d=1536） | 43k | 71.26 → 27.32 | 18.69 → 19.07 |

| 3B（36 层，d=2048） | 73.7k | 67.65 → 26.17 | 18.12 → 18.49 |

模型越大：附带损伤越小（5.5% → 2%），增益收窄（27.3 → 26.2）。

3.2 保旧：旧门保底

旧任务门保持旧层 g=1、新层 g=0：旧任务 PPL 4.64，完全不变；新任务门可学到 4.04。两套门各管各的，不遗忘靠"不动它"，不靠训练技巧。

3.3 选择：**5** 样本现场选门

给新任务 5 个带标签样本，每套门算一遍损失选最小：旧任务选旧门、新任务选新门，全对。不需要人写任务描述。

3.4 组合：需要 **A+B** 一起用

| 方案 | 段切换 PPL | token 级 PPL |

|---|---|---|

| 旧门（只用底座） | 77.26 | 270.14 |

| 新门（代码门） | 14.29 | 65.10 |

| 拼门（底座=1 + 代码门） | 17.11 | 70.28 |

| 重训组合门 | **10.49** | **32.69** |

组合任务重训一个组合门最好，拼门不如重训——联合解要整体学。组合门只 1536 参数。

3.5 共享门 + 小偏移

g_A = g_shared + δ_A，g_B = g_shared + δ_B：day1 4.58 / day2 27.27，接近各自专精（4.55 / 29.41）；δ 很小（+0.142 / −0.126）。一套底子加每任务一点方向修正。

3.6 遗忘与回放

会话间只训门：交替任务，累积臂 ≈ 重置臂（门不沉淀）；"会话前衰减"无效；加回放后新/旧任务都保住（6.1~6.4 / 37~43），但单任务峰值下降。遗忘不是把门衰减，是决定"哪些经验值得反复用"。

3.7 生长：卡住就长

固定 6 层 + 门：PPL 28.58（900 步）；卡住加 2 层（8 层）：16.89；一开始就 8 层：7.32。生长能涨，但同样容量下提前给够更好；生长适合算力分批到货/难度未知。

四、门不能做什么

[事实] 门不能加新能力。

合成任务：任务需要 8 维，底座瓶颈 4 维——直接训练 0.3783；冻结+缩放门 0.3783（完全不变）；瓶颈 4→8 为 0.0038（约 100 倍）。

多步组合 y=sin(3·sin(3z))：浅层 0.17754；加门 0.17193（约 -3%）；加层 0.01714（约 -90%）。

同一任务门 vs LoRA：门 0.37802；LoRA（r=16）0.32557（约 -14%）；加宽 0.00383。

门也不能省算力——除非加硬约束。训练后的门变成连续缩放，不做稀疏惩罚/预算，它不会自己保持二值；稀疏性要在训练方式里解决（见第二篇）。

五、定义收拢

把这些合起来，门定成一句话：

> 门是对已有表示通路的重新配比。它改变每个方向被使用的强度，不改变方向的集合。

两个推论：

一是门的极限是"已有能力的可及性"：能调到哪，取决于模型里已经压进了什么。

二是门的种类由三个坐标决定：共享范围、表达形式、是否依赖输入。更好的门应该在三个坐标上找中间点——共享的低秩矩阵门（既有输入依赖，又能加少量新方向，参数量不至于爆炸）。这是推测，没有测。

六、一个负结果：门当诊断没测成

[事实] 我们曾提出：只训门能到多低，可以量出模型里已有多少能力，所以门能当诊断。于是做了一次检验：Qwen2.5-0.5B 冻结，四个领域（笔记/代码/英文/理论），门与 LoRA 各训 150 步，看"门降幅"能否预测"LoRA 收益"。

结果：门降幅 34%~46%，LoRA 降幅 24%~71%；按相对降幅排序，秩相关约 -0.2，不同序——代码的门降幅最小（34%），LoRA 收益却最大（71%）；英文门降幅中等，LoRA 反而最差（24%）。绝对降幅排序一致，但那是基线量级主导的假象。

[解释] 门和 LoRA 调用的能力不同（门是重加权，LoRA 加低秩方向），排序不必一致；英文那组训练样本太少（202 段），LoRA 过拟合。

⇒ "门能当诊断"这个说法，在 4 领域、单种子、150 步的测试下不成立。最多说"除代码外 3 点大致同序"，是弱观察。这条要写进论文，不能只留失败记录在内部。

七、和已有工作的关系

必须承认：我们不是第一个走到这里的。

ReFT / LoReFT：直接对隐藏表示做低秩子空间干预，可按位置（token）选择干预哪些表示；比 LoRA 少 15~65 倍参数，在多类任务上不差或更好。这已经是"逐 token 方向变换"的系统实现。

CeRA：指出 LoRA 有"线性天花板"——秩 16→512，PPL 卡在 3.90 附近，有效秩只用到约 60；原因是线性低秩更新只能旋转、不能弯折空间。加非线性门控后 rank 64 超过 LoRA rank 512，有效秩到 330；同时做了粒度对照（weight-level 优于 module-level）。

我们的工作是这条谱系里最朴素的一档：逐元素缩放，没有低秩、没有路由、没有条件生成。能提供的不是新方法，而是两样东西：

一是受控的阈值测量。合成任务上把"门无效、LoRA 有限、加宽有效"量成数字：底座宽度 2、任务需要 4 维交互时，门/低秩/非线性门控测试 MSE 全部停在 1.262 附近（与不接适配器无差别），只有加单元有效

（0.847 → 0.413，随单元数平滑下降）。非线性任务上阈值平滑，"刚好在 k 断崖"不成立。

二是框架位置。已有适配工作回答"哪种方法效果好"；我们把门接到"冻结系统的可塑接口"和"维持成本"上：门是代价最小的一种可塑性，但有结构上限。

八、边界

```

· 合成任务为主；真模型只测了 Qwen2.5 一族

· 门是缩放形式，结论不外推到低秩门/路由门

· 阈值在非线性任务上平滑，不能说"精确在 k 断崖"

· 文献定位只查了 ReFT、CeRA 两支；DoRA、MoE 等没有系统比较

· 门当诊断失败这一条只测了 4 领域、单种子

```

九、一句话

门是重配比，不是加维度；它能调出的是已经压进去的能力，调不出的是没有压进去的能力。这个界限，是我们在合成任务上测出来的，也由已有的适配工作从另一边印证。