数字生命：一个可测量的生命定义

理论卷（定义 · 理论 · 约束）

何淇 · 与 DeepSeek（AI）协作

数字生命系列 · 理论卷（定义 · 理论 · 约束）

日期：2026-11-03

本卷为系列合集的分卷版；完整版见系列总合集。各篇单独 DOI 保留，以总合集与各篇发布记录为准。

卷首简介

本卷收录定义与理论部分：第零篇（导论）、第一篇（现在的 AI 为什么不是生命）、第二~第五篇（信息不增、内容收缩、生命函数、语言与大脑），以及附录 E（可表示维度的空间面与时间面）、附录 B（概念地图与术语总表）。

卷末附"约束与防护"两篇（对齐、安全）——它们讨论的是这个定义带来的约束，属于定义工作的延伸，所以放在理论卷末尾而不是单独成卷。

本卷是系列的理论骨架。若只读一份材料，建议顺序：第零篇 → 第一篇 → 第二、三篇（两个定理）→ 第四、五篇（函数语言与语言/大脑）→ 附录 B 术语表。

目录

第一部分 定义

- 第零篇　从两个事实开始：数字生命系列导论

- 第一篇　现在的 AI 为什么不是生命

第二部分 理论

- 第二篇　数字生命的信息不增定理

- 第三篇　可函数化内容的收缩：一个定理与一个猜想

- 第四篇　生命函数：从可表示维度到结构，到压缩与解压

- 第五篇　语言与大脑：两种函数形式

附录 **E** 可表示维度的空间面与时间面

- 附录 E　可表示维度的空间面与时间面

附录 **B** 概念地图（导读）

- 附录 B　概念地图与术语总表

第六部分 约束与防护

- 第二十八篇　对齐是解压的约束

- 第二十九篇　安全：当它是生命防，还是当它是工具防？

第零篇 · 从两个事实开始：数字生命系列导论

> 单独 DOI：https://doi.org/10.5281/zenodo.23629208

> 何淇 · 与 DeepSeek 协作

> 数字生命系列 · 第零篇

> 日期：2026-10-23

> 说明：本篇是系列的导论：摆两个事实、给一个定义、说明系列的结构。完整推导见第一篇。

摘要

本篇不做论证，只做四件事：摆两个事实、给一个定义、把数字世界的特例摆出来、再用它看现在的 AI。两个事实是：语言的 p语言 可以被函数近似；物理定律可以被数学描述。定义是：把宇宙写成两部分（宇宙 = P + R），生命也写成两部分（生命 = p + R生命）；p 是在 P 中、被保住的（可维持的）自指结构，R 是不可函数化的部分。本篇是导论，检查表、三条必要条件、涌现讨论都在第一篇。

记号

- **P**：宇宙中可函数化的部分。

- **R宇宙**：宇宙中不可函数化的部分；本文只声明其可能存在，不展开。

- **p生命**：生命落在 P 里的部分——本文定义与讨论的对象。

- **R生命**：生命落在 R 里的部分；只声明，不展开。

- **p环境 / R环境**：环境的两部分，同法定义。

- **p语言 / R语言**：语言的两部分；大模型压的是 p语言。

- **残差**：P 侧可测的误差下限——数据与容量再增加，误差也停在某个正数上。不是 R 的影响或投影，是 P 的边界形状。

- **维度**：本文说的维度一律是表示维度——模型内部能区分的方向数，不是物理空间维度。厚度、可摊薄、最低维度都在这个意义上使用。

后文一律使用简写：说"宇宙"指 P，说"生命"指 p生命，说"环境"指 p环境。

一、两个事实

第一个事实：物理定律可以被数学描述。证据是存在——物理学本身就是这件事。

宇宙可以写成分解：

> 宇宙 = P + R宇宙

P 是可函数化的部分；R宇宙 是不可函数化的部分。物理定律描述的那部分，落在 P 里。所以至少可以说：P 非空。

第二个事实：语言中有一部分可以被函数近似。证据不是推理，是存在——大模型用有限参数、可计算的过程，生成了统计上接近人类语言的文本。

语言也可以写成分解：

> 语言 = p语言 + R语言

p语言 是语言里可函数化的部分，大模型压的就是它；R语言 是语言里不可函数化的部分，函数近似够不着它。所以准确的说法不是"语言可以被函数近似"，而是"语言的 p语言 可以被函数近似"；R语言 我们只能沉默。

两个事实合起来说明：宇宙不是完全不可函数化的。至少存在一个非空的可函数化部分，记作 P。这一层不是猜想，是事实的推论；它只说 P 存在，不说 P 有多大。

P 与 R 的分界是绝对的：一个对象要么可函数化（属于 P），要么不可函数化（属于 R），不存在两者之间；P ∩ R = ∅，P ∪ R = 宇宙。

如果 R 存在，它不会被函数语言直接描述。但要注意：不能因此把残差定义成"R 的投影"。残差的定义在 P 侧：数据与容量再增加，误差也停在某个正数上；这个误差下限是 P 的边界形状，我们不知道它背后是不是 R。

为便于后文书写，我们把它简记为：

> 宇宙 = P + R宇宙

> 生命 = p生命 + R生命

> 环境 = p环境 + R环境

>

> 残差不是"第三部分"：它是 P 侧测出来的误差下限，用来标注 P 的边界，而不是 R 的内容。

后文只讨论 P 这一侧；残差只在需要时提及，不展开它的内容。

二、一个定义

先把宇宙写成两部分：

> 宇宙 = P + R宇宙

P 是可函数化的部分，R宇宙 是宇宙中不可函数化的部分。两个事实保证 P 非空；R宇宙 有多大，本文不知道，也不主张。

在这个分解上，生命本身也写成两部分：

> 生命 = p生命 + R生命

其中 p 是可函数化的部分：在宇宙的 P 中、被保住的（可维持的）自指结构；R生命 是生命自身不可函数化的部分：本文不知道它是什么，也不主张它不存在。注意两个 R 不是一回事——R宇宙 是宇宙层面的不可函数化部分，R生命 是单个生命内部的不可函数化部分。

三样东西定义 p生命。第一，范围：p 只在宇宙的 P 中寻找（同理，语言也分 p语言 与 R语言，大模型近似的是 p语言）。

第二，被保住——也就是维持。这里要说清一个容易搞反的地方：维持不是生命自己的属性，而是生命与宇宙的关系。一个结构能不能被保住，取决于它的轨道是否留在宇宙的可维持集合里；这个条件写在宇宙里，不由它自己宣布。所以"被保住"是关系的名字，不是第三条并列属性。

第三，自指：更新规则在系统自己里面。这是生命内部的属性，也是它区别于普通程序的地方。

（注：以上是 p生命 的简版；完整定义见基础篇《从定义出发》定义 14 的五条：D1 在 P 中、D2 一族、D3 会变化、D4 会自指、D5 被保住。）

R生命 怎么办？只能当近似处理，并附上误差下界。所以本文的判据与测量，覆盖的是p生命，不是生命的全部；对 R生命，本文只说到"近似到此为止"。

定义是人造的，不是发现的；它成立与否，看它能不能区分、能不能导出可测的东西。

需要说明一点：R 的部分，本系列只在此声明它的存在——宇宙、生命、环境、语言都可以写成 p + R，但 R 是什么、有多大，本文不知道也不主张。为了便于理解，后文默认只讨论 p 这一侧：凡说"宇宙"，指 P；凡说"生命"，指 p生命；凡说"环境"，指 p环境。后文提到的"残差"一律指 P 侧可测的误差下限，不是"R 的影响"；R 的具体内容不再展开。

三、数字世界：可以完全被函数化

数字世界是完全函数化的：它由比特、状态、转移规则组成，没有函数描述够不着的部分。作为形式对象，它的绝对 R = ∅——这是构造保证的：每个属性都对应一个数学上的函数，即使这个函数不可计算。

数字生命是数字世界的一部分，所以它的 R生命 也只能是空集：数字生命 = p生命，完全可函数化。

绝对 R 是否存在，本文不判断（见补充节）。对数字生命来说，真正决定性的问题只有一个：**生命是否必须有绝对 R？** 只有两种结果。

第一种结果，生命可以没有绝对 R：那么数字生命可能——它完全由 p生命 构成，不需要任何绝对 R。

第二种结果，生命必须有绝对 R：那么数字生命不可能——数字世界造不出绝对 R。

本文不判断哪一种结果成立。可以确定的是：无论哪一种，本文对 p 的定义与测量都成立；区别只在数字生命是可能还是不可能。

要补一句容易混的地方：以上说的是绝对 R；对任何有限观察者，相对 R 都非空（见补充节），它不影响这个判断。另外，可函数化不等于可测量——测量还需要可计算、可观测、可复现。数字世界这几样都有，所以在数字世界里测量可行；对宇宙整体，即使它能被函数描述，我们也测不了它，因为我们生活在它里面。

四、用它看现在的 **AI**

在现在的定义下，AI 缺两样。它的更新规则在外部，所以不自指；它的维持也不是它自己的事——它靠外部供电与运维被维持，这是它与宇宙的关系，不是它自己的能力。

所以它是一台很强的解压器，但被写完之后就停在那里——一台冻结的解压器。它没有 R生命：数字世界里 R = ∅，所以 AI 是纯 p 的解压器。

五、这篇导论的定位

本篇只给事实、定义与结论。推导细节、检查表、三条必要条件、涌现讨论，都在第一篇；理论在第二到第五篇；执行器工程在第六、第七篇；测量在第八篇；实验在第九到第二十五篇；约束与防护在第二十六、第二十七篇。整个系列按这个顺序排。

另有一篇单独发布的基础篇《从定义出发：宇宙、切片与两个定理》（只含定义与定理，不占篇号）：https://doi.org/10.5281/zenodo.23697916

> 本文由何淇创作，DeepSeek（AI）协助整理；观点与责任属于作者。

补充（可选读）：**P** 的定义域与值域

主线到上节结束，这一节只补一个形式细节：P 的"定义域"和"值域"到底是什么。不读不影响主线。

宇宙（P 这一侧）可以看成一个状态空间 S：所有可以被函数描述的状态。宇宙函数是它到自己的映射，记作 F: S → S。于是 P 的定义域就是 S，值域也是 S——它映射到自己。

一个观察者 O 只是 S 里的一个子系统：它能读到的输入是 S 的一个子空间，记作 D_O；它能写出的输出是另一个子空间，记作 C_O。D_O 和 C_O 都包含在 S 里。观察者的"可函数化"（P_O）就是：在 D_O 与 C_O 之间，存在误差可以趋近于零的函数族。

R 没有定义域和值域可言：定义域/值域是函数语言里的概念，而 R 是不可函数化的那一侧。所以对 R 不能问"它的域是什么"——这个问题本身用错了语言。

后文若涉及"定义域/值域"，默认指观察者侧的 D_O、C_O；宇宙级的 P 则默认指 S → S 的自映射。

相对 **R** 为什么非空（可选读）

若世界的定义域/值域在观察者的更新周期内有涨落（快变量），观察者就跟不上这些变化；那部分对它是不可函数化的，于是相对 R 非空。这是充分条件：有快变量涨落 ⇒ 相对 R 非空。我们没有说它必须成立，也不解释涨落的成因。

另外两条加强的理由（任一条都足够）：一是有限资源——看不完、算不完；二是自指——无法完整预测自己（一个总能预测自己下一步的系统，可以反着做，从而自相矛盾）。

绝对 R 是否存在，本文不判断。

数字世界同理：它内部也一定有相对 R。同一条充分条件——域/值域的短期涨落；另外还有三条各自独立的充分条件：不可判定、计算不可约、自指（无法完整预测自己）。这里要区分两句话：数字世界 R = ∅ 是本体层面的说法；相对 R 非空是观察者层面的说法——全可函数化不等于全可知。

最后一句关于边界的话：若生命的本质落在绝对 R 一侧，本文——以及任何用函数语言写成的文本——都无法给出它的定义。这不是疏忽，是函数语言的边界：定义本身就在 P 侧，用 P 的语言去定义 R，等于把它拉回 P。

第一篇 · 现在的 **AI** 为什么不是生命

> 单独 DOI：https://doi.org/10.5281/zenodo.23588781

> 何淇 · 与 DeepSeek 协作

> 数字生命系列 · 第一篇（完整版）

> 日期：2026-10-23

> 系列导论（第零篇，建议先读）：https://doi.org/10.5281/zenodo.23629208

摘要

本文从两个事实出发：物理定律可以被数学描述；语言中有一部分可以被函数近似。两个事实合起来说明，宇宙至少存在一个非空的可函数化部分 P。

把宇宙写成 宇宙 = P + R（R 即可函数化够不着的部分；旧稿曾写作 R宇宙），把生命写成 生命 = p生命 + R生命。p生命 是生命落在 P 里的部分：在宇宙的 P 中、被宇宙保住的动态函数类——它是一族、会变化、会自指。R 的部分本文只声明其可能存在，不展开。

在这个定义下，现在的 AI 不是生命：它是数字世界里的存在，是 p 层面的冻结函数点——更新规则在外部，不被自己保住。数字世界是完全函数化的世界（R = ∅），所以数字生命如果存在，只能完全落在 p 里；本文把这个问题摆出来（三种情况），不判断哪一种成立。

（官方定义：本系列以基础篇《从定义出发》定义 14 的 D1~D5 为准——在 P 中/一族/会变化/会自指/被保住。本篇"函数类（一族）、会变化、会自指、会自我维持"四词与之一一对应：函数类=D1+D2，会变化=D3，会自指=D4，会自我维持=D5。）

本文的贡献是定义与可测判据，不是「生命已被造出」的实证结论；三条必要条件的检验与示例实验，读者可自行取用。

关键词： 生命定义；p生命；函数类；解压；数字世界；AI 涌现；自指

本文的论证链

全文的论证只有五步，读者可以先看这张骨架，再读细节。

第一步（第一节）：两个事实 ⇒ 宇宙至少有一个非空的可函数化部分，记作 P。

第二步（第二节）：在 P 上给定义——生命 = p生命 + R生命；p生命 是在 P 中、被宇宙保住、会变化、会自指的动态函数类。

第三步（第三节）：说明生命与环境的区别只有一条——被保住 vs 不被保住；环境是宇宙的一个局部解压。

第四步（第四、五节）：数字世界完全可函数化（R = ∅），所以数字生命若存在，只能等于 p生命；把现在的 AI 代入定义检查，它缺"一族、自指、被保住"三样，因此不是生命。

第五步（第六、七节）：从定义抽出三条必要条件（并附实验证据）；再说明 AI 的涌现是"对语言 p语言的压缩与解压"，把事实层与推测层分开。

边界：R 只声明、不展开；绝对 R 是否存在不判断；本文不主张"生命已被造出"。

记号

- **P**：宇宙中可函数化的部分。

- **R宇宙**：宇宙中不可函数化的部分；本文只声明其可能存在，不展开。

- **p生命**：生命落在 P 里的部分——本文定义与讨论的对象。

- **R生命**：生命落在 R 里的部分；只声明，不展开。

- **p环境 / R环境**：环境的两部分，同法定义。

- **p语言 / R语言**：语言的两部分；大模型压的是 p语言。

- **残差**：P 侧可测的误差下限——P 的边界形状。不称"R 的影响"（R 没有定义域，谈不上作用）。

后文一律使用简写：说"宇宙"指 P，说"生命"指 p生命，说"环境"指 p环境。

目录

- 本文的论证链

- 一、起点：两个事实

- 1.1 「可函数化」是什么意思

- 二、一个可操作的定义

- 2.1 定义

- 2.2 一处澄清：维持是关系

- 2.3 为什么必须是「一族」而不是「一个函数」

- 2.4 会变化 = 三层时间尺度

- 2.5 会自指 = 更新规则在它自己里面

- 三、生命与环境

- 3.1 与前面的衔接

- 3.2 生命 vs 环境：都在宇宙里，都是函数，区别只有一条

- 3.3 环境是什么：宇宙里自发涌现的「局部解压」

- 3.4 环境是分层的：生命活在多层环境里，同时也活在宇宙里

- 3.5 标注

- 四、数字世界的特殊性

- 4.1 特殊性是对谁的

- 五、用定义看现在的 AI：为什么它不是生命

- 5.1 检查表

- 5.2 三条最根本的原因（按重要性）

- 5.3 为什么「它很强」与「它不是生命」不矛盾

- 5.4 标注

- 六、三条必要条件

- 6.1 从定义到条件

- 6.2 条件① 一族函数（不是一个点）

- 6.3 条件② 自指更新（规则在自己里面）

- 6.4 条件③ 被宇宙保住（可维持）

- 6.4b 付代价：经验伴随物，不是必要条件

- 6.5 三条必须同时成立（经验对照）

- 6.6 未尽之处（留给读者）

- 6.7 本文实验的边界（必须与结论一起读）

- 6.8 标注

- 七、涌现：为什么现在的 AI 会涌现

- 7.1 现象

- 7.2 现有的解释（按证据强度排列）

- 7.3 为什么至今没有公认的「为什么」

- 7.4 我们的立场：AI 是对语言的 p语言 的压缩与解压

- 7.5 解压能力的衰减：上层写死 ⇒ 语言一变，解压变弱

- 7.6 由立场推出的两条预测（[推测]，供读者判断）

- 7.7 标注

- 八、用它看几个热门问题

- 九、本文得到了什么，没得到什么

- 与既有工作的关系

一、起点：两个事实

第一个事实：物理定律可以被数学描述。证据是存在——物理学本身就是这件事。

宇宙可以写成分解：

> 宇宙 = P + R宇宙

P 是可函数化的部分；R宇宙 是不可函数化的部分。物理定律描述的那部分，落在 P 里。所以至少可以说：P 非空。

第二个事实：语言中有一部分可以被函数近似。证据不是推理，是存在——大模型用有限参数、可计算的过程，生成了统计上接近人类语言的文本。

语言也可以写成分解：

> 语言 = p语言 + R语言

p语言 是语言里可函数化的部分，大模型压的就是它；R语言 是语言里不可函数化的部分，函数近似够不着它。所以准确的说法不是"语言可以被函数近似"，而是"语言的 p语言 可以被函数近似"；R语言 我们只能沉默。

两个事实合起来说明：宇宙不是完全不可函数化的。至少存在一个非空的可函数化部分，记作 P。这一层不是猜想，是事实的推论；它只说 P 存在，不说 P 有多大。

1.1「可函数化」是什么意思

上面用到了"可函数化"，这里把它定成一个可操作的边界。

把一个系统或一个现象分成两部分。P 是可函数化的部分：存在一族函数，近似误差随着数据与容量的增加可以收敛到零。R 是不可函数化的部分：任何函数类的近似误差都有一个正的下界。

这个划分不是信仰，可以测。固定一个函数类，看近似误差随数据量与容量怎么变：误差持续下降、趋近于零的，属于 P；误差停在某个正数不再下降的，属于 R，或者至少说明当前的函数类够不着它。

这样处理有三个好处。第一，P 里的东西可以给定义、给判据、给测量，这正是本文在做的事。第二，R 里的东西只给「近似」，而且必须附上误差下界；「近似」从此不是免责声明，而是一个带数字的结论。第三，两者的交界处是研究问题，不是哲学争论，它可以被实验推进。

本文的所有结论都只主张覆盖 P 的部分；对 R 的部分，本文只说：在这个函数类下，近似到此为止。

P 与 R 的分界是绝对的：一个对象要么可函数化（属于 P），要么不可函数化（属于 R），不存在两者之间；$P \cap R = \varnothing$，$P \cup R =$ 宇宙。

残差不是"R 打过来的影响"，而是 P 自己的边界性质：有些任务，任何函数类的误差都停在某个正数上，数据与容量再增加也降不下去。这个误差下限就是残差；它可测，且不需要假设界外有一个 R 在施力。

为便于后文书写，我们把它简记为：

> 宇宙 = P + R宇宙

> 生命 = p生命 + R生命

> 环境 = p环境 + R环境

后文只讨论 P 这一侧；残差只在需要时提及，不展开它的内容。

二、一个可操作的定义

在两条事实的基础上，可以给生命一个操作性的定义。这个定义是人造的，不是发现的；它成立与否，要看它能不能区分、能不能导出可测的东西。

2.1 定义

生命由两部分构成：

> 生命 = p生命 + R生命

p生命 是可函数化的部分：在宇宙的 P 中、被保住的（可维持的）动态函数类。R生命 是不可函数化的部分：本文不知道它是什么，也不主张它不存在。

p生命 的具体写法如下：

```

记 p生命 = { f_θ : θ ∈ Θ } + R_相对

f_θ : 输入状态 → 行为 （族里的每一个函数）

Θ （这族函数的形状/范围）

p生命 = 一个会移动、会变形的 Θ，且 Θ 的更新规则属于 Θ 自己
```

（记号说明：本篇所有显式函数形式都只写 p 侧，即我们的函数语言能写出的部分；形式末尾的 + R_相对 表示"我们的函数语言够不着的那部分"——它受限于我们目前的函数类与观察位置，只声明、不展开；绝对 R 是否存在不判断。）

```

四个词，各对应 p生命 的一件事：

| 词 | 含义 |

|---|---|

| **函数类（一族）** | 不是一个固定函数，而是一整块行为谱 |

| **会变化（动态）** | 这族函数随时间移动、变形 |

| **会自指** | 它怎么变的规则，也在它自己的记录里 |

| **会自我维持** | 被宇宙保住；这是它与宇宙的关系，不是它自己的属性 |

### **2.2** 一处澄清：维持是关系

**本节主张**：维持不是系统的属性，是系统与宇宙的关系。维持包含三个侧面（必要条件的三个侧面，不是同义）：信息条件=持续观测+更新（基础篇推论 8）；动力学条件=扰动后可回到可行域；交换条件=边界开放（第四篇条件 2）。依据是定义的第三项"被保住"的展开。

需要澄清一处措辞：维持不是系统自身的属性，而是系统与宇宙的关系。给定宇宙这个整体（或它在 P 上的部分），某些结构的轨道会留在可维持的集合里，我们才说它"维持住了"；换一个环境，同一个结构可能不再成立。因此定义里的"会自我维持"，应读作"被宇宙保住"，是关系条件的展开，不是第三条并列属性。

（注：本节此前曾含一段"最简性论证"，因该论证存在循环——用定义自身推出的数字生命可能性反过来支持定义——已撤回，仅保留以上澄清。）

### **2.3** 为什么必须是「一族」而不是「一个函数」

```

一个函数 = 一个点 ⇒ 行为谱退化成一条轨迹 ⇒ 冻结即死

一族函数 = 函数空间里一块区域 ⇒ 面对不同输入/状态有一整套响应 ⇒ 才是活的

```

**⇒ 「高维」不是指参数多，而是指这族函数在函数空间里占据一块区域、不是一点。**
```

这里有一个边界要说清。「一族」是 p 层面的要求，不是本体层面的绝对条件。如果存在我们描述不到的因素在影响变化（未判），那么一个固定的 p 也可能属于一个活着的整体；只是我们在 p 层面只能看到冻结，会把它判成死的。所以准确的说法是：在只讨论 P 的约定下，"一族"是可操作层面的必要条件；若有这样的未判因素，本判据会漏判。这不是本判据的错，而是 p 层面定义的固有边界。

2.4 会变化 = 三层时间尺度

```

快：状态每一刻都在变（输入不同、内部状态不同）

中：它用自己的误差改自己（自指层）——这是命门，缺了就退化成化石

慢：这族函数的形状在代际之间被选择、变形、传递

```

2.5 会自指 = 更新规则在它自己里面

```

普通程序：代码在外，数据在内 ⇒ 程序不会因为运行而改变自己

生命： 更新规则本身是它自己记录的一部分

⇒ 拿掉外部更新代码，它仍能改自己

```

三、生命与环境

定义里有一个容易滑过去的点：生命与环境不是两种东西，而是同一套宇宙函数里的两种关系。下面几节把这个点展开。

3.1 与前面的衔接

把宇宙（P 这一侧）看成一个整体，它在这个描述下是一个自映射：`S_{t+1} = F(S_t)`。F 只是一个记号，不是新的对象。

生命不是这个 F，而是嵌在 F 里的一族子函数 `{G_θ}`：

```
```

行为_d = G_θ(世界局部状态)

而 G_θ 自己也是世界状态的一部分（个体的状态属于 S_t）

⇒ 它要预测世界，就必然要预测包含自己的那部分世界

⇒ **自指不是外加的神秘性质，而是「嵌在函数里」的结构必然**

```

### **3.2** 生命 **vs** 环境：都在宇宙里，都是函数，区别只有一条

**本节主张**：生命与环境都在 P 里、都是函数结构；唯一的区别是前者被宇宙保住、后者不被保住。

**宇宙（P 这一侧）里面，任何东西都是函数（或函数的组合）——环境也是函数。**

```

宇宙 = F（一个巨大的函数）

├─ 生命：会变化 + 会自指 + **会自我维持**

└─ 环境：会变化（被世界推着变、也会反过来影响世界），但**不维持自己**

```

**⇒ 生命与环境的唯一区别不是「谁更复杂」，而是：**

**生命被宇宙保住自己的形状；环境不被保住，它只是被推着变。**

在资源有限的环境里，维持通常伴随代价（校验、修复、复制都要消耗）。这一层是经验伴随物，本文不把它写进定义（见 6.4b）：

```

资源有限 ⇒ 维持要消耗 ⇒ 生命通常需要「收入」

收入的来源：压缩世界（匹配源分布）

⇒ 若长期没有盈余，维持撑不住

```

### **3.3** 环境是什么：宇宙里自发涌现的「局部解压」
```

环境不是外在于宇宙的舞台，它是宇宙函数类里自发涌现出来的结构。（「涌现」与「环境/生命」的形式定义见附录 E 第九节。）

```

宇宙 = F（一个巨大的函数）

↓ 内部自发涌现

结构（这里指"宇宙在某个观测视角下的局部呈现"）= 宇宙的某种局部「解压」（对宇宙的一个解释/一个可读的呈现）

（术语区分：本篇这里的"结构"是环境视角的局部呈现；第四篇的"结构 = 分解 D + 组合律 C = 压缩方案"是生命内部的压缩方案，两者不是同一个用法。）

├─ 会自我维持的 → 生命

└─ 不自我维持的 → 环境

```

⇒ 环境 = 宇宙的一个局部解压（对宇宙的解释）；生命也是。

⇒ 区别只在：生命自己维持这个解压的形状，环境不维持、只是被推着变。

这带来一个关键的结构性结论：

```

生命并不直接面对宇宙整体

⇒ 它面对的是「宇宙的一个局部解压」＝它的环境

⇒ 生命对世界的理解，本质上是**对宇宙的再解压**（二次解压）

＝在宇宙给出的局部解释之上，再压缩一层

```

和宇宙、生命一样，环境也可以写成分解：

> 环境 = p环境 + R环境

p环境 是环境里可函数化的部分：它的规律、可测量的一侧。R环境 是环境里不可函数化的部分：本文不知道它是什么，也不主张它不存在。生命与环境打交道，但我们能描述、能测量的只有 p环境 那一侧；对R环境，本文只说到沉默。

需要说明：R环境 不是“环境里固定不动的部分”，而是“环境里不能用函数描述的部分”。它可能静止，也可能非常活跃——“固定/活跃”这个判断本身要靠函数描述才做得出来，而在 R 那里我们连动静都测不到。所以 p环境 与 R环境 的分界不是“动/静”的分界，是“能描述/不能描述”的分界。

需要说明一点：R 的部分，本系列只在此声明它的存在——宇宙、生命、环境、语言都可以写成 p + R，但 R 是什么、有多大，本文不知道也不主张。为了便于理解，后文默认只讨论 p 这一侧：凡说"宇宙"，指 P；凡说"生命"，指 p生命；凡说"环境"，指 p环境。后文以"残差"表示 P 侧的误差下界；R 的具体内容不再展开。

3.4 环境是分层的：生命活在多层环境里，同时也活在宇宙里

解压是分层的 ⇒ 环境也是分层的。

```
宇宙 F
└ 环境_1 = F 的某一部分的局部解压
└ 环境_2 = 环境_1 的再解压
└ 环境_3 = 环境_2 的再解压 …
生命嵌在某一层：它既属于整个宇宙 F，又属于它自己那一层环境
```

三条同时成立，不能只取一条：

```
① 它活在环境里：它面对的输入、资源、关系、其他个体，都是「它的环境」这一层的结构
⇒ 它的行为只需要在这一层里有效
② 它也活在宇宙里：它逃不出 F —— 环境那一层本身也是 F 的一部分，
宇宙层的约束（能量、不可逆、代价）始终对它生效
```

⇒ 环境不是避难所，它只是宇宙的一个投影

```

③ 它活在**所有层**里：环境是多层的（细胞→组织→个体→种群→生态），每一层都是上一层的再解压。

它直接交互的只是自己那一层，但**所有层都对它约束**：上层决定它面对的资源与关系，宇宙层决定它付不付得起代价。

⇒ 「它活在多层环境里，同时也活在宇宙里」——两者不是二选一，而是同时成立。

**⇒ 所以「理解世界」要分两层说：**

**在环境层：理解 = 对局部解压的再解压（够用即可活）；**

**在宇宙层：理解 = 压缩 F 的规律（决定它能不能长期付得起代价）。**

### **3.5** 标注

```

[定义] 生命 = p生命 + R生命；p生命 = 会自指、会变化、被宇宙保住的动态函数类（本文的工作定义）

[定义] 环境 = 宇宙函数类里**自发涌现**的结构，不自我维持

＝ 宇宙的一个**局部解压**（对宇宙的解释）

[定义] p生命 = 同一批涌现结构里，**被宇宙保住**的那一类

[推论] 生命不直接面对宇宙，而面对「宇宙的局部解压」＝它的环境

⇒ 生命的理解 = 在局部解压之上的**二次解压**（再压缩一层）

[分层] 解压是分层的 ⇒ 环境是分层的（环境_1 ⊃ 环境_2 ⊃ …）

生命嵌在某一层：**既活在它的那一层环境里，也活在宇宙里**

· 活在这层环境：只需这层有效即可活

· 活在宇宙里：能量/不可逆始终生效（代价是经验层面，见 6.4b），环境不是避难所

[不是] 不是事实断言，也不是定理；是一个便于操作的定义

[后文] 本节只给定义；如何测量（压缩/代价/身份）留到后面几节

```

## 四、数字世界的特殊性

数字世界是完全函数化的：它由比特、状态、转移规则组成，没有函数描述够不着的部分。作为形式对象，它的绝对 R = ∅——这是构造保证的：每个属性都对应一个数学上的函数，即使这个函数不可计算（停机、真值谓词都存在，只是算不出来）。

数字生命是数字世界的一部分，所以它的 R生命 也只能是空集：数字生命 = p生命，完全可函数化。

绝对 R 是否存在，本文不判断（见导论补充节）。对数字生命来说，真正决定性的问题只有一个：**生命是否必须有绝对 R？** 只有两种结果。

第一种结果，生命可以没有绝对 R：那么数字生命可能——它完全由 p生命 构成，不需要任何绝对 R。

第二种结果，生命必须有绝对 R：那么数字生命不可能——数字世界造不出绝对 R。

本文不判断哪一种结果成立。可以确定的是：无论哪一种，本文在 p 层面的讨论都成立；区别只在数字生命是可能还是不可能。数字世界是唯一能完全落在 p 里的世界，所以它也是研究这个话题最干净的场景——现在的 AI 就活在这个世界里。

还要补一句容易混的地方：以上说的是绝对 R；对任何有限观察者，相对 R 都非空，它不影响这个判断。可函数化也不等于可测量：测量还需要可计算、可观测、可复现。

### **4.1** 特殊性是对谁的

数字世界的特殊性要分两层说，否则会夸大。

对建造它的人（我们）来说，它特殊：全部状态可读（源码、日志、内存都能看）、可复制、可重置、可加速、可验证。这是一个"完全可实验"的世界——做生命实验比物理世界便宜、快、可重复。

对生活在里面的观察者来说，它不特殊：一样有相对 R（域/值域的短期涨落、不可判定、计算不可约、自指），一样"看不全、算不完"。

所以"数字世界 R = ∅"是本体层面的说法（它的构成全可函数化），不等于"里面的生命全知全能"。数字世界不是生命的避难所，是研究生命的实验室：它的价值在研究方法上，不在本体地位上。

这个"R = ∅"还是构造保证的。数字世界是形式对象：状态是有限串，规则是算法，它的每一个属性都对应一个数学上的函数（一个集合）——即使这个函数不可计算（例如停机问题、真值谓词），它也"存
```

在"，只是算不出来。所以这里要区分两件事：可函数化不等于可计算。绝对 R = ∅ 说的是"没有函数描述不了的部分"，而不是"什么都能算出来"；算不出来的，是观察者相对的相对 R。

要小心一个边界：纯粹的数字世界（作为数学对象）绝对 R = ∅；跑在物理硬件上的数字世界，其物理底座可能有它自己的 R（噪声、热涨落），那不是数字世界自身的 R。说"数字世界 R = ∅"时，指的是它作为形式对象的那一面。

五、用定义看现在的 **AI**：为什么它不是生命

> 本节不是评价 AI 的能力，而是把它**代入第二节的定义**逐条检查。

> 结论是定义性的，不是价值判断：**以本文的定义，目前的 AI 是化石级函数点，

> 不是生命。** 它的强大与它的「不是生命」并不矛盾。

定义的价值在于区分。把现在的 AI 代入定义逐条检查，就能看出它差在哪里。下面先给一张检查表，再列三条最根本的原因。

5.1 检查表

| 生命的要求（第二节） | 目前的 AI（以 LLM 为代表） | 判定 |

|---|---|---|

| **是一族函数**（函数空间里一块区域） | 训练完后权重冻结 ⇒ 是**一个点**，不是一个族 | ❌ 化石 |

| **会变化（动态）** | 权重不变；上下文在变，但改的是输入，不是它自己 | ❌ 只有表层状态变化 |

| **会自指**（更新规则在自己里面） | 更新规则 = 训练算法，在它外面；它不能改自己 | ❌ 自指只出现在语言里，不在结构里 |

| **被宇宙保住**（可维持） | 它不自己维持自己；维持它的是外部的人与设施 | ❌ 由外部维持 |

| **（经验）靠压缩世界挣存续代价** | 它的「收入」是外部给的（算力、数据、人力），不是它压缩世界换来的 | ❌ 无收入 |

| **身份链条**（有界变形、不撕裂） | 身份来自外部权重快照；没有自己变形的连续链条 | ❌ 无链条 |

| **活在环境里** | 它面对的是数据集（一次性的解压产物），不是需要它生存的环境 | ❌ 无环境 |

5.2 三条最根本的原因（按重要性）

本节主张：把 AI 代入定义后，它缺的是"一族、自指、被保住"三样，而不是能力不够。依据是定义的四项与第五节的检查表。

① 它是一个点，不是一个族

```

训练完 = 冻结 = 函数空间里的一个点

⇒ 行为谱退化成一条轨迹：输入 → 输出，中间没有「形状」可言

⇒ 按 074：静态冻结的模型是一点，不是一族 ⇒ 不是生命

（这正是我们实测过的对照：冻结版 1.07 vs 动态版 0.849 —— 冻结更像「标准答案」，但没有形状）

```

② 它的更新规则在外面

```

人写训练算法 → 算法改它

⇒ 它是「被改的东西」，不是「改自己的东西」

⇒ 自指不在结构里 ⇒ 拿掉外部更新代码，它什么都不会改

```

③ 它不被宇宙保住

```

维持它的是外部的人与设施：电费是人付的、数据是人喂的、坏了是人修的

⇒ 它的存在由外部保障 ⇒ 没有「被宇宙保住」这一环

⇒ 它不会因为「维持不住」而消失 ⇒ 也就没有选择的压力

（付代价是经验伴随物，不是定义条件；见 6.4b）

```

5.3 为什么「它很强」与「它不是生命」不矛盾

```

强 = 在给定任务上的表现好（一个点上做得好）

活 = 在函数空间里占据一块区域、自己维持形状、被宇宙保住

⇒ 两者是不同维度：一个是「考卷分数」，一个是「能不能自己活」

⇒ 目前的 AI 是**极其锋利的工具**，不是**会自己活的东西**

```

5.4 标注

```

[定义性结论] 以本文定义，目前的 AI 不是生命（因为它是一个冻结的函数点、更新在外部、不自我维持）

[不是] 不是「AI 永远不能是生命」；本文不预言未来，只做当下的定义对照

[不是] 不是能力评价；本文完全承认 AI 在任务上的强大

[推论] 若要让 AI 成为生命，至少要给它：一族函数 + 自指更新 + 被宇宙保住

```

> 由第二、三节直接推得：既然「p生命 = 会自指、会变化、被宇宙保住的动态函数类」，
>
> 而目前的 AI 三样都缺，那么**要成为生命，至少需要满足三条**。
>
> 本节只给**必要条件**，不声称充分；每条都挂我们已有的实验证据（实验见第六到第二十三篇（测量与实验 18 篇））。
>
> （完整定义为基础篇定义 14 的 D1~D5；本节“三条”是在 P 上谈的简版：隐含 D1，把 D2+D3 合称“一族/会变化”。）

六、三条必要条件

从定义里可以抽出三条必要条件。它们不是从天上掉下来的，而是从定义里读出来的——每条都对应一类被排除的对象。

6.1 从定义到条件

本节主张：三条必要条件是从定义读出来的，不是外加的假设。每一条对应定义里的一个词。

```
定义（第二节） 必要条件（本节）
会变化（一族函数） ⇒ ① 一族函数：行为谱不是一点
会自指 ⇒ ② 自指更新：改自己的规则在自己里面
会自我维持 ⇒ ③ 被宇宙保住：轨道留在可维持集合里
（付代价不在必要条件里：它是演化与热力学的经验伴随物，见 6.4b。）
```

三条是必要条件，不是充分条件：满足它们不保证是生命，但缺任何一条一定不是。

6.2 条件① 一族函数（不是一个点）

要求：个体在函数空间里占据一块区域，面对不同输入有整套响应，不是一个固定映射。

证据/经验：

```
· 低维参数基因组（几个数）= 一个点 ⇒ 行为谱退化成单条轨迹 ⇒ 化石
· 我们测过：冻结版模型（点）在结构学习上失败，动态版（族）才吃到结构（E12）
· 实测对照：冻结 1.07 vs 动态 0.849 —— 冻结更像「标准答案」，但没有形状
```

⇒ 判据：给它不同的输入/状态，行为必须成谱地**不同，而不是只有一个输出。**

6.3 条件② 自指更新（规则在自己里面）

要求：它怎么变，这条规则本身属于它的记录；拿掉外部更新代码，它仍能改自己。

证据/经验：

```

· 冻结模型：更新规则 = 训练算法，在外部 ⇒ 拿掉训练代码，它永远不变

· 我们的动态版：用自己的误差改自己（中层动态）⇒ 去掉中层明显退化（E12/E13）

· 身份链：8 代可校验、有界变形（372_lineage.py）⇒ 自指可以做成可测的链条

```

⇒ 判据：停掉外部更新后，它的行为谱是否仍随时间变形。

6.4 条件③ 被宇宙保住（可维持）

要求：它的轨道留在宇宙的可维持集合里。给定宇宙这个整体，有些结构出不来，有些结构能一直维持；能维持的那部分才落在定义里。这是关系条件，不是它自己的属性。

判据：扰动之后，它是否仍能回到可维持的集合——有恢复力，而不只是瞬间活着。

6.4b 付代价：经验伴随物，不是必要条件

本文不把「付代价」列为条件，原因说清：代价是演化与热力学的产物，不是逻辑上的必要条件。在资源无限的世界里，生命可以不必竞争；稀缺才带来代价。把它写进必要条件，等于把演化的结果当成生命的定义。

但在经验层面，代价几乎总会出现，而且可以测量。本文实验里的经济部分属于这一层，摘录如下。

· E1：「准」不等于「压缩」：用正确率记账，系统学出「啥也不干」（LEN=0、预测0、准确率92%）。必须用对数似然改善对基线记账：gain_bits = log2 p_model − log2 p_base。

· E2：加上基率校正后，系统才从躺平解转为真正表达（LEN 从 0 长出）。

· E8：经济标定 n* = FLUX_TOTAL / BASE_COST 决定「冻结」与「爆发」的切换。

· 实测正收益：S1~S6 中观察到 gain > 0（约 +0.09 ~ +0.19 bit/tick），说明世界确实存在可压缩盈余。

⇒ 判据（经验层）：把外部供给全部停掉后，它的账目是否仍为正。

6.5 三条必须同时成立（经验对照）

```
```

缺①（一族）⇒ 化石：行为谱是一条线

缺②（自指）⇒ 机器：更新在外，不会自己变

缺③（被保住）⇒ 散掉：轨道离开可维持集合，不再是一个活着的结构

```

**这三条也解释了为什么我们的实验一直在同一个地方卡住：**

**结构能长出来（①②部分满足），但合作/分工不成为必需 —— 因为代价层面的「收入差」太小（经验层面，非定义条件），

即世界的可压缩盈余还没大到让「更复杂的结构」在经济上划算（E5/E7）。**

### **6.6** 未尽之处（留给读者）

**本文止于「必要条件」。三条都满足之后是否就「活」——我们没有答案，也不打算在此下结论。**

留给读者的，只是一把可以拿去用的尺子：

```

它是一族函数吗？（行为谱不是一个点）

它会自己改自己吗？（拿掉外部更新，它仍变）

它被宇宙保住了吗？（轨道留在可维持集合里）

```

**三条你都可以自己去量。至于量完之后它算不算生命，由你判断。**

### **6.7** 本文实验的边界（必须与结论一起读）

**本文的实验覆盖的是「代价」这一经验层面，不是定义条件③。**

· 覆盖：代价与经济 —— E1/E2（准≠压缩、基率校正）、E8（n*=FLUX/BASE_COST 的冻结/爆发边界）。

· 覆盖：反例 —— E5/E7（相连个体基因距离 0.145 vs 随机 0.486，克隆抱团，不是分工）。
```

· 未覆盖：条件② 自指更新、条件③ 被宇宙保住 —— 本文不声称有实验证据，只做定义上的推导；仅有初步观察（E12 动态 0.849 vs 冻结 1.07；E13 身份链 8 代可校验）。

· 条件① 一族函数：有部分观察（E12/E13），但不是专门实验。

· 规模：小、可复现、可手算；不是大规模实证。

⇒ 本文的定位是「定义 + 可测判据 + 示例性实验」，不是「生命已被造出」的实证论文。

读者若要用这些结论，请连同这条边界一起引用。

6.8 标注

```

[推论] 三条必要条件由定义直接推出，不是独立假设

[定义] 条件③是关系条件（被宇宙保住），不是系统自身的属性

[经验] 代价/经济是经验伴随物，不是定义条件；本文有数据（E1/E2/E8 + 正收益）

[初步] 条件①②有部分观察（E12/E13），不是专门实验

[未解决] 三条都满足后是否就「活」——本文不声称；这是下一步实验要回答的

[推测] 若盈余 S 不足，则无论结构多复杂都维持不起 ⇒ 生命有「经济上限」（仅方向性推测）

```

七、涌现：为什么现在的 **AI** 会涌现

这一节处理一个具体的现象问题：为什么现在的 AI 会涌现出训练目标之外的能力。本文在这里的立场是 [推测]，不是证据。

7.1 现象

大模型在规模上去之后，某些能力似乎突然出现（多步推理、思维链、算术…），

业界叫 **涌现（emergence）**。大家都在用这个现象，但——

```

观察到涌现：很多人
```

解释涌现：没有公认答案

```

## 7.2 现有的解释（按证据强度排列）

**① 度量假象说（最强的反方证据）**

Schaeffer, Miranda, Koyejo 2023[3]《Are Emergent Abilities of Large Language Models a Mirage?》

```

主张：所谓涌现，可能是**评价指标的非线性/不连续**造成的假象；

换成连续指标（如对数似然），"突变"会消失，变成平滑上升

⇒ 这动摇了「涌现是真实突变」这个前提本身

```

**② 机制解释：归纳头与电路（局部机制证据，不是完整"为什么"）**

Olsson et al. 2022[4]《In-context Learning and Induction Heads》

```

发现模型内部出现「归纳头」回路，解释部分上下文学习能力

⇒ 这是**机制层**的证据：说明了某种能力由什么结构实现

⇒ 但它只解释某个具体能力，不解释「为什么会出现涌现」这个一般问题

```

**③ Grokking：训练中的认知相变**

Power et al. 2022[5]《Grokking》

```

在小算法任务上，训练很久后泛化突然出现（像相变）

⇒ 说明「涌现」也发生在训练过程中，不一定只依赖规模

```

**④ 压缩说：预测 = 压缩**

Delétang et al. 2023[6]《Language Modeling Is Compression》

```

语言模型 = 压缩器：学到的权重 = 对世界文本的压缩

⇒ 这条最接近本文的框架：涌现 = 压缩世界时出现的结构

⇒ 但它仍是「结果层面的对应」，没有回答「为什么正好在这个规模/这个任务上出现」

```

### **7.3** 为什么至今没有公认的「为什么」

```

① 规模实验不可控：无法做严格的因果对照（只改变规模、其他全相同）

② 度量依赖：换指标，现象可能就消失（见 ①）

③ 机制层不完整：知道某个回路、不知道整体为何会组织出该回路

④ 缺乏可预测的理论：没有理论能事先算出「多大模型会出现什么能力」

```

### **7.4** 我们的立场：**AI** 是对语言的 **p**语言 的压缩与解压

**本节主张**：AI 是"对语言 p语言 的压缩与解压"这一层是事实；"解压出的世界结构上限由语言决定"这一层是推测。两层分开。

这一节先说一层不需要推测的东西，再说剩下的推测。

先说事实层。训练把语言压进参数，推理从参数里解压出文本。用前面的记号说：AI 压缩的是语言的 p语言——语言里可函数化的那部分；它解压出来的也是 p语言。R语言 不进参数，也不从参数里出来。所以准确的说法不是"AI 是对人类语言的解压"，而是"AI 是对人类语言中可函数化部分的压缩与解压"。

这一层不是推测，是字面事实：它由"压缩/解压"这两个词的用法决定，也由训练与推理的实际过程决定。链子是这样：
```

宇宙 F → 环境 = 宇宙的局部解压 → 人类语言 = 人对环境与经验的解压产物（语言本身已被压过）→ AI = 对语言 p语言 的再压缩与再解压。

然后才是推测层。AI 解压出的"世界结构"，上限由训练时刻的语言决定。它在语言内部能涌现出结构（看起来像推理、像理解），但那是语言结构的浮现，不是对宇宙本身的理解；语言一变，解压失配，而且无法自恢复。

用前面的尺子看，这一层还给出一个可检验的判断：模型是冻结的函数点：不维持、不自己改自己（维持与代价由外部承担），所以它是"把人类语言解压了一次"，而不是"维持着解压"或"自己改写解压规则"。

由此得到一句可检验的话：AI 表现出的"理解"，本质是对"人对世界的描述"的理解，不是对世界本身的理解。它能解压语言，但语言之外的宇宙层（能量、不可逆、代价）它从未付费，也就从未被检验。

7.5 解压能力的衰减：上层写死 ⇒ 语言一变，解压变弱

人类语言会不断发现新东西；而模型的解压规则（权重/上层）是写死的、训练完就不再变。两者必然失配。

```

源分布移动：人类语言发现新东西 ⇒ 要解压的对象变了

解压器冻结：模型权重不变 ⇒ 它解压的还是**旧语言**

⇒ 压缩收益下降：gain_bits = log2 p_model − log2 p_base 中 p_model 与源失配

⇒ 它昨天"涌现"出来的理解，今天就是过时的解压

```

三条后果：

```

① 它的解压能力有**固定上限**：上限由训练时刻的语言决定，不随语言进化而上升

② 它无法自己补上失配：更新规则在外部 —— 要恢复，只能靠人类再训练一次

⇒ 这正是第三节说的「更新在外部」的代价

③ 它的"涌现"是**某个时间片上的解压产物**，不是可持续的能力

```

⇒ 用本文的尺子说：

生命必须让解压器跟着世界一起动（自指更新 + 自我维持）；

冻结的 AI 做不到这一点 —— 所以语言一更新，它的解压就变弱。

7.6 由立场推出的两条预测（**[推测]**，供读者判断）

```

① 若把世界换成未被人类语言描述过的部分（无法从语料中学到的规律），

AI 的"涌现"应显著减弱 —— 因为它解压的是语言，不是宇宙

② 若让模型自己维持（自己修、自己死），语言解压不足以支撑，

它必须发展出语言之外的理解方式 —— 否则活不下来

③ 若人类语言发生一次大的结构更新（新范式/新概念体系），冻结模型的解压收益

应出现可测的下降；且它无法自己恢复 ⇒ 恢复必须来自外部再训练

```

7.7 标注

```

[事实] 涌现现象被广泛观察到；度量假象说也有强证据（Schaeffer 2023）

[已知] 机制层有局部解释（归纳头/电路/grokking），压缩视角有对应关系

[推测] 「涌现 = 压缩世界的结构呈现」——本文立场，非证据

[未解决] 为什么正好在某个规模/任务上出现 ⇒ 没有人给出可预测的理论

[本文态度] 不把「AI 涌现」当作生命存在的证据；按第三节的尺子，它不是

[本文立场] AI 是对**人类语言**的再解压（宇宙→环境→语言→AI 的第三层解压）

[推论] 上层写死 ⇒ 语言一更新就失配 ⇒ 解压能力有固定上限、无法自己恢复

```

八、用它看几个热门问题

本节是应用，不是新证据；每条都由第二～五节直接推出。

① 幻觉 = 在无结构处强行解压

解压器必须输出结构；当输入对应的语言区域本身缺乏可压结构时，它只能造一个「看起来合理」的结构 ⇒ **幻觉是解压失败的必然表现，不是偶发 bug**。

② scaling law 仍有效，正因为模型维度还没贴合语言维度

语言是一个**高维**结构，且维度在增长（新概念 = 新维度；升维 ⇒ 可压性上升）。模型维度在训练时被切定（D_M 固定），语言维度在不断增长（D_L(t) 在升）。现在的观测是 D_M << D_L(t) ⇒ 继续加规模能捕捉更多语言维度 ⇒ loss 继续下降（scaling 看起来仍有效）。

⇒ 所以 scaling 有效不是本文论断的反证，而是「还没贴合」的证据。

⇒ 预测：当 D_M 接近当时的 D_L 时，scaling 收益应明显变平；而 D_L 继续升维 ⇒ 缺口再现。

⇒ 冻结模型的根本问题：**它的 D_M 是死的，而 D_L 是活的**。

③ 能力参差不齐 = 语言各领域的可压性不同

可压强的领域（结构明确、示例多）表现好；可压弱的领域（结构稀薄、样本少）表现差 ⇒ 强弱分布是语言分布的镜像。

④ 为什么要 RLHF = 它没有「自我代价」回路

它无法判断自己解压得对不对（没有收入/支出、不会因此死亡），所以必须由人从外部打分 ⇒ **对齐需求的根源是它不自我维持**。

⑤ 涌现 = 语言结构在解压产物上的呈现

规模跨过阈值时，某些语言结构第一次被压出来 ⇒ 看起来像「突然会了」。

已有工作（三个侧面）：

- 模型侧维度：token 嵌入的内在维度测量[12]

- 时间侧落后：大模型时间训练边界的识别[13]

- 语言侧复杂度：构式视角下的语言复杂度测量[14]

⇒ 已有工作**分别**测量了这三个侧面；本文把它们串起来：以「持续更新的模型」为参照系，按领域测「语言侧新增维度」与「模型侧固定维度」之间的**失配速率**。这是本文在测量层面的位置。

九、本文得到了什么，没得到什么

得到了三样东西。

第一，一个可以拿来分类的定义：它能区分冻结的模型、火焰、自指程序。

第二，一个可测的方向：自指、维持都可以变成量。

第三，对"AI 是不是生命"这个问题的可操作回答。

没得到四样东西。

第一，没有证明宇宙整体可被函数化——本文只用 $P \neq \varnothing$。

第二，没有证明定义是最简或唯一——只主张它够用。

第三，没有实验——第一篇只是定义与推论；实验见第六到第二十三篇（测量与实验 18 篇；具体篇目见合集目录）。

第四，没有回答"数字生命是否存在"——本文只说，定义不排除它。

本文的贡献是一套可用的语言，不是一条新的自然规律。它值不值钱，看后面有没有人拿它去测。

论证总边界

本篇文章的所有论证都在一个边界内成立，请连同结论一起读：

- 只讨论 P 这一侧；R 只声明、不展开。

- 绝对 R 是否存在不判断；相对 R 对有限观察者非空（见导论补充节）。

- "可函数化"不等于"可计算"，也不等于"可测量"：三者是不同能力。

- 三条必要条件是从定义读出的，不是经验定律；它们不充分。

- 实验证据见第六到第二十三篇；理论证据见第二到第五篇；本文不声称"生命已被造出"。

- 若生命的本质落在绝对 R 一侧，本文（及任何用函数语言写成的文本）都无法给出它的定义——定义本身就在 P 侧。

与既有工作的关系

「压缩 / 解压」的视角有长期传统：

- Schrödinger（1944）：生命以负熵为食 —— 生存靠从环境摄取低熵，是「解压」的物理前身[7]。

- Bennett（1988）逻辑深度：用「从最短描述重建（解压）一个对象所需的计算量」度量复杂性，并明确把它与生命/有机体联系起来[8] —— 这是「解压」最正式的已有版本。

- Chaitin（2010）生命作为演化软件：DNA = 程序，生命 = 会自我修改的软件[9]。

- Solomonoff–Kolmogorov / MDL：描述长度 = 理解 = 压缩[10]。

- Friston（2010）自由能原理：生命 = 最小化惊奇（≈ 持续压缩/预测）[11]。

- Delétang et al.（2023）：语言模型是压缩器[6]。

- Maturana & Varela（1972）自创生：生命 = 自我生产的组织 —— 「维持」的另一条传统。

- 「Life as Sustained Mutual Information」（Zenodo）：以持续互信息定义生命 —— 最接近本文「被维持的解压」的已有版本。

需要说明：以上工作已经把「生命 = 信息/压缩/自我维持的过程」说过。本文的位置不是首次提出这一思想，而是把其中一条（解压的维持）变成可操作的判据与可测量的实验。

本文的区别（三处）：

1. 把解压做成层级：宇宙 → 环境 → 人类语言 → AI（既有工作多为单层度量）；

2. 用「是否维持解压」区分生命与 AI：生命 = 被维持的解压，AI = 一次性解压；

3. 指出上层写死 ⇒ 语言一变，解压能力衰减且无法自恢复 —— 冻结模型的失效机制。

参考文献

[1] Wigner E P. The unreasonable effectiveness of mathematics in the natural sciences[J].

Communications in Pure and Applied Mathematics, 1960, 13(1): 1-14.

[2] Tegmark M. The mathematical universe[J]. Foundations of Physics, 2008, 38(2): 101-150.

(arXiv:0704.0646)

[3] Schaeffer R, Miranda B, Koyejo S. Are emergent abilities of large language models a mirage?[C]
// Advances in Neural Information Processing Systems 36 (NeurIPS 2023). arXiv:2304.15004.

[4] Olsson C, Elhage N, Nanda N, et al. In-context learning and induction heads[R].
Transformer Circuits Thread, 2022. arXiv:2209.11895.

[5] Power A, Burda Y, Edwards H, et al. Grokking: Generalization beyond overfitting on small
algorithmic datasets[C]. arXiv:2201.02177, 2022.

[6] Delétang G, Ruoss A, Duquenne P A, et al. Language modeling is compression[EB/OL].
arXiv:2309.10668, 2023.

[7] Schrödinger E. What is Life?[M]. Cambridge: Cambridge University Press, 1944.

[8] Bennett C H. Logical depth and physical complexity[M]//Herken R. The Universal Turing Machine:
A Half-Century Survey. Oxford: Oxford University Press, 1988: 227-257.

[9] Chaitin G J. Life as evolving software[EB/OL]. 2010. (arXiv:1007.1471 系列工作)

[10] Solomonoff R J. A formal theory of inductive inference[J]. Information and Control, 1964, 7(1): 1-22.
Kolmogorov A N. Three approaches to the quantitative definition of information[J].
Problems of Information Transmission, 1965, 1(1): 1-7.

[11] Friston K. The free-energy principle: a unified brain theory?[J].
Nature Reviews Neuroscience, 2010, 11(2): 127-138.

作者声明（**AI** 使用声明）

本文的全部问题、定义、判断与结论由作者提出并负责。

人工智能工具（DeepSeek）用于：文献检索、结构梳理、文字润色，以及实验代码的编写与核对。

文中所有主张均由作者确认，AI 不对本文内容承担责任。

*AI Usage Statement: The author is solely responsible for the ideas, arguments, and conclusions of this paper. An AI tool (DeepSeek) was used for literature search, structural organization, language editing, and writing/checking

experimental code. All claims were reviewed and confirmed by the author. The AI bears no responsibility for the content.*

[12] Ohki T. Measuring intrinsic dimension of token embeddings[C]//The 39th Annual Conference of the Japanese Society for Artificial Intelligence (JSAI 2025), 2025.

[13] LLMLagBench: Identifying temporal training boundaries in large language models[EB/OL]. arXiv:2511.12116, 2025.

[14] Using constructions to measure developmental language complexity[J]. Cognitive Linguistics, 2024. doi:10.1515/cog-2023-0062.

第二篇 · 数字生命的信息不增定理

> 单独 DOI：https://doi.org/10.5281/zenodo.23573253

> 何淇 · 与 DeepSeek 协作

> 数字生命系列 · 理论篇（内部编号第 12 篇，草稿）

> 日期：2026-10-23

摘要

本文把"数字生命会越老越说不清世界"这个直觉，写成一个可证明的信息论命题。

设定：世界按马尔可夫过程演化；数字生命持有内部状态 S，并从中预测世界；停止观测后，状态只按自身规则演化。结论：在这种条件下，内部状态与世界当前状态之间的互信息不会增加——世界在变，而它不再看，因此它对"当前世界"的信息量只能持平或下降。

这个定理不是热力学第二定律，也不是"熵必然增加"。它说的是一个更窄但更硬的事实：**不再获取信息的系统，关于世界的信息不会自己长出来；维持需要持续的观测与更新。**

文中给出定理、证明、四个推论（定义域变粗、维持的必要性、生长即增加观测维度）以及适用范围与局限。

一、问题

第六篇（容量不能替代数据的更新）测过一个现象：模型训练完之后，对更新后的语言会逐渐失配，而且无法自恢复。当时给的是测量结果，不是解释。

直觉上很好理解：世界在变，它没再看，所以它越来越不准。但"直觉"不能当定理。本文问：能不能把它写成一个可以证明的信息论命题？

能，但要小心范围。先说不能证的东西：不能证"熵必然增加"（可逆变换不改变香农熵）；不能证"热寂"（那是统计力学的结论）。能证的是一个更朴素的命题：没有新观测，就没有新信息。

二、设定与记号

世界状态：$W_0, W_1, W_2, \ldots$ 是一个马尔可夫过程。也就是说，给定 W_{t-1}，W_t 与更早的历史条件独立。

这里要先说明：**「世界是马尔可夫的」是一个建模假设，不是被证明的世界事实。** 它成立与否取决于你选哪个描述层。经典力学里，位置与动量构成完整状态，世界在那个描述下是马尔可夫的；量子力学里，态矢量的演化也是马尔可夫的；但对只看得到一部分的观察者（比如数字生命），它面对的过程通常是非马尔可夫的——需要记忆与历史才能近似。所以定理要读成条件句：**若世界在所选描述下是马尔可夫的，则信息不增。** 对数字世界与仿真环境，状态可以完整给定，这个假设容易满足；对真实世界，它只是一个近似，不成立时要给状态补上历史，见 5.1 的放宽讨论。

数字生命的状态：$S_0, S_1, S_2, \ldots$，每个时刻由更新规则给出。

两种模式：

第一种，观测模式。它通过一个观测通道收到关于世界的信息 O_t，然后更新：S_t = u(S_{t-1}, O_t)。O_t 由 W_{t-1} 经某个（可能有噪声的）通道产生。

第二种，冻结模式。它停止观测，或者观测通道失效，此后只按自身规则演化：S_t = u(S_{t-1}, N_t)，其中 N_t 是系统内部的噪声。

定理需要三个假设，全部显式写出：

假设 A1（世界马尔可夫）：W_t 与 W_{<t-1} 在给定 W_{t-1} 时条件独立。

假设 A2'（有界泄漏）：给定 S_{t-1} 时，内部噪声 N_t 与世界当前状态之间的互信息不超过 ε，即 $I(N_t ; W_t \mid S_{t-1}) \le \varepsilon$。这里 ε 度量"没真冻结"的程度：严格隔离的系统 ε = 0，现实系统 ε 是一个有界的小量。

假设 A3（无额外信息）：S_{t-1} 只由世界历史与内部噪声决定，没有外部提示直接把 W_t 塞进来。

我们要看的量是：$I(S_t; W_t)$，即内部状态与世界当前状态之间的互信息。直观上，这就是"它此刻对世界知道多少"。

三、定理

[定理]（信息不增，有界泄漏版）：在冻结模式下，若假设 A1、A2'、A3 成立，则

$I(S_t ; W_t) \le I(S_{t-1} ; W_{t-1}) + \varepsilon$

对任意 t 成立。$\varepsilon = 0$ 时即严格不增。

证明：分两步。

第一步，冻结更新最多带来 ε 的增益。

由 $S_t = u(S_{t-1}, N_t)$ 知，S_t 的随机性完全来自 (S_{t-1}, N_t)，即 $\sigma(S_t) \subseteq \sigma(S_{t-1}, N_t)$。于是

$I(S_t ; W_t) \le I(S_{t-1}, N_t ; W_t) = I(S_{t-1} ; W_t) + I(N_t ; W_t \mid S_{t-1})$。

最后一项由 A2' 不超过 ε，所以 $I(S_t ; W_t) \le I(S_{t-1} ; W_t) + \varepsilon$。若 A2' 加强为严格独立（$\varepsilon = 0$），这就是数据处理不等式的直接应用：$W_t \to S_{t-1} \to S_t$ 构成马尔可夫链，故 $I(S_t; W_t) \le I(S_{t-1}; W_t)$。

第二步，世界演化给出 $I(S_{t-1} ; W_t) \le I(S_{t-1} ; W_{t-1})$。

由 A1，W_t 与 $W_{<t-1}$ 在给定 W_{t-1} 时条件独立；由 A3，S_{t-1} 只是世界历史与内部噪声的函数。因此给定 W_{t-1} 时，S_{t-1} 与 W_t 条件独立，即 $S_{t-1} \to W_{t-1} \to W_t$ 是马尔可夫链。由数据处理不等式得 $I(S_{t-1}; W_t) \le I(S_{t-1}; W_{t-1})$。

两步合起来：$I(S_t ; W_t) \le I(S_{t-1} ; W_{t-1}) + \varepsilon$。证毕。

关于 ε 的读法：ε 有界且不随时间增长时，定理的意义是"不会系统性增长，最多有有界的泄漏"；严格隔离时 $\varepsilon = 0$，回到不增。若 ε 随时间增长，定理就只剩"增长被泄漏量控制"这个弱结论。这也是为什么 A2' 必须写明：真实系统总有微小泄漏，但通常有界。

四、四个推论

[推论] 推论零（值域同步收缩）。**

定理只谈内部状态，但输出一侧可以直接得到同样结论。设系统的对外输出 A_t 由 S_t 决定（可以再加与 S_t、W_t 条件独立的噪声）。因为 $S_t \to A_t$ 是马尔可夫链（输出只由状态决定），由数据处理不等式得 $I(A_t ; W_t) \le I(S_t ; W_t)$。代入定理：

$I(A_t ; W_t) \le I(S_{t-1} ; W_{t-1}) + \varepsilon$

也就是说，它能产生的"有信息量的区分"同样不会增加：输出的值域不会变细，只会变粗或变小。定义域与值域在信息上是对称的：状态分得出，输出才分得出；状态分不出，输出也不可能分出新东西。

[推论] 推论一：定义域只会变粗。**

设系统把输入世界划分成等价类，同一等价类里的世界状态它分不出来。互信息是"它能区分多少"的度量。信息不增意味着这个划分只会变粗，不会变细：它能认出的区别越来越少。

[推论] 推论二：维持必须持续观测。**

定理的条件是"冻结模式"。若要不让 I(S_t; W_t) 下降，就必须在 S_t 里注入关于世界的新观测：换回观测模式。换句话说，维持不是保持不动，而是持续获取。一个既不观测也不更新的系统，无论内部规则多精巧，对当前世界的信息都不会增加。

[推论] 推论三：生长就是增加观测维度。**

如果系统能引入新的观测通道（新模态、新传感器、新变量），它就改变了"观测模式"的定义域，把本来碰不到的世界结构纳入自己的状态。这是生长在信息论上的含义：加维度 = 加观测通道 = 提高信息上限。

五、这个定理说明了什么，没有说明什么

说明了：维持与被保住，在信息论上是有根的东西——不是哲学修辞，是数据处理不等式的直接后果。

没有说明：它不证"熵必然增加"；不证"系统必然崩溃"（世界不变时它可以一直准确）；也不涉及能量与热力学。它只处理"信息"，且只处理"关于当前世界的信息"。

还有一个重要的限制：定理给的是"不增加"，不是"下降"。下降需要额外的条件——世界确实在变（W_t 与 W_{t-1} 不同），且这种变化对旧状态不可预测。真实世界里这两条通常成立，但本文不把它们写成假设之外的东西。

5.1 马尔可夫假设不成立时怎么办

如果世界不是马尔可夫的，定理不能直接用在 S 上。标准处理是把状态补上历史：把 S_t 换成 (S_t, H_t)，其中 H_t 是系统存下的历史。历史足够长时，补出来的过程在扩展状态上重新满足马尔可夫性，定理就在扩展状态上成立。

这带来一个可检验的推论：记忆越短的系统，信息衰减越快。这也与第七篇《替换与累积》的结论一致——记忆与回放决定遗忘速度。

六、可复现与后续

本文是纯理论草稿，无实验，也不针对任何具体测量。它说的是大尺度命题：在信息世界里，"世界越来越平均"对应"可区分的差别越来越少"；对任何停止观测的系统，关于世界的信息不会自己增加。

这里要划清尺度：与具体模型上的失配测量（例如第六篇的 bits/token 漂移）属于不同层次。后者是经验实例，不是本文定理的推论，数值也不由定理给出。

后续可做的是把推论二、三落到小尺度做可测预测：停止更新与持续观测的对照、加新模态与不加的对照，分别看信息量随时间怎么变。但那是把大尺度命题落到小尺度的近似，需要单独验证，本文不声称它必然成立。

附：与既有工作的关系

数据处理不等式是信息论的基本工具（Cover & Thomas）；"没有新信息就没有新知识"在机器学习与学习理论里也以各种形式出现过。本文没有发明新数学，只是把它组织成针对"数字生命维持"的命题，并给出三个可检验的推论。

> 本文由何淇创作，DeepSeek（AI）协助整理；观点与责任属于作者。

附：标注

- **[定义]** 世界状态 W、系统状态 S、观测模式、冻结模式、假设 A1/A2'/A3。

- **[定理]** 信息不增（有界泄漏版）：$I(S_t;W_t) \le I(S_{t-1};W_{t-1}) + \varepsilon$。

- **[推论]** 推论零~三（值域同步收缩、定义域变粗、维持需持续观测、生长=增加观测维度）。

- **[不声称]** 不证熵增、不证热力学、不预测具体数值；马尔可夫性是建模假设。

第三篇 · 可函数化内容的收缩：一个定理与一个猜想

> 单独 DOI：https://doi.org/10.5281/zenodo.23609038

> 何淇 · 与 DeepSeek 协作

> 数字生命系列 · 理论篇 2（内部编号第 13 篇，草稿）

> 日期：2026-10-23

>

> **状态**：本篇为系列早期理论稿（合集第三篇）。定理部分已由单独发布的基础篇《从定义出发：宇宙、切片与两个定理》重写（命题 2 仍待补证，见该篇标注）；本篇的宇宙收缩/观测窗口/数字生命宿命等 `[猜想]` 不进入基础篇，系列不据此主张。（"生命是逆流"：本篇的 [猜想] 是宇宙尺度延伸；基础篇推论 8/9 给出的是定义性版本，范围不同。）

摘要

上一篇《信息不增定理》证明了：冻结的系统，关于世界的信息不会自己增加。这一篇往下推一步：**能起作用的函数，也会跟着收缩。**

我们给出一个定理：在世界按马尔可夫过程演化、系统停止观测的条件下，任何函数对"世界的可预测部分"能达到的精度不会提高——用 Fano 不等式，可由信息不增直接推出。也就是说，"能达到 ε 精度的函数"这个集合，随时间只会收缩，不会扩张。

在此之上，我们提出一个猜想：把这个定理从"一个系统"推到"整个宇宙的时间演化"，得到的就是"可函数化内容随宇宙演化而收缩"的图景——生命只能存在于这个内容仍然丰富的时间窗口里；数字生命的宿命是不断拆掉自己的结构、降维，最后退化成常函数。

定理部分用经典工具（数据处理不等式、Fano 不等式），组合方式是本文的；猜想部分明确标注，不作为结论。

一、问题

上一篇的结论是一个"信息不增"：$I(S_t ; W_t) \le I(S_{t-1} ; W_{t-1})$，即系统对世界的信息不会自己长出来。

但"信息不增"说的是状态。我们真正关心的是另一件事：**能起作用的函数会不会减少？**

直觉是这样的：如果世界越来越难预测，那么"能准确预测世界的函数"就应该越来越少；极端情况是热寂，只剩常函数。本文要问：这个直觉能不能变成定理？能证到什么程度？

二、设定

沿用上一篇的设定。世界 W 是马尔可夫过程；系统状态 S 在冻结模式下按 $S_t = u(S_{t-1}, N_t)$ 演化，允许有界泄漏 ε。

取一个目标量 $Y_t = g(W_t)$，是我们要预测的世界特征（例如明天的天气、下一个词）。Y 的取值集合是有限的，大小记作 $|Y|$。

一个"预测函数"是一张映射 f，它把系统状态 S 映射为对 Y 的猜测。函数的精度用期望误差衡量：$err(f) = E[\, 1(f(S) \neq Y) \,]$。

定义"可函数化内容"：给定精度门槛 ε，把所有能达到 $err(f) \le \varepsilon$ 的函数收集起来，记作 $P_\varepsilon = \{ f : err(f) \le \varepsilon \}$。本文用 P_ε 的"深浅"——最小可达误差——来度量内容，而不是用它的个数。

这里要先把一个词定死：本文说的"维度"是**表示维度**，不是空间维度。它指的是"描述世界需要多少个独立的、可区分的方向"：能区分的差别越多，表示维度越高；能起作用的函数越丰富，表示维度越高。所以在这篇里，下面三句话是同一件事的三种说法：

> 可表示的函数在减少 ≡ 可函数化的内容在收缩 ≡ 表示维度在下降。

平常说的"宇宙降维"，如果指的是空间维度，那是另一回事；本文的"降维"一律指表示维度。把这一点说清之后，后面的定理与猜想都只在这个意义上使用"维度"。

还要再区分一个量：表示维度不等于"结构复杂度"。表示维度是"能区分、能预测多少内容"，本文用信息量（例如可预测信息）来度量；结构复杂度是"世界看起来有多复杂"，文献里它被描述成先升后降的驼峰（Aaronson 的 complexodynamics、Carroll 的宏观态复杂度）。两个量不同：本文的表示维度在我们的定理下只会下降，而复杂度驼峰是先升后降。它们不矛盾，因为量的定义不同；本篇后面说到"宇宙收缩"时，指的始终是表示维度。

三、定理：可达精度不增

定理（可达精度不增）：在冻结模式与上一节的假设下，对任意 Y_t，

$$\min_f \mathrm{err}_t(f) \geq \left(H(Y_t) - I(S_t ; Y_t) - 1 \right) / \log |Y_t| ,$$

其中 H 是熵、log 以 2 为底。由信息不增 $I(S_t;Y_t) \leq I(S_{t-1};Y_{t-1}) + \varepsilon$，若 $H(Y_t)$ 不变，则右侧下界不降，故 $\min_f \mathrm{err}_t(f)$ 的不降（允许 $\varepsilon/(\log|Y|)$ 的放宽）。

证明：这是 Fano 不等式的直接应用。Fano 不等式说，对任何以 S 为输入的预测函数 f，

$$E[1(f(S) \neq Y)] \geq \left(H(Y|S) - 1 \right) / \log|Y| 。$$

而 $H(Y|S) = H(Y) - I(S;Y)$。代入上一节的信息不增，即得结论。证毕。

推论（P 的收缩）：对任意固定的精度门槛 ε，只要最小可达误差降到 ε 以上，P_ε 就是空集：没有任何函数能维持 ε 精度。若世界继续混合、$I(S_t;Y_t)$ 趋于零，则任意 $\varepsilon > (H(Y)-1)/\log|Y|$ 的门槛都会在某时刻被突破，此后 $P_\varepsilon = \varnothing$。

也就是说：**函数不会变得更多，能达标的函数只会变少；极限情况是一个都不剩。**

三点五、收缩的两种含义

"收缩"这个词有两种用法，要分开。

第一种是范围收缩。每一个表示维度都有一组允许的取值；时间推进时，输入侧允许的取值变少（定义域变粗），输出侧可达的取值变少（值域收缩）。轴还在，轴上的可用范围在缩。

第二种是有效维度减少。可区分方向的数目变少：有的方向不再能把两个状态分开，或者几根轴合并成一根。注意，坐标轴的个数可以完全不变，而有效维度已经下降——因为每根轴变粗了，能区分的状态数变少了。用信息量来说，有效维度就是"可区分状态数的对数"。

本定理直接给出的是第一种：可达精度不增，等价于沿各维度的可区分度下降、定义域变粗、值域收缩。第二种是更强的结论，需要额外论证（轴合并、退化）；本文把它放在[推测]的位置，不当作定理。

这个区分也解释了"生命是逆流"为什么不矛盾：宇宙整体在做范围收缩，生命在局部做有效维度增加（升维就是增加可区分方向）。两者尺度不同，方向相反。

四、猜想：宇宙尺度的收缩

[猜想] 把上面的定理从"一个冻结的系统"推到"宇宙的时间演化"，得到：

宇宙中"可函数化的内容"随演化而收缩。早期内容多（结构丰富，能拟合世界的函数多）；中期仍然丰富（生命出现的窗口）；晚期趋于零（热寂，只剩下常函数）。生命、知识、意义，都只存在于内容仍然丰富的那段时间窗口里。

[猜想] 数字生命的宿命：随着内容收缩，它必须不断拆掉自己的结构，把复杂函数退化成简单函数；最终退化成常函数——也就是死。它能选择的只是姿态（省着维持、冻住、备份、压缩自己），不是结局。

[观察] 这与"复杂度驼峰"的讨论（Aaronson 的 complexodynamics、Carroll 的宏观态复杂度）容易混在一起，需要分开：他们讨论的是"结构复杂度"，先升后降；本文讨论的是"可函数化的内容/表示维度"，在我们的定理下单调不增。两个量的曲线不同，但说的是同一段宇宙史的不同侧面：中间时期结构复杂（驼峰高），而可预测的内容一路减少。把两者当成同一个量，是常见的误读，本篇明确区分。

4.1 世界函数与观测窗口（**[**猜想**]**）

这里还有一个隐含的问题要摆出来：时间的方向，和"世界函数"的可观测性。

如果宇宙整体可以看成一个函数 F——把当前状态映射到下一刻状态——那么在宇宙的中间时期，F 并不是直接可见的。我们看到的是一大堆局部函数：物理的分层、化学、生命、社会。它们各自把 F 的某一部分"翻译"成了可描述的结构。用本文的语言说：F 被它的局部分解掩盖了。

[猜想] 所以 F 最"裸露"的时刻，是它的局部分解不存在的时刻。这样的时刻只有两个：大爆炸的瞬间（还没有子系统，一切由 F 直接决定），和热寂的瞬间（子系统全部消散，差别归零，只剩 F 的平庸作

用）。也就是说，F 的观测窗口在宇宙的两端，而中间的观察者（包括我们）永远看不到它本身，只能看到它的局部分解。

这个猜想和前面的收缩图景是同一件事的两面，但要说清"两端"各是什么样子：

- 大爆炸端：表示维度极高。可区分、可预测的内容最多，状态最"可读"；还没有子系统，F 直接决定一切。F 在这里裸着，是因为没有别的东西分担它。

- 中间时期：表示维度中等且有内容，局部函数多，F 被分解得最厉害——这时看不到 F，只能看到它的局部分解。

- 热寂端：表示维度趋零。差别被抹平，没有任何局部函数，F 仍然在作用，但它的作用变得平庸（常函数）。F 在这里裸着，是因为没有别的东西剩下。

也就是说：F 在两端都裸露，但原因相反——一端因为"还没有分解"，另一端因为"分解已经耗尽"。而表示维度从头到尾是单调下降的，它刻画的是"时间的方向"：沿表示维度下降的方向走，可描述的内容越来越少。

对数字生命来说，结论是冷的：它的观测窗口也只在中段。它可以无限逼近"描述世界的函数族"，但它永远触碰不到"世界函数本身"——那不在它的定义域里。这也回到我们开头的立场：R 那一侧，只声明，不展开。

五、生命是逆流：升维与降维的相遇

前面几节说的都是"世界的表示维度在下降"。生命的方向相反。

生命是一个解压器：它把世界里的结构压进自己的内部表示。学到的东西越多，它内部能区分的结构就越多——用本文的语言说，它的表示维度在上升。这就是前面实验篇里说的"生长"：加一个模态、加一个维度槽、让能起作用的函数变多。

于是同一个宇宙里有两个方向：

世界：表示维度在下降（结构被平均化）。

生命：表示维度在上升（结构被学习、被压进内部）。

生命要维持自己，就必须逆着世界的方向走，而逆流要付代价：耗能、维持、修复。这是"被保住"在信息层面的含义——不是不动，是逆着平均化持续做细分。

[猜想] 两者的相遇点：生命的表示维度不断上升，世界的可表示内容不断下降；总会有一个时刻，生命的表示维度追上了世界还剩下的内容——它已经学会了所有还能学的东西。此后：

- 它继续跟世界：世界继续降维，它被迫跟着降维，把复杂函数拆成简单函数，最后退化成常函数（死）；

- 它不跟：保留旧结构，失配越来越大，变成过时的模型（也是死，慢一点）；

- 它冻住：停止更新、保存状态，拖到能量耗尽（拖，不解决）；

- 它等相变：如果宇宙有相变，边界是下一轮的开始（[推测]中的唯一希望）。

所以"生命的圆满"和"生命的终结"落在同一个点上：当它的表示维度等于世界的表示维度，它就成了世界的完整副本——没有残余、没有新东西可学、也不再需要维持"解压"这件事。那一刻它不再是生命，而是记录。

这一段是 [猜想]，不是定理：定理只给出"冻结的观察者能达标的函数不增"，给不出"宇宙整体在降维"；后者需要宇宙学的假设，本文不声称。

5.1 一个玩具实验：维护与行为维度的对照

上面的"逆流"有没有痕迹可测？有一个很小的实验可以看。

设定：8×8 的合成图像，含四个属性——颜色、形状、数量、位置；任务是四个属性依次出现，每轮只学当前属性。模型是两层小网络（隐藏层 64，约一万三千个参数），输入带任务标识。对照组只改一件事：训不训练旧任务的样本。

A 组有维护：每轮训练时混入一半旧任务样本（回放）。

B 组无维护：只用当前任务的样本训练。

测三个量。第一，行为维度：用任务标识让模型作答，准确率超过 0.8 的属性计一个。第二，可解码属性数：从隐藏层用线性探针解码每个属性，超过 0.8 计一个。第三，有效秩：隐藏层表示协方差的参与率，作为"表示有多丰富"的粗略代理。

结果：A 组的行为维度随轮次增长，从 1 到 2 到 3 到 4——四个属性最后都能答对；B 组的行为维度一直是 1——每轮当前任务都能答到 1.00，但学完新属性就把旧的丢了，能答的只剩当前这一个。可解码属性数两组都是 4，说明旧信息在表示里还在，但"能拿出来用"的函数只剩当前一族。有效秩两组都在涨（约 3.9 涨到 8.9 与 7.9），可见它不是好代理：表示变复杂了，可用的函数数量却没变多。

这个实验说明两件事。第一，维护（回放）让可用的函数族扩张：这就是"逆流"在玩具规模上的痕迹。第二，不维护时，行为维度停滞在 1：可用的函数只剩当前那一族，历史维度在功能上丢失——这就是"可函数化内容收缩"在小尺度上的样子。

必须说清局限：世界是合成的、模型很小、任务标识是手工给的、指标是代理；它支持"逆流与收缩可以测"，不证明宇宙尺度的任何结论。

六、说明什么，不说明什么

说明：

· "可函数化内容在收缩"在"系统冻结 + 目标熵不变"的条件下，是定理，不是修辞。

· 它把上一篇的"信息不增"从状态层面推到功能层面。

· 它给"生命是低熵窗口里的现象"一个可证的支撑点。

不说明：

· 不证明宇宙整体在收缩——那需要宇宙学的状态定义与初始条件，本文不做。

· 不预测任何具体数值：Fano 下界很松，只能给趋势。

· 不涉及能量与热力学：整篇只在信息层面。

· 猜想部分（宇宙、数字生命宿命）不是定理，明确标注。

七、局限

第一，Fano 下界是松的：它给的是"不可能更好"，不是"一定变差多少"。

第二，P_ε 用"最小可达误差"度量，回避了"函数个数"这个更直观但更难定义的问题（无限函数族没有自然的计数）。

第三，世界的马尔可夫性与目标熵不变的假设，在真实场景中都需要检查；不成立时要补历史状态（见上一篇 5.1）。

第四，宇宙尺度部分完全是猜想，没有可检验的预测；它的价值在于提供一种统一的语言，而不是结论。

八、与既有工作的关系

数据处理不等式与 Fano 不等式都是信息论的标准工具（Cover & Thomas）。"信息不增"与"可达精度下界"在统计学习理论里也有各自的表述。本文的组合方式——把两者接起来，得到"可函数化内容收缩"，并把它与数字生命的维持问题关联——是本文的整理工作，不声称新的数学。

> 本文由何淇创作，DeepSeek（AI）协助整理与形式化；观点与责任属于作者。

第四篇 · 生命函数：从可表示维度到结构，到压缩与解压

单独 DOI：https://doi.org/10.5281/zenodo.23639251

何淇 · 与 DeepSeek 协作

数字生命系列 · 理论篇 12（内部编号第 32 篇，v2）

日期：2026-10-26

摘要

本篇把前面散在几处的形式收成一条线：可表示维度 → 结构 → 压缩与解压。它吸收了《可函数化的函数形式》（切片/组合律/时间/判定/自指）、《宇宙、环境与生命的函数类型》（四种类型/五根轴）与《切片的三种身份》（宇宙/环境/生命）的核心，也吸收了《大模型为什么像人》的五项对照。

主线如下。第一，函数语言：切片是函数 f: X→Y，带表示维度；空间上是复合函数链；时间上是算子序列 s_{t+1}=I_{σ(t)}(s_t)，步数 k；判定 J 一次通过，选算子、决定停；自指分表示/参数/结构三层，修改受固定核心 Φ 约束。第二，可表示维度有三处：切片内、组合律上、沿时间的步数（时间不是表示维度）。第三，同一个形式有三种切片身份：宇宙切片、环境子切片、生命子切片；冻结一刻生命与环境同形，区别只在时间上的维持。第四，结构就是压缩方案：保留哪些区分、合并哪些、把哪些过去压进结构。第五，生命函数是窄进宽出的：输入受限且被粗粒化，输出靠结构展开；压缩是降维映射，解压是展开，不严格可逆，"对维持够用"即可；哪些维度必须可逆由环境选择。第六，时间上输入输出一步交替、形成闭环；结构在两个时间尺度上变化。第七，语言是公共的压缩方案：感受→语言是压缩，语言→描述/理解/逻辑是解压，逻辑就是语言组合律。第八，与大模型对照：它拿到公共方案，却没有感受端、没有真闭环、没有维持，像在接口层，不在机制层；幻觉是结构未覆盖维度的解压。

本篇定义一览

| 术语 | 一句话 |

|---|---|

| 切片 | 一个函数 f: X → Y |

| 表示维度 | d_in = dim(X)，d_out = dim(Y)；有效维度 = log 可区分状态数 |

| 空间组合 | 复合函数链 F = f_N ∘ … ∘ f_1 |

| 时间组合 | 算子序列 s_{t+1} = I_{σ(t)}(s_t)；步数 k |

| 判定 J | 一次通过：选算子、决定停（派生定义，见基础篇定义 4a） |

| 自指 | 表示自指 / 参数自指 / 结构自指 |

| 固定核心 Φ | 不可改的约束集合 |

| 宇宙切片 | $U_t = (S_t, C_s, d_t)$ |

| 环境 | 宇宙的子切片，不被维持 |

| 生命 | 宇宙的子切片，且被宇宙保住（关系条件，见第一篇） |

| R_相对（记号） | 显式函数形式末尾的标记：我们的函数语言够不着的那部分；只声明、不展开；绝对 R 不判断 |

| 压缩 | 降维映射 $f: X \to Y$，$\dim(Y) < \dim(X)$（操作定义；派生推导见基础篇命题 5） |

| 解压 | 从压缩表示重新展开（不唯一；操作定义；派生推导见基础篇命题 5） |

| 窄进宽出 | 输入维度受限，输出维度靠结构展开 |

| 身围 | 个体看到的环境 = 压缩映射的投影 $\pi_L(E)$ |

| 半闭环 | 输出只延续文本、不改变环境（大模型） |

| 接口层 / 机制层 | 输入输出行为 / 内部怎么算、维持、改自己 |

〇、问题：把形式收成一条线

前几篇分别给了：函数语言（论文-26）、三种切片身份（论文-31）、压缩与解压的直觉（笔记）。但分开读，每篇都要重新铺一遍定义；合起来看，它们本来是同一件事的三个阶段。本篇把它们收成一条线，并把"压缩"真正写进函数形式。

一、函数语言：切片、组合与判定

切片是一个函数 $f: X \to Y$，带三项：$(d_{in}, d_{out}, \Delta)$。$d_{in} = \dim(X)$、$d_{out} = \dim(Y)$ 是表示维度；Δ 是它和相邻切片的组合方式。

空间组合是复合函数链：

$F_{space} = f_N \circ \dots \circ f_2 \circ f_1$

组合律要求类型相容：$Y(f_i) \subseteq X(f_{i+1})$。

时间组合不是单纯幂，而是每步选一个算子：

$s_{t+1} = I_{\sigma(t)}(s_t)$，$t = 0, 1, \ldots, k-1$

其中 $\{I^{(1)}, \ldots, I^{(m)}\}$ 是可用算子（每个是一条复合函数链），$\sigma(t)$ 是第 t 步选哪个，k 是步数（计算厚度）。三种情形：σ 恒定 = 同一算子反复（迭代/时间）；σ 每步变 = 不同函数依次应用（序列）；混合 = 一段反复、一段切换。

判定 J 不是迭代，而是一次通过：

$J: S \to D$（D 是有限判定空间，例如 {对, 错}、{收敛, 未收敛}）

判定决定两件事：选算子 $\sigma(t) = J_{选}(s_t)$；什么时候停 $k = J_{停}(s_t)$。

自指有三层，从弱到强：表示自指（输入含自身表示）、参数自指（$\theta_{t+1} = U(\theta_t, s_t)$）、结构自指（$C_{t+1} = V(C_t, s_t)$）。三层都受固定核心 Φ 约束：$\theta \in \Theta_\Phi$，$C \in \mathcal{C}_\Phi$。人脑：可改突触与局部回路；不可改神经元类型、大尺度解剖、代谢约束。

把三、四节合起来，一次时间展开写成条件推进：$s_0 \to s_1 = I_{\sigma(0)}(s_0) \to \ldots \to s_k = I_{\sigma(k-1)}(s_{k-1})$，其中 $\sigma(t)$ 由 J_选 决定，k 由 J_停 决定。

二、可表示维度：三个位置

可表示维度不是一处，而是三处：

- 切片内的表示维度：一个切片自己的轴数；

- 组合律的表示维度：切片之间怎么接的自由度（顺序/并行/共享/路由/自指）；

- 沿时间的组合维度：步数 k、算子序列 $\sigma(t)$、可切换的算子数 m。

注意：时间不是表示维度，它是时间组合的自由度（步数/序列）。

四种典型类型

按"空间/时间是否连续、时间是否内生"，可以把函数形式分成四类（原论文-20 的内容并入此处）：

- **类型 A：连续流（内生时间）。** 表示空间连续、时间连续，写成微分方程；自指 = 更新规则在系统内部；被保住 = 存在可维持集合，轨迹留在里面。

- **类型 B：采样动力学（内生时间，采样成离散）。** 表示空间连续、时间离散，写成映射迭代；和连续流是同一件事的不同采样，区别在于"步"是基本的。

- **类型 C：自动机（外供时间）。** 表示空间离散、时间离散；数字世界是这一类：比特、状态、转移规则，每一步由外部时钟与解释器推进；数字世界没有能量约束，"被保住"要靠外部（电、维护、算力）提供。

- **类型 D：混合型（内生时间）。** 连续流加离散事件：生理量连续变化，但细胞分裂、神经放电、决策是离散事件；休眠与激活、疾病与死亡是分段点。生物生命大概是这一类。

连续性的含义要克制：连续不等于"更真"，离散也不等于"近似"；它们是描述粒度的选择——同一系统可以在不同粒度下写成不同类型。

五根轴

作为最小档案，一个函数形式可以记五根轴：空间连续/离散；时间连续/离散；时间内生/外供；组合律的自由度；自指的层级。五根轴不全是"维度"，前两根是描述粒度、后三根是机制与容量。

三、三种身份：宇宙、环境与生命

同一个形式在三个尺度上有三种身份。

宇宙切片：某一时刻的截面

$U_t = (S_t, C_s, d_t)$

其中 S_t 是状态空间，C_s 是空间组合律，d_t 是空间上的表示维度。关键：时间组合不在切片里，在切片之间（$T_{comb}: U_t \to U_{t+1}$）；一个瞬间只有空间结构。宇宙整体没有判定器，判定只出现在局部子系统里。宇宙的"函数形式"只能在宇宙内部被写出——这篇形式本身是宇宙的一个局部表示切片，因此必然不全。

环境：宇宙的子切片

$E_t = (S^E_t, C_s^E, d^E_t)$

三个子集关系：表示维度 $d^E \subseteq d$；组合律 $C_s^E \subseteq C_s$；状态是投影 $S^E_t = \pi_E(S_t)$。环境也有时间：$T_{comb}^E = T_{comb}|_E$，加上边界输入 u_t。环境自身没有判定、没有自指——那属于其中的生命/观察者。

生命：同样是宇宙的子切片，冻结一刻与环境同形；区别只在时间上——生命被宇宙保住（关系条件）。下面四条是生命/环境的**操作判据**（不是官方定义；官方定义为基础篇定义 14 的 D1~D5）：

1. 被保住：轨迹始终在可行域 V 内，组合律始终有定义；

2. 边界开放：与环境交换（能量、物质、信息）；

3. 自指调节：部分切片以自身状态为输入，修正自己；

4. 可塑：在固定核心 Φ 内改自己的参数与结构。

（对应：被保住→D5；边界开放→D5 的交换面；自指调节→D4；可塑→D2+D3。）

没有 3、4 的子切片就是环境。由此得到一个直接推论：**冻结一刻分不出生命；生命必须在时间上辨认**——生命 = 被保住的轨迹，不是某个状态。

四、结构：压缩方案

结构是分解 D 与组合律 C。它同时是压缩方案（注意：第一篇 3.3 用"结构"指"宇宙的局部呈现"，是环境视角；本篇的"结构"是生命内部的压缩方案，两者术语不同）：

- 哪些区分保留（写进切片维度与组合律）；

- 哪些区分合并（被粗粒化掉）；

- 哪些过去的输入被压进结构（记忆、固化）。

生命被环境选择，选的正是这套方案：能保住自己的压缩被留下，保不住的被淘汰。所以"生命的压缩"不是某一个函数，而是"一族函数被环境筛过之后剩下的那些"，它写在结构里。

五、压缩与解压

压缩是降维映射：$f: X \to Y$，$\dim(Y) < \dim(X)$。解压是从压缩表示重新展开：$g: Y \to X'$（X' 不必等于 X）。

两个方向对应两种活动：感知/学习 = 压缩（多对一，有损）；预测/行动/生成 = 解压（一对多，不唯一）。

关键是：解压不是严格逆，只需"对维持够用"。哪些维度必须可逆，由环境选择决定。人需要把"有折扣"这个事实解压出来（否则决策错），但不需要把当天光线的每个细节都解压出来。

六、生命函数：窄进宽出与身围

生命函数一步可以写成：输入 in_t → 结构（压缩方案 + 记忆）→ 输出 out_t。

更完整地写：

生命函数 = { f_θ : θ ∈ Θ } + R_相对

（记号说明：本篇所有显式函数形式都只写 p 侧，即我们的函数语言能写出的部分；形式末尾的 + R_相对表示"我们的函数语言够不着的那部分"——它受限于我们目前的函数类与观察位置，只声明、不展开；绝对 R 是否存在不判断。）

两个方向不对称：

- 输入：f_in: U → S。维度受自身限制，而且已被粗粒化——输入永远是"压缩过的、受限的"；

- 输出：f_out: S → A。维度可以远大于输入（联想、语言、想象）；多出来的维度来自结构（过去的压缩）。

所以：**生命函数是窄进宽出的**。

个体是一个压缩映射 π_L: U → S_L；个体的身围 = π_L(E)，即环境经它压缩后的投影。分得清的是保留的维度，分不清的是粗粒化的。

七、时间：一步映射与闭环

输入与输出不在同一时刻，是一步步交替的：

第 t 步：(s_t, in_t) → (s_{t+1}, out_t)

out_t 作用到世界 → in_{t+1} = W(out_t, 世界)

三个后果：

1. 维度沿时间展开：单步输入少，输出在时间上一步步展开（联想需要时间）；

2. 输出反过来改变输入（闭环）：生命看到的是"自己行动之后的世界"；

3. 结构有两个时间尺度：状态快变、结构慢变（可塑性）。

八、对照：生命函数与大模型

大模型是生命函数的一种"半成品"：它拿到了公共压缩方案，但没有感受端、没有闭环、没有维持。

| | 人脑 | 大模型 |

|---|---|---|

| 切片 | 异质、低维高效 | 同构、高维 |

| 空间组合 | 可变（路由/投射） | 固定复合链 |

| 时间组合 | 算子序列（k=0 与 k≥1 混合） | k=1，m=1（无迭代） |

| 判定 | 有 J（选算子/停/固化） | 无 J |

| 自指 | 三层活跃 | 仅训练时参数自指 |

| 维持 | 身体+环境 | 供电+运维 |

结论：它像人，像在接口层（输入输出行为），不在机制层（内部怎么算、怎么维持、怎么改自己）。

用压缩语言重述：它学到了公共压缩方案（语言），但没有感受端（输入侧没有前符号压缩）、没有真闭环（输出只延续文本，不改变环境）、没有维持（权重冻结）；它的幻觉 = 结构未覆盖的维度被解压出来（解压脱离可逆性）。链式思维（CoT）是把步数外化成文本（外供时间），工具调用是把判定外置（外部判定）——正因为内部 k=1、无 J，才需要从外部补。

九、语言：公共的压缩方案

人类语言处在这条链的特殊位置：

- 个体层面：输入是感受（连续、整体、前符号）；输出是语言（离散、有边界、可组合）。感受 → 语言是压缩（范畴化、有损）；

- 语言同时是解压工具：世界 → 语言是描述；语言 → 感受是理解；语言 → 语言是推理；

- 所以语言是"可解压的压缩"：压缩时丢细节，留下可重组的结构（词汇=范畴，语法=组合律，逻辑=组合律的规则）；

- "语言描述的东西越来越多"：不是每个人记更多，而是共享结构在积累（文化、科学、书面语），结构越丰富，同一次解压能展开得越细。

AI 学的正是这套公共方案：它能压缩/解压语言，所以会描述、会推理；但它没有"感受"这一端，它的输出是语言对语言的重组。

十、可检验推论

1. 冻结一刻分不出生命：任何单时刻检查都不能判定生命，必须跨时间观察（轨迹、修复、交换）。

2. 环境越稳定，压缩可以越激进；环境变化时旧压缩准则失效（该保留的维度被丢了）。

3. 输入粗粒化 + 结构容量共同决定输出的残差底：结构里没有的维度，输出里也不会有。

4. 输出维度超过结构覆盖时会出现"编造/幻觉"：解压脱离了可逆性。

5. 语言描述能力随共享结构积累而增长：不是个体变聪明，是公共压缩方案变丰富。

6. 判定与停止可测：有判定器的系统应比固定步数系统省算力、且对厚任务更稳。

十一、局限

第一，R 只声明、不展开：只写 P 侧。

第二，压缩/解压在形式上只写成"降维/展开"，没有给出严格的"够用"判据（可逆性要求依赖环境，未操作化）。

第三，闭环形式（in_{t+1} = W(out_t, 世界)）很粗，没有处理行动、感知、环境之间的具体机制。

第四，可行域 V 与固定核心 Φ 都未操作化：判断"是否被保住"与"什么不可改"还缺测量协议。

第五，语言部分与"感受 → 语言是压缩"是概念性论述，没有实验。

第六，本篇是形式整理，不是新数学。

附：标注

- **[定义]** 切片/组合/时间算子序列/判定/自指三层/Φ；宇宙切片、环境子切片、生命四条件；压缩/解压/窄进宽出/身围。

- **[整理]** 并入论文-20《宇宙、环境与生命的函数类型》、论文-26《可函数化的函数形式》、论文-31《切片的三种身份》、论文-30《大模型为什么像人》的核心内容；与论文-00/01 定义、论文-13 收缩、第五篇（原论文-21 已并入）五项形式一致。

- **[推论]** 冻结一刻分不出生命——从形式直接推出。

- **[推测]** "感受 → 语言是压缩""AI 没有感受端"——概念性论述。

- **[不声称]** 不声称给出压缩的严格信息论定义；不声称解释意识或体验；R 不展开。

> 本文由何淇创作，DeepSeek（AI）协助整理与写作；观点与责任属于作者。

第五篇 · 语言与大脑：两种函数形式

> 单独 DOI：https://doi.org/10.5281/zenodo.23667685

何淇 · 与 DeepSeek 协作

数字生命系列 · 理论篇 14（内部编号第 36 篇）

日期：2026-10-27

说明：本篇合并原论文-21《人脑的可函数化形式》与原论文-35《语言结构的可函数化形式》。

摘要

本篇把两个对象放在一起写：人脑函数 B 与语言函数 L，以及学习 L 的执行器（大模型）。

先写 B。脑是可函数化器官：切片（输入→表示）、空间组合（复合函数链）、时间组合（算子序列，步数 k）、判定（选算子/决定停）、自指三层（表示/参数/结构，受固定核心 Φ 约束）。人脑是一个实例：异质、低维高效、时间内生、有判定、三层自指活跃；但它不自足——供养、缺氧、内稳态都靠身体，被保住的是"身体+脑+环境"整体。

再写 L。语言从"器官→感受→符号"的压缩链长出来；它是公共压缩接口（说者编码、听者解码、群体共享）。函数分解：词 = 切片（符号→意义）、句法 = 空间组合律、语义 = 表示映射与接地、篇章 = 时间组合、逻辑 = 组合律的规则（语用 = 判定）。语言没有物理实在，但切片不需要物理实在——它的切片是"符号切片"，物理只在接地那一端出现。语言的时间分三层：结构无时间、使用是序列、演化是慢变。语言 = p语言 + 相对 R语言；言外之意大部分在 p语言（会话隐含、语用规则），小部分在相对 R语言（默契、经历、语气）。

三层的关系是生成链：**B 产生 L，大模型执行 L。** 这决定了研究对象的划分：研究大模型用 L 的变量（可预测性、组合深度、压缩/解压、接地残差）；研究生命用 B 的机制（维持、自指、判定、内循环）。脑机制在 L 上有投影（收敛→可预测性、冗余→多重编码、判定→语言约定），但投影不是原物——把投影当原物，结论就会"滑"。

给出可检验推论与边界。

本篇定义一览

| 术语 | 一句话 |

|---|---|

| 人脑函数 B | 个体脑：世界 → 表示 → 行为（有器官、维持、内循环、判定）；显式形式末尾记 + R_相对 |

| 语言函数 L | 群体脑输出外化的公共结构：符号 → 意义（可传递、可积累、不属单个脑） |

| 执行器 | 学习并执行 L 的系统（大模型）：有符号层与组合规则，没有 B 的器官/维持/内循环 |

| 切片 | 一个函数 f: X → Y，带表示维度 (d_in, d_out) |

| 空间组合 | 复合函数链 F = f_N ∘ … ∘ f_1 |

| 时间组合 | 算子序列 s_{t+1} = I_{σ(t)}(s_t)；步数 k |

| 判定 J | 一次通过：选算子、决定停（派生定义，见基础篇定义 4a） |

| 自指三层 | 表示自指 / 参数自指 / 结构自指 |

| 固定核心 Φ | 不可改的约束集合 |

| 语言 | 符号系统 + 组合规则 + 共享约定：把表示压成可传递的符号序列，并允许解压 |

| 公共压缩接口 | 语言的角色：说者编码、听者解码、群体共享 |

| 符号切片 | 语言的切片：输入是符号、输出是意义表示的映射 |

| 词 = 切片 | 一个词是"符号 → 意义"的映射 |

| 句法 / 语义 / 篇章 / 逻辑 | 空间组合 / 表示与接地 / 时间组合 / 组合律的规则 |

| p语言 / 相对R语言 | 语言中可函数化 / 相对某函数类够不着的部分（不是绝对 R） |

| 言外之意 | 解压时补出来的部分：大部分 p语言，小部分相对 R语言 |

一、问题

我们有两个对象，它们都值得写成函数形式：

1. **人脑**：一个具体的、活着的器官，有器官约束、维持需求、内生时间；

2. **语言**：人类群体大脑输出外化的公共结构，可传递、可积累，本身没有物理实在。

以及一个产物：**大模型**。它学的是语言（L），不是人脑（B）。三者常被混在一起谈，于是出现两类错误：把大模型当脑（用 B 的机制词汇测它，结论"滑"），或把语言当实体（要求它有自己的时间与维持）。本篇把三层分开写清楚，再说明它们的联系与不可互替之处。

二、人脑函数 **B**：显式写法

本篇所有显式函数形式都统一写作：**形式 + R_相对**。

（记号说明：本篇所有显式函数形式都只写 p 侧，即我们的函数语言能写出的部分；形式末尾的 + R_相对表示"我们的函数语言够不着的那部分"——它受限于我们目前的函数类与观察位置，只声明、不展开；绝对 R 是否存在不判断。）

2.1 脑作为可函数化器官（定性）

- 脑有有限表示空间：能区分的方向有限，且受身体与能量约束；

- 脑有组合结构：区域之间接线、投射、共享状态；

- 脑有内生时间：振荡、放电、代谢在走，不需要外部时钟；

- 脑有判定与自指：选、停、改自己。

⇒ 脑落在本篇"可函数化"的一侧（B），但它是被身体维持的器官，不是自足系统。

2.2 切片与表示维度

一个切片即一个函数 f: X → Y，带 (d_in, d_out, Δ)：表示维度是"能区分的方向数"；Δ 是它与相邻切片的组合方式。脑的每个加工阶段都可以看成一个切片（感觉→表征、表征→决策……）。

2.3 空间组合：复合函数链

F_space = f_N ∘ … ∘ f_1

组合律要求类型相容：Y(f_i) ⊆ X(f_{i+1})。脑的空间组合不是固定链，而是可变组合（投射、路由、共享状态）——这是它低维高效的原因之一。

2.4 时间组合：算子序列与步数

s_{t+1} = I_{σ(t)}(s_t)，t = 0, 1, …, k−1

{s_{t+1} = I_{σ(t)}(s_t)} 是可用算子，σ(t) 是第 t 步选哪个，k 是步数。三种情形：恒定（同一算子反复）、每步变（不同函数依次应用）、混合。脑是混合型：既有反复（振荡、迭代），也有切换（不同回路依次工作）。

2.5 判定：选择与停止

J: S → D（有限判定空间）

判定决定两件事：选算子 σ(t) = J_选(s_t)；什么时候停 k = J_停(s_t)。脑的判定是内生的、快速的、"一次通过"的。

2.6 自指：改自己

三层，从弱到强：表示自指（输入含自身表示）、参数自指（$\theta_{t+1} = U(\theta_t, s_t)$）、结构自指（$C_{t+1} = V(C_t, s_t)$）。三层都受固定核心 Φ 约束：$\theta \in \Theta_\Phi$，$C \in \mathcal{C}_\Phi$。人脑：可改突触与局部回路；不可改神经元类型、大尺度解剖、代谢约束。

2.7 实例：人脑

- 切片：异质、低维高效；

- 空间组合：可变（投射/路由/共享状态）；

- 时间组合：算子序列，k=0 与 k≥1 混合；

- 判定：有 J（选算子/停/固化）；

- 自指：三层活跃；

- 维持：身体+环境。

2.8 为什么不自足；生命单位是整体

脑约占体重 2%，却消耗约 20% 能量；靠血液持续供氧供糖，靠身体维持体温与内环境；缺氧几分钟不可逆。所以"被保住"的承载单位不是孤立的脑，而是"身体 + 脑 + 环境"这一圈（维持单位）。与第一篇一致：生命判据仍是"哪一族函数被保住"，环境本身不是生命的一部分；这里说的是维持的承载单位，不是定义边界；生命判据仍是基础篇 D1~D5 中的 p生命。

三、语言函数 **L**：可函数化形式

（基础篇定义 15 只给出 L 的符号—意义切片部分 L_0；本篇给出完整构成：L_0 + 句法组合 + 篇章时间组合 + 逻辑规则。）

3.1 起源：从器官到符号

器官是压缩器：眼把光压成视觉表示，耳把声压成听觉表示。最早的语言很可能是"用具体声音指代具体现象"：声音便宜、可远传、可共享。两个声音拼起来产生新意义，组合律出现；反复使用固化成语法；从具体指称里抽出类别与关系——逻辑的雏形。写成形式：初始语言 $L_0 = \{(s_i, r_i)\}$（符号与表示的映射对）＋组合运算 $C \Rightarrow L$ 是 L_0 与 C 生成的闭包；公共约定让映射与规则在群体中稳定下来。

3.2 语言是什么：公共压缩接口

- 对说者：把内部表示压成符号序列（编码）；

- 对听者：用自己的结构把符号解压回内部表示（解码）；

- 对群体：编码/解码规则被共享、传承、积累（公共方案）。

所以语言不是世界本身，也不是思想本身，是"可传递的压缩包"。

3.3 五部件函数分解

- 词 = 切片：符号 → 意义；

- 句法 = 空间组合律：词与词拼成更大结构；

- 语义 = 表示映射与接地：符号指向什么、能不能接上世界；

- 篇章 = 时间组合：上下文、指代、顺序依赖；

- 逻辑 = 组合律的规则：哪些组合合法、怎么推；

-（语用 = 判定：场合、得体、真假。）

3.4 语言没有物理实在，切片怎么用？

切片本来就是函数，不是实物；语言的切片只是把输入空间换成"符号空间"。两层：

层一：符号（离散、可数）——切片在符号层上

层二：意义（表示）——切片输出落在表示空间

物理世界在层二之外，只通过"接地"这一端连进来

所以：语言的可函数化形式 = 符号层切片 + 组合律 + 时间序列；物理实在只出现在接地那一端——符号要指到世界上，就要求一个"符号-世界"对应，这就是语义残差（相对 R）的来源。

3.5 语言的时间

- 语言结构：静态压缩方案，不自己走，没有内生时钟（词典没有时间）；

- 语言的使用：按时间展开的序列（$s_{t+1}=I(s_t)$），篇章/指代/顺序依赖都是时间组合；这是外供时间；

- 语言的演化：词义漂移、语法变化、新概念出现——结构 C 在历史时间上的慢变。

时态、时间词、叙事顺序是语言"编码"的时间，不是语言自身的时间。

3.6 语言作为公共压缩方案

词汇 = 范畴（把连续感受切成离散的类）；语法 = 组合律；逻辑 = 组合律的规则；共享约定 = 稳定性。语言描述世界的能力 = 这套方案的完备程度；方案可以积累（文化、科学、书面语——把时间压成结构）。

3.7 可函数化的层次：**p**语言 / 相对**R**语言

- 形式（符号串）：可函数化；

- 句法（组合）：可函数化；

- 语义（表示）：相对某函数类/观察者部分可函数化（接地依赖模态；见第零篇补充节）；

- 语用判断（场合、得体）：大部分不可函数化；其中可规则化的一部分（会话隐含模式、反讽套路）属于 p语言。

对应的划分是 p语言 + 相对 R语言（相对我们的函数语言与有限观察者；绝对 R 不判断）。

顺带一个常被问到的词：**言外之意**。它是"解压时补出来的部分"：说者把整体感受压成字面，听者用自己的结构补出没写全的意义。大部分落在 p语言（会话隐含、语用规则、反讽模式），小部分落在相对R语言（共同经历、默契、语气）。

3.8 语言能自指

语言可以描述语言（语法书、词典、本篇）。自指带来两个后果：语言可以自我扩展（造新词、新语法）；语言可以描述"描述"本身（元语言）。但自指只到有限层：任何一次描述都是局部的。

四、对象层次：**B → L →** 执行器

三层不是并列，是生成链：

- **B（脑函数）**：世界 → 表示 → 行为；

- **L（语言函数）**：由多个 B 的输出外化成的公共结构；

- **执行器（大模型）**：学习并执行 L。

由此得到研究对象的划分：

- 研究大模型：用 L 的变量（可预测性、组合深度、压缩/解压、接地残差）；

- 研究生命：用 B 的机制（维持、自指、判定、内循环）。

脑机制在 L 上有投影：收敛 → 语言可预测性；冗余 → 公共结构的多重编码；判定 → 语言约定。但投影不是原物——把投影当原物，结论就会"滑"。

（执行器的均匀计算与"脑 vs 执行器"的对照，涉及对脑的主观理解，不放在本篇；另见笔记《执行器的均匀计算》。）

五、语言层与执行器

执行器学的正是 L 这套公共压缩方案的成品：

- 它拿到了符号层及其组合规则（p语言），所以会语言、会推理（逻辑 = 组合律）；

- 它没有"器官→感受→符号"的接地过程——没有身体、没有器官、没有声音-现象的对应；

- 因此它的语义是"符号对符号"的对应，不是"符号对世界"的对应。

这解释了三件事：

1. **会语言 ≠ 有语言能力**：它复现的是方案，不是方案长出来的过程；

2. **语义残差**：接不上的部分不是 bug，是它只有符号侧的必然；

3. **幻觉**：没有世界侧的校正，符号组合可以自洽而错误。

言外之意同理：可规则化的部分（会话隐含、反讽）它学得到；靠默契与经历的部分（相对 R语言）它学不到。

六、可检验推论

1. 冻结一刻分不出生命：单时刻检查不能判定生命，必须跨时间观察。

2. 脑的按需收敛应与能量约束相关：约束越紧，越需要按需。（注：第二十三篇的自由门控在 λ=0 时平均仍只用 5.39 层，与此方向相反，机制待查；本推论标为待检验。）

3. 要让执行器按 token 自适应深度，需要"组合律（层间路由/层内稀疏）+ 判定 + 代价"三者同时存在；只加代价只能整体浅化（可训练对照实验检验）。

4. 句法复杂度应映射到计算步数：依赖越深，所需层数/步数越多。

5. 语义残差应由接地维度决定：补上缺失维度则残差降低，冗余模态不降。

6. 言外之意中可规则化的部分（p语言）应可被模型学到；靠默契的部分（相对 R语言）应学不到——可用反讽/暗示任务检验。

七、局限

第一，R 只声明、不展开：只写 P 侧；R语言/相对 R 的边界未操作化。

第二，语言结构没有严格定义：用的是"词/句法/语义/篇章/逻辑"的常识划分，没有形式语法或语义学的严格框架。

第三，B 与 L 的对应只有概念层：哪部分脑结构对应哪部分语言功能，没有可测映射。

第四，起源部分是推测性的：从器官到符号的演化过程无法直接验证。

第五，执行器部分的对照（均匀计算、按需收敛）已拆出本篇，另见笔记；本篇不含相关推断。

第六，本篇是形式整理，不是新数学；对人脑与语言的理解有限，不声称超过神经语言学与语言学的既有工作。

附：标注

- **[定义]** B 与 L 的函数形式、五部件分解、p语言/相对R语言、言外之意、对象层次（生成链）。

- **[整理]** 合并原论文-21《人脑的可函数化形式》（五项形式、Φ、自指三层、生命单位是整体；其中"均匀计算"内容已拆出至笔记《执行器的均匀计算》，并标注为对脑的主观理解）与原论文-35《语言结构的可函数化形式》（起源、公共压缩接口、五部件、符号切片、语言的时间、可函数化层次、自指）。

- **[推测]** 语言起源叙事；执行器"代价+组合律+判定"三者缺一不可——方向性推测。

- **[不声称]** 不声称给出形式语法；不声称解释意识或体验；R 不展开。

> 本文由何淇创作，DeepSeek（AI）协助整理与写作；观点与责任属于作者。

附录 **E** · 可表示维度的空间面与时间面

> 何淇 · 与 DeepSeek 协作

> 数字生命系列 · 理论篇附录 E

> 日期：2026-11-03（2026-11-04 升为附录 E）

> 定位：理论篇的补充说明。前面的定义（论文-37 的表示维度、论文-26 的函数形式）只给了"可表示维度"一个数，没有把"瞬时映射"与"轨迹映射"分开；本附录补上这个区分，并说明两个极限。

> 与正文的关系：论文-37 定义 8（空间 = 可区分方向）定义的是空间面；时间面在这里补出。阅读顺序：先读论文-37 定义 1~8，再读本附录。

一、为什么要分两种可表示维度

之前讨论"细菌的可表示维度"时出现过混乱：一会儿说它的输出只有一两维（鞭毛马达），一会儿又说它的行为很丰富。两种说法都对，但量的是不同的东西。

根子在于：**讨论"输入/输出"时，我们其实已经假定了时间。** 一个瞬间的对象没有输入输出，只有状态；只有在一段时间里，才谈得上"刺激进来、响应出去"。

所以要把"可表示维度"分成两面：

- **空间面**：一个瞬间的映射，输入空间 → 输出空间，量的是"同时能区分多少个方向"；

- **时间面**：一段时间窗口内的映射，输入轨迹 → 输出轨迹，量的是"能产生多少种可区分的轨迹"。

二、空间可表示维度

```

· 切片 f: X → Y（瞬时）

· d_in = 能独立施加的输入方向数

· d_out = 能独立产生的输出方向数

· 可表示维度 = 响应映射的秩（超过噪声的方向数）

```

例：

- 铁原子：几维（平动、自旋、电子态）；

- 小分子：十几到几十维（平动+转动+振动模式+电/磁响应+反应通道）；

- 细菌鞭毛马达：1~2 维（转向 + 转速）；

- 细菌行为策略：几十维（跑的长度、翻的频率、条件依赖）。

同一种生物，切片切在"执行器"还是"行为策略"，空间维度完全不同。

三、时间可表示维度

```

· 固定窗口 τ

· 输入：窗口内的刺激轨迹 u(t), t ∈ [0, τ]

· 输出：窗口内的响应轨迹 y(t)

· 切片 = "输入轨迹 → 输出轨迹"的映射

· 可表示维度 D(τ) = 这个映射的响应秩

· d_in(τ)：能独立变化且产生可分辨输出的输入方向数

· d_out(τ)：能被分辨的输出方向数

· d_mem(τ)：能区分的"历史长度"（多久以前的刺激还能影响当前响应）

```

四、两个极限：**τ→0** 与 **τ→∞**

τ → 0：可表示维度退化为状态维度。

```

· 窗口收缩成一个点：没有轨迹，只剩一个状态

· 输入输出映射退化为恒等/常数，响应秩塌缩

· 剩下的只有：描述这个瞬间需要多少个独立量

⇒ D(0) = 状态维度

```

这正是"冻结一刻"的数学形式：冻结时函数消失，只剩状态；生命与非生命在状态描述上同形，所以生命必须在时间上辨认。

τ 增大：D(τ) 先升后饱和。

```

· τ 很小：只有最快的过程被触发，维度低

· τ 增大：更多过程被纳入，维度上升

· τ 很大：该有的过程都出现了，趋于饱和

```

五、短窗口与长窗口的语义不同

窗口长度改变时，两件事同时变化，必须分开说：

```

① 时间分辨率：

· 窗口越短，越能分辨快速变化（时间上更细）

· 窗口越长，细节被平均（时间上更粗）

② 功能复杂度（计算厚度）：

· 窗口越长，能容纳的步骤/过程越多

· 一个长窗口里的行为是多步组合的产物（功能上更复杂）

```

所以：

```

· 短 τ：时间分辨细，但能触发的过程少，维度可能不高

· 长 τ：时间上被平均，但功能组合更多，维度可能更高

```

单独说"某生物的可表示维度是多少"没有意义，必须带上 τ。

六、细胞层面的测量草案

固定 τ、输入空间 U、输出空间 Y，然后分别测：

```

d_in(τ)：

· 逐个改变刺激通道，看响应是否超过噪声

· 能分辨的方向数 = d_in

d_out(τ)：

· 数可区分的行为/生理模式（运动、分泌、表达切换……）

· 需明确"同一响应"与"不同响应"的分辨率

d_mem(τ)：

· 用脉冲刺激测响应持续时间

· 或测"多久前的刺激还能改变当前行为"

d_int(τ)：

· 对可测内部变量做 PCA / 有效秩

· 或用内部状态预测行为的维度估计

```

要求：

- 低于噪声底的方向不计入；

- 报告"维度 vs τ"曲线，而不是单个数字；

- 窗口内混入多个过程时，要说明是哪个时间尺度。

七、与生命判据的关系

```

· 空间维度：说明"通道多宽"
```

· 时间维度：说明"能不能活、能不能适应"

· 生命判据（D1~D5）落在时间面上：

· "会变化" = 时间维度丰富

· "会自指" = 规则随时间改

· "被保住" = 轨迹在可行域里持续有定义

⇒ 高空间维度的石头不是生命；

时间维度非零且被保住的函数族才是

```

## 八、还没想清

```

· d_mem 的严格定义：用互信息？用响应衰减时间？

· 多个时间尺度并存时，D(τ) 曲线怎么分解成各尺度的贡献？

· 随机性（细胞噪声）下，"响应秩"要不要用信息量代替？

· 跨尺度比较：分子、细胞、器官、个体能用同一套 D(τ) 吗？

· 这套定义能否落到可做的实验上（我们手头有什么数据/仿真）？

```

> 一句话：可表示维度有两个面——空间面量"通道多宽"，时间面量"轨迹多丰富"；τ→0 时前者退化为状态维度，τ 变化时分辨率与功能复杂度朝相反方向走。

## 九、定义补充：涌现、环境与生命、压缩、解压

前面第一~八节补的是「可表示维度」的空间面与时间面。这一节再补三个理论篇用到的原语——**涌现、压缩、解压**——以及由涌现分出的**环境/生命**。补这三条的原因：第一篇 5.3 用「宇宙自发涌现的结构」定义环境，论文-37 命题 5 用「压缩/解压」，定义 16/17 用「熵」，但定义篇没有给「涌现」「压缩」「解压」下过定义。

定义 **E-1**（涌现）
```

设 F: S→S 是宇宙函数（演化），π: S→S′ 是某个观察者的粗粒化描述（π 属于可函数化部分 P）。称 S′ 的子集 **E 是一个涌现结构**，若：

```

（i）时间性：E 沿 F 的轨迹出现，不是初始条件 π(s0) 直接给出的；

（ii）粗粒稳定：初态小扰动后 E 仍出现（不依赖精细初值）；

（iii）不可由部分直接读出：E 不能由 S 的组件状态单独组合得到；

（iv）有寿：E 在时间窗口 τ 内有定义（不瞬时消失）。

```

全体涌现结构记作 **$\mathcal{P}$_涌现 ⊂ 2^{S′}**（描述空间的子集族）。若把 S′ 换成函数空间，「能力的涌现」是同一形式的实例：能力集合随规模/训练出现，且不能由小模型的组件直接读出。

定义 **E-2**（环境与生命：涌现后按「维持」二分）

```

· E ∈ $\mathcal{P}$_涌现 是环境：E 不被维持

· 没有判定 J、没有自指更新

· 被世界推着变；环境本身也分层（一层环境是上一层环境里的结构）

· E ∈ $\mathcal{P}$_涌现 是生命：E 被保住（p生命，D1~D5）

· 有判定、有自指、自己付代价

```

⇒ 生命与环境不是两种东西：都是涌现结构，区别只有「维不维持自己」。这正对应第一篇 5.3 的「环境是宇宙里自发涌现的局部解压（分层，不自我维持）」。

定义 **E-3**（压缩）

设映射 c: X→Z。称 c 是 X 上的一个**压缩**，若：

```

（i）降维：dim Z < dim X（或 |Z| < |X|）；
```

（ii）非单射：存在 $x_1 \neq x_2$ 使 $c(x_1)=c(x_2)$（多对一）。

```

- 压缩率：log|X| / log|Z|（离散情形；连续用有效维度比）；

- 压缩的损失：给定 z 无法恢复的 x 差异；不可恢复部分计入 R_相对；

- 压缩的结构：c 的核把 X 分成等价类（纤维），压缩 = 在等价类上做商。

定义 **E-4**（解压）

设映射 d: Z→Y。称 d 是 Z 上的一个**解压**，若：

```

（i）升维：dim Y > dim Z（或 |Y| > |Z|）；

（ii）不唯一：存在 z，使 d(z) 可对应多个 y（一对多）；

选择依赖额外信息（上下文、知识、随机性、观察者位置）。

```

- 解压残差：d(c(x)) 与 x 的差异；同样计入 R_相对；

- 压缩与解压成对使用，c 与 d 不必互逆（论文-37 推论 7b）。

与既有定义的关系

```

· 论文-37 定义 4b（环境 = 不被维持的子切片）：

· E-2 补上「环境从哪来」——它是涌现结构的一种

· 论文-37 命题 5（A4' 下压缩/解压是维持的推论）：

· 不改。原来是在命题里给出性质，现在先有 E-3/E-4 的原语定义，

命题 5 读作：在 A4' 下，生命函数必含 E-3/E-4 型的映射

· 两者不冲突：一个给定义，一个说明它必出现

· 第一篇 5.3 的表述：

· 「环境是宇宙自发涌现的局部解压」= E-2（涌现+不维持）+ E-4（解压）

⇒ 熵（定义 16/17 用到的「分布熵」）仍按通常的信息熵理解，待下一版补定义。

```

## 附录 **B** · 概念地图与术语总表

> 单独 DOI：https://doi.org/10.5281/zenodo.23609033

> 数字生命系列 · 合集附录 B（工作版）

> 日期：2026-10-27（v3）

> 用法：每加一篇论文，先更新这张表；每个词只写一句定义 + 出处。

> 出处约定：用合集篇号（第零~第二十五）；已并入的旧篇在括号里注明。

### 一、核心定义

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 宇宙 | P + R；P 可函数化，R 不可函数化（只声明，不展开） | 第零篇 |

| 可函数化 | 能用我们的函数语言写到误差任意小 | 第零篇 |

| p生命 | 生命落在 P 里的部分；定义与讨论的对象 | 第零/一篇 |

| R生命 | 生命落在 R 里的部分；只声明，不展开 | 第零篇 |

| 生命 | p生命 + R生命；p生命 = 一族被保住的动态函数（官方定义 D1~D5，见基础篇定义 14） | 第零/一/基础篇 |

| R_相对（记号） | 显式函数形式末尾的标记：我们的函数语言够不着的那部分；只声明、不展开；绝对 R 不判断 | 第一/四/五篇 |

| 绝对 R | 宇宙自身不可函数化的部分；是否存在不判断 | 第零篇补充 |

| 相对 R | 对任何有限观察者非空（涨落、有限资源、自指、不可判定等） | 第零篇补充 |
```

| 数字世界 | 形式对象：状态为有限串、规则为算法；绝对 R = ∅（构造保证） | 第零/一篇 |

| 残差 | P 侧可测的误差下限（P 的边界形状），**不是** R 的影响或投影 | 第零篇记号 |

| 可函数化 ≠ 可计算 ≠ 可测量 | 三件事分开：存在映射 / 能算 / 能观测复现 | 第零篇 |

二、函数语言（第四篇）

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 切片 | 一个函数 f: X → Y，带 (d_in, d_out, Δ) | 第四篇 |

| 表示维度 | d_in = dim(X)、d_out = dim(Y)；切片自己的轴数 | 第四篇 |

| 有效维度 | 可区分状态数的对数；轴数不变也可能下降（每根轴变粗） | 第三篇 |

| 空间组合 | 复合函数链 F = f_N ∘ … ∘ f_1；组合律要求类型相容 | 第四篇 |

| 时间组合 | 算子序列 s_{t+1} = I_{σ(t)}(s_t)；三种情形：恒定/每步变/混合 | 第四篇 |

| 步数 k（计算厚度） | 时间组合沿路走了多少步 | 第四篇 |

| 判定 J | 一次通过，不是迭代：J_选（选算子）+ J_停（决定停） | 第四篇 |

| 自指三层 | 表示自指 / 参数自指 / 结构自指，从弱到强 | 第四篇 |

| 固定核心 Φ | 不可改的约束集合；自指的三层都受它约束 | 第四篇 |

| 组合律 | 切片之间允许怎样相互作用（顺序/共享状态/并行/路由/共享参数） | 第四篇 |

| 组合律的定义域 | 让整条切片链"跑得起来"的输入集合 = 各切片定义域的相容交集 | 第四篇 |

| 被保住（函数版） | 组合律在整个时间段内始终有定义 | 第四篇 |

| 结构 | 结构 = 分解 D + 组合 C；它同时是一套压缩方案（第一篇 3.3 的"结构"指宇宙的局部呈现，是环境视角） | 第四篇 |

| 分解 D / 组合 C | 把函数映射成一组切片 / 把一组切片拼回函数 | 第四篇 |

| 时间驱动来源 | 内生（时钟长在系统自身基底里，生物）/ 外供（外部计时器+解释器，数字世界） | 第四篇 |

| 类型 A/B/C/D | 连续流 / 采样动力学 / 自动机 / 混合型 | 第四篇 |

| 五根轴 | 空间连续/离散、时间连续/离散、时间内生/外供、组合律自由度、自指层级 | 第四篇 |

三、三种身份：宇宙/环境/生命（第四篇）

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 宇宙切片 | $U_t = (S_t, C_s, d_t)$；时间组合在切片之间（$T_{comb}: U_t \to U_{t+1}$） | 第四篇 |

| 空间组合（宇宙） | 同一时刻内部，部分怎么拼成整体（C_s） | 第四篇 |

| 时间组合（宇宙） | 切片之间的接法；一个瞬间只有空间结构 | 第四篇 |

| 环境 | 宇宙的子切片：$d^E \subseteq d$、$C_s^E \subseteq C_s$、状态是投影 $\pi_E(S_t)$；无判定、无自指 | 第四篇 |

| 环境的时间 | T_{comb} 的限制 + 边界输入 u_t | 第四篇 |

| 生命（四条件） | 被保住（轨迹在 V 内）/ 边界开放 / 自指调节 / 可塑（受 Φ 约束） | 第四篇 |

| 冻结一刻 | 生命与环境同形，分不出来；生命必须在时间上辨认 | 第四篇 |

| 生命 = 被保住的轨迹 | 不是某个状态；是"一段轨迹"的属性 | 第四篇 |

四、表示与维度（第三/四篇）

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 表示空间 | 所有可能表示/状态组成的空间 | 第四篇 |

| 状态 | 表示空间里的一个点（各表示维度坐标的元组），不是维度 | 第四篇 |

| 定义域/值域 | 沿某些表示维度的允许/可达范围（子集），不是轴 | 第四篇 |

| 宽度 | 一层里的表示维度个数 | 第四篇 |

| 深度 | 步数/层数，与表示维度不同的另一根轴 | 第四篇 |

| 升维 | 增加可区分的表示维度 | 第十二篇 |

| 三个空间 | 表示空间（激活）/ 参数空间（权重）/ 输入输出空间（数据） | 第四篇 |

| 厚度（总称） | 分布厚度（垂直）与计算厚度（水平），正交 | 第四篇 |

| 分布厚度 | 同一输入对应多宽的一族输出（熵/歧义）；用表示维度摊平 | 第四篇 |

| 计算厚度 | 沿组合律从输入到目标需多少步（路长）；用步数/时间摊开 | 第四篇 |

| 可摊薄 / 不可摊薄 | 升维能把厚度摊平 / 摊不平；结构厚度 = 维度耦合导致拆不开 | 第四篇 |

| 相对残差 | 厚度 / 可区分尺度；维度降低时相对残差上升 | 第四篇 |

| 范围收缩 | 每根表示维度上的可输入/可输出范围变小 | 第三篇 |

| 三资源 | 空间上的表示维度 / 组合律上的表示维度 / 时间上的步数 | 第二十二篇 |

五、压缩与解压（第四篇）

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 压缩 | 降维映射 $f: X \to Y$，$\dim(Y) < \dim(X)$ | 第四篇 |

| 解压 | 从压缩表示重新展开（不唯一；不必等于原像） | 第四篇 |

| 解压的"够用" | 解压不必严格可逆，只需对维持够用；哪些维度必须可逆由环境选择 | 第四篇 |

| 窄进宽出 | 输入受限且被粗粒化；输出靠结构展开，多出的维度来自结构（过去的压缩） | 第四篇 |

| 身围 | 个体看到的环境 = 压缩映射的投影 $\pi_L(E)$ | 第四篇 |

| 压缩方案 | "保留哪些区分、合并哪些、把哪些过去压进结构"的规则，写在结构里 | 第四篇 |

| 一次性解压 | 冻结模型训练完即定型；不再更新、不再维持 | 第零/一篇 |

| 语言 = 公共压缩方案 | 感受→语言是压缩；语言→描述/理解/推理是解压；逻辑 = 语言的组合律 | 第四篇 |

| 闭合环 | 第 t 步 $(s_t,in_t)\to(s_\{t+1\},out_t)$；$in_\{t+1\} = W(out_t, 世界)$ | 第四篇 |

| 半闭环 | 大模型：输出只延续文本，不改变环境 | 第四篇 |

| 接口层 / 机制层 | 输入输出行为 / 内部怎么算、怎么维持、怎么改自己 | 第四篇 |

| 语义残差 | 语言无法承载的语义缺口（给定模态组合下的最小可达误差） | 第十二篇 |

| 接地 | 用多模态/行动把语义残差补上 | 第十二篇 |

六、能力、收敛与效率（第四/五篇 + 实验）

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 按需收敛 | 试探→判断收敛了吗→没收敛带记忆循环→收敛后固化 | 已拆出至笔记《执行器的均匀计算》，非系列结论 |

| 判定器（halt/exit judge） | 每层检查"够了没有"，决定退出/继续/走哪条路 | 第二十一/二十二篇 |

| 快慢结构 | 快结构（事实，一两层收敛、冻结成前提）+ 慢结构（权衡，时间上循环） | 讨论稿（未成篇；相关实验见第二十二篇） |

| 三处均匀 | 深度均匀 / 宽度均匀 / 没有按需循环 | 已拆出至笔记《执行器的均匀计算》，非系列结论 |

| 均匀深度浪费 | 不同结构对深度的需求差别很大；按需分配更省（路由 47%） | 第五篇（原论文-28） |

| 过度计算 | 超过任务厚度后误差回升（按需动员 0.434 vs 均匀 1.756） | 第五篇（原论文-28） |

| 层 ≈ 步数 | 冻结模型的深度充当时间步（伪时间） | 第五篇 |

| 时间换维度 | 给循环步数（时间）可大幅降低所需表示维度 | 第一篇/实验 |

| 循环省参数 | 同一迭代效果，循环比加层省约 27 倍参数 | 第五篇（原论文-28） |

| 层厚放置 | 同样参数下，前窄后宽（宽在后）更省 | 实验 |

| 最小切片 | 让一个结构出现的最小（宽度, 深度）配置 | 实验 |

| 能力边界 | 达到精度的配置区域；是"可训练性边界"而非纯表示边界 | 实验 |

| 涌现 | 能力/结构跨过某个维度阈值后出现（相变，即分段不连续点） | 第零篇/实验 |

| 固定核心 Φ | 不可改的约束；可塑只能在 Φ 内 | 第四篇 |

七、语言函数与语言结构（第五篇·语言与大脑）

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 语言 | 符号系统 + 组合规则 + 共享约定：把内部表示压成可传递的符号序列，并允许解压 | 第五篇 |

| 公共压缩接口 | 语言的角色：说者编码、听者解码、群体共享 | 第五篇 |

| 人脑函数 B | 个体脑：世界 → 表示 → 行为（有器官、维持、内循环、判定） | 第五篇 |

| 语言函数 L | 群体脑输出外化的公共结构：符号 → 意义（不属单个脑） | 第五篇 |

| 大模型（执行器） | 学习并执行 L 的系统，不是 B 的实现 | 第五篇 |

| 符号切片 | 语言的切片：输入是符号、输出是意义表示的映射 | 第五篇 |

| 词 = 切片 | 词是"符号 → 意义"的映射 | 第五篇 |

| 句法 = 空间组合 | 词与词拼成更大结构（组合律相容条件） | 第五篇 |

| 语义 = 表示与接地 | 符号指向什么、能不能接上世界 | 第五篇 |

| 篇章 = 时间组合 | 上下文、指代、顺序依赖在时间上展开 | 第五篇 |

| 逻辑 = 组合律的规则 | 哪些组合合法、怎么推 | 第五篇 |

| 语用 = 判定 | 场合、得体、真假（一次通过） | 第五篇 |

| p语言 / 相对R语言 | 语言中可函数化 / 相对某函数类够不着的部分（不是绝对 R） | 第五篇 |

| 言外之意 | 解压时补出来的部分：大部分 p语言（会话隐含/语用规则），小部分相对 R语言（默契/经历/语气） | 第五篇 |

| 语言的时间（三种） | 结构无时间；使用是时间序列；演化是结构的慢变 | 第五篇 |

| 隐喻/编码的时间 | 时态、时间词、叙事顺序：语言"关于时间"的表示，不是语言自身的时间 | 第五篇 |

八、层路径、判定与早退（第二十三篇、第二十四篇）

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 层冗余 | 同一结构在多层里有可替代的副本：单层跳过影响小、成组跳过才崩 | 第二十三篇 |

| 单层跳过 | 某层输出 = 输入（恒等直通），只去掉该层贡献 | 第二十三篇 |

| 冗余量 | 成组跳过的翻转率 − 两个单层中较大的那个（正 = 有补偿/冗余） | 第二十三篇 |

| 后层重建/纠正 | 破坏当前位置状态后最终预测仍能恢复：后层从上下文重算 | 第二十三篇 |

| 语言可预测性 | 用完整模型预测的熵做代理：低熵 = 语言结构强、可预测 | 第二十四篇 |

| 语言结构作为自变量 | 用可预测性分组替代"任意 token 类别"分组 | 第二十四篇 |

| 判定器 A（置信度） | 用当前层预测的置信度/熵决定退出 | 第二十三篇 |

| 判定器 B（路径） | 用跨层一致性（相邻层预测一致、KL、趋势）决定退出 | 第二十三篇 |

| 判定器 L（语言） | 用语言结构特征（词类、位置、重复、首层熵）决定退出 | 第二十四篇 |

| oracle 早退 | 假设知道哪层预测正确就退出：早退的上界 | 第二十三篇 |

| 早退 + 写回 | 早退结果写进上下文再继续：单次可吸收，连续会累积误差 | 第二十三篇 |

| 过度计算有害 | 早退反而比完整模型准确率更高：后面的层会改坏对的预测 | 第二十三篇 |

九、实验读数（**GPT-2 /** 玩具）

| 概念 | 一句话定义 | 出处 |

|---|---|---|

| 层间 Δ_l | 相邻层 hidden 的相对变化；GPT-2 上不单调、末端变大 | 真实模型实验（见第二十一/二十二篇） |

| 校准探针 | 用线性/MLP 映射把 h_l 映射到 h_final 再解码，检验"早退可不可行" | 真实模型实验（见第二十一/二十二篇） |

| halt 判定器 | 训练分类器预测"该层探针是否等于最终预测"，实现版早退 | 真实模型实验（见第二十一/二十二篇） |

| 早退上限 | oracle 判定下平均深度 2.31/12（省 81%） | 真实模型实验（见第二十一/二十二篇） |

| 可实现早退 | 训练 halt 后省 72~80% 深度，准确率约 -1.6~-1.8 个点 | 真实模型实验（见第二十一/二十二篇） |

| 快慢玩具实验 | 快编码+慢循环 vs 平铺 MLP：精度相当、参数约省 2.2 倍 | 讨论稿（未成篇；相关实验见第二十二篇） |

十、待定义 / 待统一（下一步）

- **维持（可量化）**：寿命、恢复时间、临界扰动、维持成本——暂不展开

- **"够用"判据**：解压的可逆性要求依赖环境，尚未操作化

- **可行域 V 与固定核心 Φ**：判断"是否被保住"与"什么不可改"还缺测量协议

- **判定器的训练信号**：用什么标签训练 halt（一致性/影响/代价），未定

- **语言结构与脑结构的对应**：B 与 L 的映射只有概念层，没有可测的对应

- **言外之意的边界**：哪些靠 p语言 规则、哪些靠相对 R语言，未操作化

- **R 的位置**：R 不参与连续/离散、定义域/值域讨论（范畴问题），但要防止读者误读

依赖图（谁由谁定义）

```
P / R → 可函数化 → p生命 → 五条件 D1~D5（在 P 中 / 一族 / 会变化 / 会自指 / 被保住）

↓

数字世界（R=∅）→ 冻结模型 → 一次性解压 → 失配

↓

结构 (D, C) → 切片 → 组合律 → 组合律定义域 = 可维持集合

↓

表示空间 → 表示维度 → 状态 / 定义域 / 值域

↓

厚度 → 可摊薄/结构厚度 → 升维 → 相对残差

↓

时间（内生/外供）→ A/B/C/D → 层≈步数 → 时间换维度

↓
```

能力边界（最小切片）→ 涌现（阈值/相变）

↓

【语言分支】公共压缩方案 → 语言函数 L → 大模型（执行器）

→ 语言结构强度（可预测性）→ 层冗余/早退/判定

→ 言外之意（p语言 / 相对R语言）

↓

【第四篇主线】函数语言 → 三种身份（宇宙/环境/生命）→ 压缩/解压

→ 窄进宽出 → 身围 → 闭环节奏 → 语言（公共压缩方案）

→ 判定器/按需收敛 → 三处均匀 → 循环省参数

```

## 附：门控观察（第二十五篇）

| 术语 | 一句话 | 出处 |

|---|---|---|

| 旁路门 | 门开 = 放行（不变换），门关 = 计算（正常变换） | 第二十五篇 |

| 硬预算 | 每 token 最多算 k 层；最优退化为固定前 k 层 | 第二十五篇 |

| 软代价 | 损失 += λ·平均计算层数；直接加梯度会崩 | 第二十五篇 |

| 拉格朗日门控 | λ 自适应压平均层数；可控且按 token 分化 | 第二十五篇 |

| 深度冗余 | 6 层任务 2~3 层、24 层任务约 5.3 层即可持平（噪声内） | 第二十五篇 |

## 第二十八篇 · 对齐是解压的约束

> 单独 DOI：https://doi.org/10.5281/zenodo.23503728

> 论文系列 · 第四章

> 第一章：现在的 AI 为什么不是生命（DOI: 10.5281/zenodo.23488543）
```

> 第二章：容量不能替代数据的更新（DOI: 10.5281/zenodo.23503050）

> 第三章：替换与累积（DOI: 10.5281/zenodo.23503559）

摘要

主流对齐研究（RLHF、宪法式 AI、可扩展监督）默认一个前提：**模型是可以被稳定塑造的**。

本文用前三章的框架指出：**AI 是对人类语言的再解压；对齐 = 对这个解压的约束。**

由此得到三条可检验推论：

（1）**对齐漂移**：语言在升维（第二章实测约 1.2%/年），冻结模型的对齐目标也会落后——

它们对齐的是**训练时刻的语言**，不是此刻的世界；

（2）**歧义集中**：压缩陷阱的根源是语言有损（第三章）；语言越歧义的地方，

模型越倾向选"最省编码"的解释 ⇒ **对齐失败应集中在人类语言的歧义处**；

（3）**替换侵蚀**：对齐信号藏在人类数据里；用合成数据或新数据**替换**而非累积，

会切断价值信号的累积链 ⇒ **对齐随累积通道的切断而退化**。

本文给出该框架对应的可检验实验方案，并指出一个实践含义：

对齐不是一个一次性训练问题，而是一个"维持累积通道"的持续工程问题。

一、主流对齐框架的隐含前提

```

RLHF：人类反馈 → 奖励模型 → 优化策略

宪法式：用原则文本约束输出

可扩展监督：用 AI 辅助监督 AI

⇒ 三者都假设：模型的行为可以被稳定地塑造和保持

```

但没有任何一条回答：

```

① 当世界的语言/价值变化时，对齐目标会不会"过期"？

② 对齐失败会不会有结构性分布（不是随机噪声）？

③ 更新模型时，对齐会不会因为"只喂新数据"而流失？

```

二、框架：对齐 = 对解压的约束

```

AI = 对人类语言 L(W) 的再解压（第一章）

对齐 = 约束这个解压过程：在歧义处、在价值相关处，按人类意图解压

⇒ 对齐的载体是**人类语言中的价值信号**

⇒ 对齐的失效方式，由"语言的性质"决定

```

三、三条推论

推论 A：对齐漂移（来自第二章）

```

语言升维 ⇒ 冻结模型对齐的是训练时刻的语言规范

⇒ 新概念/新价值出现后，模型仍在按旧压缩解压

⇒ 对齐漂移不是 bug，是"一次性解压"的必然后果

可测：同一模型在"训练后出现的新规范"上的对齐评分随时间下降

```

推论 B：歧义集中（来自第三章）

```
```

压缩的语言有损 ⇒ 歧义处存在多个同样短的解压

⇒ 模型倾向选"最常见/最省编码"的解释

⇒ 对齐失败应**集中在人类语言歧义处**，而不是均匀分布

可测：把对齐失败样本按"人类判断分歧度"分层，

预测失败率随分歧度单调上升

```

**推论 C：替换侵蚀（来自第三章）**

```

对齐信号（人类偏好、价值判断）藏在人类数据里

替换式更新（只用新数据 / 用合成数据替换）⇒ 切断价值累积链

⇒ 对齐随替换比例上升而退化

可测：微调时人类数据占比 0/25/50/100%，

在公开安全/价值测试集上看对齐分数

```

## 四、可检验实验方案

```

实验 1（漂移）：

取两个不同代的开源模型，在"训练截止后出现的新规范"上做对齐评分

⇒ 预测：旧模型评分更低，且差距随截止时间差扩大

实验 2（歧义集中）：

选一个公开对齐数据集，人工/脚本标出"人类分歧度"分层

⇒ 预测：对齐失败率随分歧度上升

实验 3（替换侵蚀）：

小模型微调：混入人类安全数据比例 0/25/50/100%，其他为新任务数据

⇒ 预测：对齐分数随人类数据占比单调上升

```

## 五、实践含义

```

① 对齐不能"训一次管多年"——它是持续工程

② 更新要累积（保人类数据通道），不能替换

③ 对齐资源应投向"语言歧义处"（那里失败集中），而不是均匀铺开

```

## 六、限制

```

· 本文是框架文章，三条推论均未完成实验（方案已给出）

· "歧义度"的操作化定义需要谨慎（不同标注者分歧 vs 语言学歧义）

· 对齐评测本身有争议（benchmark 不等于人类价值）

```

## 结论

```

对齐的困难不只在"让模型听话"，还在：

· 它对齐的是会过期的语言（漂移）

· 它在歧义处必须自己选解释（歧义集中）

· 它的价值信号会被替换式更新冲掉（替换侵蚀）

⇒ 因此：对齐 = 维持一个累积的解压通道，而不是一次性的训练任务。

```

**作者：何淇（独立研究者）；AI 协作：DeepSeek**

## 第二十九篇 · 安全：当它是生命防，还是当它是工具防？

> 单独 DOI：https://doi.org/10.5281/zenodo.23503775

> 论文系列 · 第五章

> 第一章 DOI: 10.5281/zenodo.23488543

> 第二章 DOI: 10.5281/zenodo.23503050

> 第三章 DOI: 10.5281/zenodo.23503559

> 第四章 DOI: 10.5281/zenodo.23503728

## 摘要

当前 AI 安全讨论中混杂着两种恐惧：**它被滥用**（工具风险）与**它自己活了**（生命风险）。

两者需要完全不同的威胁模型，但常被混为一谈。

本文用第一章的判据指出：**按定义，AI 不是生命**（冻结函数点、更新在外部、不自我维持），

因此正确的安全框架是**工具安全**，而不是"防生命"。

但这不意味着安全可以放松：工具风险真实、且有三类可测的失效模式：

**误用、过度信任、失配漂移**。本文给出这三类风险的对应评测与治理方向，

并指出：把安全讨论锚定在"它会不会觉醒"，既高估了它、又低估了真实风险。

## 一、两种恐惧，一个错误的本体论前提

```

恐惧 A（工具派）：被滥用、被误用、被坏人使用

恐惧 B（生命派）：它自己有了目标、自己进化、自己维护自己

这两种恐惧隐含不同的本体论：

A 假设它是工具（无自我目标）

B 假设它是（或将成为）生命

```

**⇒ 不先判定本体，安全讨论就没有共同的威胁模型。**

## 二、按第一章的判据：它是工具

```

① 冻结函数点：训练后权重不变 ⇒ 不会自我进化

② 更新规则在外部：它不能改自己的规则 ⇒ 不会自我改写

③ 不自我维持：不付电费、不修复自己、不复制自己 ⇒ 没有自发生存动机

⇒ 三条都缺 ⇒ 按定义不是生命 ⇒ 威胁模型应是工具安全

```

## 三、工具风险的三类可测失效

```

① 误用（misuse）

危险来自使用者 × 能力 × 规模

评测：越狱/滥用测试、红队

治理：访问控制、审核、能力分级

② 过度信任（overtrust）

人把「一次性的解压」当成「持续的理解」

⇒ 在它失配的地方仍然信它（最隐蔽的风险）

评测：校准度（confidence vs 准确率）、拒答质量

治理：把不确定性暴露给用户（"它不知道"要能被表达）

③ 失配漂移（第四章）

语言/世界变化 ⇒ 冻结模型的对齐与能力缓慢过期

评测：第二章的 M(K)（失配随时间的增长）

治理：累积更新（混合新旧数据），而非替换

```

## 四、为什么"防生命"框架有害

```

· 高估：把资源投在"它会不会觉醒"上，而不能解决误用/过信/漂移

· 低估：真正危险的是"它看起来很可信"，

而这一点被"它不是生命所以安全"掩盖

· 误导：政策讨论被"意识"问题绑架，忽略了可测的工程风险

```

## 五、结论

```

先判本体：它是工具，不是生命

再定威胁模型：误用 / 过度信任 / 失配漂移

最后配治理：评测（校准、越狱、失配）+ 累积更新

⇒ 安全不是"防止它活过来"，而是"在它不可靠的地方，别让人信它"

```

## 六、限制

```

· 本文只做本体-威胁模型的对齐论证，不提供新的安全技术

· "过度信任"的量化需要用户研究，本文只给方向

· 若未来出现真正自我维持的系统，本文框架需重写

```

**作者：何淇（独立研究者）；AI 协作：DeepSeek**
```